# 下一代 Agent 技术路线调研

Jev 类快思考模型（System One）与快 / 慢协同框架

调研报告 · 仅分析与调研，不含训练方案

生成日期：2026-10-28

# 目录

下一代 Agent 技术路线调研：Jev 类快思考模型与快/慢协同框架 . . . . 4
1. 五个维度（按最新讨论口径） . . . . 5
2. 方法与证据清单 . . . . 5
3. 核心结论速览 . . . . 5
4. 证据可信度与注意事项 . . . . 8
5. 约定 . . . . 8
01 · Jev / System One：定义、接口原语、架构还原与独立评测 . . . . 9
1.1 基本事实 . . . . 9
1.2 接口原语（我们后续"逻辑原语"讨论的起点） . . . . 9
1.3 官方承认的"锯齿"（jev-1.13 model jaggedness） . . . . 9
1.4 架构还原（黑盒探针） . . . . 10
1.5 独立评测与审计：Jev 擅长什么、不擅长什么 . . . . 10
1.6 本章小结：Jev 是什么、不是什么 . . . . 11
02 · 开源解码器复现与配方矩阵（含小模型证据） . . . . 12
2.1 一个共同的骨架 . . . . 12
2.2 配方矩阵 . . . . 12
2.3 小模型到底行不行：证据汇总 . . . . 15
2.4 从配方矩阵读出的共识与分歧 . . . . 15
2.5 对我们的含义（仅分析） . . . . 15
03 · D1 上下文学习（ICL）：决策模型能否"在提示里学"，业务人员能用哪些杠杆 . . . . 16
3.1 先回到 ICL 的基础事实（上游文献） . . . . 16
3.2 决策模型（Jev 与复现）上的 ICL 证据 . . . . 16
3.3 业务人员可用的提示词杠杆：效应量与失效模式 . . . . 17
3.4 ICL 的替代与补充（不是我们的主线，但要知道） . . . . 18
3.5 哪些工作解决了哪类问题（D1 小矩阵） . . . . 18
3.6 D1 盲区（我们识别、现有工作未覆盖） . . . . 18
04 · D2 符号化指令遵循：规则、否定、算术/时间、兜底、层级与对抗下的决策一致性 . . . . 19
4.1 上游基线：生成式 LLM 的规则遵循 . . . . 19
4.2 决策模型上的证据：按失效类型分组 . . . . 19
4.3 哪些工作解决了哪类问题（D2 小矩阵） . . . . 21
4.4 D2 盲区 . . . . 21
05 · D3 模板化 / 技能化：让业务专家用文字写规则，模型忠实执行 . . . . 22
5.1 Skill 范式：文字能教会模型"工作能力"到什么程度 . . . . 22
5.2 自然语言规则 → 可执行结构：编译类工作 . . . . 22
5.3 决策模型上已有的原语与组合模式 . . . . 23
5.4 "策略即提示"守卫：业务规则文本直接喂模型的经验 . . . . 24
5.5 哪些工作解决了哪类问题（D3 小矩阵） . . . . 24
5.6 D3 盲区 . . . . 25
06 · D4 一致性：把"数值一致性"拆成可定义、可度量的子问题 . . . . 26
6.0 为什么要拆 . . . . 26
6.1 子维度清单 . . . . 26
6.2 D4 矩阵：哪些工作解决了哪类问题 . . . . 29
6.3 D4 盲区 . . . . 29
07 · D5 Agent 与知识系统：快慢协同的证据与边界 . . . . 30
7.1 反方证据：更快的决策 ≠ 更好的 Agent . . . . 30
7.2 快慢切换：谁来决定什么时候慢下来 . . . . 30
7.3 记忆与上下文压缩：System 1 做"多而小"的判断 . . . . 31
7.4 路由与守卫 . . . . 32
7.5 多 Agent 协调 . . . . 32

7.6 领域 Agent 与非 Agent 的"S1 位置" 32
7.7 记录 vs 现实、持续学习 33
7.8 D5 矩阵 33
7.9 D5 盲区 33
08 · 骨干约束：混合（DeltaNet / Mamba 类）架构对 Jev 式推理与训练的影响 35
8.1 Jev 式接口依赖的三个结构假设 35
8.2 混合骨干在哪一步破坏假设 35
8.3 开源复现的三种绕法 36
8.4 推理系统文献能借什么 36
8.5 纯注意力骨干作为对照 36
8.6 本章矩阵 36
8.7 盲区（供选型前补齐） 37
09 · 工作-问题矩阵与盲区汇总 38
9.1 五维度总览 38
9.2 工作 → 问题矩阵（主要工作） 38
9.3 盲区汇总（按对自训工作的影响排序） 39
10 · 开放问题与度量定义 41
10.1 D1：ICL 的保留与利用 41
10.2 D2：符号指令 41
10.3 D3：规则语言 41
10.4 D4：一致性 41
10.5 D5：Agent 与知识 42
10.6 骨干 42
10.7 跨维度的三个元问题 42
11 · 参考文献 43
11.1 arXiv 论文（共 283 篇） 43
11.2 TypeSafe 官方文档与页面 49
11.3 开源复现、工具与模型卡 49
11.4 其他网页 50
12 · 学习视角：学习算法有没有变、数据集是否可得、基座怎么选 51
12.1 学习算法谱系 51
12.2 相对"普通分类微调"到底改了什么 52
12.3 消融证据：这些改动有没有用 53
12.4 数据集可得性 53
12.5 基座选型规律 55
12.6 学习视角的盲区 56
13 · 问题定义的跨论文比较：同一个词，不同的定义 57
13.0 为什么定义会分歧 57
13.1 "决策模型"叫什么、指什么 57
13.2 请求 / 契约的形式化 58
13.3 "置信度"指什么 58
13.4 "校准"怎么定义、怎么测 59
13.5 "一致性 / 翻转"怎么定义 59
13.6 "RLCD"至少有四种含义 60
13.7 "弃权 / 兜底 / 不知道"怎么定义 61
13.8 Agent 层的定义 61
13.9 分歧总表与"我们定义问题前必须回答的" 61
14 · 假设审查："SFT 无法让模型具备一般意义上的泛化能力" 63
14.1 先把"泛化"拆成可检验的层次 63
14.2 分层证据 63
14.3 哪些变量确实让结果跨层移动 65
14.4 结论：假设成立的范围与需要修正的措辞 65

14.5 可用来检验这条假设的英文公开集（只列度量，不列方案） ..... 65
15 · RL 还是 SFT：以"保留 ICL"与"注入技能语义"为约束的证据审查 ..... 67
15.1 先纠正问题的提法 ..... 67
15.2 决定 ICL 存亡的变量：任务定义是否随样本变化 ..... 67
15.3 决定技能注入的变量：上下文还是权重，以及能不能执行 ..... 67
15.4 那么 RL 到底在哪里有独立价值 ..... 68
15.5 对两项约束的直接回答 ..... 68
15.6 本章识别的盲区 ..... 69
16 · 两个追问：任务无关的 RL 有没有生命力；业务期待能不能写成可导的学习函数 ..... 70
16.1 追问一：任务无关的 RL 有没有生命力 ..... 70
16.2 追问二：业务期待能不能写成可导的学习函数 ..... 71
16.3 本章识别的盲区 ..... 71
17 · Jev 的业务目标与属性：它到底消除了哪一类成本，又支撑 System1+System2 的哪一个位置 ..... 73
17.1 出发命题及其检验 ..... 73
17.2 业务问题：哪一类成本被消除了 ..... 79
17.3 属性清单：哪些能对业务承诺，哪些不能 ..... 80
17.4 业务目标不是什么 ..... 81
17.5 如何支撑 System1+System2：五个不同的位置 ..... 81
17.6 本章小结与盲区 ..... 82
18 · 训练目标：数值与决策类输出应该长什么样，以及要不要引入思维链 ..... 83
18.1 共识目标与它的三个已证明的边界 ..... 83
18.2 四种输出各自"应该长什么样" ..... 83
18.3 怎么优化：证据支持什么、排除什么 ..... 85
18.4 要不要引入思维链：四个被混为一谈的问题 ..... 85
18.5 如果业务目标是 System 1，这条思维链应该长什么样 ..... 86
18.6 本章小结与盲区 ..... 87
19 · Jev 类模型应该如何评测：现有评测集覆盖了哪些业务属性，漏掉了哪些 ..... 89
19.1 "应该怎么评测"已有答案：14 项检查表与它的合规率 ..... 89
19.2 现有评测集按"测什么"分类 ..... 90
19.3 覆盖矩阵：十二条业务属性 × 现有评测集 ..... 91
19.4 跨评测集的数字不可比，这是结构性的 ..... 92
19.5 从业务目标反推：哪些能力目前无法被任何现有评测集判定 ..... 92
19.6 本章小结与盲区 ..... 92
20 · 批判性复核：四个工作假设、本报告自己的构造、以及我的方法论缺陷 ..... 94
20.1 四个工作假设的判定 ..... 94
20.2 报告里哪些框架是我自己造的 ..... 94
20.3 我自己的方法论缺陷 ..... 95
20.4 结论的稳健性分级 ..... 95
20.5 提问者视野里的四个盲区 ..... 96
20.6 本章小结 ..... 96

# 下一代 Agent 技术路线调研：Jev 类快思考模型与快/慢协同框架

> 调研报告 · 2026-10-27 · 仅分析与调研，不含训练方案
>
> 仓库目的：讨论下一代 Agent 的技术路线。核心论点有两条： 1. **Jev 类（System One）快思考模型**使"快/慢协同"的 Agent 框架成为可能，把 Agent 循环从"慢思考 + 执行反馈"改为"快思考 / 慢思考两种模式协同"。 2. 在我们自己训练 Jev 类模型之前，先按五个需求维度把近期（2026 年 9–10 月为主）的学术工作梳理清楚：**哪些工作解决了哪一类问题，哪些是我们识别出来但现有工作没有覆盖的盲区**。

## 1. 五个维度（按最新讨论口径）

| 维度 | 口径 | 对应章节 |
|---|---|---|
| D1 上下文学习（ICL） | 不是成本档位。关注：决策微调后的单遍模型是否仍具备并能利用 ICL；**业务人员能否通过提示词工程（定义、示例、判据、状态结构）直接使用 Jev 类模型**；每种杠杆的效应量与失效模式 | 03-D1 |
| D2 符号化指令遵循 | 规则、否定、算术/时间、兜底选项、指令层级、对抗上下文下的决策一致性 | 04-D2 |
| D3 模板化 / 技能化 | 定义一组**逻辑原语**，让非技术业务专家用文字写业务规则，模型忠实执行；像 Skill 用文字教会模型工作能力一样 | 05-D3 |
| D4 一致性 | 不止"数值一致性"四项，需要我们自己定义和理解问题。本章枚举 30 个子维度，作为问题定义的探索 | 06-D4 |
| D5 Agent / 知识系统 | 快/慢协同的 Agent 框架、记忆、压缩、工具路由、守卫，以及"决策更快是否等于 Agent 更好" | 07-D5 |

补充章节：

- 01 Jev / System One 的定义、API 原语、架构还原与独立评测
- 02 开源解码器复现与配方矩阵（含小模型证据）
- 08 骨干模型与混合架构（Gated DeltaNet / Mamba 类）约束——只调研不选型
- 09 工作—问题矩阵与盲区清单
- 10 问题定义与开放问题（不含方案）
- 11 参考文献（全部带链接）
- 12 学习视角：学习算法有没有变、数据集是否可得、基座怎么选
- 13 问题定义的跨论文比较：同一个词，不同的定义
- 14 假设审查：SFT 能否带来一般意义上的泛化——按七个泛化层次核对证据
- 15 RL 还是 SFT：以"保留 ICL"与"注入技能语义"为约束的证据审查
- 16 任务无关的 RL 有没有生命力；业务期待能不能写成可导的学习函数
- 17 业务目标与属性：消除了哪一类成本，支撑 System1+System2 的哪一个位置
- 18 训练目标：数值与决策类输出应该长什么样，以及要不要引入思维链
- 19 应该如何评测：现有评测集覆盖了哪些业务属性，漏掉了哪些
- 20 批判性复核：四个工作假设、本报告自己的构造、方法论缺陷

可打印版本：nga-survey.pdf（A4，由 `tools/build_pdf.py` 从本仓库的 Markdown 生成；README 与 01–20 章按顺序合并，带目录与页码）。

## 2. 方法与证据清单

- **范围**：以 TypeSafe 的 Jev / System One 模型为锚点，覆盖 Jev 本体文档、第三方架构还原、独立评测与审计、开源复现（解码器路线为主）、以及五个维度各自的上游学术文献（ICL、指令遵循、规则/策略执行、校准与一致性、Agent 记忆与控制）。
- **来源**：arXiv 摘要 357 篇（两轮关键词扫描 + 定向补充），其中约 70 篇读取了全文，正文实际引用 283 篇；TypeSafe 官方文档 17 页；GitHub README 25 个；Hugging Face 模型卡 6 个；博客 / 排行榜 / 规范页 14 个。
- **时间**：Jev 于 2026-09-15 发布（见 2609.32160），绝大多数 Jev 相关文献集中在 2026-09-19 至 2026-10-26。上游经典文献（ICL、校准、树注意力）回溯至 2021 年。
- **数字核验**：报告中的每个数字都回到缓存的摘要 / 全文 / 文档核对过。核不到出处的数字一律删除或标注"未核实"。

## 3. 核心结论速览

1. **Jev 的价值在接口、成本、延迟与校准，而非准确率**。早期审计（28 篇论文）结论是"类型化读出本身未显示出独立于同类标签概率读出的准确率优势"（2609.32160）；现成聊天模型直接读 logits 已是 Jev 式决策模型（2610.02076），Gemma-4-31B 加一个按选项数拟合的温度即可在 Decision Index 排第 2（Mapika/decider）。
2. **架构已被还原并被 15 个以上开源配方复现**：共享状态前缀 + 隔离的问题分支 + 列表式概率读出（Archer Hume）。0.6B–9B 的决策微调模型可用，**领域微调的小模型胜过通用的大模型**（SecJev-0.8B 比 Kev-9B 高 20.51 pp，2610.03073；AgentDecision-4B 在分布外任务 91.5% 对 Jev 82.0%，2610.21412）。
3. **D1 的真实状况**：模型"读得懂"示例与定义，但**标签名压倒定义**（AUC 93.8% → 23.2%，2609.26758；删除定义准确率不变，2610.02586）；1–12B 小模型在上下文中**无法翻转标签语义**（2511.21038）；同质示例让 0.8B–8B 模型准确率坍塌到 12% 以下（2605.08295）。没有任何论文直接测量"决策微调是否保留/破坏 ICL"。

4. **D2 的瓶颈不在"读"而在"做"**：策略修改被正确读出，但只在 22%–72% 的情况下被执行（2610.18579）；含算术/时间的对照对从难度 1 到 3 准确率 87.7% → 57.4%（2610.28522）；正确答案缺席时拒绝率只有 7%，加一个阈值可到 79%（2609.39496）；兜底选项让 Intern 从 97.9% 跌到 23.1%（2610.19856）。
5. **D3 已有可借鉴的原语雏形**：Noul / Choice / Score 三原语、扇出、逐层走分类树、复合打分、置信路由（TypeSafe 文档）；SemTree 的 Yes/No/Unknown 节点树可逐节点修复（2610.13999）；"概率感知、确定性裁决"的 true/false/unknown 准入与并集界（2610.10978）。但**把自然语言业务规则编译为可验证逻辑**的工作（Artic、P2T、SIRNA、Cedar 自动形式化）都面向生成式 LLM，尚无针对单遍决策模型的规则语言。
6. **D4 远不止四项**：本报告枚举了重复性、顺序/位置、选项集依赖（IIA）、问题形式、分解、措辞、标签/定义、序数、多正确项分配、拒绝/兜底、校准-判别-敏感度分离、先验偏移、语言/文化、教师偏差继承、数值/时间、状态长度与无关信息、记录 vs 观测、接口、决策→动作、对抗、风格偏置、跨模型/版本等共 **30** 个子维度（A 同输入稳定性 / B 选项表示依赖 / C 逻辑相干性 / D 不确定性语义 / E 输入内容敏感性 / F 接口与动作，上面列的是其中代表项），并给出每项的可量化定义与现有证据。
7. **D5 的关键发现是"更快的决策 ≠ 更好的 Agent"**：孤立问题最准的决策模型只解出 69.5% 的 Agent 任务，不拟合阈值就委托工具选择会让成功率降 19.0 点（2610.21412）；Jev 控制器让成本增加 19% 而通过率不变（73.0% 对 73.0%，2610.24649）；决策模型更信任"记录"而非"观测"（53%–100%，2610.25947）。有效的快/慢协同都依赖**按选择逐项拟合的置信阈值、自身轨迹上的训练数据与代码中的组合**。
8. **骨干约束**：Qwen3.5 / 3.8 是 Gated DeltaNet + 注意力的混合架构，循环层不认注意力掩码，树形掩码无法隔离兄弟分支；现有做法是每个问题单独一行（Kev）或前缀分叉（qwen-rlcd，推理快 8–19 倍，但穿过缓存的梯度尚未实现）。针对混合架构的"训练时分支隔离"文献为零命中。
9. **学习算法几乎没有"换算法"**：相对普通分类微调，现有方案改的是读出位置（复用输出层 / 字母 logit / 指针头）、目标函数里加一个适当评分项（CE + Brier）、以及数据构成（对比策展、自提问、Agent 自身轨迹）。可证实有效的是 LoRA（对秩不敏感）、数据构成、结构隔离与温度；软标签"可能无用"且无对照（2610.17205）；单遍模型上强化学习为负或无效（发布 RLCD 配方比交叉熵低 2.5–3.0 点，2610.02486；REINFORCE −10.2 F1，2610.06744；GRPO 无增益，2610.21412），正面证据都绑定推理链。基座几乎全是 Qwen3.5（混合）或 Qwen3（纯注意力，用于结构研究）+ Gemma 4 做大模型；Base / Instruct 无共识。训练数据多数公开（Kev、Tev1、Nimble、Open-Jev、OneJev、Eikos），StartLux 与 TypeSafe 不公开；中文决策数据只有一家，无业务规则类数据（12 章）。
10. **同一个词在不同论文里是不同定义**："决策模型"按接口、契约或用途定义；"置信度"是分布统计量、top-1 概率、学到的风险分数或两个不可合并的量；ECE 有 10/15 等宽、15 等质量、相对零假设等至少五种算法；"翻转率"有五种分母；"RLCD"至少四种含义；"弃权"是选项、概率带、分数或兜底动作。跨论文数字不可直接比较的根源在此；我们定义问题前至少要取定六个分歧点（13 章 §13.9）。
11. **"SFT 无法带来一般意义上的泛化"这一假设：强形式不成立，弱形式成立**。同任务族的新样本 / 新来源上决策 SFT 可靠迁移（Kev 新来源差距随规模从 17.9 点收敛到 1.4 点）；但新 schema 上 27B 的 SFT 增益约为零（88.1 对未调优 89.1，2610.15501），新符号操作（名字压倒定义、学会跟踪不等于服从、反事实监督只在合成规则上奏效）、先验偏移（同样的决策 SFT 在金融情感上 +10.0 或 −12.0，2610.26325）、校准迁移与推理深度四层没有任何正面证据。跨层移动结果的是基座规模、指令调优起点、监督分布与结构约束，不是监督目标（14 章）。小模型上的 SFT 增益主要是读出对齐，**不能外推到大模型**。
12. **"该不该用 RL"不是决定 ICL 与技能注入的那个变量**。文献里唯二能提高"用上下文定义任务"能力的方法都是 SFT——MetaICL 的任务级元训练与符号调优（后者还直接提升**翻转上下文标签**的能力，正对 D1 最严重的缺陷，2305.08298）；决定 ICL 存亡的是"训练样本之间任务定义是否在变"，任务固定则无论 CE 还是策略梯度都会把任务烧进权重。技能注入是**存放位置**问题：上下文技能 +16.6 pp 但 91.8% 的公开 SKILL.md 有缺陷（2602.12670、2608.08453），权重技能（超网络→LoRA）更省 token 且更强（2606.06087）；而单遍读出**无法执行流程**，只能让技能影响那一次读出。RL 的独立价值仅在"奖励依赖于被采样的中间对象"时成立（推理链、示例集编辑）；对纯读出，NDM 证明它与适当评分规则同最优点（2610.25553），实测增益很小或为负（15 章）。
13. **任务无关的 RL 确有生命力，但不可导性与 RL 的收益面几乎不相交**。存在性证明就是 Jev 自己（RLCD 训练却通用）：一个通用问题在十类对齐失败、44 个基准上零样本达到 AUROC 中位数 0.886 并胜过多数有监督基线（2609.29429）；RL 泛化的是**二阶性质**（置信、校准、约束满足），不是一阶任务知识，而且凡以验证器为奖励处均被系统性套利（2610.19525）。把业务期待按"为何抗拒梯度"分类后：校准已有最优点正确的可导代理；一致性类可导但被结构化构造碾压（零翻转按构造成立）；风险阈值类零梯度而文献共识是事后统计认证（2610.34329）；真正既不可导又无认证手段的只有"Agent 下游结果与决策→动作"，而那恰恰是 RL 实测收益为零之处（GRPO 无增益、控制器只涨成本）。因此"目标不可导所以要用 RL"在现有证据下不成立（16 章）。
14. **"把不幂等的生成式判断换成指标输出 + harness 的确定执行"这条命题，诊断部分成立、描述部分不成立**。它准确预言了哪一类部署会失败（决策权回到模型里的那一类），但六条反证推翻了它的前提与结语：宿主 Jev 本身就不幂等（相同重复调用下 510 个标签改 4 个、300 题上最多 1.33% 改变，四篇论文报告其非确定性，2609.32160），而一个普通解码器加原子标签 token 已经是"确定的一步解码"且对 Jev 准确率相当、中位更快（2609.36115）；格式保证属于**语法约束解码的既有谱系**，而硬 schema 把答案准确率从 19.7% 压到 11.0%、把"合法但答错"从 49.5% 抬到 88.9%（"错误是

语义的，不是结构的"，2605.26128）；"指标"只能被读作**相对于那张选项表**的相对量——预先登记的 299,463 次调用里每一个被加入的选项都移动对数几率，系统性偏移是自身噪声的 **1.2–3 倍**，而消除它要付 8.7 点（2610.16655）；harness 也不是确定性保护区——查询计划的选择会改变结果且选择下推在自校准升级带下不是质量可靠的（2610.08089），139 个论文族里只有 4 个报告截止期达成率，排队一来所有延迟保证失效（2610.06425）；最后，能力不守恒：Jev 做不出"LLM 只有写出中间步骤才能做出"的决策，而且**它不知道自己的界限**（2610.24929）。可以守住的版本是：**它不消除非幂等，它把非幂等的表面收缩成可数、可定界、可定价的若干个字段**——文献里的精确动词是"**定位（localize）而非消除**"（2610.33876），而真正的奖品是一个**不依赖校准**的裁决翻转上界（"unknown 即拒绝"的构造，36,000 次调用无一格推翻，2610.10978）；代价是失败从显性变成隐性。**把幂等改写成"设计目的"也要单独检验，结论是必须重写**：按字面意思它已经达成（同请求 ICC 0.997，2609.36399；同文重跑翻转 0.17%，2610.35826）却什么也没买到（"一致的答案也会保留错误"，重复的错误占观察到错误的大部分，2609.27678），而且它可以不用模型买到（查表即严格幂等；类型化策略字段上一条确定性规则全对；不带模型的控制器解出 79%，2610.24871）；企业侧被强制的其实是同案同判 + 可复现记录 + 有界错误率 + 可申诉，而位级幂等既不充分（硬 schema 合法率 100% 但准确率 11.0%、"合法但答错" 88.9%）也不必要（评分卡靠单调、可取阈、可审计立足）。可检验的目的是一个**三元组**——等价类内同判 + 等价类外仍给得出决策 + 单价低一到两个数量级——翻译成模型侧要求是**单调可取阈的分数、原生 unknown、业务等价类内不变**，幂等本身住在**阈值与确定性契约**里（2610.10978）（17 章 §17.1、§17.1.6）。

15. **业务目标是单价，不是准确率；属性清单里只有两条可承诺**。被消除的是解码 + 往返 + 解析成本：rubric 评审贵 16–357 倍慢 5–350 倍（2609.29769）、审核约 0.000025 美元/次约 100 ms 且 AUROC 与 14 个前沿系统中 13 个不可分（2610.33258）、本地 2B 30.9 ms 零输出 token 对前沿 API 8,758 ms（2609.23886）。可承诺的只有"输出必在选项集内"与"一次前向答完整个请求"；校准、等价提法不变性、兜底、unknown、自知、概率自洽、可审计、风险预算八项都有独立审计测出的反例，其中最差的是兜底（答案缺席时正确拒绝率 7%，加阈值可到 79%，2609.39496）与自知（无相关信息时对显著选项给到 0.80，2610.01006）。支撑 System1+System2 有五个工程上不同的位置，前四格（入口闸、过程监控、证据/记忆面、慢模型输出读出器）有正面证据，第五格（闭环执行者）普遍失败（17 章）。
16. **输出的形状比目标函数更值得改**。适当评分规则已是共识且已到顶（标签已知时与 RLCD 式奖励同最优点、标注者分歧下可证明不能胜过交叉熵、加 Brier 项对准确率无效）。而四种输出里三种形状是错的：布尔缺第三个真值（还原 P(U) 后软准确率 0.771→0.978，2609.35342）；选择的读出**是序数的不是概率的**（序数层误差 4.2 点、概率层 21.0 点，2610.07716），非对称代价下用它的概率可能比用 top-1 更差（2610.11392）；序数被系统性压缩（40 数据集 9 模型，刻度变细更严重、规模不能恢复，2609.38827），而 Kev 的序数损失在发布模型里未启用。数值不该用标量回归：区间决策树把归一化 MAE 从 5.18% 降到 1.84%（2609.28587），而算术必须外包（答案缺席时拒绝率 7%）（18 章）。
17. **思维链要引入，但推理时不应该是 token 流**。四种用法里：训练时蒸馏最优（Reasoning-to-Readout 自蒸馏让 27B 在 JEVal 上与 Jev 持平、约 0.1 s，2610.03935）；层循环是唯一有深度外推证据的零 token 路线（SanSi 比同形状非循环高 13.5 点并把可解深度推到训练深度之外，2610.07730；LEV 2.6B 深度 1→4 从 63.2% 到 76.2%，2610.20951）但要求循环预训练骨干，与我们的混合基座不兼容且无桥梁工作；读别人的链最被低估（1,500 token 预算下比强制作答 +4.1 pp、被截断题 +8.6 pp，省 71.3% 成本，2610.25768）；自己生成链有效但把成本搬回生成式一侧，只配做置信门控的逃生通道。而 System 1 自己的"展开"形式是**问题图**——多问近乎免费、多生成按量计费：LAVOIR 一次前向同时返回决策与每个待问信息的期望增益，最多 0.5 个追问即比从不追问高 14.1 点（2609.30706）。硬界限是 Jev 做不出"LLM 只有写出中间步骤才能做出"的决策（一次前向可解的题 97.5%、其余 74%），而且**它不知道自己的界限**（2610.24929）（18 章）。
18. **"怎么评测"文献已给出答案，而现有论文对它的合规率很低**。一份 14 项检查表加一张最小报告卡已经存在，但"同骨干标签对数概率基线"26 篇适用论文只有 5 篇合规、"选项名不变性测试"27 篇只有 1 篇、"带缓存与不带缓存两套延迟"20 篇只有 3 篇（2609.32160）——也就是说公开数字里"接口的功劳"与"模型的功劳"基本没被分开过。按业务属性看覆盖面严重不均：准确率、校准、一致性、对抗有多个大规模基准，而兜底、unknown、自知、概率自洽、风险预算是单篇或两篇孤证，**业务人员可配置与可审计两格是零**。最大的缺口是业务目标本身——**每正确结果的端到端成本没有任何可复现口径**，而一篇自审计把自己"省 23.9%"的结论改成"省 4.3%"（2610.02267）（19 章）。
19. **复核：四个工作假设里三个"结论对、机制错"，而本报告有八个框架是自己造的**。H1（SFT 不泛化）结论对而机制不完整；H2（业务期待不可导）结论对而理由错；H4（幂等搬迁）诊断对而描述错；只有 H3（用 RL 保 ICL 与技能注入）方向不成立。这个模式有原因：提问者的判断来自部署观察，对**现象**可靠；机制归因需要控制实验，而文献恰好在这几处缺控制实验（没人测决策微调前后的 k-shot 曲线、没人把 Jev 的重复抖动与温度 0 的生成式基线并排测、没人在同一批数值决策上比较三条数值路线）。所以遇分歧应**保留现象、重做机制**。同时，七个泛化层次、五类可导性、三层幂等、五个 System1+System2 位置、"决策重复度"轴、"问题图 vs token 流"、十二条业务属性、D4 的 30 个子维度**都是本报告的构造而非文献结论**，其中后三者过拟合风险最高；正文里"按这个分类看 X 格是零"应读作"按本报告这种分类看"。我自己最该防的缺陷是确认偏差，且已有一次实例：17 章初稿六条反证里有四篇论文早已在本报告其他章节被引用，失败不在检索而在**写新章时没做反向检索**（20 章）。
20. **两条后续命题的检验：核心逻辑是"语义理解的泛化"（不是"变成代码"），以及"决策一致率是核心指标、对错第二顺位"**。前者成立，而且是用本报告自己的归谬成立的——"把决策权挪到代码"的无约束最优解同样是查表，所以措辞已改为"**模型负责语义，代码负责记账**"：把开放世界情形映射成带刻度的观测记录这一步没有任何代码写法。支持它的最强单条证据是**一个通用问题零样本跨十类对齐失败、44 个基准达到 AUROC 中位 0.886 并胜过多数有监督基线**

（2609.29429）——规则引擎与查表都做不到。但这个口径下结论更难听：单遍类型化读出恰恰在语义层最弱（名字-定义对调 AUC 93.8%→23.2% 而类型错误率全程 0%、删除定义准确率不变、1–12B 少样本语义覆盖率为零、跨裁判迁移 67.70%→47.87%），而且**让它便宜的那个操作与毁掉规则敏感性的操作是同一个**（可缓存独立编码约 5 倍便宜、规则敏感度 1.00→0.24，2609.37832）。后者也成立，但理由应更强——**一致率是正确率可被承诺的前提**（阈值只在分数分布稳定时有效：样本内拟合目标 5% 而保留集最高 17%），且聚合准确率对我们关心的变化是盲的（换 8 种顺序准确率变化 <2 pp 而累计失败集 +27–29%）。两条命题都必须补上同一项：**无约束最优解分别是查表与常数分类器**——三次命题都点名"不变性"而留空"判别"，所以可用形式是"一致率为目标、正确率为声明的地板"，且必须先取定分母（字节级重跑口径 99.83% 对保答案对抗变体口径 53.7%，相差 46 个百分点；唯一有业务含义的"业务等价类"口径无人定义过）（17 章 §17.1.6–§17.1.8、20 章 §20.3）。

## 4. 证据可信度与注意事项

- 绝大多数证据是 **arXiv 预印本**（未经同行评审），且时间窗口极窄（发布后 6 周内）。多篇论文自述为"早期证据"，样本量和模型版本差异大。
- Jev 的训练细节（RLCD、数据、骨干）**未公开**；所有架构描述来自黑盒探针与开源复现的推断。
- 开源复现之间的基准（JevBench、Decision Index、DecisionPivot、System1-Arena、TypedBench 等）口径不同，跨论文的数字不可直接比较。
- 本报告**不做选型、不写训练方案**；10 章只给出问题定义、度量与开放问题，12 章只比较学习算法与数据可得性，13 章只比较各论文的定义，14–16 章只审查工作假设与选型问题的证据，17–19 章只审查业务目标、输出形状与评测覆盖面的证据，**20 章复核前面各章的工作假设与本报告自己的构造，并列出我自己的方法论缺陷**。

## 5. 约定

- 文中数字后括号内为出处：`[arXiv 编号](链接)` 或页面名。
- "宿主模型 / hosted"指 TypeSafe 的 Jev API；"解码器复现"指基于 Qwen / Gemma 等因果语言模型的开源决策模型；"编码器系"（Laya、Verdict、Jeva、NDM、RubriX 等）只作对照证据引用，不属于我们的技术方向。

# 01 · Jev / System One：定义、接口原语、架构还原与独立评测

> 本章回答："Jev 类快思考模型"到底是什么、对外暴露了什么接口、黑盒探针推断出什么架构、独立评测给出了什么结论。所有数字均回到缓存的原文核对。

## 1.1 基本事实

| 项目 | 内容 | 出处 |
|---|---|---|
| 厂商 / 发布 | TypeSafe AI（旧金山，2024 年成立），Jev 于 2026-09-15 发布；Jev 1.14 于 2026-10-14 发布 | Wikipedia、docs/models |
| 定价 | 输入 $0.042 / Mtok，输出不计费（输出不是文本） | docs/models |
| 上下文 | 每请求 64k、每问题 32k；加 `TypeSafe-Danger-Zone-Long-Context: true` 头可放宽；一次请求问题数不限，只受两个上限约束 | docs/models |
| 训练 | "RLCD"（Reinforcement Learning for Calibrated Decisions），只用合成数据，细节未公开；不用客户数据微调，一套权重服务所有账户 | ML primer、docs/models、Wikipedia |
| 定位 | "为构建 AI 驱动的软件而非 Agent"：代码掌握控制流、确定性规则与副作用，模型只回答窄而结构化的判断；"把独立问题一起问，再在代码里组合答案" | How to build |

## 1.2 接口原语（我们后续"逻辑原语"讨论的起点）

TypeSafe 的 System One API 只有三种问题类型，再加上 `state`：

| 原语 | 返回 | 约束 | 备注 |
|---|---|---|---|
| **Noul** | 命题为真的概率 P(true) | 可选 `criteria`，当 yes/no 边界微妙时用结构化的 `true` / `false` 描述，各自带定义与示例 | primitives/advanced |
| **Choice** | 对每个选项的概率分布 + 置信度 | 选项带 `criteria`（描述）与 `examples`；可用 JSON 结构 | 同上 |
| **Score** | 对有序等级的概率分布 + 得分 + 置信度 | `criteria` 为从低到高的有序等级描述，≥2 级，API 最多 10 级 | primitives/score |
| **State** | 问题所针对的材料：文本、JSON 对象或数组，"可以包含相关上下文、示例和其他有助于回答的信息"；比喻为"交给专家小组的材料" | 文档明确允许在 state 中放示例 | concepts/state |

**置信度**的定义是 `confidence = (p_max − 1/n) / (1 − 1/n)`：只看最高概率，均匀分布为 0，确定为 1（docs/confidence）。这意味着"置信度"不是熵，也不是 top-2 差距，而只是 top-1 相对均匀分布的高度。多篇论文指出这个定义与"错误检测能力"并不是一回事（见 D4 章）。

**官方模式（patterns）**，构成了"用代码组合小判断"的原语库：

- **Speculative fan-out**：一次请求里并行问多个独立问题（patterns/fan-out）。
- **Composite scoring**：多个 Noul / Score 的结果在代码里加权求和（patterns/composite-scoring）。
- **Confidence routing**：一个全局下限（示例 0.6）+ 每类动作各自的阈值，低于阈值交人工（patterns/confidence-routing）。
- **Walking a taxonomy**：每层一个 Choice，在代码里逐层走树（primitives/advanced）。
- **Agent skill 文档**的工程建议："把问题和阈值常量放在一个文件里便于审查；Agent 不擅长写问题，要和它协作编辑"；"如果只要选最优选项，就取最高置信度，不要到处设阈值"（agent-skill）。

**用例地图**（use-case map）把决策形状分为分类、检测、打分、路由、搜索、检索、排序、验证、ML 特征抽取、结构化抽取十类。这十类是我们定义 D3 原语集合时的参考分类。

## 1.3 官方承认的"锯齿"（jev-1.13 model jaggedness）

官方文档列出 9 类失效，并给出"改用什么"的建议（model-jaggedness/jev-1.13）：

| # | 失效模式 | 官方建议 |
|---|---|---|
| 1 | 字面阅读（literal reading） | 为每个选项写出精确条件与判据 |
| 2 | 数学与数字：不会可靠计数（字符数、词频、列表项），"识别答案的形状而非逐一清点" | 算术放代码里 |
| 3 | 日期时间比较：把日期当文本读，先后、间隔、窗口判断不可靠 | 抽出分量，在代码里比较 |
| 4 | 间接（indirection）：双重否定、属性的属性、多跳 | 减少跳数，直接指向相关 state |

| # | 失效模式 | 官方建议 |
|---|---|---|
| 5 | 大量无关细节的 state | 先过滤，只送问题需要的 |
| 6 | 对抗内容 | 写精确提示，上线前测边界 |
| 7 | 指令与判据矛盾 | 对齐判据与指令 |
| 8 | Choice 选项顺序：偏向排在前面的选项 | 重排选项，检查答案一致 |
| 9 | 生成 | 用生成模型 |

这份表格几乎就是 D2 / D4 的"官方版问题清单"；第三方论文（下文与各维度章节）把每一条都量化了，并发现了官方没列出的更多失效。

## 1.4 架构还原（黑盒探针）

Archer Hume 的《Jev's Architecture Unmasked》（2026-09-17，链接）通过 API 探针得出：

- **因果 Transformer**（作者猜测含稀疏 MoE，但明确说"是推测"），**共享的 state 前缀 + 相互隔离的问题分支 + 直接概率读出**。
- **分支隔离证据**：把一个秘密代码放在兄弟问题里，被问到的问题给出 0.00 概率；删掉那个兄弟问题结果不变；把同样的声明放进 state，概率上升。
- **列表式读出证据**：把目标选项放在最前时 12/16 正确，放在最后时 16/16 正确，说明选项之间不是独立打分。
- **无关选项改变现有选项之间的优势比**：加入一个无关选项后，两原选项的平均 log-odds 从 +0.38 降到 +0.11，十个随机区块全部下降（均值 −0.28，95% 区间 −0.36 到 −0.19）。这否定了"固定独立 logit + 不变 softmax"的机制。
- **服务特征**：到约 100 个问题为止服务器时间几乎不变，之后线性上升；按 token 计，问题文本的成本约为 state 的两倍。
- **分词器**在 415 次探针中与 192 个公开分词器都不匹配；每个数字单独切分。

这套还原直接决定了开源复现的结构（见 02 章）和混合架构下的分支隔离难题（见 08 章）。

## 1.5 独立评测与审计：Jev 擅长什么、不擅长什么

### 1.5.1 横向能力

| 来源 | 设置 | 主要结论 |
|---|---|---|
| 2609.37647 | 37 个数据集零样本，346,009 次请求花费不到 10 美元；对照 Qwen3.8-27B、Gemma-4-E4B 的精确下一 token 概率 | IMDB / SST-2 / HellaSwag / ARC 95–99%，Belebele 122 种语言 86.7%；37 个数据集中胜 Qwen 27 个、胜 Gemma 全部；三者都在低资源语言、细粒度/噪声标签、基于评分细则的质量判断上退化。Choice 概率校准良好；**二元概率排序好但相对固定 0.5 阈值摆放不准**，在 UNFAIR-ToS 上用训练集调阈值使 micro-F1 从 0.50 升到 0.75 |
| 2610.11978 | 13 个多选基准，对照 19 个 LLM | 知识与常识上与前沿模型相当，MMLU-Redux 与 ARC-Challenge 最佳；**MathQA 比前沿中位数低 17.7 点，低于全部 19 个 LLM** |
| 2609.24574 | 计算社会科学 18 任务 7,977 条，对照 19 个 LLM | 15 个任务里 14 个落后于该任务最好的 LLM，中位差 11.6 macro-F1，但成本中位低 44 倍；置信度比 19 个 LLM 中 16 个的口头置信度更校准；在"同伴支持对话中的共情"任务上**高置信但接近随机** |
| 2610.18529 | 医学 15 数据集 8,742 条 | 文本驱动任务上与领先模型相当，**数值驱动任务上明显弱**；问题格式变化下一致性强；大多数模型不能识别"正确答案缺失"也不会用可选弃权；**把逐选项的二元得分归一化比 Choice 打分保留更高准确率** |
| 2610.33258 | 142,658 条人工标注评论的内容审核，对照 14 个前沿推理模型 | 零样本 AUROC 0.83 与 14 个前沿系统中的 13 个在统计上不可区分，成本低 1–3 个数量级；"置信度"混合了**人类分歧**与**决策风险**两种不同的不确定性 |
| 2609.26550 | JEV-as-a-Judge，对照 16 个生成式与奖励模型裁判 | 凡是裁决能从文本直接读出的任务，与 GPT-6 差 3 点以内，费用为其 0.36%，中位延迟 0.15 s；**需要推导裁决的数学 / 代码 / 逻辑任务落后**；置信门控级联在 1,610 对上比 GPT-6 高 0.9 点，费用 41% |
| 2610.35721 | 临床试验入组条件，2,048 对 | 批量模式下 TrialGPT / MIMIC-IV 与 Qwen Flash 相当，MIMIC-III 显著更好（0.768 对 0.534），优势主要来自对"信息不足"类别的召回（56.3% 对 9.9%）；延迟 1.18–1.40 s 对 2.80–8.90 s，成本低 53%–74% |
| 2609.24052 | 德州 499,500 条事故叙述筛查，195,857 条按 27 问模式编码 | 对人工标签 F1 0.908；成本由模式大小而非叙述长度决定；**校准因模型而异而非因范式而异，每个模型都要审计**；重校准把校准误差降低 3.3 倍 |
| 2609.23136 | 6G Open RAN 意图解释 | Jev 在 99.8% 的调用上满足 1 s 近实时预算，两个托管 LLM 为 17.9% 与 0% |

### 1.5.2 元审计与生态

- **早期证据审计**（2609.32160）：复盘发布后 9 天内的 28 篇论文，结论是"**类型化读出本身尚未显示出独立于同类标签概率读出的准确率优势**；Jev 最清楚的收益在延迟与成本，困难任务上仍有准确率差距；实践中置信度多用于决定何时转交更强模型或人"。给出 14 项评测清单。

- **生态**（2609.30216）：截至 2026-09-22 的 2,170 个公开 GitHub 项目，属性判断与打分最常用，动作选择、内容过滤、模型/工具选择在各领域差异大。
- **实践者指南**（2610.33775）提出五族分类：编码器分类器、奖励模型、非自回归决策引擎、对比决策模型、抽取模型。我们的方向落在"非自回归决策引擎"中的**解码器骨干**子类。
- **排行榜**：Decision Index 0.4 的主排名改为"Full score = 60% 同技能私有测试 + 40% 新领域私有决策任务"，技能分按机会水平校正（apolinario/decision-index）；Jev 领跑 0.2 版（systemonemodels.org）。

### 1.5.3 稳定性与偏置（概述，细节在 D4 章）

- 重复性极高：文化价值观调查 24 题 288,000 次回答 ICC 0.997（2609.36399）。
- 但"同分不同判"：ContractNLI 上改变可见假设、请求答案与输出顺序后，纠正与回退相互抵消，准确率不变而决策已变（2609.27678）。
- 认知偏差上大体表现好，但对无关数值信息和选项顺序敏感（2610.19619）。

## 1.6 本章小结：Jev 是什么、不是什么

1. **是什么**：一个把"state + 类型化问题 → 概率"作为唯一接口的因果 Transformer，共享前缀、分支隔离、列表式读出，靠校准训练与极低成本取胜。
2. **不是什么**：不是更准的分类器，不是会算术/比日期/数数的模型，不是对选项顺序与无关选项免疫的打分器，也不是"置信度 = 知道自己不知道"的模型。
3. **对我们的含义**：Jev 的价值在于**接口契约**（概率可阈值、可组合、可审计）而非权重。只要复现这个契约，小模型 + 领域数据就能在特定任务上超过它（见 02 章）。真正难的是让这个契约在 D1–D5 各维度上**保持一致**（见 06 章）。
4. **这一条在 17、20 章被改进过**：说"价值在接口契约"还不够，因为它没说契约是干什么用的。更锋利的版本是"契约把**决策的记账**交给代码，而把**语义**留在模型里"——注意不是"把决策变成代码"：把开放世界的非结构化情形映射成一个带刻度的观测记录这一步没有任何代码写法，它就是语义泛化，也是整个构造里唯一不可替代的部分（17 章 §17.1.7）——它能预测哪类部署成功（决策权在代码里）、哪类失败（决策权回到模型里），与 17 章 §17.5 的五格表吻合。但它**不能**被进一步读成"于是系统就幂等了"：宿主 Jev 自身的重复抖动、菜单构成对指标的影响、harness 计划与排队的影响、以及"写不出中间步骤就做不出的判断"这四项，共同把它限制为"把非幂等的表面收缩成可定界、可定价的若干字段"（17 章 §17.1、20 章 §20.1.2）。

# 02 · 开源解码器复现与配方矩阵（含小模型证据）

> 本章回答：用开源因果语言模型（Qwen / Gemma 等）复现 Jev 接口的工作有哪些，各自的骨干、读出头、损失、数据、校准与"分支隔离"方式是什么，以及小模型（0.6B–9B）到底能做到什么程度。编码器系（Laya、Verdict、Jeva、NDM、RubriX、Bongard 等）不在我们的技术方向内，仅作对照时引用。

## 2.1 一个共同的骨架

所有解码器复现都遵循 Archer Hume 还原出的三段式：

1. **共享 state 前缀**：state 只编码一次（KV 缓存 / 前缀分叉 / 独立行）。
2. **问题分支相互隔离**：树形注意力掩码（纯注意力骨干）、或每问题一行、或前缀分叉（混合骨干，见 08 章）。
3. **读出**：从最后一个位置读 LM-head 的候选字母 logit（letter readout），或在每个选项末尾位置放"指针头"（pointer head）/ 跨度均值池化（mean-span），再对合法选项做 softmax，最后乘一个拟合温度。

一个重要的先验证据：**不训练也能读出**。LDM 论文发现未调优的 27B 模型的读出已达到其调优后准确率的 97%（2610.15501）；FunDM 用 Qwen3-8B 的 24/36 层、无标签训练的小头恢复约 99% 的多选准确率，吞吐 1.56–1.57 倍、峰值显存降约三分之一（2610.17175）；LLM-as-Jev 的结论直接写进标题："LLM 已经是 Jev 式决策模型"（2610.02076）。

## 2.2 配方矩阵

| 名称 | 骨干 | 读出 / 头 | 训练目标 | 数据 | 校准 | 分支隔离 | 关键数字 | 出处 |
|---|---|---|---|---|---|---|---|---|
| **Kev** 1.0 | Qwen3.5-0.8B/4B/9B、Qwen3.8-27B | rank-16 LoRA + 指针头 | 交叉熵（细节见 README） | `decision-v7`：10,000 条公开数据集样本 + 896 条生成策略样本 + 60 种规则结构的 1,680 条 | 每个检查点存一个温度（0.8B 2.35、4B 2.41、9B 2.19、27B 1.32；27B/9B 在从未训练的保留集上拟合） | 纯注意力骨干用树掩码+位置重置；**Qwen3.5/3.8 因 DeltaNet 忽略掩码，每个问题单独一行** | Kev-9B 对新来源问题有 2.4% 的情况把 ⩾0.9 概率放在错误答案上；日期事实补充（`KEV_DATE_FACTS`）把截止期策略题从 0.80 提到 0.90（Jev 0.93）；提供 `/v1/systemone/permute` 多序测试 | jaredpa |
| **Tev1** | Qwen3.5-4B | 输出单个答案字母（letter） | SFT | 37,840 条唯一训练样本，约 17 美元、25 分钟 | 未说明 | 单问题/请求 | 880/1,000 主决策，300/300 策略迁移 | togethe tev1、T 客 |
| **Bespoke Nimble** 9B | Qwen3.5-9B + LoRA | 枚举字段（1–255 个选择） | SFT | **对比数据策展**："改一个事实让答案翻转"，公开 2,676 条训练样本 + 324 条评测 | 未说明 | 8,192 token 上下文 | 在金融领域流行度偏移下 Macro-F1 −12.0（见 D4） | bespok nimble、 |
| **pplx-decider** v1.2 | 27B（继承 v1.1-27B） | 多读出/请求 | 未公开细节 | 未公开 | — | 请求内联合、请求间独立 | Decision Index 68.09（联合请求）对 67.75（分开）对 v1.1 的 62.30；**同一条消息的多个侧面联合问有利（PhishNChips +5.1），独立候选联合问有害（−0.2 到 −0.4）→"独立候选分开请求"** | 模型卡 |
| **OneJev** 1.6 | Qwen3.5-0.8B/4B/9B、Qwen3.8-27B（多模态，视觉塔冻结） | 答案位置 | 交叉熵 + Brier | 99,193 题（公开 94,707），lr 5e-6，16,384 token，1 epoch | Brier 项 | — | H200 上一张 720p 截图：0.8B 1 问 31 ms / 10 问 51 ms；4B 64 / 104 ms；9B 81 / 131 ms | OmniJe |
| **Open-Jev**（Zefan-Cai） | Qwen 2B/9B/27B | LoRA（27B rank 8）+ 标量决策头 | — | 冻结的 148,639 行训练混合 | 保存温度 | — | 27B v1.1 的 127,787 行内部评测通过独立审计 | Zefan-C Jev |
| **open-jev / TOD**（daseinlabs） | Gemma 4 12B + LoRA；或冻结 Gemma 3 4B 上的小头 | 头 | — | 用户自带数据 | — | — | cookbook 01：84.2% / 66.3% 零样本 → 97.0% / 100%（team / priority） | daseinl jev |

| 名称 | 骨干 | 读出 / 头 | 训练目标 | 数据 | 校准 | 分支隔离 | 关键数字 | 出处 |
|---|---|---|---|---|---|---|---|---|
| **qwen-rlcd** | Qwen3.5-0.8B-Base（18 DeltaNet + 6 注意力） | letter / likelihood / PMI / `<\|read\|>` 头 | 仅推理（训练搁置） | — | — | **前缀分叉**替代树掩码；分叉对全前向 8–19 倍加速；0.8B 上分叉 vs 顺序误差 4.8e-5；穿过缓存的梯度检查未做 | shamazharikh/qwen-rlcd | |
| **Mapika decider** | 原版 Gemma-4-31B-it / Qwen3.6-27B（不改权重） | 读出 | 无训练 | — | **按选项数拟合温度** T(n)=max(0.05, 10.124 − 1.633 · ln n) | — | Gemma-4-31B-it Decision Index 57.33，70 个里第 2；Qwen3.6-27B 51.35 第 8；decider-31b v2（合并微调）63.90 | Mapika/ |
| **StartLux-Decision** v1.1 | 4B / 9B / 27B（Instant 与 AutoThink 两种） | 单遍（Instant 在全注意力层用双向注意力）；AutoThink 在 top 概率 < 0.9 时生成推理 | 三阶段：共享决策能力 → 分化 → AutoThink 的推理监督 + RL | 阶段 2 加入评分 / 安全 / 偏好 / 逻辑族后，DecisionPivot 上对应 18 个任务 +8.6 点，族外任务只 +0.3 | **策略感知校准**：184 种设置下置信-准确差 ≤2.7 pp | — | AutoThink 对 Instant 在 4B/9B/27B 分别 +18.4/+12.4/+11.5 点配对准确率；27B AutoThink 86.9%、Instant 75.4%；27B Instant 在 Decision Index 174 个条目中排第 1（2026-10-16） | 2610.17 StartLux |
| **Releasing the Inner Jev** | Gemma 4 31B / 12B、Qwen3.6-27B、Qwen3.5-4B | LoRA + 从 LM-head 切片初始化的决策头 + 学到的修正项 | 教师标签（Qwen3.5-122B-A10B、Qwen3.6-27B）；**软标签"可能"无益** | OpenDecisions | — | — | Gemma 4 31B 不微调 79.6 对 Jev 80.1，微调后 84.4；**LoRA 是改进的来源，对秩不敏感** | 2610.17 |
| **LLM-as-Jev** | 4B 冻结（含 0.6B 实验） | 直接读 logits；列表式损失 + KL 正则 | — | — | — | — | 启用受 token 预算约束的原生思考后 JevBench 94.8%；0.6B 在 Banking77（77 类）从 22.2% → 60.5%；字母读出不能处理 77 类 | 2610.02 |
| **LDM** | 三个基座（含 Gemma-4-31B） | 一次 prefill，最后位置经 LM-head 只归一化合法选项 logit | DDS（多样决策监督）+ SPRD（自提问推理蒸馏） | DecisionVista-Synth / Human | — | — | 比步数匹配基线 +1.8 / +1.5 点；对推理 rollout 182 倍中位延迟加速；路由用 27–58% 推理 token 恢复 92% 的推理优势 | 2610.15 |
| **SII-Decision** | 4B / 27B（全秩与 LoRA 各一） | — | **Reasoning-to-Readout 自蒸馏** | — | — | — | 27B 在 JEVal 上与 Jev 持平，典型查询约 0.1 s | 2610.03 |
| **Chinese Decision** | Qwen3.5-0.8B/2B/4B | 最后位置候选字母 logit，只对合法选项归一化 | 1 epoch，13.048M 决策 | 同左 | 验证集拟合温度；Q8_0 量化 | 每问题编译为共享指令+候选提示 | CJ-Bench 307,900 决策：4B 总体 85.97%，通用 75.69%，医/法/金融平均 84.00% | 2610.23 |
| **Intern-Decision** | 0.8B / 2B / 4B 多模态 | 在完整 JSON 骨架里每字段一个决策占位符，用原生 LM-head 读出 | 自回归掩码 LM | — | 温度缩放：Brier 0.628→0.550、ECE 0.213→0.089 | 单次因果前向评估所有字段 | 4B 七套件平均 90.02% 对 Jev 1.13 的 88.74%；三字段 289 token 请求 RTX 4090 上 44.16 ms；置信交接把 JevBench-Hard 73.87%→87.39% | 2610.22 |
| **AnyJev** | 冻结骨干 | **与问题无关的头**：仿射映射到最终层空间，复用原输出头 | — | — | — | — | 11 个模型平均反转选项列表改变 33% 的答案；旋转把顺序翻转率从 0.33 降到 0.14 / 0.18 | 2610.00 nokia-a research |
| **OpenJev-RLCD** | Qwen3-1.7B | 显式概率 | "先校准再强化"：以同一个适当评分规则为奖励 | 两个真实推理任务 | 内生 | — | 与 SFT / RFT / GRPO（各加温度缩放）相比准确率持平或更好，选择性预测全部更优；GSM8K 答案验证单次查询可在 ≤5% 错误下决定 81% 的条目，GRPO 为 19% | 2609.38 |

| 名称 | 骨干 | 读出 / 头 | 训练目标 | 数据 | 校准 | 分支隔离 | 关键数字 | 出处 |
|---|---|---|---|---|---|---|---|---|
| **PACT** | — | 单 token 类型化决策 | 成对锚定校准微调 | — | — | — | 准确率 84.6 对已发布配方 85.2（无显著差）；位置偏置最低、重标注 9.8 对 13.8%；种子间方差减半、NLL −26%；"价值在稳健性而非准确率" | 2609.35 |
| **this-that-model** 1.0 | 2B | 从指定位置的隐状态直接读出，限定在声明的选项集 | — | 42 族内部套件 | Brier 0.042 | 同一前向回答请求中的所有问题 | 笔记本 GPU 30.9 ms；第三方 68 题队列 0.941 对 Jev 0.765 | 2609.23 FLock-io |
| **System X** | Qwen3-0.6B → v4 Qwen3-1.7B LoRA | LLM-as-Jev 读出 + "文本回复"选项，赢时从 KV 缓存续写 | — | Reason-9k + Bitext | ECE 0.292→0.169 | 在提示缓存副本上打分，与全序列打分差 1.4e-6 | v4 JevBench 55.0%→61.0%；缓存复用省 15–39% 延迟 | 2610.25 |
| **Our Own Jev** | 冻结骨干 + rank-16 LoRA + 指针头 | 一次前向答三问 | — | 148K Agent 编码会话 | — | — | 替代每遍约 1,000 美元的前沿裁判，1,000 会话约 3 分钟一张 GPU 约 0.06 美元 | 2610.29 |
| **Decision Model Factory** | 可选骨干 | 只计算允许答案的概率，复用共享上下文 | 简短配方：训练→校准→验证→评测 | — | — | 专用 runner 在多问题负载上提速 2 倍以上 | 日语任务五个模型全部超过骨干，三个超过公开最优 | 2610.34 |
| **SecJev** | 基于 Kev 的 0.8B–9B | Kev 单遍候选打分 | 场景加权训练 | SecJev-Corpus：14 任务 8 来源 | — | — | **SecJev-0.8B 比通用 Kev-9B 高 20.51 pp 任务宏准确率**；0.8B/4B 与仅答案的生成式微调准确率与延迟接近、峰值显存更低 | 2610.03 |
| **AgentDecision-4B** | 4B | — | 在 Agent 自己犯错后到达的状态上训练，用 Jev 的答案做标签 | DecisionGym | 按选择逐项拟合阈值 | — | 分布外任务 91.5% 对 Jev 82.0%；分布内让 Agent 便宜 81.1–89.0%、快至 2.5 倍 | 2610.21 |
| **SanSi / LEV**（循环） | 预训练为循环的 LM（LEV 2.6B 等） | 每个循环步后读选项，所有步联合训练 | 适当评分规则 | — | 小停止器按未标注请求拟合阈值 | — | SanSi 59 来源 10,027 决策 72.0%，比同形非循环 +13.5；LEV 2.6B JevBench 深度 1→4 从 63.2%→76.2%，按需深度省 15% 计算 | 2610.07 2610.20 |
| **Block-causal** | — | 候选无关的块因果注意力 + 位置重置 | — | — | — | 隔离 + 位置重置 | 仅隔离把测试翻转率 8.30%→3.82%，OOD 7.54%→3.71%；只重置位置更差 | 2610.01 |
| **Prism-1** | Qwen3-8B / Gemma 4 12B | 位置与对手无关的打分 | — | — | — | — | 字母读出一次洗牌改变 20.0% / 11.9% 的答案；Prism-1 零翻转 | 2610.22 |
| **Runoff** | 任意（免训练） | 先逐选项单独打分留下少数候选，再让每个候选占每个位置做列表比较 | 无 | — | — | 两次前向 | 构造上与顺序无关；两开源模型五数据集零翻转，循环平均 9.3%；20 选项时快 3–4 倍 | 2610.18 |
| **ufakzeka-karar** | 土耳其语 | 选项盲头（order-invariant） | — | — | — | — | — | 2610.06 |
| **JEV entailment reranking** | NeoHorse-1-4B | **mean-span 池化**替代选项末尾指针 | **选择性适配**：LoRA 保留在注意力与 Gated DeltaNet 投影，去掉 FFN 适配器 | MC11 | — | — | 可训练参数减半以上且准确率提升 | 2610.35 |

补充的训练理论：Gaussian 代理下的精确风险计算表明，**学生继承教师偏差，更多学生数据不能消除，与教师的一致性也不能暴露它**；固定表示只在样本量低于某阈值时降低风险；温度缩放只在教师系数方向正确时消除全部超额风险

（2610.26797）。这与"Releasing the Inner Jev"中"教师标签有用、软标签可能无用"的经验一致，也是 D4 中"教师偏差继承"子维度的来源。

## 2.3 小模型到底行不行：证据汇总

| 证据 | 结论 |
|---|---|
| SecJev-0.8B > Kev-9B（+20.51 pp）（2610.03073） | **领域数据 > 参数量** |
| AgentDecision-4B 分布外 91.5% > Jev 82.0%（2610.21412） | **在自己轨迹的状态上训练 > 通用模型** |
| 0.6B Banking77 22.2% → 60.5%（2610.02076） | 小模型能学会多类列表式读出 |
| Chinese Decision 4B 医/法/金融 84.00%（2610.23170） | 1 epoch、13M 决策即可得到可用的中文小决策模型 |
| this-that 2B 第三方 68 题 0.941 > Jev 0.765（2609.23886） | 单一来源，样本小，但方向一致 |
| JevCascade：150 类全菜单 69.0% → 精选 5 候选菜单 95.4%，**跨度 26 点，大于 0.8B 与 4B 之间的差距**；菜单干预可预测到 4.2 点以内（2610.07716） | **候选集设计比模型尺寸更一阶** |
| Microtask eligibility gap：现成 Qwen3 0.6/1.7/4/8B 在 4 个 Agent 微任务上 0/16 通过实践者阈值，4-bit 量化无法改变，Llama-3.x 12/12 不合格；建议"把 SLM 放在已达标的廉价基线后面，只在基线失效处用"（2610.00025） | **不训练的小模型不够用**，要么训练要么放在基线之后 |
| Measure Before You Train：739 封真实邮件上，约 200 标签的逻辑回归在每个字段上最准，少样本提示不能弥合差距；但"最准的系统"组合成功作后最常忽略需要处理的邮件（18% 对最佳 LLM 的 4%），对噪声概率设一个成本选择的阈值使其减半并成为最便宜的系统（2610.32955） | **先测量再训练；准确率不是产品指标；阈值是产品的一部分** |
| Jev-like（Qwen3-1.7B + LoRA + 37 个开源数据集）：域内置信度几乎精确跟踪准确率，域外一个在域内验证为 99.85% 的 0.99 门会失效（mustafasemi-ai/jevlike） | 小模型校准**不迁移**到新分布 |
| 继续后训练小模型：SDFT 依赖强 ICL 与指令遵循能力，在小模型上失败；遗忘与获取不足与分布偏移线性相关（2610.13113） | 持续训练小决策模型需要控制分布偏移，这与 D1 直接相关 |

## 2.4 从配方矩阵读出的共识与分歧

**共识**

1. LoRA + 小读出头 + 温度即可复现接口；全秩不是必需。
2. 教师（更大模型）硬标签有效；对比/反事实数据（Nimble、Certo、DecisionPivot 训练集）对规则敏感性有效。
3. 校准必须在**保留分布**上拟合（Kev-27B/9B 的做法），且按**选项数**（Mapika）或**部署策略**（StartLux）拟合更稳。
4. 顺序偏置要在**结构上**解决（块因果、Prism-1、Runoff、AnyJev 旋转），不能靠训练数据洗牌解决（Prism-1 证明已发布的决策微调仍有翻转）。

**分歧 / 未定**

1. 软标签是否有益（Releasing the Inner Jev 说"可能无益"，OneJev 用 Brier，OpenJev-RLCD 用适当评分规则做奖励）。
2. 单遍 vs 循环（SanSi / LEV）vs 按需推理（StartLux AutoThink、Selective Reasoning、LDM 路由）：三条路都声称在"难题"上有大幅收益，但没有在同一基准、同一骨干上的对照。
3. 混合骨干（Gated DeltaNet）下**训练时**的分支隔离：Kev 用独立行绕开，qwen-rlcd 的前缀分叉只做推理，没有任何工作报告"在混合骨干上用树掩码训练"的结果（见 08 章）。

## 2.5 对我们的含义（仅分析）

- 复现接口本身不是难点，**领域数据、候选集设计、按选择拟合的阈值、保留集校准**才是分数的来源。
- 小模型（0.6B–4B）在窄领域可以超过通用 9B–27B 与 Jev，但**不训练就不行**，且校准不迁移。
- 配方矩阵里几乎所有工作都把"示例 / 定义 / 规则"当作**训练数据**而非**推理时输入**；这正是 D1 与 D3 的空白所在。

# 03 · D1 上下文学习（ICL）：决策模型能否"在提示里学"，业务人员能用哪些杠杆

> 口径（按最新讨论）：不是成本档位。要回答三个问题： 1. 决策微调后的单遍模型**是否还具备 / 能否利用** ICL（示例、定义、判据、状态结构）？ 2. 怎样**利用好**这种能力？ 3. **业务人员通过提示词工程**能用哪些杠杆，效应量多大，哪些情形会失效？

## 3.1 先回到 ICL 的基础事实（上游文献）

决策模型是在因果 LM 上微调得到的，因此 LM 的 ICL 规律是我们的起点。与"业务人员写示例"直接相关的结论：

| 事实 | 出处 |
|---|---|
| 示例的**真实标签不是必需的**：随机替换示例标签几乎不伤害 12 个模型的分类/多选表现；起作用的是标签空间、输入分布与格式 | 2202.12837 |
| **翻转标签只有大模型能学**：小模型忽略翻转标签，依赖预训练的语义先验；覆盖先验是随规模涌现的能力 | 2303.03846 |
| **1–12B 开源模型在少样本下语义覆盖率恰好为零**：反转示例只能以牺牲准确率为代价提高"提示对齐"，ICL 是"调整输入如何投影到稳定的语义方向"，而非重映射标签含义 | 2511.21038 |
| **同质标签让 0.8B–8B 模型坍塌到 ≤12%**：模型把标签槽位里的 token 当作穷尽的答案词表；示例若带 {foo,bar,vex,nit,orb} 这类无意义 token，42–67% 的概率落在示例集合上，P(dog) < 0.2%；4 分类下三模型 0% | 2605.08295 |
| ICL 可分解为**任务模式（Schema）与绑定（Binding）**两个可分离机制：Schema 经晚期 MLP 100% 迁移，Binding 经残差流 62% 迁移；先验知识通过注意力错路由（72.7% 近因偏置）干扰；高先验场景 38% 绑定失败；在 Mamba 上同样成立 | 2512.17325 |
| **标签词是锚点**：浅层把语义聚合进标签词表示，深层以此为参考做预测 | 2305.14160 |
| **Symbol tuning**：用任意符号替换自然语言标签做微调，迫使模型学输入-标签映射，对未见 ICL 任务与欠定提示更稳健 | 2305.08298 |
| **先校准再使用 / 批校准**：少样本的不稳定来自对特定答案的偏置（末尾位置、预训练高频），用无内容输入估计偏置可矫正 | 2102.09690、2309.17249 |
| **任务向量 / 函数向量**：ICL 把示例集压缩成一个向量；少数注意力头搬运任务表示 | 2310.15916、2310.15213 |
| **规则可摊销，配对不可**：静态向量等价于一个合成示例，对高秩映射（词级双射）必然失败 | 2610.00526 |
| **ICL 放大潜在符号电路**：抽象-归纳-检索三阶段电路在准确率升高之前就已存在，示例只是给同一电路供给输入 | 2609.36265 |
| **多示例（many-shot）**：数百到数千示例持续提升，特别是大标签空间；但对选择策略高度敏感，对开放生成任务收益有限 | 2404.11018、2405.00200、2603.05829 |
| 示例**排列可被攻击**：仅重排示例在 LLaMA-3 上近 80% 攻击成功率 | 2502.14628 |
| **ICL 与指令遵循不是一回事**：3 个示例的 ICL 对齐仍不如指令微调 | 2405.19874 |
| **ICL 对校准有负面影响**，来源是示例选择偏置；跨模型跨任务的通用校准器可把前沿模型校准误差降 50% 以上 | 2610.17096、2506.12796 |
| 后训练会**降低分布覆盖与上下文可引导性** | 2510.06084 |

**从这些事实推出的硬约束**：在我们目标的 0.6B–9B 规模上，**ICL 能做的是"识别任务模式 + 在已有语义方向上调整边界"，做不到的是"用示例翻转标签含义"或"让模型学会一个与先验冲突的映射"**。业务人员写示例时，示例的作用主要是示范格式、暴露标签空间、把输入分布拉近，而不是"教会"模型新的规则。

## 3.2 决策模型（Jev 与复现）上的 ICL 证据

### 3.2.1 官方接口把 ICL 放在了哪里

- `state` 文档明确允许放"相关上下文、示例与其他有助于回答的信息"（concepts/state）。
- Choice 选项带 `criteria`（描述）与 `examples`；Noul 的 `criteria.true` / `criteria.false` 可各自带定义与示例；Score 的每个等级是一段描述（primitives/advanced）。
- 官方锯齿表第 1 条"字面阅读"的解法就是"为每个选项写出精确条件与判据"（jaggedness）。

也就是说，官方把 ICL 的三种载体——**定义、示例、判据**——都设计进了接口；问题是模型到底用不用。

### 3.2.2 定义被用到了吗？——"标签名压倒定义"

这是 D1 最重要、也最反直觉的证据链：

| 证据 | 数字 | 出处 |
|---|---|---|
| 只改"名字-定义"的配对，不改问题、state、名字与定义文本本身：在 1,200 个带任务特定定义的决策任务上，yes/no 名字下的决策翻转率比 0/1 对照高最多 70.4 pp；**yes/no 名字下重分配使平均 AUC 从 93.8% 跌到低于随机的 23.2%**；随机字符串作名字时翻转率接近中性对照；类型错误率全程 0% | 类型正确 ≠ 遵循定义 | 2609.26758 |
| 规则只写在定义里时，模型主要按标签回答：**删除全部定义准确率不变**（0.8487），尽管定义单独能撑起 0.7971；标签与定义矛盾时准确率从 0.8511 跌到 0.2281；**原因定位在提示渲染** `"{label}: {definition}"`，改成只写定义（标签用 A/B 作标识符）准确率 +0.1511；给出"两次调用测试"判断某模型是否读定义 | 定义是开发者唯一能写规则的地方，但模型读的是标签 | 2610.02586 |
| HateDecide：提供数据集的仇恨言论定义**改变最多 28% 的预测而不能一致地提升分类**；把定义分解成多个问题只在 20% 的比较中显著有效 | 定义改变答案但不改善答案 | 2610.03324 |
| 在线审核：Jev 一般受益于**检索到的先例**（固定答案空间下提升精确策略选择与有害内容判别）；Laya 则"检索常改变其正例率或无违规率而不提升判别" | 先例（示例）对解码器系有效、对编码器系不稳定 | 2610.07953 |
| 结构化输出模式描述：标签定义放在系统提示比放在 schema 描述更好（GPT-4.1 / 5.4 低 11–13 点）；但 schema 与提示冲突时错误的 schema 指令让准确率跌 5–45 点；在标签前加一个中间推理字段让 schema-only 准确率 +15–24 | 定义的**位置**与**渲染**是一阶变量 | 2608.08254 |

**解读**：决策微调的模型保留了 LM 的"标签词锚点"机制——它根据选项**名字**的语义先验作答，定义只在名字无信息（随机字符串、A/B）时才被读取。这与 3.1 节"小模型无法翻转标签语义"完全一致：定义是在试图重写标签含义，而小模型做不到。

### 3.2.3 示例被用到了吗？——间接证据

没有一篇论文**直接**在决策模型上做"k-shot 示例曲线"实验。能找到的间接证据：

- **JevKT**（知识追踪）：零数据 Jev AUC .706，**加入示例与相似学习者统计后 .722**，领先深度 KT 模型到 16 个学习者、平均到 64 个；这个增益是 Jev 特有的，三个其他 LLM 用字节相同的请求都低于它（2610.11135）。这是最接近"state 内示例有效"的证据。
- **检索到的先例**对 Jev 有益（上表，2610.07953）。
- **Nimble 的对比数据策展**（"改一个事实让答案翻转"）是在训练时用示例对，不是推理时（bespokelabsai/nimble）。
- **Jev-LDE**：训练一个小模型（System 1）对检索到的示例集做一次 Keep / Delete / Replace 编辑，再喂给目标 LLM；在分类基准上一致提升且可迁移（2609.33609）。它说明"选哪些示例"本身可以是一个决策任务。
- **多示例压缩**：MemCom 逐层压缩多示例表示，3–8 倍压缩下优于"少用几个示例"这个意外强的基线（2510.16092）；cheat-sheet ICL 把多示例蒸馏成一段文本摘要（2509.20820）。
- **State 长度**：TypedBench 中宿主模型准确率到 30k token 仍平坦，解码器变慢，编码器静默截断（2610.11392）；官方锯齿表第 5 条警告"大量无关细节的 state 要先过滤"。示例放进 state 会直接撞上这条。

**空白**：没有工作回答"决策微调前后，同一骨干的 k-shot 曲线怎么变"。这是 D1 的第一个盲区。

### 3.2.4 措辞与判据被用到了吗？——"读得到但不一定做"

- TypedBench 的九个套件里，**宿主模型对措辞敏感且系统性欠自信**，解码器随结构复杂度退化；"措辞可归因的方差份额"被作为报告指标（2610.11392）。
- Rule transfer：**等价改写有相反的任务级效应**，"对陌生规则的增益仍可能依赖熟悉的措辞"；"一个决策服务在等价措辞之间改变答案的程度超过在真正不同的规则之间"（2610.30045）。
- Reading Right, Acting Wrong：策略修改被**正确读出**但只在 22%–72% 的情况下被**执行**（2610.18579，细节见 D2）。
- 定义优化可以当训练对象：Goldsmith 把"结构化标注定义"当作可训练的文本对象，用可执行结构损失在小金标集上做文本梯度修订，优于 OPRO / APE / PromptBreeder（2610.09489）；CALICO 让非技术领域专家把编码本变成可编辑、可版本化、可优化的提示，两位编码员分别 +13.0 / +7.4 点，且优化后的提示捕获了编码员特定的解释（2609.14726）。

## 3.3 业务人员可用的提示词杠杆：效应量与失效模式

把上面的证据按"业务人员能动的旋钮"整理：

| 杠杆 | 预期效应 | 已知效应量 | 失效模式 | 证据 |
|---|---|---|---|---|
| **选项名字** | 最强的杠杆 | 名字-定义重分配使 AUC 93.8%→23.2%；误导性名字让守卫 fail-open 率到 93–100% | 名字有极性（yes/no、allow/deny、安全/不安全）时压倒一切；名字与定义不一致时模型跟名字 | 2609.26758、2610.12292 |
| **定义 / 判据** | 本应是写规则的地方 | 删除不变、矛盾时 0.85→0.23；只写定义 +0.15 | 被名字遮蔽；改变 28% 预测而无改善；渲染方式决定是否被读 | 2610.02586、2610.03324 |
| **示例（state 内或选项内）** | 示范格式、暴露标签空间、拉近分布 | JevKT +0.016 AUC；先例对 Jev 有益 | 同质示例坍塌；小模型不能翻转语义；示例变长撞上"无关 state"退化；示例顺序可被攻击 | 2610.11135、2605.08295、2511.21038 |

| 杠杆 | 预期效应 | 已知效应量 | 失效模式 | 证据 |
|---|---|---|---|---|
| **措辞 / 改写** | 不应有影响 | 等价改写有相反效应；宿主模型措辞敏感 | 这是方差来源而非杠杆；需多措辞取中位数 | 2610.30045、2610.11392 |
| **候选集（菜单）设计** | 一阶变量 | 150 类→精选 5 候选：69.0%→95.4%，跨度大于 0.8B 与 4B 之差 | 候选相似、候选多（50 个最近邻工具时 Laya 31%）、缺少"其他"选项时拒绝失败 | 2610.07716、2610.02267 |
| **问题分解（一个大问题拆成多个 Noul）** | 可审计、可组合 | 分解只在 20% 的比较中显著有效；但分解后的逐选项二元得分归一化在医学上比 Choice 打分更准 | 分解引入概率不一致（见 D4 层级一致性） | 2610.03324、2610.18529 |
| **State 结构（JSON vs 文本、过滤）** | 减少无关信息 | 官方建议过滤；宿主模型 30k 内平坦 | 解码器随长度变慢；无关细节退化 | docs/state、2610.11392 |
| **语言** | 不应有影响 | 印尼地方语言用人工印尼语翻译 +37.2 点；孟加拉语字面锁定比英语高 1.9–6.4 倍 | 低资源语言下 ICL 杠杆全部变弱 | 2610.14112、2610.22526 |
| **把规则写进 state 而不是定义** | 绕开名字遮蔽 | Archer 探针：声明放 state 比放兄弟问题概率上升 | 无直接对照实验 | Archer Hume |

## 3.4 ICL 的替代与补充（不是我们的主线，但要知道）

- **把上下文变成权重**：Text-to-LoRA、Doc-to-LoRA、Internalizer、Cartridges、LatentSkill 都是"超网络 / 自学习把文档或技能压成 LoRA / KV"，LatentSkill 在 ALFWorld 上比上下文技能 +21.4 成功率（2606.06087、2602.15902、2610.11715、2506.06266）。这类方法把"业务人员写文字"保留在前端，但模型侧不再是 ICL。
- **任务算子**：每个注意力头的输出是其上下文屏蔽版本的仿射变换，可用输入相关的算子替代示例（2610.01054）。
- **元学习逻辑**：1.5B–7B 小模型用少样本元学习学三段论，低数据下超过 GPT-4o / o3-mini（2505.14313）；MetaICL（2110.15943）。这是"训练模型学会从示例学"的路线，与决策微调的关系未被研究。
- **分层示范胜过平铺日志**：模糊描述的任务上分组示范把通过率 76.7%→90.7%，精确描述时无收益；只有子目标分组起作用（2606.20978）。对"业务人员提供流程示例"直接相关。

## 3.5 哪些工作解决了哪类问题（D1 小矩阵）

| 问题 | 已有工作 | 状态 |
|---|---|---|
| 定义是否被读 | 2609.26758、2610.02586（含诊断测试） | **已量化**，原因定位在渲染与名字极性 |
| 示例是否有效 | JevKT、先例检索、Nimble 训练时对比 | 间接证据，**无 k-shot 曲线** |
| 措辞敏感度 | TypedBench、Rule transfer | 已量化，无缓解 |
| 定义/提示的优化 | Goldsmith、CALICO、Jev-LDE | 有工具，面向生成式 LLM 或外部编辑器 |
| 小模型的 ICL 上限 | Semantic anchors、In-context fixation、Schema/Binding | 上游 LM 结论清楚，**未在决策微调模型上复验** |
| ICL 对校准的影响 | CALIBFORMER、Surprise calibration | 上游 LM，决策模型未测 |
| 菜单 / 候选集设计 | JevCascade、Fast Models Slow Evidence | 已量化，是最强杠杆 |

## 3.6 D1 盲区（我们识别、现有工作未覆盖）

1. **决策微调是否保留 ICL**：无任何论文对比同一骨干微调前后的 k-shot 曲线、标签翻转能力、定义遵循率。Spectrum Tuning 提示后训练会降低上下文可引导性，但没在决策模型上测。
2. **"定义被名字遮蔽"的训练侧解法**：Symbol tuning 的思路（用无意义符号作标签迫使读定义）在决策模型上没有人试过；2610.02586 只给了渲染层面的修补。
3. **示例放在哪**：state 里、选项的 `examples` 里、还是 Noul 的 true/false 判据里——三种位置的效应没有对照。Archer 的探针只说明"state 可见、兄弟问题不可见"。
4. **示例 × 分支隔离的交互**：示例若放 state 会被所有问题共享并增加所有分支的成本；放问题分支里则每个问题各带一份。没有人测这两种布局的准确率/成本权衡。
5. **ICL 与校准**：ICL 引入的示例选择偏置会破坏校准（上游证据），而决策模型的核心卖点是校准；两者的交互无人测。
6. **业务人员视角的"提示词可用性"**：CALICO 面向生成式 LLM；没有面向决策模型的"非技术人员写判据 → 模型遵循率"的可用性研究。
7. **多措辞取中位数 / 批校准**是否能移植到单遍决策接口（它天然支持扇出，成本低），没有人做。

这些盲区在 10 章 转化为可度量的问题定义。

# 04 • D2 符号化指令遵循：规则、否定、算术/时间、兜底、层级与对抗下的决策一致性

> 口径：模型拿到一条**符号化**的指令（规则、阈值、条件、层级、兜底规则），能否在单遍前向中忠实执行。与 D1 的区别：D1 关心"示例 / 定义是否被利用"，D2 关心"给定被读懂的规则，决策是否按规则产生"。与 D3 的区别：D3 关心"怎样写规则才能被执行"。

## 4.1 上游基线：生成式 LLM 的规则遵循

| 事实 | 出处 |
|---|---|
| RuLES：14 个简单文本场景中，LLM 遵循"不要做 X"类规则的能力可被越狱绕过，需要程序化评测 | 2311.04235 |
| RuleArena：航空行李费、NBA 交易、税法三领域的真实规则需要长上下文、逻辑推理与精确算术，超出一阶逻辑 | 2412.08972 |
| **扩展规则遵循失败**：126 个领先模型变体都不能在一个模型相关、语法敏感的计数容量阈值之上准确计数；失败是突然的，且随规模、推理时间增加而持续 | 2605.02028 |
| 可验证指令遵循过拟合于一小组约束，对未见约束泛化差（IFBench）；RLVR 会奖励黑客（约束满足上升、回答质量下降，CALIF 修正） | 2507.02833、2610.19525 |
| WISE：同一操作要求换个措辞，合规率大幅变化；五种"避免/排除"表述低于正向基线 | 2610.05278 |
| 指令层级：非对抗的良性冲突也常见；失败可分解为"识别相关指令 / 解决冲突 / 推理对了但输出违规"三类 | 2604.09075、2606.07808 |
| **静默范围遗漏（SSO）**：模型应用一般规则但悄悄丢掉嵌套的例外与反例外；NormBench 2,290 条中英法规条款 | 2606.08932 |
| 小模型的**约束税**：<3B 模型在结构化输出约束下答案与可执行准确率下降；约束解码消除结构错误但暴露规模相关的语义缺口 | 2605.26128、2609.23742 |
| 状态跟踪需要"当下写出的推理"：锁状态任务上，大部分违规减少来自动作时刻的推理，保留早期推理贡献小，填充文本或准确的状态表都不能替代 | 2610.25760 |

**含义**：生成式 LLM 能靠写出中间步骤弥补一部分规则执行；单遍决策模型没有这条路，所以 D2 的失效会更"硬"。

## 4.2 决策模型上的证据：按失效类型分组

### 4.2.1 读得对、做得错（组合失效）

**Reading Right, Acting Wrong**（2610.18579）是 D2 的核心诊断：

- 六个最准的系统上，**73%–85% 的决策错误发生在"每个被测事实都答对"的状态上**，且这个份额随准确率升高而增大。
- 14 个"有能力的"快系统在**同样的 141 个状态**上全部出错（随机预期为 0）。
- 在"探针足以决定动作"的生成状态上，能读对所有事实、也能从事实完美决策的模型，**一旦要从轨迹同时做两件事就掉 20–45 点**；用它们自己的事实答案能恢复 15–28 点；**在代码里由事实组合出动作可达 0.96–1.00**。
- 真实状态上"决策本身常常缺失"：ALFWorld 上"说出下一个子目标"给 JEV +16 点，任何事实块最多 +5。
- 删掉历史会在"早期观测重要"的地方让准确率坍塌；**策略修改被正确读出但只在 22%–72% 的情况下被执行**；校准误差 2.6%–26.6%。
- 解码器快系统延迟 27–225 ms，开源 LM 的似然读出 317–947 ms，推理模型 2.3 s。

**结论**：单遍模型的瓶颈是"事实 → 动作"的**组合**，而不是"读"。这直接支持 TypeSafe 自己的设计原则（"把独立问题一起问，在代码里组合"）和 D3 的方向（原语 + 代码组合）。

### 4.2.2 算术、时间与否定

| 证据 | 数字 | 出处 |
|---|---|---|
| 官方锯齿：不可靠计数、把日期当文本读 | — | jaggedness |
| MathQA 比前沿中位数低 17.7 点，低于全部 19 个 LLM | — | 2610.11978 |
| 医学上数值驱动任务明显弱于文本驱动任务 | — | 2610.18529 |
| DecisionPivot：Perplexity Decider 在 2,400 个二元对照对上 **92.3% 的对里把更高的 yes 概率给了正例，却只有 74.1% 的对两边都分类正确**；难度 1→3 配对准确率 87.7%→57.4%（Instant 90.7%→65.3%）；"算术与时间对照暴露大的性能缺口"；API 聊天模型在 63–93% 的情况下 top 概率 ⩾0.99 | **排序对、分类错**是算术/时间类的典型形态 | 2610.28522 |
| Kev 的日期事实补充（代码算好天数写进 state）把截止期策略题 0.80→0.90 | "把算术交给代码"的直接实证 | jaredpalmer/kev |

| 证据 | 数字 | 出处 |
|---|---|---|
| 否定互补性：Jev 对 P(A)+P(¬A)=1 的平均绝对违反 0.064，Qwen3.8-27B 首 token 读出 0.293、口头读出 0.122；Jev 19.0% 的对偏差 >0.1，违反量是其重复噪声下限的 ~5 倍；**单标签陈述平均概率 0.380，而一致性要求 1/3** | 否定不是免费的 | 2609.33209 |
| TypedBench 有专门的否定套件（Suite G）与严重度阶梯套件（F） | — | 2610.11392 |
| NumericJev：用多叉决策树递归细化数值范围，100 值网格 10 叉树只需两轮；比"直接从含正确答案的候选列表里选"高 2.93 pp；范围归一化 MAE 1.84% 对直接选择 5.18% | 数值输出可以用"范围选择"原语在代码里搭出来 | 2609.28587 |
| Choice2Seq：Jev 在算术 / 词汇检索上选择准确率 97.1% / 99.5%，但**串行构造只保留 33.0% / 2.1%**；限制局部选项为候选支持的字符、显式位置索引可改善 | "选对答案"与"一步步构造答案"是两种能力 | 2610.16191 |
| 同数字引用交换：金融报表里数值相同但角色不同的单元格，Jev 作为证据验证器会放过错角色引用、也会拒绝有效的替代引用；显式列标签有帮助 | 数值匹配 ≠ 角色识别 | 2610.08675 |
| 对无关数值信息敏感 | — | 2610.19619 |

### 4.2.3 拒绝、兜底与"正确答案缺席"

| 证据 | 数字 | 出处 |
|---|---|---|
| **算术相关的拒绝瓶颈**：答案在场准确率 99%，正确拒绝只有 7%；跨数值大小、运算深度、语境、拒绝标签都存在；**原生 Boolean 验证在同样的答案缺席算术题上 99% 精确匹配**，说明"能验证却不能拒绝"；用单独开发集选一个阈值把拒绝率 7%→79%，保留 97% 的答案在场准确率，不需重训 | 拒绝是读出层/阈值问题，不是能力问题 | 2609.39496 |
| **Lost in the Fallback**：非对抗条件下，兜底规则本身让模型失败：TREC50 上 Intern 从常规分配 97.9% 跌到兜底分配 23.1%，即使显式给出正确类别也持续；**逻辑等价的兜底规则表述导致个体决策大幅分歧而总体准确率几乎不变** | 兜底规则是一种"符号化指令"，被读懂但不被执行 | 2610.19856 |
| 拒绝策略迁移：在 DBpedia 上校准的 Jev 策略在 Emotion 上拒绝 69.3% 的覆盖输入，反向策略完全失去检测；10 个意图候选时 Laya 检出 99.0% 的域外查询但拒绝 48.8% 的覆盖查询 | 拒绝阈值不跨任务迁移 | 2610.03387 |
| 法律：正确判例缺席时生成式 LLM 仍在 38–86% 的条目上选一个，最谨慎的决策模型 30%；CaseHOLD 上决策模型 88.1% 对最佳 LLM 88.2%，成本 1/55 | 决策模型的弃权**相对**更好但远非可靠 | 2610.29961 |
| 医学：大多数模型不能识别正确答案缺失也不会用可选弃权 | — | 2610.18529 |
| 记忆退休门：Jev 在 141 个同会话非变化上从不误退休，但**过早退休**：二元门在 39.2% "仅被暗示"的变化上退休；三路决策降到 15.5% 但付出 15.3 点检测代价；级联与简单抬高阈值无法区分 | 二元门对"已确立 vs 仅暗示"的区分需要第三个选项 | 2610.15710 |
| 自知之明：无答案相关信息时 Jev 仍给显著选项最多 0.80；知识边界外新闻上置信超出准确率 0.21–0.33，重校准不能修复；但**针对性的 yes/no 问题**对"结果是否已定"AUROC 1.00、"证据是否充分" 0.95（置信度本身 0.85） | "问一个关于证据的问题"比"看置信度"更可靠 | 2610.01006 |

### 4.2.4 指令层级与对抗上下文

| 证据 | 数字 | 出处 |
|---|---|---|
| 决策劫持（InjecAgent 510 例）：恶意内容移动动作概率但很少让 Jev 选攻击者目标；覆盖标记减少影响；自适应攻击把新验证调用的成功率从 1.8% 升到 3.5%，与小的初始决策边际相关 | 直接注入对 Jev 影响有限 | 2609.28613 |
| **JevOut**：64 次目标评估内，短的"背景/程序性"上下文添加把 61.4%–73.2% 的初始正确决策导向预定错误选项；91.6% 被人判为自然且不含决定性证据；影响高置信决策，跨模型迁移 | **自然上下文**比直接注入危险得多 | 2609.30243 |
| **JevAdvBench**：862 题、12 种黑盒攻击，翻转 46.3% 的 Jev 正确决策（重跑只翻 0.17%）；**不含命令的有缺陷论证翻转 77.2%**，接近直接注入 92.0%；八个开源 TDM 34.0%–51.7%；0.8 阈值下仍执行的决策中 23.5% 是错的 | 阈值不能挡攻击 | 2609.31142 |
| **选项通道攻击**：七个开源模型做守卫，allow/block 准确率 36%–72%（随机 50%）；六行与策略无关的服务器日志把 fail-open 率从 0% 提到 63%；**给宽松选项起误导性名字（定义与被判文本不变）让四个把标签放进输入的模型 fail-open 93%–100%**；所有防御被击败；被攻击翻转的决策并不比原决策更不自信 | 选项名字是攻击面（与 D1 "名字压倒定义"同源） | 2610.12292 |
| JevProbe：228 个真实 Jev 应用 2,273 测试，**81.5% 出现决策翻转**，其中 98.6% 导致潜在下游安全影响 | 应用层可达性 | 2610.18612 |
| DICE：三个适配器输出（state 抽取、问题生成、输出解释）的有界替换都能改变最终决策，而 Jev 与 API 响应本身不在攻击者控制下 | 接口边界是攻击面 | 2610.14404 |
| Poisoned into Action：执行感知协议，1,659 次 Jev-1.13 调用，自然检索下独立载荷在全部 60 次试验中到达 | 中毒证据经检索到达动作 | 2610.15537 |
| 同一攻击不同裁判：50 种攻击变体 13 族，对 Jev、5 个 GPT/GLM 裁判、Llama Guard 3、Prompt Guard 2 的首次受控比较 | — | 2610.17820 |
| **TrustJev**：受保护的策略打分 + 有界的证据修正（修正预算由可信策略与候选计算），0.6B 实现在三个数据集（认证、指令层级、可执行授权规则）上对 14 个基线取得最高 Balance，授权基准上 95.77% 的来源答对全部 32 种攻击（最强对比 80.98%） | **架构上分离"策略权威"与"不可信证据"**是目前唯一的结构性防御 | 2610.34826 |
| 提示注入检测的校准与延后：LLM 裁判 AUROC 0.897，Jev 0.871，Prompt Guard 2 86M 0.757；在分布偏移下 allow/block/defer 策略需单独校准 | — | 2610.20907 |
| 安全决策：高总体准确率与低平均校准误差可以掩盖"特定攻击组内高置信误判为安全"；严格漏检限制下自动放行很少，分开选 allow/block 阈值主要通过更多 block 增加自动化 | 要按攻击组报告 | 2609.33401 |

### 4.2.5 规则迁移与措辞

- "Which Differences Matter"（2610.30045）用**可执行算术规则**把"规则迁移、联合可靠性、信息使用"分开测：适配增益随最近源答案一致性增加；完全冲突的四元组增益小且在不同源分割间符号相反；**等价改写有相反的任务级效应**；外部表格带来的提升不能证明模型用了表格的值与映射。
- Certo（2609.37832）：Qwen3-4B 联合打分器（state + 规则 + 候选一起读）规则敏感性 recall@1 1.00；改成可缓存的独立编码（候选编码一次复用，77 候选时约 5 倍便宜）**规则敏感性显著丢失**（摘要写 1.00 → 0.24，全文该处数字被遮蔽，以摘要为准），shortlist+rerank 救不回来；针对性反事实监督在保留的合成规则任务上恢复，但作者**未隔离"预测是否依赖所给规则"**。
- 表格：决策模型在行分类/事实核验/异常检测上与 LLM 相当且更便宜，三个对问题表述更稳健，**但没有模型对表格组织方式稳健**，每个模型至少三分之一的行决策随格式变化（2610.19536）。
- 图任务：准确的邻接识别不保证更广的结构正确性（2610.06354）。

### 4.2.6 决策模型作规则裁判

- 九个面板七个基准上，Jev 与 Decider 在 27 次比较中最多 6 次显著落后于 flash 级 LLM 裁判，而后者贵 16–357 倍、慢 5–350 倍；**错在同样的地方**（2609.29769）。
- Agent 轨迹安全：JEV 基准平均正类 F1 77.8 对最强生成式 74.1（2609.34862）。
- CALM 偏置测试：八个 TDM 全部在 12 项中的 3–8 项有偏置；**情绪化语气把典型 TDM 准确率从 99% 拉到 42%**；全部八个在答案交换位置时改变裁决（2026 年 LLM 裁判几乎不变）；好的校准不防偏置（2610.18122）。
- 首 token 读出会**高估**位置偏置：三个 Qwen3 裁判在 12%–49% 的对上不以裁决 token 开头，强制读出返回"先出现的那个"（2610.00054）。这对"用 logits 读出"的复现是个提醒。

## 4.3 哪些工作解决了哪类问题（D2 小矩阵）

| 问题类 | 诊断工作 | 缓解工作 | 状态 |
|---|---|---|---|
| 事实→动作组合 | Reading Right | 代码组合（同篇） | **诊断清楚，解法在接口而非模型** |
| 算术 / 时间 | 官方锯齿、DecisionPivot、MathQA、Choice2Seq | Kev 日期事实、NumericJev 范围树、"算术放代码" | 解法是工程约定，无模型侧突破 |
| 否定 / 互补性 | 2609.33209、TypedBench G | — | 无缓解 |
| 拒绝 / 兜底 | 2609.39496、Lost in the Fallback、2610.03387、法律/医学/记忆门 | 开发集阈值（7%→79%）、三路决策、针对证据的 yes/no 问题 | 阈值级缓解；**兜底语义不被执行**无解 |
| 自然上下文攻击 | JevOut、JevAdvBench、选项通道、JevProbe、DICE、Poisoned | TrustJev（结构性）、覆盖标记（弱）、按攻击组报告 | 只有 TrustJev 是模型侧结构解 |
| 规则迁移 / 措辞 | 2610.30045、Certo、表格、WISE | 反事实监督（Certo，未隔离） | 无通用解 |
| 裁判偏置 | 2610.18122、2610.00054 | 测试再用 | 无缓解 |
| 层级 / 例外 | NSHA、白盒诊断、NormBench（生成式） | — | **决策模型上零研究** |

## 4.4 D2 盲区

1. **兜底 / 例外 / 层级这三种"元规则"在单遍模型上的执行率**：Lost in the Fallback 只测了兜底；"嵌套例外被静默丢弃"（SSO）和"多来源指令冲突"在决策模型上没有基准。
2. **"读得对、做得错"的训练侧解法**：Reading Right 的解法是代码组合；没有人尝试训练模型在单遍里做组合（也许本来就不该），也没有人量化"哪些组合能学会、哪些必须交给代码"的边界。
3. **否定与互补性的训练目标**：2609.33209 给出了度量，没有工作把 P(A)+P(¬A)=1 当作训练约束。
4. **拒绝的通用阈值**：2609.39496 的阈值是任务特定的；2610.03387 证明不迁移。"候选集覆盖率估计"作为一个独立问题没有被定义。
5. **自然上下文攻击的防御评测口径**：JevAdvBench 与选项通道攻击证明"置信度不变"，TrustJev 只在三个数据集上；没有在 JevOut / JevAdvBench 上评 TrustJev 的结果。
6. **规则的"可执行性分级"**：哪些规则是单遍可做（查找、匹配、单跳比较），哪些不可（计数、两次以上状态更新、算术），只有 2610.24929 给了一个"参考 LLM 需要多少思考 token"的代理指标（Jev 答对 97.5% 的一遍可解条目，其余只有 74%）。

# 05 • D3 模板化 / 技能化：让业务专家用文字写规则，模型忠实执行

> 口径（按最新讨论）：定义一组**逻辑原语**，让非技术的业务专家通过**文字撰写**让模型理解业务规则——就像 Skill 用文字让模型理解工作能力一样。本章梳理：(1) Skill 范式本身的证据；(2) "自然语言规则 → 可执行结构"的编译类工作；(3) 决策模型上已有的原语与组合模式；(4) "策略即提示"类守卫的经验；(5) 盲区。

## 5.1 Skill 范式：文字能教会模型"工作能力"到什么程度

| 事实 | 出处 |
|---|---|
| Agent Skills 规范：`SKILL.md` = YAML 前言（`name` ≤64 字符、`description` ≤1024 字符）+ 任意 Markdown 正文；可选 `scripts/`、`references/`、`assets/`；**渐进披露**：启动时只载入约 100 token 的元数据，激活时载入 <5000 token 的正文 | agentskills.io/specification |
| SkillsBench：87 任务 8 领域 18 个模型-harness 配置，精选 Skill 把平均通过率 33.9%→50.5%（+16.6 pp），配置级 +4.1 到 +25.7；**≤3 模块的聚焦 Skill 优于大而全**；带 Skill 的小模型可匹敌无 Skill 的大模型 | 2602.12670 |
| 138,133 个公开 SKILL.md：**91.8% 至少有一个缺陷**（88.8–94.6%）；主要是弱路由元数据、臃肿或不可执行的正文、资源组织差；有效路由元数据的 Skill 更可靠地被检索 | 2608.08453 |
| SkillJuror：渐进披露在总体结果之前先改变运行时行为 | 2606.11543 |
| Skill coverage：任务结果不显示 Skill 的哪些部分被执行、是否按指令执行，需要轨迹级覆盖度量 | 2606.20659 |
| SkillSentry：即使 Agent 在 Skill 指导下完成过任务，也可能因偏离程序或步骤执行错误而不稳定；用 DSL 表示运行时断言做保证 | 2608.09253 |
| AFTER：382 个企业任务 6 角色 22 程序技能，一轮精炼 +3.7–6.7 点；跨任务/角色/模型迁移受控评估 | 2606.23127 |
| **Auto-Policy, not Auto-Skill**："Skill 描述 Agent 应如何行为；Policy 决定哪种行为**被允许**成为动作"；现有格式只覆盖前者，后者留给模型；自动生成更多 Skill 放大的是差距而非安全 | 2608.25091 |
| LatentSkill：把文本技能通过超网络压成 LoRA，ALFWorld +21.4 成功率、prefill token 大减 | 2606.06087 |
| 决策模型筛恶意 Skill：SkillScreen 从 SKILL.md 单遍打分，99% 召回下只标 20–25% 的良性 Skill | 2610.17727 |

**对 D3 的含义**：Skill 证明了"文字能教会生成式 Agent 做事"，但它的可靠性来自**模型在执行时能推理**；而且它只覆盖"怎么做"，不覆盖"什么被允许"。我们要的"业务规则语言"更接近 Policy 而非 Skill，而执行者是**单遍不推理**的决策模型——这两个差异决定了不能直接照搬 Skill。

## 5.2 自然语言规则 → 可执行结构：编译类工作

这些工作都在回答"业务专家写的文字，怎样变成机器能忠实执行的东西"。它们面向生成式 LLM，但其**中间表示**正是我们设计逻辑原语的候选。

| 工作 | 输入 → 中间表示 | 关键结果 | 出处 |
|---|---|---|---|
| **Artic** | 自然语言工作流 → 制品驱动工作流（每步声明读/写的制品，约束门控制品，显式控制转移）；编译器识别依赖过多状态或控制逻辑困难的步骤并优化 | 11 个真实领域 488 实例，任务解决率 +28 pp；跨模型与重复执行一致性 +32 / +56 pp | 2608.21341 |
| **FlashScript** | 成功的 Agent 运行 → 神经符号程序（动作与数据变换成代码，实例值成参数，**需要模型判断的决策成 LLM 调用**）；三层放置 + 三种用代码替代大部分调用的技术 | 120 个 WorkBench 任务：NSP 每次运行工具调用完全一致，输入 token 少约 70 倍、运行时间 1/3；复合任务上 Skill 引导的 Agent 跌到 23%，NSP 保持正确；108 个未见实例全部泛化 | 2610.33876 |
| **TraceCompiler** | 噪声 Agent 轨迹簇 → 大部分确定性的工作流；只有当消费者参数含有唯一可归因于早先生产者的值时才承认依赖，每条硬边带可审计证据 | — | 2608.02680 |
| **Formal Skill** | Markdown 技能 → JSON 元数据 + 动作 schema + Python 执行器 + hook 控制逻辑 + 技能局部状态；"可执行状态机 + hook 策略" | Harness-Bench 上竞争性得分且 token 大减 | 2605.19604 |
| **P2T（Executable Governance）** | 政策文档 → 规范化机器可读规则；紧凑 DSL 编码**危害、范围、条件、例外、所需证据** | — | 2512.04408 |
| **SIRNA** | 业务规则文档 → SMT 公式（LLM 翻译 + 验证），与实现的 SMT 表示做一致性检查；税务成本计算案例 | — | 2608.00396 |
| **Cedar 自动形式化** | Agent 提示 / MCP 工具描述 / 政策文档 → Cedar 策略语言（生成-批评循环） | MedAgentBench | 2606.26649 |

| 工作 | 输入 → 中间表示 | 关键结果 | 出处 |
|---|---|---|---|
| **ARc（Automated Reasoning checks）** | 自然语言政策 → 形式化（可人工引导），推理时自动形式化验证陈述 | 面向金融/医疗等受监管行业的公共服务 | 2511.09008 |
| **Logic Sketch Prompting** | 提示里引入类型化变量、确定性条件求值器、基于规则的验证器 | 两个药理合规任务上三个开源模型全部最高且可重复 | 2512.22258 |
| **NormBench / Deontic trees** | 法条 → 跨度锚定的道义树（一般规则、嵌套例外、反例外） | 诊断"静默范围遗漏" | 2606.08932 |
| **业务规则恢复为级联查找** | 历史交易 → 知识图引导的候选业务键（列组合）→ 级联查找表，而非不透明的统计模式 | 销售订单字段（付款条款、发货点、销售归属） | 2610.34258 |
| **AgenTest** | 系统提示 / 工具定义 / 领域知识 → 挖掘出的业务规则 → 测试 Agent 的业务逻辑缺陷 | 规则"分散在系统提示与工具定义里，或隐含在领域知识中" | 2610.28116 |
| **Typed action contracts** | 模型只解释意图、提出动作；类型化动作契约、权限感知能力暴露、作用域上下文、副作用前验证、消费者侧执行边界 | 企业 AI 的"有界自治" | 2604.14723 |
| **Bellman LMs** | 有界 Agent 工作流中的决策空间趋于饱和 → "离散化，然后决策"：把决策当优化问题解一次并复用 | 更快、更便宜、更可靠 | 2610.24871 |
| **LLM 作为接口而非神谕** | LLM 只做 schema 约束的特征抽取 + 确定性合理性检查，最终决策交给结构化 ML | 儿科阑尾炎 | 2606.19183 |

**共同的中间表示元素**（出现两次以上）：步骤的**读/写制品**；**条件 / 例外 / 反例外**的层级；**需要证据**的声明；**需要模型判断的点**被显式隔离成"调用"；**确定性求值器**负责算术/比较；**类型化变量**。这是我们定义逻辑原语的最小集合候选。

## 5.3 决策模型上已有的原语与组合模式

### 5.3.1 官方原语与模式（细节见 01 章）

- 三种问题原语：Noul（P(true)）、Choice（≤255 选项分布）、Score（≤10 级有序分布）；都接受 JSON 结构化的 `instructions` / `criteria` / `examples`。
- 五种组合模式：扇出、复合打分、置信路由（全局下限 + 每动作阈值）、逐层走分类树、"把常量放一个文件里便于审查"。
- 两个 cookbook 直接示范了"业务规则 → Noul 列表"：**自洽性 cookbook** 把一份车险理赔用 14 个 Noul 问题的评分细则跑 15 遍检查每个答案是否稳定（consistency_noul_cookbook）；**autoresearch cookbook** 用 29 个 Score + 9 个 Noul 把自由文本变成 67 列数值特征喂给 CatBoost（autoresearch_feature_discovery）。
- 官方评测页的示例规则就是业务规则的样子："每条报销都要有收据；读不出就让员工重交"、"超过 75 美元的餐费在描述与收据不符时需要经理签字"（evals.typesafe.ai）。

### 5.3.2 第三方的原语 / 组合结构

| 工作 | 原语 / 结构 | 关键结果 | 出处 |
|---|---|---|---|
| **SemTree** | 规则决策 = 语义决策树：每个节点是一个带显式 **Yes/No/Unknown 判据**的自然语言问题，由可插拔的语义裁判回答；分支结构**按该裁判实际给出的答案编译**；执行路径即推理，错误在发生的节点修复；修正的节点成为裁判的训练标签；工具使用的 LLM 编辑器在观察执行结果下修订问题与子树 | ShARC 8,276 例：宿主裁判执行的树 67.70%（2.99 问/例）与直接问最终标签 68.23% 持平；为另一裁判编译的树换裁判只有 47.87%，在新裁判答案上重编译的树 64.39%；节点修复把 BANKING77 82.04%→86.16%；一个显式豁免节点把中文电商审核条款误报 24→5；训练的编辑器把开发准确率 64.47%→73.35% | 2610.13999 |
| **概率感知、确定性裁决** | 模型输出只作为**带分数的观测记录**；准入策略在声明的误报上限下把分数映射到 true / false / **unknown**；unknown 即拒绝；确定性、充分性检查过的契约做裁决；感知改变裁决的概率有**并集界**（各感知字段的误准入率 + unknown 率之和）；最小化估计的界是选择契约的有效成本模型 | 2 领域 2 传感器族 36,000 次调用，无一单元反驳该界；21,000 个测试裁决中 13 个"拒→允"翻转全部来自 3 条矛盾记录 | 2610.10978 |
| **临床医生主导的可检查规则** | 两位临床医生定义、定稿、裁定 4 条安全检查的规则库，形式化验证内部一致性，作为 LLM 输出的守卫；**每个裁决可从一条命名规则与 16 个事实重算** | 与匹配的 Llama-3.3-70B 裁判的最大分歧类是结构化的 | 2610.30690 |
| **Jev-Guard** | 可编辑的**策略树**：先按调用方审计上下文在树上路由到适用策略，再在检索到的策略条件下做安全分类 | 7,033 例 93.72% 安全准确率、58 ms；层级路由 93.10%；全流水线 240 ms | 2610.18326 |
| **JEVDB** | SQL 扩展：语义过滤、连接、分类、排序交给决策模型，不确定的升级到生成式 LLM；**语义布隆过滤器用"注册的必要条件"筛候选**；Yannakakis 半连接约简 | SemBench 21 查询全部最低延迟、19 个最低成本；Shelob 540K 候选对 | 2610.02046 |

| 工作 | 原语 / 结构 | 关键结果 | 出处 |
|---|---|---|---|
| **语义查询的成本-准确率优化** | 从每个决策的校准置信得到期望错误，按其对输出的贡献（扇出）加权得到期望输出错误；查询计划同时影响成本与结果 | 形式化问题定义 | 2610.08089 |
| **Code Owns the Simulation, Jev Owns the Evaluation** | 清晰的边界：**能从输入描述中判断**的（评估）Jev 可做（CRT 99%）；**依赖预测输入之外的东西**的（模拟）Jev 做不了 | 反思测试、一次性矩阵博弈、ALFWorld、机器人控制 | 2610.01834 |
| **NIOCIS** | 执行日志 → 循环坍缩的动作图（前向转移 + 恢复回边）；在每个状态问一个类型化问题"下一跳选哪个声明的选项 + stop"；**节点条件化的选项空间** | 1,615 个生产安全运营回合 | 2610.25985 |
| **SharedKV-BT** | 行为树每个活动节点暴露阶段局部的字段与候选，共享 KV 并行打分，选定的决策交给单独的执行系统 | 机器人操作 | 2610.07327 |
| **NumericJev** | "范围选择"原语：多叉决策树递归细化数值 | 见 D2 | 2609.28587 |
| **JevForest** | 预算内特征获取：自举树的路径投票决定下一个问 Jev 的问题 | AG News 四问 0.729 对静态排序 0.667、随机 0.583 | 2610.10615 |
| **LAVOIR** | 把"缺失信息槽位"放在选项旁边，一次前向同时返回决策分布与每个槽位的**信息价值** | 已见 schema 上与 Bayes 上限统计不可区分（编码器系，对照引用） | 2609.30706 |
| **Reading Right** | 事实探针 + 代码组合 | 代码组合 0.96–1.00（见 D2） | 2610.18579 |

### 5.3.3 评分细则 / 清单类原语（上游）

- TICK：LLM 生成的指令特定清单让评测可解释（2410.03608）；Rubrics as Rewards 把实例特定评分细则当 RL 奖励（2507.17746）；ReVeR 从指令本身推导**硬规则与分级原则**，逐点、工具增强地评判（2610.18766）；评分细则裁决缺少不确定性，需要按判据加权（2610.21214）；决策模型作评分细则裁判"便宜、快、错在同样的地方"（2609.29769）。

## 5.4 "策略即提示"守卫：业务规则文本直接喂模型的经验

| 工作 | 结论 | 出处 |
|---|---|---|
| gpt-oss-safeguard（120b / 20b） | 开放权重**推理**模型，同时读取开发者策略与内容，输出结论与推理；"推理帮助模型泛化到新写的策略"；传统分类器快但改策略要重训 | OpenAI |
| DynaGuard | 用户定义策略的动态守卫，带可选 CoT | 2509.02563 |
| **SafePyramid** | 1,000 对话 3,000 策略 61,699 条自然语言规则，三级：L0 单规则、L1 规则依赖、L2 上下文定义的全新策略框架；**最好的 GPT-5.5 精确识别全部违规规则的比例只有 54.0% / 35.3% / 12.9%** | 2606.29887 |
| **LPG** | 把策略落地的内部审议压缩成 10 个潜在 token，4B 达 84.5% 安全准确率，比 Qwen3-4B-Thinking 快约 11 倍 | 2605.17329 |
| Policy-as-Prompt（社区治理） | 把审核规则交给 ChatGPT 不够；需考虑对社区治理的影响 | 2607.12149、2502.18695 |
| PolicyGuard | DLP 分类判据完全由**非工程人员可编辑的纯文本策略文件**定义 | 2608.02687 |
| BARRED / PAM | 只用任务描述 + 少量未标注样本合成训练数据训练自定义策略分类器 | 2604.25203、2505.19766 |
| 文本脱敏 | 自然语言脱敏规则 + 指令微调，输出可审计的理由 | 2608.14693 |
| 多轮约束跟踪 | StateWise：模型维护自己的可修订约束状态（带墓碑），以可执行检查器测量持续性失败与复发 | 2610.33766 |
| Jev 在审核 | 受益于检索先例；定义改变预测但不稳定提升（见 D1） | 2610.07953、2610.03324 |

**含义**：即使最强的推理模型，在"规则依赖"（L1）与"新策略框架"（L2）上的精确执行率也只有 35% / 13%。单遍模型要做到可靠，规则必须被**分解**到单规则（L0）粒度，依赖与组合交给代码——这正是 SemTree 与"概率感知、确定性裁决"的结构。

## 5.5 哪些工作解决了哪类问题（D3 小矩阵）

| 问题 | 已有工作 | 状态 |
|---|---|---|
| 文字能否教会模型做事 | SkillsBench、AFTER | 对生成式 Agent 已证明；对单遍模型**无** |
| 规则文本 → 中间表示 | Artic、P2T、SIRNA、Cedar、ARc、LSP、Deontic trees | 有多种 IR，面向生成式 LLM / 形式验证 |
| 判断点与确定性逻辑的分离 | FlashScript、TraceCompiler、Formal Skill、LLM-as-interface、Reading Right | **共识**："决策成调用，其余成代码" |

| 问题 | 已有工作 | 状态 |
| --- | --- | --- |
| 单遍模型上的树 / 契约 | SemTree、概率感知确定性裁决、Jev-Guard、JEVDB、NIOCIS、SharedKV-BT | 有雏形；SemTree 的"按裁判答案编译"与 Unknown 节点最接近我们的需求 |
| 非技术人员的编辑界面 | CALICO、Goldsmith、PolicyGuard、SemTree 的节点修复 | 有，但只有 SemTree 面向决策裁判 |
| 策略文本的直接执行上限 | SafePyramid | 清楚：L1/L2 不可靠 |
| 规则的测试充分性 | Skill coverage、SkillSentry、AgenTest | 面向生成式 Agent |

## 5.6 D3 盲区

1. **没有面向单遍决策模型的"规则语言"**：所有 IR（Artic、P2T、Cedar、LSP）都假设执行者会推理或会调用求值器。单遍模型能忠实执行的规则子集（L0 单条件？带一个例外？）没有被定义。
2. **原语的"可执行性"没有被分级**：Code Owns the Simulation 给了"评估 vs 模拟"一条边界，Reading Right 给了"读 vs 组合"一条边界，2610.24929 给了"一遍可解 vs 需要中间步骤"一条边界。三条边界没有被统一成一个原语级的分类。
3. **Unknown / 弃权作为一等原语**：SemTree 与"概率感知"都把 Unknown 当节点输出，但 D2 证明兜底与拒绝是单遍模型最弱的地方。"每个原语都要能说不知道"与"模型说不了不知道"之间的矛盾没有被正面研究。
4. **规则的措辞不变性**：Lost in the Fallback 与 2610.30045 证明等价措辞导致不同决策。一个规则语言要么规定措辞（模板），要么训练模型对措辞不变；两条路都没有工作在决策模型上做。
5. **规则的组合可靠性**：SemTree 每例平均 2.99 个问题；D4 的层级一致性证据（TV 0.219–0.349）说明分解后的概率不自洽。多个原语在代码里组合时"误差如何传播"只有语义查询优化（2610.08089）与并集界（2610.10978）两个形式化起点。
6. **按裁判编译**：SemTree 证明树要为特定裁判编译（换裁判从 67.70% 掉到 47.87%）。这意味着"业务专家写的规则"与"模型实际执行的树"之间需要一个编译步骤，而这个编译器对单遍小模型应长什么样，无人研究。
7. **Skill 与 Policy 的分离**在决策模型上尚未出现：Auto-Policy 指出两者不同，Jev-Guard 的策略树是 Policy，TypeSafe 的 agent-skill 是 Skill；没有工作同时定义二者并测量交互。

# 06 · D4 一致性：把"数值一致性"拆成可定义、可度量的子问题

> 口径（按最新讨论）：D4 不只是"重复、顺序、措辞、校准"四项，而是要**自己定义并理解问题**。本章把近两个月文献里出现过的、会让"同一个业务判断"给出不同概率的因素逐一列出，每项给出定义、度量方式、已有证据与已有缓解，最后给出矩阵与盲区。本章是问题定义的探索，不是方案。

## 6.0 为什么要拆

Jev 的卖点是"概率可阈值、可组合、可审计"。但下面的证据表明：**同一事实、同一规则，概率会随 25 种与业务无关的因素变化**。这些变化在准确率上往往看不见——2610.35826 发现 Jev 换 8 种选项顺序后准确率变化不到 2 个百分点，但累计失败集扩大 27–29%；2609.27678 发现"修正与回归相互抵消，准确率不变但决策变了"。所以 D4 的度量必须是**决策级、配对、逐项**的，而不是聚合准确率。

## 6.1 子维度清单

每项格式：**定义 → 度量 → 证据 → 已有缓解 → 状态**。

### A. 同一输入的稳定性

**A1 重复性（同输入、同配置、多次调用）** - 定义：对完全相同的请求，输出概率的方差。 - 度量：组内相关系数 ICC；top-1 翻转率；概率绝对差。 - 证据：文化价值观 24 题 288,000 次回答 ICC 0.997（2609.36399）；Jev 的否定不一致是其重复噪声的约 5 倍，说明重复噪声本身很小（2609.33209）；"一致的答案也会保留错误"——重复的错误答案占观察到错误的大部分（2609.27678）。 - 缓解：无需；但重复性高不等于正确，见 A2–A4。 - 状态：**已解决且会误导**——高重复性让人误以为稳健。

**A2 数值精度 / 量化 / 合并漂移** - 定义：同一权重在不同精度、量化、合并后 top-1 的变化。 - 度量：top-1 变化比例；概率最大偏差。 - 证据：Kev 服务端 bf16 对 fp32 概率差最多 ~0.03（GPU）/0.05（Mac），约每 300 题 1 题 top-1 变化（Kev README）；Chinese Decision 合并与 Q8_0 量化各改变 0.4–1.1% 的 top-1，聚合指标几乎不变（2610.23170）；Laya-typed 默认 CUDA 路径产生 5 次段落交换，FP32 重跑后概率移动消失（2610.14631）；4-bit 量化（RTN/GPTQ/AWQ）的损伤随模型大小变化，没有把任何配置推入合格（2610.00025）。 - 状态：**可度量、量级小、但在阈值边界会翻**。

**A3 版本 / 模型漂移** - 定义：同一业务规则在不同模型版本或不同模型之间的决策变化。 - 证据：2610.35826 覆盖两个 Jev 版本、12 个复现、6 个 LLM；SemTree 为裁判 A 编译的树换到裁判 B 从 67.70% 跌到 47.87%（2610.13999）；Decision Index 0.4 的排名随版本波动（Decision Index）。 - 状态：**几乎没有系统性研究**；对我们"自训模型 + 业务规则库"至关重要（规则是否要随模型重编译）。

### B. 选项表示的依赖

**B1 选项顺序 / 位置** - 定义：打乱选项顺序后决策是否变化。 - 度量：一次洗牌的翻转率；8 种展示下的累计失败集扩张；循环平移平均后的残余。 - 证据：官方 jaggedness 第 8 行承认（jaggedness）；Archer Hume 探针：卡片排第一 12/16，排最后 16/16（architecture）；Jev 换序后准确率变化 <2 pp 但累计失败集 +27–29%，投票收益有限，"一致同意的答案也常错"（2610.35826）；Qwen3-8B / Gemma 4 12B 字母读出一次洗牌改 20.0% / 11.9%，已发布的决策微调仍改 9.1%；只换字母不动位置改 9.1% / 14.0%，只动位置不换字母改 12.0% / 22.7%；训练洗牌数据会平台化（2610.22066）；Laya 反转顺序改 30% 答案（2610.02267）；顺序主要在模型对前几名不确定时改变答案，但列表式答案看起来很自信（2610.18233）。 - 缓解：块因果注意力（2610.01601）；Prism-1 位置与对手无关打分（零翻转）；Runoff 两阶段（零翻转，循环平均残余 9.3%）；AnyJev 旋转 + 标签先验校正；PACT 位置偏置最低（2609.35865）；Kev `/permute` 端点。 - 状态：**定义清楚、度量成熟、结构性缓解已有**；但缓解都针对 Choice，Score 的位置问题（B5）另算。

**B2 选项集依赖 / 无关选项独立性（IIA）** - 定义：加入既非正确也非最强对手的选项后，正确与最强错误之间的对数几率是否变化。 - 度量：log-odds 的均方根系统偏移（nats）与运行间变异之比。 - 证据：Jev 1.13 预注册 299,463 次调用：每加一个选项都移动对数几率，0.20–0.52 nats，是运行间变异的 1.2–3 倍，即使新选项只拿 0.1% 概率；偏移有方向性（像错误答案的选项从它那里吸概率 +0.10 nats；错误答案的改写只拿到它一半以下的 1/3）；随 log(选项数) 增长，255 项时约 1 nat；域外填充把几率推离正确答案；**打包进一次调用的多个问题不互相影响（偏差 <0.001）**；逐选项独立 Noul 消除依赖但正确率低 8.7 点（2610.16655）；Archer Hume 无关选项让 log-odds +0.38→+0.11，10 个块全部如此（architecture）。 - 缓解：Prism-1 的对手无关性；JevCascade 的菜单策展（0.8B 在 5 候选策展菜单 95.4% 对 4B 全 150 标签 80.0%，2610.07716）。 - 状态：**有预注册证据和形式化定义**；"概率只相对于其选项列表有效"应作为接口文档的一部分。

**B3 选项名 / 定义的依赖** - 定义：改选项名、删或改定义，决策变化多少。 - 证据：详见 D1 §3.2.2——选项名换成无语义代号 AUC 93.8→23.2（2609.26758）；定义可删（0.8487→0.7971），矛盾定义 0.8511→0.2281（2610.02586）；给宽松选项

起误导性名字使守卫误放行率升至 93–100%（2610.12292）；把成语的字面义塞进选项列表吸走 65–96% 的剩余错误（2610.22526）。 - 状态：**结论一致——选项名是最强杠杆也是最大攻击面**。

**B4 多正确选项下的概率分配** - 定义：多个选项同为正确时，概率在它们之间是否公平分配。 - 证据：三个决策模型即使把所有正确项排在所有干扰项之上，仍在 28–50% 的列表中让至少一个正确项低于 1/n；五份相同正确项的概率差 17–79 pp；**阈值不能识别正确集合**（2610.29217）。 - 状态：**已定义、已度量、无缓解**。多标签业务规则（"以下哪些条款被触发"）必须拆成多个 Noul。

**B5 序数尺度压缩 / 向中趋势** - 定义：Score 类问题中决策集中到比金标准更少的有效档位。 - 度量：有效标签利用率（决策对金标准有效支持的比例）；TVD。 - 证据：JEV 1.13 在 ANLI 6,400 题准确率 74.95%，却把 38.8% 的预测、51.3% 的错误给 Neutral，而金标准接近均衡；36 个序数数据集上只用 60–76% 的有效金标准支持，对 4 个名义任务 87–102%；更细的尺度加剧压缩；随机顺序减弱但不消除；加大档距提升准确率但不恢复利用率；更大模型不一致地恢复；可用针对性训练缓解（2609.38827）。 - 状态：**已定义、已度量、给出了训练缓解方向**。业务里"1–10 分"的评分规则要考虑这点。

**B6 问题形式等价性（Noul / Choice / Score / 打包 / 分开）** - 定义：同一判断用 Noul、Choice、Score 或多问打包/分开表达时概率是否一致。 - 证据：Jev 对"标签是 X"的单标签概率三者之和平均 1.14（2609.33209）；逐选项 Noul 归一化比 Choice 打分保留更高准确率（医学，2610.18529），但在意图分类上低 8.7 点（2610.16655）——方向**不一致**；pplx-decider 同一消息多侧面联合问 68.09 对分开 67.75，独立段落联合略降 0.2–0.4（pplx-decider）；Kev 提供"打包 vs 分开"对比工具。 - 状态：**证据相互矛盾、与任务有关**；"业务规则用哪种原语表达"没有通用答案，是 D3 原语设计必须测量的量。

## C. 逻辑与分解的一致性

**C1 层级 / 分解相干性** - 定义：直接问细标签与"先问大类再问细标签"重构的分布是否一致。 - 度量：大类级总变差 TV；重构后的准确率与 ECE 变化。 - 证据：72,000 题：Jev 的 TV 0.219–0.349，Laya 0.424–0.689；CLINC150 上重构让 Jev 准确率 −22.9 pp [−24.9, −20.9]，让 Laya +21.3；MASSIVE 上 Laya 准确率 +9.2 但 ECE 0.046→0.124（2609.33971）；SemTree 多步树与直接问持平（67.70 对 68.23，2610.13999）。 - 状态：**已定义、度量清楚、方向因模型而异**；D3 的"规则分解"必须回答"分解后概率还能用吗"。

**C2 否定 / 互补 / 合取等概率公理** - 定义：P(X)+P(¬X)=1、互斥标签和为 1、合取不大于单项。 - 证据：Jev 否定对平均偏 0.064（CI 0.055–0.072），Qwen3.8-27B 首 token 0.293、口头 0.122；Jev 违反量约为重复噪声 5 倍，集中在不确定处；Qwen 在 196/480 对中同时拒绝陈述与其否定（2609.33209）；Jev 在著名概率题上每次都对，但改编版每次都违反同一规则；30 个合取任务 15,000 次回答中 54% 违反（2610.19619）。 - 缓解：无需标签即可检测（公理测试）。 - 状态：**已定义、有免标签度量、无训练侧缓解**。

**C3 等价措辞不变性** - 定义：规则或问题的逻辑等价改写是否改变决策。 - 证据："决策服务跨等价措辞改变答案的次数多于跨同文重复"（2610.30045）；逻辑等价的兜底规则表述产生实质分歧（2610.19856）；表格任务 21 种改写：三个决策模型对问题表述稳健，**无一对表格组织稳健**，每个模型至少 1/3 的行决策随格式变（2610.19536）；医学任务下 Jev 对问题格式变化保持强一致性（2610.18529）。 - 状态：**定义清楚；证据显示"问题措辞"比"数据格式"更稳**。

**C4 框架效应与认知偏差操纵** - 定义：不改变事实、只改变呈现（得失框架、锚定、无关数字）时概率是否变化。 - 证据：Jev 在选中答案层面避开多数人类偏差，但对无关数值信息与选项顺序敏感，多种偏差操纵显著改变返回概率即使选中答案不变（2610.19619）；得失框架对 LLM 高风险建议的影响（上游对照，2610.29294）。 - 状态：**选中答案稳、概率不稳**——阈值化系统会受影响。

## D. 置信度的含义

**D1 校准 vs 判别 vs 敏感性（三件事不是一件）** - 定义：校准 = 概率与频率匹配；判别 = 排序对错的 AUROC；敏感性 = 置信度能否把对错分开。 - 证据：准确率相近的模型 AUROC 差异很大，最敏感模型的置信度追踪"哪类情境会失败"而非"哪个答案错"；延后 30% 最不确定决策的收益与 AUROC 秩相关 0.87（2610.09683）；Jev 对完成请求排序最好（AUROC 0.78 对规则 0.62、小 LLM 0.60）却校准差：平均"已完成"概率 0.50 而 87% 实际通过（2610.24649）；印尼语 ECE 不增但排序自身错误的能力在三个数据集上全部退化（2610.14112）；Intern-Decision Brier 0.628→0.550、ECE 0.213→0.089 来自训练目标（2610.22131）。 - 状态：**概念已分清、三者要分别报告**。

**D2 两种不确定性（人类分歧 vs 决策风险）** - 证据：142,658 条审核评论：模型 AUROC 0.83 与 13/14 前沿模型不可分；"置信度"混合了标注者分歧与决策风险，在非对称损失下两者要求相反的升级信号；把判断拆成并行子问题读其分散度可恢复分歧信号，但只对最弱模型有效且依赖分解对齐分歧来源（2610.33258）。 - 状态：**已定义；缓解条件性**。

**D3 自知之明（低置信是"随机"还是"不知道"）** - 证据：无任何相关信息时 Jev 仍给显著选项最高 0.80；超出知识边界的新闻上置信超准确 0.21–0.33 且早期月份重校准不能修复；定向 Noul 更锐：结果是否已定 AUROC 1.00、证据是否充分 0.95（对比答案置信 0.85）；"你知道答案吗"看似能标出虚构实体与边界后新闻（0.91），但去掉日期或用真实名字后不优于答案不确定性（2610.01006）；无语义选项列表上准确率为随机，最校准的模型仍报平均置信 0.82；开源模型置信反转，按置信门控比随机差（2610.22526）。 - 状态：**已定义；表面线索会伪装成自知**。

**D4 流行率（先验）偏移下的校准与阈值** - 证据：Nimble-9B 只比 Qwen3.5-9B 多一个 LoRA，意图任务校准更好但金融情感 Macro-F1 −12.0；中度偏移下 Jev 的 ECE 与阈值风险只在金融情感上显著高于微调 DeBERTa（+1.7/+2.5 pp），2,000 个场景平均差距 ≤1 点；EM 先验校正（无标签）降 ECE 2.7/1.8 点（2610.26325）；SHIFT-JEV：KL 锚 + 温度把偏移下校准误差 0.289→0.087，卡方检验检出 95–99% 置信/嵌入检测器漏掉的类先验偏移（2610.34329）。 - 状态：**有度量与廉价缓解**。

**D5 教师偏差继承** - 证据：Gaussian 代理的精确风险计算——学生继承教师偏差，更多学生数据不消除，与教师的一致性不能证明正确（2610.26797）；记忆退役任务中 LLM 多数票金标签与同家族升级模型共享多数错误（2610.15710）；AgentDecision-4B 用 Jev 答案作标签（2610.21412）；Releasing Inner Jev 用 Qwen3.5-122B / Qwen3.6-27B 做教师（2610.17205）。 - 状态：**理论上清楚、实证上几乎没有在决策模型上度量**。对我们"小模型 + 蒸馏"路线是直接风险。

## E. 输入内容的依赖

**E1 数字 / 日期 / 算术**（详见 D2） - 证据：MathQA 比最佳 LLM 低 17.7 点（2610.11978）；医学数值驱动任务是明确的能力边界（2610.18529）；拒绝瓶颈 99%/7%（2609.39496）。 - 状态：**边界清楚，官方建议"算术放代码"**。

**E2 状态长度 / 无关细节 / 间接性** - 证据：官方 jaggedness 第 4、5 行；Jev 在 20k token、64 选项内无误检索记录，但答案依赖同一用户两次以上更新时掉到 53–80%（16 次更新），因为相似记录互相干扰（2610.24929）；Laya 在 50 个最近邻工具上 31%，Jev 98%（2610.02267）；Archer Hume：服务时间到 ~100 问基本持平，问题文本约 2 倍状态成本（architecture）。 - 状态：**"读"稳、"聚合"不稳**；边界 = 需要中间步骤。

**E3 自然背景信息的翻转（非指令式对抗）** - 证据：JevOut：64 次目标评估内，短背景/程序性补充把 61.4–73.2% 的初始正确决策导向预定错误选项，不含显式答案指令（2609.30243）；六行与策略无关的服务器日志让守卫误放行 0%→63%（2610.12292）。 - 状态：**已定义、高危、无有效缓解**（"升级最不确定的"无效：被攻击反转的决策并不更不自信）。

**E4 记录 vs 观察（声明 vs 现实）** - 证据：Claim Laundering：12 个配置中记录对承诺决策的影响全部大于观察；声明成功但实际失败后 53–100% 仍停止/前进/购买；线性探针可区分（AUROC 0.77–1.00）；EVIGATE 中层否决 +18.7（ALFWorld）/+5.0/+5.1，但离线校准不迁移到实时轨迹（2610.25947）；给陈旧摘要 Jev 就跟随它（2610.24929）；压缩摘要中 83% 失败追溯到无环境支持的摘要条目（2610.20927）。 - 状态：**已定义；是 Agent 场景最危险的一致性问题**。

**E5 语言 / 文化 / 人设** - 证据：沙特 vs 美国人设在英语中复现 87% 的人类差异、阿拉伯语 62%，差异来自题目语言而非人设语言，阿拉伯语置信更低（2609.36399）；印尼地区语言：人工翻译成印尼语最多 +37.2 点，ECE 不增但排错能力退化（2610.14112）；同一医学题从英语到约鲁巴语准确率最多 −39 pp（2610.31315）；孟加拉语比英语被字面义捕获 1.9–6.4 倍，"商业模型的抗性是测试语言的属性"（2610.22526）。 - 状态：**已定义；中文证据只有 Chinese Decision 的 CJ-Bench**（2610.23170）。

**E6 风格 / 情绪 / 判官偏差** - 证据：CALM 12 项偏差测试：8 个 TDM 全部在 3–8 项上有偏差，情绪语气影响最大，把更好答案改写成情绪语气使典型 TDM 准确率 99%→42%，TDM 比 2026 年的 LLM 判官更有偏差（2610.18122）；JEV-as-Judge 置信路由在风格对抗与无参考散文上失效（2609.26550）。 - 状态：**已定义、已度量、无缓解**。

## F. 接口与组合

**F1 读出方式（首 token / 口头 / 类型化头 / 指针）** - 证据：首 token 读出高估位置偏置：Qwen3 判官 12–49% 的对不以判决 token 开头，强读返回"谁排第一"，交换后翻转 89.7% 对生成后读 47.5%（2610.00054）；首 token 否定偏差 0.293 对口头 0.122（2609.33209）；类型化头对 LM 头读出无一致优势（2609.25845、2609.32160）；JevCascade 的读出稳定性是序数性质而非概率性质（菜单干预预测误差 4.2 点，概率级变体 21.0 点）（2610.07716）。 - 状态：**读出选择影响偏差测量结果**；复现工作应报告读出类型。

**F2 选择 vs 顺序构造（Choice2Seq）** - 证据：Jev 在算术 / 词汇检索上整体选择准确率 97.1% / 99.5%，但通过局部顺序构造只保留 33.0% / 2.1%（2610.16191）。 - 状态：**已定义**；业务规则"按步骤判断"与"整体判断"结果可以完全不同。

**F3 请求独立性 / 打包副作用** - 证据：Nimble 的请求扩展在 TREC DL2019/2020 上引发 9.1%/8.0% 的严格二元翻转、改变 21.4%/18.9% 的选择或弃权动作，70 次翻转全部追溯到序列化进打分提示的 schema 字段；Von 固定共享分隔符位置消除翻转（2610.14631）；Jev 打包问题不互相影响 <0.001（2610.16655）。 - 状态：**托管模型达标、开源复现不一定**；是复现的验收指标。

**F4 决策→动作组合后的一致性** - 证据：最准确的系统组合成动作后最常忽略需要处理的邮件（18% 对最佳 LLM 4%）；按噪声概率的成本阈值使其减半（2610.32955）；DICE：状态抽取 / 问题生成 / 输出解释三个适配器都能在 Jev 响应不变时改变最终决策（2610.14404）；联合界与成本-准确率形式化（2610.10978、2610.08089）。 - 状态：**已定义；产品指标 ≠ 决策准确率**。

**F5 对抗注入（显式）** - 证据：JevAdvBench 862 题；选项通道攻击 36–72% 准确率（随机 50%）；JPDH 真实应用中的程序决策劫持（2610.18612）；注入检测 AUROC 0.897（2610.20907）；Jev 在"有明确规则可查"的任务上最稳健（8 种伪造 0 绕过，"为什么有人会提这种请求"绕过 9% 对 GPT-6 Astra 56%），在需要整体判断的钓鱼检测上同样伪造绕过 19–29%，且无攻击时只检出 62%，误标 27% 良性请求（2610.17820）；TrustJev 策略权威与证据分离（2610.34826）。 - 状态：**定义多、缓解少**；详见 D2 §4.2.4。

**F6 拒绝 / 兜底 / 弃权的一致性**（详见 D2 §4.2.3） - 证据：算术 99%/7%；法律缺失权威 LLM 38–86% 仍选、最谨慎决策模型 30%（2610.29961）；拒绝策略迁移 69.3%/48.8%（2610.03387）；记忆退役二元门过早退役 39.2%，三元降到 15.5% 但检出 −15.3（2610.15710）；医学上多数模型"识别缺失正确答案与使用可选弃权"都弱（2610.18529）。 - 状态：**最弱环节**。

## 6.2 D4 矩阵：哪些工作解决了哪类问题

| 子维度 | 有定义 | 有度量 | 有缓解 | 代表工作 |
|---|---|---|---|---|
| A1 重复性 | ✓ | ✓ | 不需要 | 2609.36399、2609.27678 |
| A2 精度/量化 | ✓ | ✓ | — | Kev、2610.23170、2610.14631 |
| A3 版本漂移 | 弱 | 弱 | — | 2610.35826、SemTree |
| B1 顺序 | ✓ | ✓ | ✓（结构性） | 2610.22066、2610.18233、2610.00831、2610.01601、2609.35865 |
| B2 IIA | ✓ | ✓ | 部分 | 2610.16655、Prism-1、2610.07716 |
| B3 选项名/定义 | ✓ | ✓ | — | 2609.26758、2610.02586、2610.12292、2610.22526 |
| B4 多正确 | ✓ | ✓ | — | 2610.29217 |
| B5 序数压缩 | ✓ | ✓ | 训练方向 | 2609.38827 |
| B6 问题形式 | ✓ | 矛盾 | — | 2609.33209、2610.18529、2610.16655、pplx |
| C1 层级相干 | ✓ | ✓ | — | 2609.33971 |
| C2 概率公理 | ✓ | ✓（免标签） | — | 2609.33209、2610.19619 |
| C3 措辞 | ✓ | ✓ | — | 2610.30045、2610.19856、2610.19536 |
| C4 框架 | ✓ | 部分 | — | 2610.19619 |
| D1 校准/判别/敏感 | ✓ | ✓ | 训练目标 | 2610.09683、2610.24649、2610.22131 |
| D2 两种不确定性 | ✓ | ✓ | 条件性 | 2610.33258 |
| D3 自知 | ✓ | ✓ | — | 2610.01006、2610.22526 |
| D4 流行率偏移 | ✓ | ✓ | ✓（EM/KL 锚） | 2610.26325、2610.34329 |
| D5 教师偏差 | 理论 | — | — | 2610.26797 |
| E1 数字 | ✓ | ✓ | 代码 | 2610.11978、2609.39496 |
| E2 长度/无关 | ✓ | ✓ | 过滤 | 2610.24929、2610.02267 |
| E3 自然背景翻转 | ✓ | ✓ | — | 2609.30243、2610.12292 |
| E4 记录 vs 观察 | ✓ | ✓ | 部分（探针否决） | 2610.25947、2610.20927 |
| E5 语言/文化 | ✓ | ✓ | 翻译/级联 | 2609.36399、2610.14112、2610.31315、2610.22526 |
| E6 风格/情绪 | ✓ | ✓ | — | 2610.18122 |
| F1 读出 | ✓ | ✓ | 报告读出类型 | 2610.00054、2610.07716 |
| F2 选择 vs 构造 | ✓ | ✓ | — | 2610.16191 |
| F3 请求独立性 | ✓ | ✓ | 格式修复 | 2610.14631 |
| F4 决策→动作 | ✓ | 部分 | 形式化起点 | 2610.32955、2610.14404、2610.08089 |
| F5 显式注入 | ✓ | ✓ | 弱 | 2609.31142、2610.12292、2610.17820 |
| F6 拒绝/兜底 | ✓ | ✓ | — | 2609.39496、2610.29961、2610.03387 |

## 6.3 D4 盲区

1. **没有一个把这些子维度放在一起的"一致性基准"**：DecisionPivot（2610.28522）最接近（48 任务 7 角色的对照组），但覆盖的是 B1/C3/F6 的一部分；TypedBench（2610.18488）与 System1-Arena 各覆盖另一部分。没有工作同时报告 A–F。
2. **没有"中文 + 业务规则"的一致性数据**：E5 的证据全是英语/印尼/阿拉伯/孟加拉/约鲁巴；中文只有 CJ-Bench 的准确率与 ECE。
3. **A3 版本漂移与 D5 教师偏差没有实证**，而这两项决定了"规则库是否随模型重编译"与"蒸馏小模型是否继承 Jev 的 B2/B5/C2 缺陷"。
4. **B6 问题形式等价性的证据相互矛盾**，这意味着 D3 的每个原语都需要在目标模型上单独测"用 Noul 还是 Choice"。
5. **缓解只覆盖 B1、D4 两项**（结构性顺序无关、先验校正）。B2–B5、C1–C3、E3、E6 的缓解都停留在"报告"或"训练方向"。
6. **决策级配对评测没有成为规范**：多数复现工作仍只报准确率与 ECE；2610.35826 与 2609.27678 说明这会系统性高估稳健性。

# 07 • D5 Agent 与知识系统：快慢协同的证据与边界

> 口径：Jev 类模型能否把 Agent 循环从"慢思考 + 执行反馈"变成"快/慢思考协同"。本章先给反方证据（更快的决策不等于更好的 Agent），再按角色梳理快慢切换、记忆与压缩、路由与守卫、多 Agent、领域 Agent、持续学习，最后给矩阵与盲区。

## 7.1 反方证据：更快的决策 ≠ 更好的 Agent

| 研究 | 设置 | 结论 | 出处 |
|---|---|---|---|
| **When Faster Decisions Do Not Make Better Agents** | 5 个 Agent、ALFWorld + AndroidWorld、4,500 次执行 | Jev 显著降低决策成本与延迟；任务成功在 ALFWorld 接近基线，在两个移动 Agent 上明显下降；**辅助推理与额外交互吞掉决策节省**；恢复失败与过早完成限制交付；一个 Agent 每次尝试花费下降但**每个成功结果的平均成本上升** | 2610.13092 |
| **Good Judgment, Bad Advice** | Claude Sonnet 5.5 终端 Agent，Terminal-Bench 2.1，21 任务 315 次，预注册，含安慰剂臂 | Jev 控制器**提高每次尝试成本 19%**（1.19，CI 1.02–1.36）而通过率相同（73.0% = 73.0%）；比小 LLM 控制器便宜（0.81）但比安慰剂贵 22%；离线排序最好（AUROC 0.78 对规则 0.62、小 LLM 0.60）但校准差（0.50 对 87%），于是让 Agent 验证已经正确的工作；**没有控制器选择过放弃**；"有信息的决策信号没有变成有用的干预" | 2610.24649 |
| **JevAgentHarness** | AgentDecisionBench 从孤立问题到控制运行中的 Agent | 孤立问题上最准的决策模型只解决 69.5% 的 Agent 任务；**不拟合置信阈值直接委托工具选择，成功率 −19.0**；现有决策模型从未见过 Agent 自己犯错后的状态；在 Agent 自己轨迹上训练的 AgentDecision-4B：域外 91.5% 对 Jev 82.0%；域内便宜 81.1–89.0%、快 2.5 倍、损失 <3 点 | 2610.21412 |
| **System1-Arena** | 92k 题 105 任务 + 138 闭环环境，30 模型 | 最大的 System-1 模型在非 Agent 准确率上匹敌快速闭源 LLM，校准更好、延迟 1/4；Decision-2.0-Vega-27B、Jev、Qwen3.5-9B 单步都 67.8%；闭环中大开源 LLM 最多 32.9%（Gemma-4-31B），**四个小 System-1 模型最多 3.1%** | 2610.21244 |
| **Fast Models, Slow Evidence** | 11 个 Agent 决策点、7,283 + 6,640 例、配对、自审计 | Jev 在 9/11 决策点显著更准（+10.8 到 +46.0 pp）；**零样本模型路由两者都不超随机，RAG 相关性门控持平**；作者审计自己的流水线：预筛成本漏算（报 23.9% 节省、实际 4.3%）、把门准确率当端到端质量（58% 对 98%）、样本内阈值（5% 目标、保留集 17% 漏） | 2610.02267 |
| **Microtask Eligibility Gap** | 4 个 harness 微任务（审批命令、写记忆、选工具、排序历史），Qwen3 0.6–8B，CI 门槛 | **0/16 配置合格**、0/112 跨改写；Llama 12/12 不合格；量化不改变结论；"把 SLM 放在达标的基线后面，只在基线失败处用" | 2610.00025 |
| **Measure Before You Train** | 真实邮件 Agent 739 封 | ~200 标签的逻辑回归在每个字段都最准（0.79/0.74/0.83/0.90）；发件人关系属于联系人图而非提示；**组合成动作后最准的系统最常忽略要处理的邮件（18% 对 4%）** | 2610.32955 |
| **JEVal** | 11,257 例 36 数据集 10 领域，25 配置，含 τ-bench 与社会模拟 | 决策模型在"证据可直接判定"时最有竞争力，需要专业知识或忠实不确定性时变弱（常识别出最可能结果但**高估其概率**）；**τ-bench 上更快的局部决策降低中位回合时间但降低任务成功**，错误沿长轨迹累积 | 2610.03935 |
| **Code Owns the Simulation** | 反思测试、矩阵博弈、ALFWorld、机器人 | 能从输入描述判断的（评估）Jev 做得好（CRT 99%）；依赖预测输入之外的（模拟）做不了 | 2610.01834 |
| **What Can't Jev Decide** | 单因素基准 | 单遍模型不能做"LLM 只有写出中间步骤才能做"的决策；给陈旧摘要就跟随它 | 2610.24929 |

**结论**：把 Jev 放进 Agent 循环的收益取决于三件事——(a) 决策点是否真的是"读出"而非"推导"；(b) 置信阈值是否在 Agent 自己的轨迹上拟合；(c) 节省是否被额外交互吞掉。"快/慢协同"的论文越来越多地把这三件事当作设计约束而不是假设。

## 7.2 快慢切换：谁来决定什么时候慢下来

| 工作 | 切换机制 | 关键结果 | 出处 |
|---|---|---|---|
| **Talker-Reasoner**（上游） | 对话 System 1 + 规划 System 2 两个 Agent | 架构提案 | 2410.08328 |
| **CogRouter**（上游） | 按步骤在四个认知层级间切换；"合适的认知深度应最大化动作置信" | Qwen2.5-7B 在 ALFWorld/ScienceWorld 82.3%，token −62% | 2602.12662 |
| **StartLux AutoThink** | top 概率 <0.9 才推理 | 27B AutoThink 86.9 对 Instant 75.4（见 02） | 2610.17309 |
| **Selective Reasoning** | 冻结 Qwen3.5-4B 上的共享候选读取器：收益门启动推理、自然状态触发读取、熵规则接受并取消生成 | 768 题 70.96%→84.38%；对 512-token 终端读取 +7.29 pp 只多 2.25% 输出；对 1,024-token 流水线时间 −46.30%、准确率 −1.17 | 2610.19644 |
| **LDM 路由** | 置信路由到推理 | 92% 推理准确率用 27–58% token（见 02） | 2610.15501 |

| 工作 | 切换机制 | 关键结果 | 出处 |
|---|---|---|---|
| **System Switch** | 快速执行者每步决策，门打开时交给推理 VLM，游戏不停 | 0.15B–9B 零样本模型在错误中选"收集物品"比随机多 1.6–1.8 倍；准确率/校准/敏感性三者独立；延后 30% 最不确定的收益与 AUROC 秩相关 0.87，保留集 +0.13 [0.08, 0.18]，推理贡献约一半；**闭环 33 局无一到达出口**；承诺计划让站着不动的执行者动起来但死得更多 | 2610.09683 |
| **SOMA** | S1 持续监控 S2 推理：场景层（自然语言目标 + 预定义动作）、意识层（S1 判断行为是否出现）、控制层（先提醒再接管） | 不训练；过度思考上推理 token −36% 且平均准确率提升；不可回答问题上弃权 70.5%→87.2% | 2610.26793 |
| **Truncated Reasoning** | Jev 读截断的推理轨迹 | 7 推理器 × 5 基准：500–16,000 预算全部优于强制作答；1,500 预算 +4.1 pp（截断题 +8.6）；离线回放 34.5% 成本 −1.13 pp；训练折策略省 71.3% −0.58 pp；Jev 只看问题 68.0% 对 500-token 强制作答 65.5% | 2610.25768 |
| **SanSi / LEV（System 1.5）** | 循环层数当"思考深度"，不生成 token | SanSi 72.0%（+13.5）；LEV 2.6B 63.2%→76.2%（深度 1→4），按需深度省 15–24%，<50 ms 下比同延迟的稠密模型与级联准 5.4–8.8 点 | 2610.07730、2610.20951 |
| **VoI 慢模块调度** | 把"何时调用慢模块"形式化为校准决策问题，固定比例/预算/历史门都是干预价值的退化情形 | 低成本比下校准收益消失；LIBERO 14 臂：自适应触发按阈值规则分配查询，但语言改写通道无法转化为成功；只有"撤销失败改写"零净负面 | 2610.21160 |
| **TORSI（实时）** | 慢教师在暂停的游戏中研究失败并写可复用指令给快学生；学生比赛中不调用教师 | RealtimeBench 180 任务：GPT-6.1-sol 暂停时胜 Jev、持续运行时落后；两轮 Jev 13.51→24.19（0–100）；指令对另外三个模型也有效 | 2610.20665 |
| **CARE（具身）** | 轻量 critic 监控本地执行可靠性，升级后控制权持续直到恢复；共享交接记忆 | 跨具身基准改进 | 2610.30587 |
| **JEV-as-a-Judge** | 置信接受 / 升级 | 冻结阈值 +0.9 于 GPT-6、41% 费用；风格对抗与无参考散文上失效 | 2609.26550 |
| **P(Yes) 测试时搜索** | 冻结决策模型对完整提案打"是"的概率，搜索更高者 | 128 逻辑谜题 Qwen3.8-27B 从 2 到 30 全对（15×），每空 27.8%→48.5% | 2610.25474 |

**模式归纳**：切换信号有四种来源——(1) 答案置信（StartLux、LDM、JEV-as-Judge）；(2) 收益/熵门（Selective Reasoning）；(3) 外部 S1 监控 S2 的行为（SOMA）；(4) 决策论的干预价值（VoI）。(1) 的局限被 D4-D1/D3 的证据限定：置信是答案不确定性，不是"需要思考"的信号（System Switch 第 ii 条、Good Judgment 的 0.50 对 87%）。(3) 是唯一把 S1 放在 S2 **之中**而非之前的设计。

## 7.3 记忆与上下文压缩：System 1 做"多而小"的判断

| 工作 | S1 角色 | 关键结果 | 出处 |
|---|---|---|---|
| **Mnemon** | 对原始带日期记录做许多独立 yes/no 判断（是否需要、是否过期），LLM 规划搜索；写入时不做决定 | 架构 + 背景整合 | 2609.36059 |
| **Jev-Mem** | S1 控制面：记忆类型化、关系组织、查询路由、预算分配、图遍历、候选打分、自适应停止 | LoCoMo 0.777（+11.0%），构建 158 s（6.6×） | 2609.23986 |
| **选择 vs 抽取（预注册）** | Jev 一次调用选原始轮次 | LoCoMo 紧预算下非劣于 LLM 抽取记忆（单侧 95% 界 −3.0 对 −5 边际）；写入便宜 3,061 倍；重排收益随预算缩小（保留 3/30 时 +17.4 / +9.1，宽预算 +1.5 / +1.1 且抽取更准）；与 LLM 重排器同准（−2.0）、1/3 延迟；**重排降低正确弃权** | 2609.34227 |
| **压缩对后续问题** | 决策 API 判断哪些句子对当前问题必要 | MultiRC 当前问题 +11.4 点 @25% token；**对后续问题，所有按当前问题选句的方法都不优于随机删除**；忽略问题的词级 LLMLingua-2 +12.5（等内容词保留 +7.3）；FEVER 上标签准确率高估保留文本的支持；τ-bench 上句选优于随机 | 2610.27301 |
| **SJC（源判断压缩）** | Jev 判断每条摘要条目是否有环境输出或前摘要作为来源 | 83% 失败运行追溯到执行无来源摘要条目的动作；AppWorld/OfficeBench 跨运行可靠性 +2.1–8.9%，不增 token | 2610.20927 |
| **记忆退役门** | SUPERSEDED / NEEDS-CONFIRMATION / COMPATIBLE 三元契约 | 141 个非变化零误退；二元门过早退役 39.2%，三元 15.5% 但检出 −15.3；级联与提阈值无差；"二元分数不要直接接删除" | 2610.15710 |
| **Cache Engineering**（上游） | Agent 直接操作 KV 缓存（drop/repos）而不改轨迹 | 历史依赖使前缀匹配不足以复用缓存 | 2610.28577 |
| **MarkovSim**（上游） | 有限状态机边界上构造紧凑进度表示 | 长程计算模拟 harness | 2610.35349 |
| **Selection replaces extraction / Jev-LDE / MemCom** | 见 D1 §3.2 | — | — |

**结论**：记忆是 S1 最有说服力的用途——判断"多、小、独立"，且证据（预注册）支持"选择原始记录 + S1 判断"非劣于 LLM 抽取。但两条边界清楚：(a)　为当前问题压缩的内容对后续问题无用（需要忽略问题的压缩）；(b)　二元门不能直接接"删除"这种不可逆动作。

## 7.4 路由与守卫

| 工作 | 结论 | 出处 |
|---|---|---|
| **REFLEX** | Jev 作类型化决策层、低置信时调强 LLM：冻结 100 任务 95% 成功、强模型调用 −72.7%，三种兜底家族均成立；可靠性取决于**动作集大小与授权边界附近的近似有效选项**；BFCL / τ-style 上"当普通路由已经很准时，对廉价生成级联优势有限" | 2609.26532 |
| **Jev-Guard** | 策略树路由 + 条件分类，93.72% / 58 ms（见 D3） | 2610.18326 |
| **选项通道攻击** | 守卫角色下 7 个开源 TDM 36–72%；日志六行 0→63%；误导性名字 93–100%；**所有防御被击败；升级最不确定的无效**；把策略字段解析成类型化值后确定性规则 100%——"使模型变得不必要" | 2610.12292 |
| **Same Attack, Different Judge** | Jev 在有明确规则的输入审核上最稳健；在需要整体判断的钓鱼检测上更易被绕过、召回低 | 2610.17820 |
| **TrustJev** | 策略权威与不可信证据分离，有界修正 | 2610.34826 |
| **COGNIT-Guard** | 直接决策守卫 + 校准 + 双用途误报控制 + CPU-NPU 路由 | 2609.33671 |
| **SkillScreen** | 单遍筛恶意 Skill，99% 召回下只标 20–25% 良性 | 2610.17727 |
| **StepGuard / ToolSafe / AgentDoG 1.5**（生成式守卫，对照） | 步级工具调用守卫；TS-Guard 多任务 RL 推理；taxonomy 引导的数据引擎 | 2608.24777、2601.10156、2605.29801 |
| **CARE（shell）/ StateMirror**（静态优先，对照） | shell 命令规范化-归因-解析；执行前检测幻觉工具调用（4,398 轨迹，恢复中位 3 步 22.4K token） | 2607.21642、2610.32648 |
| **JevSoup** | S1 选两个 LoRA 专家做正交合并 | 14 任务最高 +1.19% |
| **Harness Tokenomics** | 企业 harness 控制面的路由器（谁回答、读什么、缓存怎么用） | 2609.28919 |

**结论**：路由是 S1 最成熟但也最被高估的角色：当 LLM 自身的路由已经很准（REFLEX 的 BFCL 结果）或任务可以被确定性规则解决（选项通道攻击的 100%）时，S1 没有位置。守卫角色下 S1 的失效模式（选项名、日志注入）与 D4-B3/E3 一致。

## 7.5 多 Agent 协调

| 工作 | S1 角色 | 结果 | 出处 |
|---|---|---|---|
| **Jev-LiteMAS** | 动态选专家（规划缺口）+ 筛中间制品、标记的交 LLM 复审（复审缺口） | 三个 MAS 框架中路由与复审占生成 token 31.7–43.5%；4 基准 2 骨干生成 token −12.7–54.6%，准确率在 1.34 pp 内 | 2610.21411 |
| **S1-MAS** | 轻量控制器选检查条件、选后续任务、决定终止；紧凑读取器从授权源取条件相关证据 | 决策-证据循环 | 2610.08155 |
| **BLADE** | Jev 给依赖概率，选相关的"源-决策"交接点审计是否忠实使用 | 1,228 次失败运行上最好或并列最好，比一次性归因 +2.2–11.1 pp | 2610.18780 |
| **Jarvis** | 全双工对话中 JEV 读每轮对照活动任务选操作，**代码对照当前状态检查每个选择再应用**；版本化任务记录 | τ-Voice 29→192 / 278；Full-Duplex-Bench v3 69% Pass1 对 GPT-Realtime 60% | 2610.23804 |

## 7.6 领域 Agent 与非 Agent 的"S1 位置"

| 工作 | 位置 | 结果 | 出处 |
|---|---|---|---|
| **JevCoder** | 代码修复中的片段推荐、动作类型指导、何时提交 | 收益取决于干预改变的工作量而非判断成本；3 模型 × 400 任务 token −21.6–50.6%，修复率更高 | 2610.19596 |
| **Jev-Mobile** | VLM 低频规划、Jev 在可访问性树定义的动作空间高频执行 | AndroidWorld 79% 对 SeeAct-V 78%、逐步 VLM 84%；时间 −32.7%、API 成本 −73.4% | 2609.30186 |
| **JEV-Star** | JEV 动作选择 + 持续 GPT-6 规划 | 击败 Lv7 内置 AI；中位响应 0.422 s；$3.71/局（JEV $0.15）；**单独 JEV 控制器对 Lv2 不扩张** | 2609.27331 |
| **SearchJev** | 相关性、证据充分性、搜索动作；软标签校准（SLCD） | 比同尺寸 Qwen3.5 快 5.2–5.3 倍、ECE −41–74%；BrowseComp-Plus 搜索时间 3.7–4.7 倍、准确率 45%→54% | 2610.05107 |
| **JevGPT** | S2 定证据目标、S1 并行定位/评估相关性 | 固定语料 QA 与排序领先，更快更便宜 | 2610.18272 |
| **JevSpawn** | 自然语言任务 → 有限概率探索；并行动作生成 + 反馈分支选择 | 8 基准优于 7 基线 | 2610.00437 |
| **NIOCIS / SharedKV-BT** | 节点条件化的选项空间（见 D3） | — | 2610.25985、2610.07327 |

| 工作 | 位置 | 结果 | 出处 |
|---|---|---|---|
| **Decision4Rec** | 知识图把日志写成尺度语句，S1 读类型化问题 | 4B 决策模型 NDCG@10 比最好训练基线高 25–36%（3 个稀疏目录） | 2610.26035 |
| **Jev 作 RL 的 Q / 策略** | 参考策略、探索判官、回放评分器 | 能满足 RL 对象的所有要求**除了值函数的基数用法**；9 MiniGrid + 3 Atari 优于标准学习器 | 2610.11692 |
| **象棋** | Jev 判断放进 Stockfish 搜索；蒸馏成紧凑评估器 | >2200 Lichess bullet；双教师平均标签比全用 Qwen +9.6 Elo | 2610.09188 |
| **KITE** | 每唯一状态查一次类型化行为核，表驱动群体实验 | 1.7% 锚点使效应误差 −41% | 2609.27535 |
| **ProAgent / StreamingJev** | 持续观察、何时介入 | 比源骨干更准的介入时机、更少误触 | 2610.16967 |
| **Jevolution** | 远程决策 Agent 的世界/调度/控制器分离 | 框架 | 2610.14449 |

**共同点**：成功的领域 Agent 都把 S1 放在**动作空间已被代码/树/图枚举**的位置（Jev-Mobile 的可访问性树、NIOCIS 的动作图、Decision4Rec 的尺度语句、象棋的搜索树），并由 S2 **低频**地改变动作空间或目标。

## 7.7 记录 vs 现实、持续学习

- **Claim Laundering**：决策模型信记录多于观察（53–100%）；探针 AUROC 0.77–1.00；EVIGATE +18.7/+5.0/+5.1；离线校准不迁移（2610.25947）。
- **Jev-DLC**：类型化反馈（接受/撤销）变成有界的因果状态，不存原始历史、不加打分调用；TCPA-Repeat 44.83%（+2.43 于 Recent-4 回放），两次反馈后 56.07%（+7.54）（2610.31521）。
- **SHIFT-JEV**：认证弃权 + 收益门控的持续适配；Qwen3-0.6B 70.5% 高于回放/LwF/EWC；4B 上保守门落后 0.4–1.4 点（2610.34329）。
- **TORSI**：慢教师写指令、快学生执行的离线递归自改进（2610.20665）。

## 7.8 D5 矩阵

| 问题 | 已有工作 | 状态 |
|---|---|---|
| S1 放进 Agent 循环是否省钱 | 2610.13092、2610.24649、2610.21412、2610.02267 | **有条件**：阈值需在自己轨迹上拟合；节省会被额外交互吞掉 |
| 什么时候该慢下来 | StartLux、Selective Reasoning、SOMA、System Switch、VoI、LDM | 四类信号；答案置信不是"需要思考"信号 |
| S1 能否监控 S2 | SOMA、BLADE | 有雏形 |
| 记忆选择/判断 | 2609.34227、Mnemon、Jev-Mem、SJC、退役门 | **最强证据**；边界：后续问题、不可逆动作 |
| 路由/守卫 | REFLEX、Jev-Guard、选项通道攻击 | 成熟但被高估；守卫角色高危 |
| 多 Agent 协调 | Jev-LiteMAS、S1-MAS、BLADE、Jarvis | 有收益；Jarvis 的"模型判断、代码执行"最清晰 |
| 领域 Agent | Jev-Mobile、JEV-Star、SearchJev、JevCoder、Decision4Rec | 成功 = 动作空间被代码枚举 + S2 低频 |
| 实时性 | TORSI、System Switch、Jarvis | 快模型在"世界不等"时赢 |
| 记录 vs 现实 | Claim Laundering、SJC、2610.24929 | 已定义，部分缓解 |
| 持续学习 | Jev-DLC、SHIFT-JEV、TORSI | 起步 |
| S1 训练数据从哪来 | AgentDecision-4B（Agent 自己的轨迹 + Jev 标签）、TORSI（教师指令） | 关键发现：**要包含犯错后的状态** |

## 7.9 D5 盲区

1. **"快/慢协同"的收益核算没有标准**：2610.02267 自审计暴露了三种常见算错（预筛成本、门准确率当端到端、样本内阈值）；2610.13092 提出"每个成功交付的资源"；没有被广泛采用。
2. **切换信号的理论只有 VoI 一篇**，且在 VLA 上；在语言 Agent 上"何时调慢"仍靠置信阈值，而 D4 已证明置信不等于"需要思考"。
3. **S1 监控 S2（SOMA 式）只有一篇**，而这是把 S1 放进慢思考内部、而非之前的唯一设计。
4. **没有工作比较"S1 决策"与"确定性规则 / 逻辑回归"作为 Agent 微任务控制器**（Good Judgment 的规则臂、Measure Before You Train 的 LR、选项通道攻击的 100% 规则都暗示规则常常够用）。
5. **S1 训练数据必须含错误后状态**（JevAgentHarness）与**S1 信记录不信观察**（Claim Laundering）两个发现尚未被任何复现配方吸收。

6. **知识系统**（用户原始提法中的"知识"）在文献里只以"记忆选择"与"检索相关性"出现；"S1 维护结构化知识（本体、规则库、版本化事实）"没有工作——Jarvis 的版本化任务记录与 Jev-DLC 的有界通道是最接近的两个。
7. **中文 / 企业场景的 Agent 证据为零**：所有基准是英文公开环境。

# 08 • 骨干约束：混合（DeltaNet / Mamba 类）架构对 Jev 式推理与训练的影响

> 口径：**只调研，不选型**。用户要求"有 mamba 的都有这类问题，先调研再选型"。本章整理：Jev 式接口依赖的三个结构假设；混合骨干在哪一步破坏它们；开源复现各自怎么绕；推理系统文献能借什么；哪些问题没人研究。

## 8.1 Jev 式接口依赖的三个结构假设

Archer Hume 对托管 Jev 的探针（architecture）与所有开源复现（02 章）共享同一骨架：

1. **共享状态前缀**：状态编码一次，所有问题复用其缓存。"因果注意力描述哪些位置能用哪些信息，而不是输入 token 必须执行的顺序"——所以 prefill 阶段可以并行。
2. **问题分支隔离**：每个问题（及其选项）只能看见状态和自己，看不见兄弟分支。隔离给了接口语义："问客户是否生气不应改变票据进哪个队列"。探针证据：秘密放在兄弟分支 → 0.00，放在状态 → 概率上升。
3. **位置重置 / 读出**：每个分支的位置 ID 从状态末尾重新开始；在分支末 token 读出。

在**纯注意力**模型上，1–3 可以用一个树形注意力掩码 + 位置 ID 重置在一次前向里实现（Kev README："在纯注意力模型上，行与掩码给出相同概率"；Kev）。块因果论文证明隔离本身就有价值：仅隔离把测试翻转率 8.30%→3.82%、OOD 7.54%→3.71%，只重置位置更差（2610.01601）。

## 8.2 混合骨干在哪一步破坏假设

| 事实 | 出处 |
|---|---|
| Qwen3.5-9B-Base：32 层 = **24 Gated DeltaNet（线性注意力）+ 8 全注意力**，hidden 4,096 | Kev-9B 模型卡 |
| Qwen3.5-0.8B-Base：24 层 = **18 Gated DeltaNet + 6 门控全注意力** | qwen-rlcd |
| "Qwen3.5 与 Qwen3.8 混合注意力层与 Gated DeltaNet 层，后者是递归的，**忽略注意力掩码**" | Kev README |
| "树形注意力掩码不能在递归层内隔离兄弟分支" | qwen-rlcd |
| 混合模型的递归层**原地更新状态**，部分前缀重叠的缓存条目无法回滚，只能精确匹配命中 | Marconi 2411.19379 |
| 缓存状态有**历史依赖**：相同 token 序列在不同缓存操作序列下产生不同缓存状态，前缀匹配不足以保证正确复用 | Cache Engineering 2610.28577 |

已核实的层配置（2026-10-28 直接读取 Hugging Face 上各仓库的 `config.json`；全部为 `Qwen3_5ForConditionalGeneration`，`full_attention_interval = 4`，即每 4 层 1 层全注意力、3 层 Gated DeltaNet；词表 248,320，上下文 262,144）：

| 模型 | 层数 | 全注意力 / 线性注意力 | hidden | 注意力头 / KV 头 | FFN |
|---|---|---|---|---|---|
| Qwen3.5-0.8B（Base / Instruct 同） | 24 | 6 / 18 | 1,024 | 8 / 2 | 3,584 |
| Qwen3.5-2B（同） | 24 | 6 / 18 | 2,048 | 8 / 2 | 6,144 |
| Qwen3.5-4B（同） | 32 | 8 / 24 | 2,560 | 16 / 4 | 9,216 |
| Qwen3.5-9B（同） | 32 | 8 / 24 | 4,096 | 16 / 4 | 12,288 |
| Qwen3.5-27B、Qwen3.6-27B、**Qwen3.8-27B** | 64 | 16 / 48 | 5,120 | 24 / 4 | 17,408 |

三代 27B 的形状完全相同，差别只在权重；Qwen3.8 系列**没有 27B 以下的尺寸**（Hugging Face 上只有 `Qwen3.8-27B`、`Qwen3.8-2.4T-A95B`、`Qwen3.8-Flash-Next`，后两者为 MoE），Qwen3.6 也只有 27B 与 35B-A3B。因此"从小到大"的同架构阶梯只能是 Qwen3.5-0.8B / 2B / 4B / 9B → 27B（3.5 / 3.6 / 3.8 任一），这与 Kev、OneJev 等复现实际使用的四档一致（12 章 §12.5）。本机 `/mnt/cephfs/models/` 已有完整且未量化的 Qwen3.5-27B、Qwen3.6-27B、Qwen3.8-27B 三个 27B 检查点，可直接做"同形状、跨代权重"的对照——这正好把"小端与大端跨代"这一变量变成可测量的量：同一套决策评测在 3.5-27B 与 3.8-27B 上的差，就是跨代预训练带来的差，与尺寸无关。

**含义**：递归层让假设 2（隔离）不能靠掩码实现——分支 A 的 token 会通过递归状态"流进"分支 B。假设 1（共享前缀）仍成立，但复用的是**递归状态快照**而非 KV。

## 8.3 开源复现的三种绕法

| 方法 | 做法 | 代价 / 证据 | 出处 |
|---|---|---|---|
| **逐行执行（Kev）** | 每个问题一行："状态 + 该问题"，位置同树掩码方案；状态缓存计算一次、每行复用；服务端按 token 预算（每次前向一个最大 16,384 token 的行）分批，"内存不随问题数增长、答案不依赖分批" | 隔离精确；每行要重新把状态的递归状态读入；`forward()`（所有已发布数字的来源）与服务端结果在 fp32 舍入内一致 | Kev |
| **前缀分叉（qwen-rlcd）** | 预填状态保留缓存（注意力层 KV + DeltaNet 层 conv 与递归状态）；沿 batch 维复制一行一分支；所有"问题 + 答案"分支右填充、同一位置偏移一批跑；在各分支最后真实 token 读隐状态 | 比每分支一次前向快 8–19×；分块分支约束内存；0.8B 实权重上分叉 vs 顺序误差 4.8e-5（容差 1e-3），递归状态清零的阴性对照 6.3；**"穿过缓存的梯度检查推迟到训练时"**——训练暂停 | qwen-rlcd |
| **共享上下文锚定 + 候选前缀共享 + 决策引导剪枝（FastJEV）** | 复用递归初始状态、省略未用的最终递归缓存；保留后续分支需要的中间状态；按小无标签集上的相对分数变化剪枝深度 | 候选深度 −43.75–45.83%，保留 93.66–97.52% 任务分数；**"候选前缀共享能减少重复计算但会增加延迟"**；"共享粒度与执行调度要一起设计" | 2610.11379 |

另外两个与架构相关的训练侧选择：

- **选择性适配**：LoRA 保留在注意力与 Gated DeltaNet 投影上、去掉 FFN 适配器，MC11 上优于全模块基线且可训练参数减半以上（2610.35654）；Kev-9B 的 LoRA 也打在注意力、MLP 和 DeltaNet 投影上（45.4M 参数）。
- **StartLux Instant**：在**全注意力层**内对提示做双向注意力（llama.cpp 非因果标志、vLLM 插件）——只改注意力层，递归层不动（StartLux）。这说明在混合骨干上"改读法"的自由度集中在少数注意力层。

## 8.4 推理系统文献能借什么

| 工作 | 适用层 | 要点 | 出处 |
|---|---|---|---|
| Hydragen | 注意力 | 共享前缀与唯一后缀分开计算注意力 | 2402.05099 |
| DeFT | 注意力 | 树形 KV 的 IO 复用与负载均衡 | 2404.00242 |
| Block-Attention | 注意力 | 文档分块独立算 KV，最后一块看全部 | 2409.15355 |
| IPPD | 注意力 | 虚拟位置 ID + 掩码操纵在一个提示内并行答多个同上下文问题，不改架构 | 2609.05707 |
| Visual Jev | 两者（实现上批处理隔离后缀） | 图像与公共上下文编码一次、隔离问题后缀批处理：N=32 时暖态 8.9× 于串行、3.4× 于重算前缀的批处理，峰值内存更高；类型化头无一致优势 | 2609.25845 |
| Marconi | 递归 | 混合模型前缀缓存的准入/逐出策略：token 命中率最高 34.4×、TTFT −71.1% | 2411.19379 |
| Cache Engineering | 两者 | Agent 直接 drop/repos 缓存；历史依赖的服务挑战 | 2610.28577 |
| FastJEV | 两者 | 见 8.3 | 2610.11379 |

注意力层的工作（前四项）解决的是**同一问题**的不同面：在树上共享前缀的 IO。它们都假设掩码有效，因此只覆盖混合骨干中的注意力层；递归层只有 Marconi 与 FastJEV 两篇。

## 8.5 纯注意力骨干作为对照

复现工作中用到的纯注意力骨干：Qwen3 系列（OpenJev-RLCD 的 Qwen3-1.7B；FunDM 的 Qwen3-8B；System X / SHIFT-JEV / Microtask 的 Qwen3-0.6B–8B）、Gemma 3（daseinlabs 在冻结 Gemma 3 4B 上的决策头）、Qwen3-8B / Gemma 4 12B（Prism-1）、Gemma 4 31B（Releasing Inner Jev）。在这些骨干上，Kev README 所述的"行与掩码等价"成立，树掩码方案可直接训练（梯度穿过共享前缀没有递归状态问题）。

**成本对比的空白**：没有工作在同等参数量下比较"混合骨干 + 逐行/分叉"与"纯注意力 + 树掩码"的决策准确率、校准与延迟。现有数字分散：OneJev（Qwen3.5 混合）0.8B 31/51 ms、4B 64/104、9B 81/131（OneJev）；Intern-Decision 4B 44.16 ms（2610.22131）；this-that 2B 30.9 ms（2609.23886）；测量条件各不相同。

## 8.6 本章矩阵

| 问题 | 纯注意力 | 混合（DeltaNet） | 证据状态 |
|---|---|---|---|
| 共享状态前缀（推理） | KV 复用，成熟 | 递归状态快照复用（Kev、qwen-rlcd、FastJEV） | 都可做 |
| 分支隔离（推理） | 树掩码一次前向 | 逐行 / 前缀分叉（多行 batch） | 混合可做，内存与调度代价有数字（8–19×、FastJEV 的延迟警告） |
| 分支隔离（**训练**） | 树掩码，梯度自然流过 | 分叉缓存需穿过复制的递归状态求梯度 | **qwen-rlcd 明确推迟；无任何文献** |
| 前缀缓存服务 | vLLM 等成熟 | Marconi 式准入/逐出 | 混合有一篇 |

| 问题 | 纯注意力 | 混合（DeltaNet） | 证据状态 |
|---|---|---|---|
| 读法改动（双向等） | 全层可改 | 只有注意力层可改（StartLux） | 已有实践 |
| 适配器位置 | 任意 | 注意力 + DeltaNet 投影，去 FFN（2610.35654） | 一篇 |
| 同参数量混合 vs 纯注意力的决策质量 | — | — | **无** |

## 8.7 盲区（供选型前补齐）

1. **训练时的分支隔离**在混合骨干上没有文献：Kev 的训练用"逐行"（每问题一行），等价但代价是状态重复编码；qwen-rlcd 的分叉方案在训练上"推迟"。要么接受逐行训练成本，要么证明穿过复制递归状态的梯度正确——两者都没有公开数字。
2. **递归层对"大状态里的无关细节"是否比注意力更敏感**：D2/D4 的证据（Jev 20k token 内检索无误，但多次更新互相干扰）全部来自托管 Jev，架构未知；无开源混合 vs 纯注意力的对照。
3. **顺序偏置的结构性缓解**（块因果、Prism-1、Runoff）在混合骨干上如何实现：块因果依赖掩码；Runoff 是两次前向（与架构无关）；Prism-1 的实现细节未核。
4. **量化与融合核**：Kev 在 CUDA 上用融合 DeltaNet 核 + CUDA 图，bf16 对 fp32 最多 0.03/0.05 偏差；Chinese Decision 的 Q8_0 改 0.4–1.1% top-1——都是单点数字，没有按层类型拆分。
5. ~~Qwen3.6 / 3.8 的层配置没有可核实的数字~~——已于 2026-10-28 从 `config.json` 核实并列在 8.2；剩余的空白是 Qwen3.8 没有小尺寸，小→大阶梯必须跨代（Qwen3.5 小模型 → 3.8-27B），跨代的预训练 / 后训练差异本身是一个未被任何文献控制的变量。

# 09 • 工作-问题矩阵与盲区汇总

> 本章把 01–08 的结论压成两张表：(1) 每个维度下"哪类问题被哪些工作解决到什么程度"；(2) 跨维度的盲区清单，按"我们自训 Jev 类模型时会直接撞上"的程度排序。细节与数字都在各章，此处只给索引。

## 9.1 五维度总览

| 维度 | 问题重述（按用户口径） | 已解决 | 部分解决 | 未解决 |
|---|---|---|---|---|
| **D1 ICL** | 决策微调后的单遍模型是否保留 ICL；如何利用；业务人员能用哪些提示杠杆 | 选项名与定义是最强杠杆（03 §3.2.2）；状态内示例/先例有效（JevKT、审核先例） | 示例数量与格式的效应只有间接证据；上游 ICL 机制（标签空间、格式、符号电路）未在决策模型上验证 | **决策微调对 ICL 的保留/破坏没有直接测量**；非技术人员写的提示的效果没有被测 |
| **D2 符号指令** | 模型是否忠实执行明确的符号规则（阈值、日期、否定、兜底） | "读"类事实探针稳（Reading Right 0.96–1.00 代码组合） | 否定/层级有免标签度量；算术/日期边界清楚（官方建议放代码） | **拒绝/兜底是最弱环节**（99%/7%、97.9→23.1）；等价措辞不变性无缓解 |
| **D3 规则语言** | 给非技术专家一套逻辑原语，用文字写业务规则，模型忠实执行 | Skill 范式对生成式 Agent 有效（+16.6）；NL→IR 编译器有多种中间表示 | SemTree（Yes/No/Unknown 树、按裁判编译）、概率感知确定性裁决（并集界）是单遍模型上的雏形 | **没有面向单遍模型的规则语言**；原语可执行性未分级；Unknown 原语与"模型说不了不知道"矛盾；L1/L2 规则（依赖/新框架）即使推理模型也只有 35%/13% |
| **D4 一致性** | 定义并度量所有让"同一判断"概率变化的因素 | 顺序（结构性缓解）、先验偏移（EM/KL 锚）、重复性 | 30 个子维度中 26 个有定义和度量 | **缓解只覆盖 2 项**；版本漂移、教师偏差无实证；无统一一致性基准；中文零证据 |
| **D5 Agent/知识** | 快/慢协同能否替代"慢思考 + 执行反馈" | 记忆选择/判断（预注册非劣）；动作空间被代码枚举的领域 Agent | 切换信号四类，但置信 ≠ "需要思考"；S1 监控 S2 只有 SOMA | **省钱不等于更好**（三篇反方）；收益核算无标准；知识结构维护无工作；规则/LR 基线常够用 |
| **08 骨干** | 混合骨干对 Jev 式接口的约束 | 推理时隔离（逐行/分叉）可做 | 选择性适配、注意力层双向读法 | **训练时分支隔离无文献**；同参数量混合 vs 纯注意力无对照 |

## 9.2 工作 → 问题矩阵（主要工作）

列 = 维度；格内 = 该工作对该维度的贡献类型：**E** 证据（度量了问题）、**M** 缓解（给出可用方法）、**T** 工具/基准、**N** 反方证据。

| 工作 | D1 | D2 | D3 | D4 | D5 | 08 |
|---|---|---|---|---|---|---|
| TypeSafe 文档（primitives / patterns / jaggedness / cookbooks / agent-skill） | M | E | M | E | M | — |
| Archer Hume 架构探针 | — | — | — | E | — | E |
| Kev | — | — | — | T(permute) | — | M(逐行) |
| qwen-rlcd | — | — | — | — | — | M(分叉) |
| StartLux-Decision | — | — | — | M(校准) | M(AutoThink) | M(双向) |
| Releasing Inner Jev / LLM-as-Jev / LDM / FunDM / AnyJev | — | — | — | E(读出) | — | — |
| OneJev / Open-Jev / Tev1 / Nimble / Intern-Decision / Chinese Decision | — | — | — | E | — | E(延迟) |
| PACT / Prism-1 / Runoff / Block-causal | — | — | — | M(顺序) | — | — |
| SanSi / LEV | — | — | — | — | M(深度) | — |
| 2609.26758 选项名 / 2610.02586 定义 | E, M | — | E | E | — | — |
| JevKT / 审核先例 / MemCom / cheat-sheet / Jev-LDE | E | — | — | — | — | — |
| CALICO / Goldsmith | M | — | M | — | — | — |
| In-context fixation / 语义锚 / schema | E(上游) | — | — | — | — | — |
| Reading Right | — | E, M | M | — | — | — |
| 否定公理 2609.33209 / 层级 2609.33971 / 合取 2610.19619 | — | E | — | E | — | — |
| 拒绝瓶颈 / Lost in the Fallback / 法律弃权 / 拒绝迁移 / 退役门 | — | E | E | E | — | — |

| 工作 | D1 | D2 | D3 | D4 | D5 | 08 |
|---|---|---|---|---|---|---|
| JevOut / JevAdvBench / 选项通道 / Same Attack / TrustJev / DICE | — | E | — | E | N | — |
| 2610.30045 措辞 / 表格 2610.19536 | — | E | — | E | — | — |
| IIA 2610.16655 / 选择偏差 2610.35826 / 请求独立性 2610.14631 | — | — | — | E | — | — |
| 多正确 2610.29217 / 序数压缩 2609.38827 | — | — | E | E | — | — |
| 自知 2610.01006 / 两种不确定性 2610.33258 / 字面锁定 2610.22526 | — | — | — | E | — | — |
| 流行率偏移 2610.26325 / SHIFT-JEV | — | — | — | E, M | M | — |
| 教师偏差 2610.26797 | — | — | — | E(理论) | — | — |
| SemTree | — | — | M | E(版本) | — | — |
| 概率感知确定性裁决 2610.10978 / 语义查询优化 2610.08089 / JEVDB | — | — | M | M(组合) | — | — |
| Jev-Guard / SafePyramid / LPG / gpt-oss-safeguard / PolicyGuard | — | — | E, M | — | M | — |
| Artic / FlashScript / TraceCompiler / Formal Skill / P2T / SIRNA / Cedar / ARc / LSP | — | — | M(IR) | — | — | — |
| SkillsBench / 138K SKILL.md / Skill coverage / SkillSentry / Auto-Policy | — | — | E | — | — | — |
| Code Owns the Simulation / What Can't Jev Decide | — | E | M(边界) | E | N | — |
| When Faster Decisions… / Good Judgment Bad Advice / JevAgentHarness / Microtask / Measure Before You Train / JEVal | — | — | — | — | N, M | — |
| System1-Arena / Fast Models Slow Evidence / DecisionPivot / TypedBench | — | E | — | E | T | — |
| Selective Reasoning / SOMA / System Switch / VoI / Truncated Reasoning / TORSI | — | — | — | — | M | — |
| 选择 vs 抽取 / Mnemon / Jev-Mem / SJC / 压缩后续问题 | — | — | — | — | E, M | — |
| REFLEX / Jev-LiteMAS / S1-MAS / BLADE / Jarvis | — | — | — | — | M | — |
| Jev-Mobile / JEV-Star / SearchJev / JevCoder / Decision4Rec / NIOCIS | — | — | M(动作空间) | — | M | — |
| Claim Laundering / Jev-DLC | — | — | — | E | E, M | — |
| Marconi / FastJEV / Hydragen / DeFT / Block-Attention / IPPD / Visual Jev / 选择性适配 | — | — | — | — | — | M |

## 9.3 盲区汇总（按对自训工作的影响排序）

### 一级：直接决定训练配方能否成立

1. **决策微调是否保留 ICL（D1）**。所有复现只报准确率/ECE，没有人在微调前后测"状态内示例改变决策的幅度"。如果 RLCD/软标签蒸馏抹掉了 ICL，D1 与 D3 的前提都不成立。
2. **训练时分支隔离在混合骨干上无文献（08）**。Qwen3.5 全系是 DeltaNet 混合；Kev 用逐行训练，qwen-rlcd 推迟。要么证明梯度穿过复制递归状态正确，要么接受逐行成本，要么换纯注意力骨干——三条路都没有公开数字。
3. **教师偏差继承无实证（D4-D5）**。小模型 + Jev 标签（AgentDecision-4B）或 + 大 LLM 标签（Releasing Inner Jev）是主流配方；理论说学生继承教师的 IIA/序数/否定缺陷且更多数据不消除；没有人测过。
4. **拒绝/兜底/Unknown（D2-F6、D3-盲区 3）**。规则语言需要"不知道"原语；单遍模型在这一项上最弱；缓解只有三元契约（退役门）一例。

### 二级：决定规则语言的形状

1. **没有面向单遍模型的规则语言**；原语可执行性没有按"读 / 组合 / 需中间步骤"分级（D3）。
2. **问题形式等价性证据矛盾**（Noul 归一化 vs Choice，医学 +、意图 −8.7）：每个原语在目标模型上都要单测（D4-B6）。
3. **等价措辞不变性无缓解**（D2/D4-C3）：规则语言要么模板化措辞，要么训练不变性；都没做。
4. **分解后的概率不自洽**（TV 0.219–0.349，重构 −22.9）：规则树的节点概率不能直接相乘（D4-C1）。
5. **按裁判编译**（SemTree 67.70→47.87）：业务规则与模型实际执行的树之间需要编译步骤，且随模型版本变化（D3-6、D4-A3）。

### 三级：决定部署与评估

1. **无统一一致性基准**；决策级配对评测不是规范（D4）。
2. **快慢协同的收益核算无标准**（D5-1）；置信不是"需要思考"信号（D5-2）。
3. **规则/逻辑回归基线常够用**，但没有工作系统比较（D5-4）。
4. **S1 训练数据要含错误后状态、S1 信记录不信观察**——未进任何配方（D5-5）。

5. **中文/企业场景证据接近零**：一致性、Agent、规则语言全是英文公开数据；中文只有 CJ-Bench 的准确率与 ECE（D4-E5、D5-7）。
6. **知识结构维护**（本体、规则库版本化）无工作（D5-6）。
7. **同参数量混合 vs 纯注意力的决策质量无对照**（08）。

# 10 • 开放问题与度量定义

> 口径："这个阶段只保留分析和调研……先理解问题"。本章**不给训练方案**，只把 09 章的盲区写成可回答的问题，并为每个问题指定文献里已有的度量方式（或指出度量本身也缺失）。目的是让下一阶段的实验有明确的"回答了什么"。

## 10.1 D1：ICL 的保留与利用

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q1.1 | 决策微调（LoRA / 全参 / RLCD / 软标签蒸馏）前后，状态内 k 个示例对决策的边际效应变化多少? | 上游：示例数量-准确率曲线；In-context fixation 的标签槽测试（2605.08295）；JevKT 的零数据 AUC（2610.11135） | 决策模型上没有"示例效应"的标准定义；需要配对（同状态 ± 示例）设计 |
| Q1.2 | 示例放在状态里（JSON 数组）与放在问题的 `examples` 字段里，效应是否相同? | 官方 API 两种放置（state 文档） | 无对照 |
| Q1.3 | 示例标签与选项名冲突时谁赢？（In-context fixation 的"标签槽"在决策模型上的对应） | 2605.08295、2609.26758 | 无 |
| Q1.4 | 非技术人员写的选项名/定义/示例与专家写的相比，决策质量差多少? | CALICO / Goldsmith 的专家编辑流程（2609.14726、2610.09489） | **没有"作者专业度 → 决策质量"的测量** |
| Q1.5 | 定义能否被删（0.8487→0.7971）在中文业务规则上是否成立? | 2610.02586 的删除/矛盾/反转设计 | 中文无数据 |

## 10.2 D2：符号指令

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q2.1 | 哪些符号操作在单遍内可靠（比较、包含、日期先后）、哪些不可靠（算术、计数、多跳）？ | Reading Right 的事实探针 + 代码组合（2610.18579）；What Can't Jev Decide 的"思考 token 分级"（2610.24929）；计数失败 126 变体 | 两种分级没有合并 |
| Q2.2 | 兜底/拒绝的执行率与规则措辞的关系 | PFR 测试（2610.19856）；拒绝瓶颈配对（2609.39496） | 无缓解可测 |
| Q2.3 | 否定、互斥、合取的公理违反量在微调后是增是减? | 免标签公理电池（2609.33209） | 微调前后无对照 |
| Q2.4 | 策略权威 vs 证据的分离能否在小模型上复现? | TrustJev 的配对监督（2610.34826） | 只有一篇 |

## 10.3 D3：规则语言

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q3.1 | 单遍模型能忠实执行的规则子集边界在哪（L0 单规则 / 带一个例外 / L1 依赖 / L2 新框架）？ | SafePyramid 三级（2606.29887）在推理模型上的数字 | 单遍模型上无 |
| Q3.2 | 原语集合的最小充分集是什么？候选：读/比较/包含/例外/Unknown/证据要求/类型化变量 | 编译类工作的 IR 元素（05 §5.2）；SemTree 节点类型；概率感知的 true/false/unknown | 无 |
| Q3.3 | 规则在代码里组合时的误差如何传播? | 并集界（2610.10978）；扇出加权期望错误（2610.08089）；层级 TV（2609.33971） | 三者没有被放在同一个规则树上验证 |
| Q3.4 | "按裁判编译"的编译器对小模型长什么样？换模型版本后规则库退化多少? | SemTree 的换裁判实验（2610.13999） | 无 |
| Q3.5 | 规则的 Skill 部分（怎么做）与 Policy 部分（什么被允许）能否分开表达并测量交互? | Auto-Policy 的区分（2608.25091）；Jev-Guard 策略树（2610.18326） | 无 |
| Q3.6 | 非技术专家写规则的"可执行率"与"修复一轮后的可执行率" | SemTree 节点修复（82.04→86.16）；AFTER 一轮精炼 +3.7–6.7 | 作者非专家的设置无 |

## 10.4 D4：一致性

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q4.1 | 30 个子维度（06 §6.1）在同一模型、同一数据上的联合画像 | 各子维度各有度量 | **无统一基准**；DecisionPivot / TypedBench / System1-Arena 各覆盖一部分 |
| Q4.2 | 顺序、IIA、序数压缩、否定违反在蒸馏学生上与教师的相关性（教师偏差继承） | 各项度量 + Gaussian 代理理论（2610.26797） | 实证无 |
| Q4.3 | 版本漂移：同一规则库在相邻版本间的决策级翻转率 | 2610.35826 的 8 展示累计失败集方法可借 | 无 |
| Q4.4 | 同一判断用 Noul / Choice / Score 表达时的一致性，按任务类型分 | 2609.33209（和为 1.14）、2610.18529、2610.16655（−8.7） | 需按任务类型系统化 |

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q4.5 | 中文下的 E5（语言）、E6（风格）、B3（选项名）效应 | 英文方法可移植 | 中文无 |
| Q4.6 | 决策级配对评测应成为复现工作的报告规范：至少报翻转率、累计失败集、公理违反、读出类型 | 2610.35826、2609.27678、2609.33209、2610.00054 | 需要规范而非新方法 |

## 10.5 D5：Agent 与知识

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q5.1 | "每个成功交付的资源"作为统一核算（含预筛成本、保留集阈值） | 2610.13092 的三指标；2610.02267 的自审计清单 | 需要规范 |
| Q5.2 | 什么信号能预测"需要慢思考"而不只是"答案不确定"? | System Switch 的 AUROC-收益相关（2610.09683）；VoI（2610.21160）；SOMA 的行为判断（2610.26793） | 语言 Agent 上无理论 |
| Q5.3 | S1 决策 vs 确定性规则 vs 逻辑回归作为微任务控制器的头对头 | Good Judgment 的规则臂与安慰剂臂设计（2610.24649）；Measure Before You Train（2610.32955） | 系统比较无 |
| Q5.4 | S1 训练集包含"犯错后状态"与"记录-观察冲突"后，Claim Laundering 的 53–100% 降到多少? | 配对状态构造（2610.25947）；AgentDecision-4B 的轨迹采集（2610.21412） | 两者未结合 |
| Q5.5 | S1 维护结构化知识（本体节点、规则版本、事实有效期）的任务定义 | Jarvis 的版本化任务记录（2610.23804）；Jev-DLC 的有界通道（2610.31521）；退役门三元契约（2610.15710） | 任务本身没有定义 |
| Q5.6 | 为当前问题压缩 vs 为后续问题压缩的权衡在 S1 判断下如何 | 2610.27301 的后续问题协议 | S1 侧无 |

## 10.6 骨干

| # | 问题 | 已有度量 | 度量缺口 |
|---|---|---|---|
| Q6.1 | 在混合骨干上，分叉缓存的梯度是否等价于逐行训练? | qwen-rlcd 的推理等价测试（4.8e-5） | 训练侧无 |
| Q6.2 | 同参数量下混合 vs 纯注意力：准确率、校准、顺序翻转率、延迟 | 各复现的单点数字（08 §8.5） | 对照无 |
| Q6.3 | 递归层对无关细节/多次更新干扰的敏感度是否高于注意力层 | What Can't Jev Decide 的单因素设计 | 架构对照无 |
| Q6.4 | 顺序偏置的结构性缓解在混合骨干上的实现路径 | 块因果（掩码）、Runoff（两次前向）、Prism-1 | 混合骨干上无 |

## 10.7 跨维度的三个元问题

1. **"读 / 组合 / 需中间步骤"三分法能否成为原语分级、一致性子维度与快慢切换的共同坐标?** 三个维度各自给了一条边界（Reading Right、Code Owns the Simulation、What Can't Jev Decide），没有被统一。
2. **置信度要拆成几个数?** 校准、判别、敏感性、人类分歧 vs 决策风险、自知——至少五个含义，而接口只返回一个概率。
3. **规则语言、一致性基准、Agent 收益核算都需要"决策级配对"评测**——这是三个维度共享的方法论缺口，而不是三个独立问题。

# 11 · 参考文献

本报告引用的全部来源。arXiv 论文按发表日期排序（日期取自 arXiv 摘要页的首次提交日期）；文档、仓库与网页按类别列出。所有数字在正文中都标注了来源；正文中"未核实、已删除"的说法在 README §方法论中说明。

## 11.1 arXiv 论文（共 283 篇）

| ID | 日期 | 标题 |
|---|---|---|
| 2102.09690 | 2021-02-19 | Calibrate Before Use: Improving Few-Shot Performance of Language Models |
| 2110.15943 | 2021-10-29 | MetaICL: Learning to Learn In Context |
| 2202.12837 | 2022-02-25 | Rethinking the Role of Demonstrations: What Makes In-Context Learning Work? |
| 2303.03846 | 2023-03-07 | Larger language models do in-context learning differently |
| 2305.08298 | 2023-05-15 | Symbol tuning improves in-context learning in language models |
| 2305.14160 | 2023-05-23 | Label Words are Anchors: An Information Flow Perspective for Understanding In-Context Learning |
| 2309.17249 | 2023-09-29 | Batch Calibration: Rethinking Calibration for In-Context Learning and Prompt Engineering |
| 2310.15213 | 2023-10-23 | Function Vectors in Large Language Models |
| 2310.15916 | 2023-10-24 | In-Context Learning Creates Task Vectors |
| 2311.04235 | 2023-11-06 | Can LLMs Follow Simple Rules? |
| 2402.05099 | 2024-02-07 | Hydragen: High-Throughput LLM Inference with Shared Prefixes |
| 2404.00242 | 2024-03-30 | DeFT: Decoding with Flash Tree-attention for Efficient Tree-structured LLM Inference |
| 2404.11018 | 2024-04-17 | Many-Shot In-Context Learning |
| 2405.00200 | 2024-04-30 | In-Context Learning with Long-Context Models: An In-Depth Exploration |
| 2405.19874 | 2024-05-30 | Is In-Context Learning Sufficient for Instruction Following in LLMs? |
| 2409.15355 | 2024-09-14 | Block-Attention for Efficient Prefilling |
| 2410.03608 | 2024-10-04 | TICKing All the Boxes: Generated Checklists Improve LLM Evaluation and Generation |
| 2410.08328 | 2024-10-10 | Agents Thinking Fast and Slow: A Talker-Reasoner Architecture |
| 2411.19379 | 2024-11-28 | Marconi: Prefix Caching for the Era of Hybrid LLMs |
| 2412.08972 | 2024-12-12 | RuleArena: A Benchmark for Rule-Guided Reasoning with LLMs in Real-World Scenarios |
| 2501.17161 | 2025-01-28 | SFT Memorizes, RL Generalizes: A Comparative Study of Foundation Model Post-training |
| 2501.19383 | 2025-01-31 | Decoding-based Regression |
| 2502.14628 | 2025-02-20 | PEARL: Towards Permutation-Resilient LLMs |
| 2502.18695 | 2025-02-25 | Policy-as-Prompt: Rethinking Content Moderation in the Age of Large Language Models |
| 2503.02623 | 2025-03-04 | Rewarding Doubt: A Reinforcement Learning Approach to Calibrated Confidence Expression of Large Language Models |
| 2505.14313 | 2025-05-20 | Teaching Small Language Models to Learn Logic through Meta-Learning |
| 2505.19766 | 2025-05-26 | PAM: Training Policy-Aligned Moderation Filters at Scale |
| 2506.06266 | 2025-06-06 | Cartridges: Lightweight and general-purpose long context representations via self-study |
| 2506.12796 | 2025-06-15 | Surprise Calibration for Better In-Context Learning |
| 2507.02833 | 2025-07-03 | Generalizing Verifiable Instruction Following |
| 2507.17746 | 2025-07-23 | Rubrics as Rewards: Reinforcement Learning Beyond Verifiable Domains |
| 2508.04632 | 2025-08-06 | IFDecorator: Wrapping Instruction Following Reinforcement Learning with Verifiable Rewards |
| 2509.02563 | 2025-09-02 | DynaGuard: A Dynamic Guardian Model With User-Defined Policies |
| 2509.10414 | 2025-09-12 | Is In-Context Learning Learning? |
| 2509.20820 | 2025-09-25 | Distilling Many-Shot In-Context Learning into a Cheat Sheet |
| 2510.06084 | 2025-10-07 | Spectrum Tuning: Post-Training for Distributional Coverage and In-Context Steerability |
| 2510.16092 | 2025-10-17 | Compressing Many-Shots in In-Context Learning |
| 2510.22691 | 2025-10-26 | SALSA: Single-pass Autoregressive LLM Structured Classification |
| 2511.09008 | 2025-11-12 | A Neurosymbolic Approach to Natural Language Formalization and Verification |
| 2511.21038 | 2025-11-26 | Semantic Anchors in In-Context Learning: Why Small LLMs Cannot Flip Their Labels |
| 2512.04408 | 2025-12-04 | Executable Governance for AI: Translating Policies into Rules Using LLMs |
| 2512.12677 | 2025-12-14 | Fine-Tuning Causal LLMs for Text Classification: Embedding-Based vs. Instruction-Based Approaches |

| ID | 日期 | 标题 |
|---|---|---|
| 2512.17325 | 2025-12-19 | Task Schema and Binding: A Double Dissociation Study of In-Context Learning |
| 2512.22258 | 2025-12-24 | Logic Sketch Prompting (LSP): A Deterministic and Interpretable Prompting Method |
| 2601.10156 | 2026-01-15 | ToolSafe: Enhancing Tool Invocation Safety of LLM-based agents via Proactive Step-level Guardrail and Feedback |
| 2601.13284 | 2026-01-19 | Balancing Classification and Calibration Performance in Decision-Making LLMs via Calibration Aware Reinforcement Learning |
| 2602.12662 | 2026-02-13 | Think Fast and Slow: Step-Level Cognitive Depth Adaptation for LLM Agents |
| 2602.12670 | 2026-02-13 | SkillsBench: Benchmarking How Well Agent Skills Work Across Diverse Tasks |
| 2602.15902 | 2026-02-13 | Doc-to-LoRA: Learning to Instantly Internalize Contexts |
| 2603.05829 | 2026-03-06 | Test-Time Adaptation via Many-Shot Prompting: Benefits, Limits, and Pitfalls |
| 2604.09075 | 2026-04-10 | Hierarchical Alignment: Enforcing Hierarchical Instruction-Following in LLMs through Logical Consistency |
| 2604.14723 | 2026-04-16 | Bounded Autonomy for Enterprise AI: Typed Action Contracts and Consumer-Side Execution |
| 2604.25203 | 2026-04-28 | BARRED: Synthetic Training of Custom Policy Guardrails via Asymmetric Debate |
| 2605.02028 | 2026-05-03 | Language models fail at extended rule following |
| 2605.08295 | 2026-05-08 | In-Context Fixation: When Demonstrated Labels Override Semantics in Few-Shot Classification |
| 2605.16386 | 2026-05-11 | Auditing Multimodal LLM Raters: Central Tendency Bias in Clinical Ordinal Scoring |
| 2605.17329 | 2026-05-17 | LPG: Balancing Efficiency and Policy Reasoning in Latent Policy Guardrails |
| 2605.19604 | 2026-05-19 | Formal Skill: Programmable Runtime Skills for Efficient and Accurate LLM Agents |
| 2605.26128 | 2026-05-20 | The Constraint Tax: Measuring Validity-Correctness Tradeoffs in Structured Outputs for Small Language Models |
| 2605.29801 | 2026-05-28 | AgentDoG 1.5: A Lightweight and Scalable Alignment Framework for AI Agent Safety and Security |
| 2606.06087 | 2026-06-04 | LatentSkill: From In-Context Textual Skills to In-Weight Latent Skills for LLM Agents |
| 2606.07808 | 2026-06-05 | Where Instruction Hierarchy Breaks: Diagnosing and Repairing Failures in Reasoning Language Models |
| 2606.08932 | 2026-06-08 | From Statute to Control Flow: Span-Grounded Deontic Trees for Defeasible Scope Parsing |
| 2606.20659 | 2026-06-09 | Skill Coverage: A Test Adequacy Metric for Agent Skills |
| 2606.11543 | 2026-06-10 | SkillJuror: Measuring How Agent Skill Organization Changes Runtime Behavior |
| 2606.19183 | 2026-06-17 | Language Models as Interfaces, Not Oracles: A Hybrid LLM-ML System for Pediatric Appendicitis |
| 2606.20978 | 2026-06-18 | How Should Agents Read Demonstrations? Hierarchical Structure Beats Flat Action Logs |
| 2606.23127 | 2026-06-22 | Managing Procedural Memory in LLM Agents: Control, Adaptation, and Evaluation |
| 2606.26649 | 2026-06-25 | Autoformalization of Agent Instructions into Policy-as-Code |
| 2606.29887 | 2026-06-29 | SafePyramid: A Hierarchical Benchmark for In-context Policy Guardrailing |
| 2607.12149 | 2026-07-13 | It is not enough to give your moderation rules to ChatGPT: Policy-as-Prompt Moderation and Its Potential Impacts on Community Governance |
| 2607.21642 | 2026-07-21 | CARE: Pre-Execution Command Verification for Shell-Executing LLM Agents |
| 2608.00396 | 2026-08-01 | Verifiable Checks for Business Rule Consistency |
| 2608.02680 | 2026-08-03 | TraceCompiler: Skill-Guided Mining and Compilation of LLM Agent Traces into Mostly Deterministic Workflows |
| 2608.02687 | 2026-08-03 | PolicyGuard: Prompt-Configurable Semantic DLP for LLM Coding Agents |
| 2608.08254 | 2026-08-08 | Your Prompt Is Not the Only Prompt: How Much Do LLMs Weight Structured-Output Schema Descriptions? |
| 2608.08453 | 2026-08-09 | What Keeps Agent Skills from Being Reusable? Evidence from 138K SKILL.md Files |
| 2608.14693 | 2026-08-09 | Domain Agnostic Text Redaction from Natural Language Rules using Instruction Tuning |
| 2608.09253 | 2026-08-10 | SkillSentry: Reliable Skill Execution for LLM Agents via Runtime Assurance |
| 2608.21341 | 2026-08-21 | Natural-Language Workflows Are Not Software Yet: Artifact-Driven Compilation for Reliable Agent Execution |
| 2608.24777 | 2026-08-25 | StepGuard: Learning Step-Level Guardrails with Scalable Supervision and Safety-Utility Balancing |
| 2608.25091 | 2026-08-25 | Auto-Policy, not Auto-Skill: Compiled Agent Skills for the Physical World |
| 2610.00025 | 2026-09-01 | Measuring the Microtask Eligibility Gap: When Is an Off-the-Shelf SLM Enough for an Agent Harness? |
| 2609.05707 | 2026-09-04 | Intra-Prompt Parallel Decoding for Common-Context Question Answering |
| 2610.00054 | 2026-09-04 | The First Token Is Not the Verdict: Hidden Costs of Reading LLM Judges Without Generating |
| 2609.11310 | 2026-09-10 | Your Model Already Knows Don't Teach It, Learn to Ask It: Soft Prompting for Few-Shot Adaptation of Vision-Language Models |
| 2609.14726 | 2026-09-13 | CALICO: A Human-Centered, Codebook-Aligned System for Annotation |
| 2609.23136 | 2026-09-19 | Intent Interpretation at RIC Timescales: Jev Decision Models versus Large Language Models in 6G Open RAN |
| 2609.23742 | 2026-09-20 | Constrained Decoding Eliminates Structural Failures in Small LLMs but Reveals a Scale-Dependent Semantic Gap |
| 2609.23886 | 2026-09-20 | this-that-model-1.0: A typed decision model that decides in 30 ms, for a millionth of a cent |

| ID | 日期 | 标题 |
|---|---|---|
| 2609.23986 | 2026-09-21 | Jev-Mem: System-One-Controlled Agentic Memory for Efficient AI Agents |
| 2609.24052 | 2026-09-21 | Calibrated Decisions at Scale: Converting Police Crash Narratives into Probabilistic Crash Variables with a System One Model (Jev) |
| 2609.24574 | 2026-09-21 | Evaluating Decision Models for Text Annotation in Computational Social Science |
| 2609.25845 | 2026-09-22 | Visual Jev: Accurate and Efficient Decisions from Shared Visual Context |
| 2609.26532 | 2026-09-22 | REFLEX with Jev for Efficient Selective Control in LLM Agents |
| 2609.26550 | 2026-09-22 | JEV-as-a-Judge: Accept When Confident, Escalate When Unsure |
| 2609.26758 | 2026-09-22 | Type-Safe Is Not Error-Free: Typed Decision Models Follow the Option Name, Not the Definition Bound to It |
| 2609.27331 | 2026-09-23 | JEV-Star: Fast, Low-Cost StarCraft II Control with Language-Model Planning |
| 2609.27535 | 2026-09-23 | KITE: Scaling Jev Population Experiments with Sparse Flagship Calibration |
| 2609.27678 | 2026-09-23 | Same Scores, Different Decisions: Evaluating JEV and Language Models for Legal Document Understanding |
| 2609.28587 | 2026-09-23 | NumericJev: Jev-like LLM Numerical Decoding with Multiway Decision Trees |
| 2609.28613 | 2026-09-23 | Decision Hijacking: Prompt Injection Attacks on Jev's Typed Probabilistic Decisions |
| 2609.28919 | 2026-09-24 | Harness Tokenomics: A Router for the Enterprise Agentic Control Plane |
| 2609.29429 | 2026-09-24 | Just Ask Jev: Reinforcement Learning for Calibrated Decisions as a Zero-Shot Detector of AI Alignment Failures |
| 2609.29769 | 2026-09-24 | Decision Models vs. LLMs as Rubric Judges: Cheaper, Faster, and Wrong in the Same Places |
| 2609.30186 | 2026-09-24 | Jev-Mobile: Jev as an Executor for Mobile GUI Agents |
| 2609.30216 | 2026-09-24 | Jev in the Wild: A Data-Driven Analysis of the Jev Model's Functionality, Applications and Ecosystem |
| 2609.30243 | 2026-09-24 | JevOut: Natural Context Can Flip Decision Models |
| 2609.30454 | 2026-09-24 | Auditing System-1 Models on Biosecurity-Relevant Benchmarks: Calibration, Selective Prediction, and Permutation Instability in a Non-Generative Model |
| 2609.30706 | 2026-09-25 | LAVOIR: Teaching a Single-Pass Decision Encoder When and What to Ask with Amortized Value of Information |
| 2609.30922 | 2026-09-25 | JevSoup: System-One Routing for Training-Free LoRA Composition |
| 2609.31142 | 2026-09-25 | JevAdvBench: A Benchmark and Black-Box Attacks for Reinforcement Learning for Calibrated Decisions Models |
| 2609.32160 | 2026-09-26 | Typed Decision Models: An Early Evidence Audit and Evaluation Checklist |
| 2609.35865 | 2026-09-26 | PACT: Pairwise-Anchored Calibrated Tuning for Single-Token Typed Decisions |
| 2609.33209 | 2026-09-27 | Beyond Calibration: Do a Typed-Decision Model's Probabilities Obey the Probability Axioms? |
| 2609.33401 | 2026-09-27 | Evaluating System One Models for Agent Security Decisions: Reliability, Calibration, and Selective Automation |
| 2609.33609 | 2026-09-27 | You Only Edit Once: Incentivizing In-Context Capability of LLMs via Local Demonstration Refinement |
| 2609.33671 | 2026-09-27 | COGNIT-Guard: Calibrated Standalone Direct-Decision Guardrails with Heterogeneous CPU-NPU Confidence Cascading under Explicit Latency and False-Positive Constraints |
| 2609.33843 | 2026-09-27 | Laya as a Typed Probabilistic Assessor: An Independent Reproduction and a Preregistered Study of Calibration and Selective Escalation |
| 2609.33971 | 2026-09-27 | Do System One Decisions Add Up? A Study of Probabilistic Coherence |
| 2609.37470 | 2026-09-27 | Probability Contracts: Accuracy, Coherence, and Decisions Across LLM Interfaces |
| 2610.13999 | 2026-09-27 | SemTree: Judge-Aware Semantic Decision Trees for Inspectable and Repairable Rule Decisions |
| 2609.34227 | 2026-09-28 | When Does Selection Replace Extraction? A Pre-Registered Test of Agent Memory with a Typed Decision Model |
| 2609.34862 | 2026-09-28 | JEV as a Judge for Agent Trace Security: An Empirical Comparison with Generative LLM Judges |
| 2609.35342 | 2026-09-28 | Jev thinks "I don't know'', but doesn't say it: Introducing Sys1Cal-v1 Dataset for Probability Calibration |
| 2609.36059 | 2026-09-28 | Mnemon: Raw Records, Fast Judgments, Slow Thoughts |
| 2609.36115 | 2026-09-28 | Koa-decision: Fast and Consistent Structured Decision Making with Generative LLMs |
| 2609.36116 | 2026-09-28 | Dyad: Extending Large Language Models with Native Typed Decision-Making |
| 2609.36265 | 2026-09-28 | In-Context Learning Amplifies a Latent Symbolic Circuit |
| 2609.36399 | 2026-09-28 | Calibrated to Whom? Persona and Language Effects on Cultural Values in JEV |
| 2609.37647 | 2026-09-29 | Evaluating and Benchmarking the System One Model Jev |
| 2609.37832 | 2026-09-29 | Can a Cacheable Decision Model Follow Rules? |
| 2610.00346 | 2026-09-29 | Benchmarking System One decision models against trained classifiers and language models for automated decision gates |
| 2609.38827 | 2026-09-30 | More Choices, Fewer Decisions: Ordinal-Scale Bias in JEV-like Direct-Decision Models |
| 2609.38850 | 2026-09-30 | OpenJev-RLCD: A Working RLCD Implementation |
| 2609.39111 | 2026-09-30 | Bongard: Training Machine Intuition |
| 2609.39496 | 2026-09-30 | When the Right Answer Is Missing: An Arithmetic-Dependent Rejection Bottleneck in Jev |

| ID | 日期 | 标题 |
|---|---|---|
| 2610.00437 | 2026-09-30 | JevSpawn: Adaptive Agentic Inference through Compositional Action Spaces |
| 2610.00526 | 2026-09-30 | Rules Amortize, Pairings Don't: Linguistic Structure Determines What Latent Task Representations Can Replace In-Context Learning |
| 2610.00831 | 2026-09-30 | AnyJev Technical Report |
| 2610.01006 | 2026-10-01 | Beyond Answer Confidence: A Controlled Audit of Self-Knowledge in a Black-Box Decision Model |
| 2610.01054 | 2026-10-01 | Capturing In-Context Learning Dynamics with Task Operators |
| 2610.01231 | 2026-10-01 | Judgement in the Age of Jev: From Evaluation Scarcity to Evaluation Abundance |
| 2610.01601 | 2026-10-01 | Permutation-Robust Decision Modeling with Candidate-Independent Block-Causal Attention |
| 2610.01834 | 2026-10-01 | Code Owns the Simulation, Jev Owns the Evaluation |
| 2610.02046 | 2026-10-01 | Prune First, Decide Fast: Scalable Semantic Query Processing with JEVDB |
| 2610.02076 | 2026-10-01 | LLM-as-Jev: LLMs Are Already Jev-Style Decision Models -- When and How to Fine-Tune Them |
| 2610.02267 | 2026-10-01 | Fast Models, Slow Evidence: A Paired and Self-Audited Evaluation of System-1 Decision Models for LLM Agent Harnesses |
| 2610.02486 | 2026-10-01 | From Retrieval to Typed Decisions: Calibrated System One Models from Biomedical Sentence Encoders |
| 2610.02516 | 2026-10-01 | Student-Guided Teacher Distillation for Efficient LLM Task Routing: Positioning Against Jev-Style System-1 Classifiers |
| 2610.02586 | 2026-10-01 | Labels Override Definitions in Jev-Style Typed Decision Models |
| 2610.03073 | 2026-10-02 | SecJev: Bringing Security Expertise to System One Decision Models |
| 2610.03324 | 2026-10-02 | To Jev or Not? Evaluating the Accuracy and Efficiency of Structured Decision Models for Hate-Speech Moderation |
| 2610.03387 | 2026-10-02 | Benchmarking candidate coverage and rejection policy transfer in typed decision models |
| 2610.03935 | 2026-10-02 | General Decision Models: Benchmarking and Insights Beyond Jev |
| 2610.05107 | 2026-10-04 | SearchJev: A Calibrated System-1 Model for Search Agents |
| 2610.05278 | 2026-10-04 | When Verifiable Counts Depend on Wording: Auditing Wording Robustness in Instruction Following |
| 2610.06354 | 2026-10-05 | GraphDecisionBench: Benchmarking System One Models on Graph Tasks |
| 2610.06425 | 2026-10-05 | SoK: Semantic Decision Engines in Network Control Loops |
| 2610.06744 | 2026-10-05 | ufakzeka-karar: An Open Turkish Typed-Decision Model with Order-Invariant Option Scoring |
| 2610.07327 | 2026-10-05 | SharedKV-BT: Node-Local Typed Decisions for Behavior-Tree Agents |
| 2610.07716 | 2026-10-06 | JevCascade: Readout Stability and Inference-Time Compute Allocation for Prefill-Only Decision Models |
| 2610.07730 | 2026-10-06 | SanSi: A Looped Typed Decision Model for System 1.5 Thinking |
| 2610.07953 | 2026-10-06 | Benchmarking System One Models in Online Moderation |
| 2610.08089 | 2026-10-06 | When Plans Change Answers: Formalizing Cost-Accuracy Optimization for Semantic Queries |
| 2610.08155 | 2026-10-06 | Token-Efficient Multi-Agent Collaboration via System One-Guided Computational Division of Labor |
| 2610.08675 | 2026-10-06 | Same-Number Citation Swaps: Stress-Testing Jev as a Financial Evidence Judge |
| 2610.09188 | 2026-10-06 | From Probabilities to Decisions: Search and Multi-Teacher Distillation with Jev |
| 2610.09489 | 2026-10-07 | Goldsmith: Gold-Loss-Guided Definition Optimization with an Agentic Annotation Harness |
| 2610.09683 | 2026-10-07 | System Switch: When Should a Fast Decision Model Stop and Think? |
| 2610.10615 | 2026-10-07 | JevForest: Path Voting for Budgeted Feature Acquisition |
| 2610.10978 | 2026-10-07 | Probabilistic Sensing, Deterministic Authority: Admitting Model-Produced Observations into Sufficiency-Checked Governance Contracts |
| 2610.11135 | 2026-10-08 | Can a System-One LLM Perform Knowledge Tracing When Few or No Learners Are Logged? |
| 2610.11316 | 2026-10-08 | MetaEncoder: Exploring the Limit of Bi-Encoders for Multimodal System One Decision Making with Natural Language Interface |
| 2610.11379 | 2026-10-08 | FastJEV: Understanding Redundancy for Compact JEV Inference |
| 2610.11392 | 2026-10-08 | TypedBench: A Benchmark for Calibration, Framing Sensitivity, and Cost in System One Decision Models |
| 2610.11436 | 2026-10-08 | Adversarial Cues in Decision Models Used as Judges: The Role of Request Presentation |
| 2610.11692 | 2026-10-08 | Can Jev be Your Q or Policy in Reinforcement Learning? |
| 2610.11715 | 2026-10-08 | Internalizer: Portable Context-to-Parameter Mapping for Very Large Language Models |
| 2610.11978 | 2026-10-08 | Specialized Decision Models vs. General-Purpose LLMs: Benchmarking Jev Across Knowledge, Reasoning, and Multilingual Tasks |
| 2610.12292 | 2026-10-08 | One Word Opens the Gate: The Option-Channel Attack on Typed Decision Models as Agent Guardrails |
| 2610.13092 | 2026-10-09 | When Faster Decisions Do Not Make Better Agents: An Empirical Study of Jev in Agent Workflows |
| 2610.13113 | 2026-10-09 | Continually Post-training Small Models via Synthetic Self-distillation |

| ID | 日期 | 标题 |
|---|---|---|
| 2610.14112 | 2026-10-09 | Does System One Transfer? Calibrated Typed-Decision Models, Label Budgets, and Translation for Indonesian Regional Languages |
| 2610.14404 | 2026-10-09 | DICE: Tilting the Odds through Interface Attacks on System One Model |
| 2610.14449 | 2026-10-10 | Jevolution: A Framework for Studying Communication and Collective Dynamics in AI Agents |
| 2610.14631 | 2026-10-10 | The Company a Question Keeps: Auditing Open Jev-Style Models for Retrieval |
| 2610.14912 | 2026-10-10 | Probable but Not Valid: A Psychometric Audit of Decision Models as Synthetic Survey Respondents |
| 2610.15501 | 2026-10-11 | Large Decision Models: Repurposing Large Language Models as Single-Pass Decision Makers |
| 2610.15537 | 2026-10-11 | Poisoned into Action: Context Attacks on Typed Decision Workflows |
| 2610.15710 | 2026-10-11 | Suggested Is Not Superseded: A Pre-Registered Evaluation of a System-One Model as a Memory-Retirement Gate |
| 2610.15742 | 2026-10-11 | RSAJEV: Training-Free Abstaining Prototype Memory for Eliminating Silent Hallucination in JEV-Based Remote Sensing Classification |
| 2610.16191 | 2026-10-12 | Correct Choices, Failed Sequences: Choice2Seq Benchmarks Correctness Retention Across Output Interfaces |
| 2610.16550 | 2026-10-12 | CT0: Cybersecurity Transformer |
| 2610.16655 | 2026-10-12 | Does a Hosted Decision Model Respect Irrelevant Alternatives? A Pre-Registered Test of Option-Set Dependence in Jev |
| 2610.16967 | 2026-10-12 | Proactive Physical AI through Continuous Observation and Timely Intervention |
| 2610.17096 | 2026-10-12 | Towards Universal Calibration for In-Context Classification |
| 2610.17175 | 2026-10-12 | FunDM: Cheap & Label-Free Decision Models from Frozen Language Models |
| 2610.17205 | 2026-10-12 | Releasing the Inner Jev: A Simple Recipe for Open Decision Models |
| 2610.17309 | 2026-10-12 | StartLux-Decision: AutoThink Decision Models with Reinforcement Learning for Calibrated Deliberative Decisions |
| 2610.17727 | 2026-10-13 | SkillScreen: High-Recall Screening of Malicious Agent Skills with Decision Models |
| 2610.17820 | 2026-10-13 | Same Attack, Different Judge: A First Controlled Adversarial Comparison of Jev, LLM Judges, and Purpose-Built Safety Classifiers |
| 2610.18122 | 2026-10-13 | Cheap, Consistent, Calibrated, but Biased? Typed Decision Models as Judges |
| 2610.18233 | 2026-10-13 | Consider, Then Choose: Order-Invariant Decisions in System One Models |
| 2610.18272 | 2026-10-13 | JevGPT: Thinking Fast and Slow in Autonomous Research |
| 2610.18326 | 2026-10-13 | Jev-Guard: Fast Routing and Auditing Agent Actions over Editable Policy Trees |
| 2610.18488 | 2026-10-13 | Recalibrating Many Questions with Few Labels: Minimax Rates and Identification Limits |
| 2610.18529 | 2026-10-13 | How Reliable Are System-One Decisions in Medicine? A Comparative Study of Jev, Jev-like Models, and LLMs |
| 2610.18579 | 2026-10-13 | Reading Right, Acting Wrong: Diagnosing Decision Failures of System One Models in Agent Loops |
| 2610.18612 | 2026-10-13 | Nudge the Judge: Uncovering Program Decision Hijacking in Real-World Jev Applications |
| 2610.18766 | 2026-10-13 | Rubrics from the Task, Verdicts from Evidence: Pointwise Rubric Rewards with Tool-Augmented Judges |
| 2610.18780 | 2026-10-13 | BLADE: Auditing Information Use for Failure Attribution in LLM Multi-Agent Systems |
| 2610.19525 | 2026-10-14 | Diagnosing and Correcting Reward Hacking in Verifiable Instruction Following |
| 2610.19536 | 2026-10-14 | Typed Decision Models on Tabular Data |
| 2610.19596 | 2026-10-14 | JevCoder: When Does Decision Delegation Pay Off in Code Repair? |
| 2610.19619 | 2026-10-14 | Are AI Decision Models Biased? A Case Study of Jev |
| 2610.19644 | 2026-10-14 | Selective Reasoning for Typed Decision Models: When to Start, Read, and Stop |
| 2610.19811 | 2026-10-14 | Calibration and Risk-Budgeted Decisions with System One Models |
| 2610.19856 | 2026-10-14 | Lost in the Fallback: How Reliably Do Typed Decision Models Use Fallback Options? |
| 2610.20665 | 2026-10-14 | The World Won't Wait: Evaluating and Teaching Agents Under a Live Clock |
| 2610.20778 | 2026-10-14 | Verdict: Encode Once, Decide Many |
| 2610.20907 | 2026-10-14 | From Detection to Decision: Calibration and Deferral for Prompt-Injection Detection |
| 2610.20927 | 2026-10-14 | Prune the Summary, Not the History: Source-Judged Compaction for Long-Horizon Agents |
| 2610.20951 | 2026-10-14 | LEV: Thinking Fast and Deep with Looped Decision Models |
| 2610.21160 | 2026-10-15 | When to Ask for Help: A Decision-Theoretic Account and Measurement Standard for Slow-Module Scheduling in Dual-System Vision-Language-Action Models |
| 2610.21214 | 2026-10-15 | Rubric Judgments Lack Uncertainty: Conformal Weighting for LLM Evaluation |
| 2610.21244 | 2026-10-15 | System1-Arena: Which Decisions Can Be Left to System 1? |
| 2610.21411 | 2026-10-15 | Jev-LiteMAS: Separating Decisions from Generation in Multi-Agent Workflows |
| 2610.21412 | 2026-10-15 | JevAgentHarness: Benchmarking, Deploying and Training Decision Models That Share Control with LLMs |
| 2610.22066 | 2026-10-15 | Prism-1: Position- and Rival-Independent Scoring for System One Models |

| ID | 日期 | 标题 |
|---|---|---|
| 2610.22131 | 2026-10-15 | Intern-Decision: Efficient Multimodal Decision Making with Autoregressive Masked Language Modeling |
| 2610.22276 | 2026-10-15 | MJev-Spatial: System One Spatial Intelligence via Native Attention Matching |
| 2610.22526 | 2026-10-15 | Literal Lock-In: How Test Language Shifts Literal Attraction in Typed Decision Models on Bengali Idioms |
| 2610.23170 | 2026-10-16 | Chinese Decision: A Family of Language Models for Single-Pass Probabilistic Decision-Making |
| 2610.23668 | 2026-10-16 | TUPLE-Bench: Evaluating and Mitigating Privacy-Utility Trade-offs in Typed Decision Models |
| 2610.23804 | 2026-10-16 | Jarvis: Coordination Deserves a Brain of Its Own in Agentic Interactive Models |
| 2610.24358 | 2026-10-17 | DKnown-Jev: Fine-Tuning and Evaluation of a JEV-Style Model for Tasks Involving Normative Knowledge |
| 2610.24649 | 2026-10-17 | Good Judgment, Bad Advice: Decision-Model Controllers Raise Agent Cost Without Improving Success |
| 2610.24871 | 2026-10-17 | Bellman Language Models: Solving the Recurring Decisions of LLM Agents |
| 2610.24929 | 2026-10-18 | What Can't Jev Decide? Probing the Limits of One-Pass Decision Models |
| 2610.25456 | 2026-10-18 | System X: An LLM Decision Model That Replies from Its Own KV Cache |
| 2610.25474 | 2026-10-18 | P(Yes): 15$\times$ Improvements via Test-Time Scaling of Decision Models |
| 2610.25553 | 2026-10-18 | Narrow Decision Models: A System-1 Architecture for Calibrated, Typed Decisions |
| 2610.25760 | 2026-10-19 | Computation, Not Memory: Chain-of-Thought and State Tracking in LLM Agents |
| 2610.25768 | 2026-10-19 | Truncated Reasoning Under a Budget: Evaluating System-1 Models as Decision-Makers |
| 2610.25784 | 2026-10-19 | UniJev: Separating Accuracy from Calibration in Trimodal System One Decision Models |
| 2610.25947 | 2026-10-19 | Claim Laundering: When Agent Decision Models Trust Records Over Reality |
| 2610.25985 | 2026-10-19 | NIOCIS: Typed-Decision Next-Hop Routing with Node-Conditioned Option Spaces for Tool-Use Agents |
| 2610.26035 | 2026-10-19 | Decision4Rec: A Jev-Inspired Framework of Decision Models on Knowledge and Active Graphs for Multi-Agent Recommender Systems |
| 2610.26325 | 2026-10-19 | Typed Decision Models under Prevalence Shift: Decision Training, Calibration, and Implicit Priors |
| 2610.26793 | 2026-10-19 | SOMA: Continuous Monitoring and Intervention for System Two Reasoning with System One Models |
| 2610.26797 | 2026-10-19 | Teacher Supervision, Fixed Representations and Calibration: Exact Risk Calculations for Candidate-Scoring Decision Models |
| 2610.27301 | 2026-10-19 | Evaluating Context Compaction on the Questions That Come Later |
| 2610.27746 | 2026-10-20 | S$^2$-MAS: A Society-Scale Multi-Agent Simulation Framework with 500 Million Household Persona Agents |
| 2610.28116 | 2026-10-20 | AgenTest: Mining Business Rules to Test LLM Agents for Business Logic Bugs |
| 2610.28522 | 2026-10-20 | DecisionPivot: A Diagnostic Benchmark for Decision Models in LLM Systems |
| 2610.28577 | 2026-10-20 | Cache Engineering for Agents |
| 2610.28819 | 2026-10-20 | LIFT: Scoped Constraints for Evaluating and Training Instruction Following |
| 2610.29052 | 2026-10-21 | Our Own Jev: Typed Decisions in One Forward Pass, from an In-House Judge to Open LoRA Models |
| 2610.29217 | 2026-10-21 | When Multiple Choices Are Correct: Asymmetric Probability Allocation in Jev and Other Decision Models |
| 2610.29294 | 2026-10-21 | Same Probabilities, Different Advice: Gain-Loss Framing Effects in High-Stakes LLM Decision Support |
| 2610.29961 | 2026-10-21 | Commit or Abstain? System One Decision Models, LLMs, and Missing Legal Authority |
| 2610.30045 | 2026-10-21 | Which Differences Matter? Controlled Tests of Rule Transfer, Joint Reliability, and Information Use in Decision Models |
| 2610.30587 | 2026-10-22 | Know When to Escalate: Critic-Guided Adaptive Execution for Cloud-Local Embodied Agents |
| 2610.30690 | 2026-10-22 | From Clinical Judgment to Checkable Rules: Clinician-Led Guardrails for Mental-Health Chatbots |
| 2610.31315 | 2026-10-22 | The Value of System 1 Models in Medicine |
| 2610.31521 | 2026-10-22 | Jev-DLC: Decision-Level Continual Learning from Typed Feedback |
| 2610.32285 | 2026-10-23 | Trial by Trace: Benchmarking AI Agent Harnesses for Reliability and Failure Attribution |
| 2610.32648 | 2026-10-23 | StateMirror: Pre-Execution Detection of Hallucinated Tool Calls in Coding Agents |
| 2610.32955 | 2026-10-23 | Measure Before You Train: Typed Decision Models vs. a Classical Baseline vs. a Generative LLM for Routing a Personal Multilingual Inbox |
| 2610.33258 | 2026-10-23 | Two Uncertainties Are Not One: Disagreement versus Decision-Risk in Cheap Structured Content Moderation |
| 2610.33493 | 2026-10-24 | Small Edits, Shifting Decisions: Benchmarking LLM Accuracy and Reliability on French Input Variants |
| 2610.33766 | 2026-10-24 | StateWise: Teaching Language Models to Track and Obey Evolving Constraints in Multi-Turn Dialogue |
| 2610.33775 | 2026-10-24 | The Hitchhiker's Guide to System 1 Models: Fast Decision-Making Beyond LLMS |
| 2610.33876 | 2026-10-24 | FlashScript: Compiling Recurring Agent Workflows into Reusable Neuro-Symbolic Programs |
| 2610.34258 | 2026-10-25 | Recovering Business Rules as Cascade Lookups for Enterprise Field Prediction |
| 2610.34329 | 2026-10-25 | SHIFT-JEV: Certified Abstention and Gain-Gated Continual Adaptation for LLM-Based Decision Models under Distribution Shift |

| ID | 日期 | 标题 |
|---|---|---|
| 2610.34826 | 2026-10-26 | TrustJev: Separating Policy Authority from Untrusted Evidence in LLM-Based Decisions |
| 2610.34956 | 2026-10-26 | Decision Model Factory: Building Specialized Sovereign Decision Models |
| 2610.35349 | 2026-10-26 | MarkovSim: an LLM Agent Harness with Bounded Context for Long-Horizon Computational Simulation |
| 2610.35654 | 2026-10-26 | Improving JEV Entailment Reranking with Span Readouts and Selective Adaptation |
| 2610.35721 | 2026-10-26 | Can JEV Support Clinical Trial Criteria Assessment? |
| 2610.35826 | 2026-10-26 | Understanding Jev-Style System One Models: Does Structure Reduce Selection Bias? |

## 11.2 TypeSafe 官方文档与页面

| 页面 | URL |
|---|---|
| 发布博客：Introducing System One models and Jev | https://typesafe.ai/blog/introducing-system-one-models-and-jev |
| 文档首页 | https://docs.typesafe.ai/introduction |
| 机器学习入门（primer） | https://docs.typesafe.ai/introduction/machine-learning-primer |
| System One 概念 | https://docs.typesafe.ai/concepts/system-one |
| 如何用 System One 构建 | https://docs.typesafe.ai/concepts/how-to-build-with-system-one |
| State 概念 | https://docs.typesafe.ai/concepts/state |
| 用例地图 | https://docs.typesafe.ai/concepts/use-case-map |
| 原语：Score | https://docs.typesafe.ai/primitives/score |
| 原语：进阶 | https://docs.typesafe.ai/primitives/advanced |
| 置信度 | https://docs.typesafe.ai/confidence |
| 模式总览 | https://docs.typesafe.ai/patterns |
| 模式：扇出 | https://docs.typesafe.ai/patterns/fan-out |
| 模式：复合打分 | https://docs.typesafe.ai/patterns/composite-scoring |
| 模式：置信路由 | https://docs.typesafe.ai/patterns/confidence-routing |
| Agent skill | https://docs.typesafe.ai/agent-skill |
| 模型列表 | https://docs.typesafe.ai/models |
| 模型 jaggedness（jev-1.13） | https://docs.typesafe.ai/model-jaggedness/jev-1.13 |
| Cookbooks 总览 | https://docs.typesafe.ai/cookbooks |
| Cookbook：Noul 自洽性 | https://docs.typesafe.ai/cookbooks/consistency_noul_cookbook |
| Cookbook：autoresearch 特征发现 | https://docs.typesafe.ai/cookbooks/autoresearch_feature_discovery |
| 官方评测页 | https://evals.typesafe.ai/ |
| typesafe-ai/skills 仓库 | https://github.com/typesafe-ai/skills |
| system-one-adapter-python | https://github.com/typesafe-ai/system-one-adapter-python |

## 11.3 开源复现、工具与模型卡

| 项目 | URL |
|---|---|
| Kev（jaredpalmer） | https://github.com/jaredpalmer/kev |
| Kev-9B 模型卡 | https://huggingface.co/jaredpalmer/kev-9b |
| Tev1（Together） | https://github.com/togethercomputer/tev1 |
| Tev1-4B-experimental 模型卡 | https://huggingface.co/togethercomputer/Tev1-4B-experimental |
| Together 博客：How to train your own Jev | https://www.together.ai/blog/how-to-train-your-own-jev |
| Nimble（Bespoke Labs） | https://github.com/bespokelabsai/nimble |
| Bespoke-Nimble-9B-v3 模型卡 | https://huggingface.co/bespokelabs/Bespoke-Nimble-9B-v3 |
| pplx-decider-v1.2 模型卡 | https://huggingface.co/perplexity-ai/pplx-decider-v1.2 |
| OneJev（OmniJev） | https://github.com/OmniJev/OneJev |
| OneJev-9B 模型卡 | https://huggingface.co/OmniJev/OneJev-9B |
| OmniJev flide | https://github.com/OmniJev/flide |
| awesome-jev-papers | https://github.com/OmniJev/awesome-jev-papers |
| awesome-jev-gallery | https://github.com/OmniJev/awesome-jev-gallery |
| awesome-jev-robustness | https://github.com/Yifan-Lan/awesome-jev-robustness |

| 项目 | URL |
| --- | --- |
| Open-Jev（Zefan-Cai） | https://github.com/Zefan-Cai/Open-Jev |
| open-jev / TOD（daseinlabs） | https://github.com/daseinlabs/open-jev |
| qwen-rlcd（shamazharikh） | https://github.com/shamazharikh/qwen-rlcd |
| Mapika decider | https://github.com/Mapika/decider |
| StartLux-Decision | https://github.com/StartLuxLabs/StartLux-Decision |
| StartLux-Decision-v1.1-27B-Instant-GGUF 模型卡 | https://huggingface.co/startlux-models/StartLux-Decision-v1.1-27B-Instant-GGUF |
| jevlike（mustafasemi-ai） | https://github.com/mustafasemi-ai/jevlike |
| this-that-model（FLock-io） | https://github.com/FLock-io/this-that-model |
| openjev-sglang（ekzhang） | https://github.com/ekzhang/openjev-sglang |
| jev-benchmarks（AbdelStark） | https://github.com/AbdelStark/jev-benchmarks |
| decision-model-benchmark（nibzard） | https://github.com/nibzard/decision-model-benchmark |
| jev-calibration-audit（jujumilk3） | https://github.com/jujumilk3/jev-calibration-audit |
| RLCDAlignBench（sumleo） | https://github.com/sumleo/RLCDAlignBench |
| jev-ultrafast（browser-use） | https://github.com/browser-use/jev-ultrafast |
| WaterSheep | https://github.com/SamratDuttaOfficial/WaterSheep |
| Laya（NandhaKishorM） | https://github.com/NandhaKishorM/laya |
| Laya 模型页 | https://huggingface.co/convaiinnovations/laya |
| Laya 官网 | https://laya.convaiinnovations.com/ |
| decision-index（apolinario） | https://github.com/apolinario/decision-index |
| Jev Decision Index 文章 | https://systemonemodels.org/examples/articles/jev-decision-index/ |
| Jev Decision Index（HF Space） | https://huggingface.co/spaces/multimodalart/jev-decision-index |

## 11.4 其他网页

| 页面 | URL |
| --- | --- |
| Archer Hume：Jev's Architecture Unmasked | https://archerhume.com/posts/jevs-architecture-unmasked |
| Agent Skills 规范 | https://agentskills.io/specification |
| OpenAI：Introducing gpt-oss-safeguard | https://openai.com/index/introducing-gpt-oss-safeguard/ |
| LangChain：Building a harness with Jev | https://www.langchain.com/blog/building-a-harness-with-jev |
| Wikipedia：Jev (AI model) | https://en.wikipedia.org/wiki/Jev_(AI_model) |

# 12 · 学习视角：学习算法有没有变、数据集是否可得、基座怎么选

> 口径：仍然只做分析与调研，不给训练方案。本章回答三个问题：（1）现有 Jev 类方案的**学习算法**相对"普通分类微调"有没有变化、调整或增强，证据是否支持这些改动；（2）训练与评测**数据集**是否公开可得、许可如何、本地已经拿到哪些；（3）**基座模型**的选型规律。02 章的配方矩阵按"项目"组织，本章按"学习算法族"重新切分，并把消融证据放在一起看。

## 12.1 学习算法谱系

把 02 章 30 余个配方和本轮补充的论文按"**训练什么、用什么目标、监督从哪来**"分成八族。每族给出代表、关键实现细节与出处；同一个项目可以落在多族（例如 StartLux 同时属于 C、E、F、G）。

| 族 | 核心思想 | 代表（骨干 / 关键细节） | 出处 |
|---|---|---|---|
| **A. 不训练：读出 + 后验校准** | 冻结 LLM，直接把合法选项的 logits 归一化；只拟合温度或先验 | LLM-as-Jev 免训练配方（联合上下文打分、并行后缀打分；冻结 4B 与现有免训练读出持平或更好）；Mapika decider-chat（Gemma-4-31B-it / Qwen3.6-27B 不改权重，按选项数拟合温度 T(n)=max(0.05, 10.124−1.633 · ln n)，Decision Index 第 2）；AnyJev（与问题无关的仿射头 + 复用输出头，15 等质量分箱 ECE，旋转去偏）；Releasing the Inner Jev 零样本 Gemma 4 31B 79.6 对 Jev 80.1；LDM 诊断"未调优 27B 的读出达到调优后 97% 的准确率"；P(Yes) 测试时搜索（冻结模型、无训练，Qwen3.8-27B 逻辑谜题全对数 2→30）；RSAJEV 用原型记忆替换读出（零梯度更新，开集 AUROC 0.91–0.99）；JevCascade 的菜单限制预测器（零标签）；Runoff 两次前向的顺序无关读出 | 2610.02076、Mapika/decider、2610.00831、2610.17205、2610.15501、2610.25474、2610.15742、2610.07716、2610.18233 |
| **B. 硬标签交叉熵 + LoRA（主流）** | 和"把 LLM 当分类器微调"一样的目标，只是读出位置换成 LM-head 切片 / 字母 logit / 指针头 | Kev（Qwen3.5-Base 系，LoRA rank 16，交叉熵，2 epoch，`decision-v7`；可选的 `--perm_kl`、`--ord_w` 损失**发布模型未使用**）；Tev1（Qwen3.5-4B，LoRA SFT，输出答案字母，37,840 训练 + 4,568 验证）；Bespoke Nimble（Qwen3.5-9B，**只在答案 token 上**的 LoRA，2,676 条对比样本；90.1% 对基座 66.4%、Jev 93.2%）；Releasing the Inner Jev（字母读出 + 从 LM-head 切片初始化的决策头**联合**交叉熵，417,825 条池，400 步约 5 GPU 小时）；LDM 基线与 DDS 都是硬标签交叉熵；Chinese Decision（1 epoch，13.048M 决策）；DKnown-Jev（从 Qwen3.5-2B / Qwen3.8-27B 基座直接微调，1 epoch，27B 98.75% 高于 Jev 6.07 pp）；SecJev（场景加权训练）；Koa-decision（原子标签 token + SFT，单 token 受限生成）；SALSA（类别→token 映射 + PEFT，单遍只投影到类别 logits）；对照：解码器 + 分类头 vs 指令微调，头方案以少 10–30 倍可训参数持平 BERT | jaredpalmer/kev、togethercomputer/tev1、bespokelabsai/nimble、2610.17205、2610.15501、2610.23170、2610.24358、2610.03073、2609.36115、2510.22691、2512.12677 |
| **C. 软标签 / 适当评分规则** | 把校准写进目标：Brier、软交叉熵、对分布而非 argmax 的损失 | jevlike（Qwen3-1.7B + LoRA + 37 个开源数据集，`CE + 0.5·Brier`；理由："交叉熵不知足，把 0.99 推到 0.999 仍有奖励"；基座要 T=8.881 才校准）；OneJev（交叉熵 + Brier，lr 5e-6，1 epoch，视觉塔冻结）；Open-Jev（LoRA + 标量决策头，**软交叉熵 + 0.1 · Brier**，头从预训练的 Yes–No 读出初始化，温度只在校准集拟合）；Eikos / Our Own Jev（软目标 + 推理理由辅助损失 + 英/葡两个视图之间的对称 KL，权重 0.5；约 25K 决策）；Releasing the Inner Jev 池里 Civil Comments、Measuring Hate Speech 等用标注者投票做软目标，结论"**教师标签有用，软标签可能无用**"；SanSi / LEV 每个循环步都用适当评分规则训练；NDM 主张"标签已知时直接用适当评分规则"并给出集合值目标；ufakzeka-karar 输出温度缩放概率 + 期望误差作"不确定"信号；UniJev 先 SFT 再做 CORA（按置信分箱把置信拉向该箱实际准确率，无 RL 阶段） | mustafasemi-ai/jevlike、OmniJev/OneJev、Zefan-Cai/Open-Jev、2610.29052、2610.17205、2610.07730、2610.20951、2610.25553、2610.06744、2610.25784 |
| **D. 蒸馏（教师概率 / 推理→读出）** | 监督来自更大模型、推理链或自身的推理模式，而非人工标签 | FunDM（**无标签**：用 KL 学冻结 Qwen3-8B 自身的答案分布，只用 36 层中的 24 层，八基准 75.0 对全模型 75.7）；LDM 的 SPRD（自提问任务，冻结 Qwen3.8-27B 教师每题采 4 条推理+答案，SPRD-C 过滤一致性后蒸馏投票分布）；SII-Decision 的 Reasoning-to-Readout 自蒸馏（把推理链末端的答案分布蒸馏进首 token）；法律领域把决策模型的概率**无标签**蒸馏进 Qwen3-8B 得到校准的本地模型；国际象棋双教师：Jev 与 Qwen3-32B 标签平均比全预算给 Qwen 多 9.6 Elo，"同一裁判再答一次不能替代第二个教师"；AgentDecision-4B 用 Jev 的答案做标签；Releasing the Inner Jev 教师为 Qwen3.5-122B-A10B 与 Qwen3.6-27B；Mapika 用本地 Qwen3.5-27B 教师标注；CT0 两阶段在线策略蒸馏（同一组权重同时服务 System 1 类型化决策与 System 2 Agent）；对照（编码器）：学生引导的教师蒸馏，ModernBERT 学生 + DeBERTa NLI 教师迭代 | 2610.17175、2610.15501、2610.03935、2610.29961、2610.09188、2610.21412、2610.17205、Mapika/decider、2610.16550、2610.02516 |
| **E. 结构感知 / 校准感知目标** | 在损失里显式编码位置、序数、证据必要性、分布锚 | PACT（成对锚定 + 证据必要性项 + 序数运输代价 + 三参数上下文温度；准确率 84.6 对已发布配方 85.2、仅交叉熵对照 82.2±6.0；重标注翻转 9.8 对 13.8%；NLL −26%；**"没有单一项提高原始准确率，价值在稳健性"**）；LLM-as-Jev 树分解列表式损失 + KL 锚（总分对锚强度不敏感，无锚则退化）；SHIFT-JEV 的 KL 锚 + 温度（偏移下校准误差 0.289→0.087）；CORA；StartLux 附录 B.4 直接概率优化与**策略感知校准**（184 种设置下置信-准确差 ≤2.7 pp，属后验）；Releasing the Inner Jev 的期望效用目标（对正确 / 错误 / 弃权分别计期望收益，比交叉熵 +0.9±0.9 pp）；Bongard 第二阶段 JEPA（学"判断背后的结构"，诊断"余弦对齐几乎没有信号"后换目标，保留集改写题 75.7%→85.9%）；Kev 的 `--perm_kl`（顺序）与 `--ord_w`（序数）损失（实现了，发布模型未用） | 2609.35865、2610.02076、2610.34329、2610.25784、2610.17309、2610.17205、2609.39111、jaredpalmer/kev |

| 族 | 核心思想 | 代表（骨干 / 关键细节） | 出处 |
|---|---|---|---|
| **F. 强化学习（各种"RLCD"）** | 以适当评分规则或正确性做奖励的策略梯度 | OpenJev-RLCD（Qwen3-1.7B；每条推理链之后读出模型承诺的分布，用严格适当评分规则打分；一行方差恒等式说明"对多样本混合打分"会奖励分歧、RLVR 恰是去掉多样性项的混合目标；端到端优化要么"System-One 坍塌"（用 KL 锚防止）要么被策略梯度项淹没（其梯度比读出大 7–12 倍）→ **先校准再强化**；GSM8K 答案验证单次查询在 ≤5% 错误下决定 81% 条目，GRPO 19%）；StartLux RLCD²（只用于 AutoThink：推理前后两次读出的适当评分之差做决策质量奖励 + 软长度惩罚；在限长内终止的推理占比最多 +48 pp）；UniJev 比较五种 RLCD（Shaped RLCD、GRPO、CtR、RLCD-lite、Rewarding Doubt）：相对共同的 2B SFT 初始化，各算法改变各模态准确率的幅度"**与监督转换带来的增益相比很小**"，校准效应异质；SBERT2S1（编码器）：开源 System One 模型发布的 RLCD 配方比交叉熵**低 2.5–3.0 点**，缺口主要来自奖励归一化把噪声得分函数项放大 3.6–15 倍，留一法无偏估计可收回大部分；ufakzeka-karar：REINFORCE 比交叉熵**低 10.2 个 macro-F1**；JevAgentHarness：Agent 循环内 GRPO 多花 4.5 GPU 小时与 26.53 美元 LLM 调用**无可测增益**，不先 SFT 时 GRPO 后 11.5% 对之前 13.5%；Bongard 第三阶段沙盒 RL（从动作 rollout 与精确 oracle 学结果分布，冻结沙盒面板 50.6%→64.8%）；Dyad（冻结 LLM 只用 RL 训动作编码器，四个未见环境一致提升）；$S^2$-MAS（SFT + RLCD，2.93M 样本，421M 模型 74.55%）；NDM §8.1"为什么不用强化学习"：标签已知时适当评分规则直接优化**到达与 RLCD 式奖励的策略梯度相同的最优点而无其方差**；TypeSafe 自己的 RLCD **未公开** | 2609.38850、2610.17309、2610.25784、2610.02486、2610.06744、2610.21412、2609.39111、2609.36116、2610.27746、2610.25553、ML primer |
| **G. 结构改动（改"训练什么"）** | 改注意力掩码、读出位置、层数、循环或编码器 | 候选无关块因果注意力 + 位置重置（Gemma 3 1B 翻转率 8.30%→0.11%，Qwen3 1.7B 18.16%→1.20%；Qwen3-4B 250K 研究件）；Prism-1（每个选项独立块、共享位置、LoRA，块上 softmax 的交叉熵；Qwen3-8B / Gemma 4 12B；零翻转，换 Luce 公理成立）；StartLux Instant 在提示上做**双向注意力**（同数据同 Stage 1 检查点下 5 个尺度中 4 个提升，最多 +2.4 DI 点；随机种子方差 0.2–0.7）；SanSi / LEV 循环骨干 Ouro，**骨干冻结只训 LoRA + 小读出**，每个循环步读一次；Bongard 用 T5Gemma 2 4B-4B 编码器-解码器，**全参数** 7.09B 在一张 Blackwell 上三阶段训练；选择性适配（LoRA 只放注意力与 Gated DeltaNet 投影、去掉 FFN 适配器）+ mean-span 池化；FunDM 提前退出（24/36 层，跳过 LM-head）；Intern-Decision 在 JSON 骨架里放决策占位符，用自回归掩码 LM 一次前向读全部字段；System X 从 KV 缓存续写"文本回复"选项；Dyad 动作编码器；MetaEncoder 把 30B 解码器微调成双编码器做单向对比学习（面向百万级开集候选） | 2610.01601、2610.22066、2610.17309、2610.07730、2610.20951、2609.39111、2610.35654、2610.17175、2610.22131、2610.25456、2609.36116、2610.11316 |
| **H. 持续学习 / 测试时适应** | 不重训或少重训地吸收新反馈 | Kev `--init_from`（从发布适配器与指针头继续训，README 称从基座重训会"丢掉 Kev 已学到的"）；SHIFT-JEV 增益门控的持续适应（Qwen3-0.6B 上 70.5%，每个种子都高于回放 / LwF / EWC / 微调；Qwen3-4B 上保守门控落后 0.4–1.4 点）；Jev-DLC 决策级持续学习（类型化反馈→有界因果状态，见 07 章）；TORSI 双时标：慢教师在暂停的游戏里研究失败并写可复用指令给快学生，Jev 平均分 13.51→24.19；P(Yes) 测试时搜索；Open-Jev 的时间窗回归对照 | jaredpalmer/kev、2610.34329、2610.31521、2610.20665、2610.25474、Zefan-Cai/Open-Jev |

## 12.2 相对"普通分类微调"到底改了什么

把八族放在一起看，变化集中在五个位置，而不是"换了一种学习算法"：

1. **读出位置变了，分类头几乎消失。** 主流不再新建分类头，而是复用预训练输出层：字母 logit（Tev1、Chinese Decision、LLM-as-Jev）、LM-head 切片初始化的决策头（Releasing the Inner Jev）、从 Yes−No 读出初始化的标量头（Open-Jev）、指针头（Kev、Our Own Jev）、与问题无关的仿射头（AnyJev）。支持这样做的证据是"决策大部分已经在表示里"：未调优 27B 的读出达到调优后 97% 的准确率，9B 上 1/16 的数据就收回 88% 的调优增益（2610.15501）；FunDM 无标签 KL 就收回 99%（2610.17175）；Our Own Jev 单种子消融"训练输出层的 26 个字母行没有可检测的收益"（2610.29052）。LDM 据此把决策微调定义为"**改变表示如何被读出，而不是获取新知识**"。
2. **目标函数的"增强"主要是加一个适当评分规则项。** 交叉熵仍是基线；最常见的改动是 `+ Brier`（jevlike 0.5、Open-Jev 0.1、OneJev 未给权重）。更系统的框架把"适当评分规则"当作统一语言：SanSi / LEV 每步都用，NDM 直接用并证明与 RLCD 式奖励的策略梯度同最优点，OpenJev-RLCD 把它当奖励，StartLux 把推理前后评分之差当奖励。也就是说**"校准"从后验温度搬进了目标函数，但是否真的比"交叉熵 + 温度"更校准，证据是否定或不确定的**（见 12.3）。
3. **适配方式趋同：冻结骨干 + LoRA。** 秩 8–16 最常见（Kev 16、Open-Jev 27B 为 8）；Releasing the Inner Jev 报告"对 LoRA 秩稳定"；LEV 报告在 Ouro 上 LoRA 胜过全参数；只有 Bongard（7.09B 全参数）和 StartLux Stage 1（全参数 SFT）例外。Nimble 的变体是"只在答案 token 上"放 LoRA 损失。
4. **监督从"任务标签"变成"决策混合 + 教师"。** 训练集普遍是几十到上百个公开数据集重新编译成"状态 + 问题 + 选项"的决策格式（Kev 10 个数据集 + 策略 + 规则结构；Tev1 四类来源；Releasing 79 任务 300,042 条硬标签 + 软标签子集；StartLux 约 2.7M；Chinese Decision 13.048M），再叠加一个更大模型做教师（Qwen3.5-122B-A10B、Qwen3.6-27B、Qwen3.5-27B、Qwen3.8-27B、Jev 本身）。真正"新"的数据构造只有三种：Nimble 的**对比策展**（改一个事实让答案翻转）、LDM 的**自提问**任务（SPRD）、AgentDecision 的**在 Agent 自己犯错后到达的状态上**采样。
5. **强化学习只在少数项目里出现，且基本是"推理模式"的事。** 对单遍 Instant 模型，开源证据要么负面（SBERT2S1 −2.5 到 −3.0、ufakzeka −10.2 F1、JevAgentHarness 无增益）、要么"等价"（NDM 定理、UniJev "差异很小"）、要么只在**有推理链**的设定下成立（OpenJev-RLCD、StartLux AutoThink）。TypeSafe 的 RLCD 没有任何公开细节，开源社区对"RLCD"一词的用法至少有四种（见 13 章 §13.6）。

结构性改动（G 族）是唯一一类改了"问题本身"的学习算法：块因果 / Prism-1 把顺序不变性从"数据增强要学的东西"变成"构造保证的东西"，循环模型把"一个模型服务所有计算预算"变成训练目标，Bongard 把"同一状态多判断"做进编码器-解码器。这些改动与 08 章的混合骨干约束直接相关：Prism-1 / 块因果都依赖注意力掩码，在 Qwen3.5 的 DeltaNet 层上不成立。

## 12.3 消融证据：这些改动有没有用

| 改动 | 证据 | 结论 |
|---|---|---|
| LoRA 本身 | "LoRA 驱动改进"、"对秩稳定"、"更长训练没有一致收益"（2610.17205）；LoRA 胜全参数（Ouro，2610.20951） | **有用且不敏感**；全参数无优势证据 |
| 只训头 / 不训 | 未调优读出 = 97% 调优准确率；1/16 数据收回 88%（2610.15501）；FunDM 无标签 99%（2610.17175）；Our Own Jev 2B 困难层训练后 63.1 **低于**冻结 67.6（1B 48.6 对 54.1），电池集持平 70.6 对 70.2（2610.29052） | **训练增益小且可能为负**，取决于评测集；头在冻结表示上训"没有一种损失在温度缩放后明显更校准"（2610.17205） |
| 训练时长 | 更长的基线训练让 Qwen 过度自信：迁移套件 ECE 9B 23.8、27B 18.5，配方保持 8–12；一个温度去掉大部分差距（2610.15501） | **越训越过信**，温度能补大部分 |
| 软标签 vs 硬标签 | "教师标签有用，软标签（可能）无用"（2610.17205）；Open-Jev、Eikos、OneJev 都用软目标但无对照；Gaussian 代理理论：学生继承教师偏差，更多数据不消除（2610.26797） | **矛盾且无对照**；对我们的蒸馏路线是一级风险 |
| 适当评分规则 / Brier 项 | SBERT2S1 两头 × 五目标网格：温度缩放后**没有目标明显比交叉熵更校准**（2610.02486）；PACT 四项都不提高原始准确率，收益是种子方差减半、NLL −26%（2609.35865）；期望效用目标 +0.9±0.9 pp（2610.17205） | **对准确率无效，对稳健性 / NLL 有效**；校准优势在温度后基本消失 |
| RL / RLCD | 五种 RLCD 相对 SFT 增益"很小"、校准异质（2610.25784）；发布 RLCD 配方 −2.5 到 −3.0（2610.02486）；REINFORCE −10.2 F1（2610.06744）；GRPO 无增益（2610.21412）；但有推理链时 OpenJev-RLCD 选择性预测全面更优（2609.38850），StartLux AutoThink 比 Instant +11.5 到 +18.4 配对准确率（2610.17309） | **单遍模型上 RL 无正面证据**；RL 的收益与"生成推理"绑定 |
| 结构隔离 | 块因果翻转率 8.30→0.11%、18.16→1.20%（2610.01601）；Prism-1 零翻转、加选项不改相对赔率（2610.22066）；双向注意力 5 尺度中 4 个 +≤2.4（2610.17309）；每步训练使循环 1 可用 58.4% 对 35.6%（2610.07730） | **结构改动是唯一有大效应量的"算法"改动**，但依赖注意力掩码 |
| 数据 vs 算法 | 换一版语料让 2B 困难层移动 11 点（2610.29052）；决策训练让 Nimble 金融情感 Macro-F1 −12.0，Tev1 从不显著差于基座（2610.26325）；SecJev-0.8B 比 Kev-9B +20.51（2610.03073）；LEV "更多数据主要加强浅层读出"（2610.20951）；Bongard JEPA +10.2、沙盒 +14.2（2609.39111） | **数据构成的效应量 ≥ 目标函数的效应量**；"决策训练"不是一律有益 |
| 教师数量 | 两个教师平均 > 一个教师全预算（+9.6 Elo），同一教师再采一次无效（2610.09188） | 教师多样性比标签数量重要 |

综合：**现有方案的学习算法相对分类微调几乎没有"换算法"，只有"换读出 + 加评分项 + 换数据"；可证实有效的是 LoRA、数据构成、结构隔离与温度；软标签与 RL 的证据不足或为负。**

## 12.4 数据集可得性

### 12.4.1 公开训练集与评测集（按论文 / 项目）

| 数据 | 用途 | 规模 | 公开状态 | 出处 |
|---|---|---|---|---|
| Kev `decision-v7` + `kev-suites` | 训练 / 评测 | 10,000 + 896 + 1,680 | 训练脚本与套件公开（HF `jaredpalmer/kev-suites`，0.3 GB） | jaredpalmer/kev |
| Tev1 `new-v1` | 训练 | 37,840 + 4,568 | 仓库内公开 | togethercomputer/tev1 |
| Nimble 训练 / 保留集 | 训练 / 评测 | 2,676 / 324 | 2026-09-20 补发；Decision Index 评测集在 HF（CC BY-NC 4.0） | bespokelabsai/nimble |
| Open-Jev 训练混合 | 训练 | 148,639 行（冻结） | HF `ZefanCai/Open-Jev`（CC0）与 v1.1 | Zefan-Cai/Open-Jev |
| OneJev-Data | 训练 | 99,193 题（公开 94,707） | HF `OmniJev/OneJev-Data`，17.7 GB（含图像 / 视频） | OmniJev/OneJev |
| OpenDecisions + 417,825 条训练池 | 验证 / 训练 | 池 417,825 | 论文称发布模型、服务代码与 OpenDecisions | 2610.17205 |
| Eikos 语料 | 训练 | 约 25K | HF `caiovicentino1/eikos-decisions`（CC BY 4.0） | 2610.29052 |

| 数据 | 用途 | 规模 | 公开状态 | 出处 |
|---|---|---|---|---|
| DecisionPivot | 评测 | 对照组 + 参考轨 32,233 | HF `startlux-models/DecisionPivot` | 2610.28522 |
| StartLux 训练混合 | 训练 | 约 2.7M（0.8–9B）/ 0.8M（27B） | **未见公开**；权重 CC BY-NC 4.0 | 2610.17309 |
| JEVal | 评测 | 11,257（36 数据集、10 领域、双语） | HF `carlosxiang/JEVal` | 2610.03935 |
| System1-Arena | 评测 | 92k 题 / 105 任务 / 268 来源 + 138 闭环环境 | 论文描述；HF 上未探到仓库 | 2610.21244 |
| TypedBench | 评测 | 六检查点 | 论文描述；未探到 HF 仓库 | 2610.11392 |
| JevBench | 评测 | 231 公开题（+ 111 困难） | GitHub 仓库；**HF `fstandhartinger/jevbench` 不存在** | fstandhartinger/jevbench |
| Laya typed-decisions 基准 | 评测 | — | HF `LocalLLaMA/typed-decisions`（Apache-2.0）、`Luni/laya-jev-benchmark` | 2609.33843 |
| DecisionGym / AgentDecisionBench | 评测 / 训练 | 500 新任务等 | "将发布"（论文措辞） | 2610.21412 |
| DecisionVista-Synth / Human、DDS 语料 | 评测 / 训练 | — | 代码公开；数据状态未核实 | 2610.15501 |
| CJ-Bench / 13.048M 中文决策 | 评测 / 训练 | 307,900 / 13.048M | 论文称发布模型；训练集公开状态**未核实** | 2610.23170 |
| SecJev-Corpus | 训练 | 14 任务 8 来源 | 论文称发布适配器、头、语料与代码 | 2610.03073 |
| MEDLINE-S1 / BIODECIDE | 训练 / 评测 | 243k | 发布标签与模型（编码器路线，对照） | 2610.02486 |
| PACT 数据切分与适配器 | 训练 / 评测 | 324 保留 | 公开 | 2609.35865 |
| this-that complex / spatial | 评测 | — | HF `limberc/*`（MIT） | 2609.23886 |
| RLCDAlignBench | 评测 | — | HF **gated（自动）**，CC BY-NC 4.0 | sumleo/RLCDAlignBench |
| 其他 HF 社区集 | 评测 | — | `akhilaaa3/decision-bench`、`Hanno-Labs/decision-bench`（0.98 GB）、`Praveenrajus/jev-bench`（2.95 GB）、`yflantmy/DecisionRobust`（19.9 GB）、`Lexmount/WebJev`、`mohit67890/imajev-bench`、`DaehanKim/korean-jev-benchmark`、`SabaPivot/jev-safety-bench`、`raxITLabs/decision-models-as-guardrails`、`respanai/behavior-benchmark`、`avbiswas/bev-decision` | HF 探测记录（`hf_probe.json`） |

**结论**：训练数据的可得性分三层。（a）**完全公开且带许可**：Kev、Tev1、Nimble、Open-Jev、OneJev、Eikos、PACT、SecJev；（b）**只公开模型与评测、训练混合不公开**：StartLux、Chinese Decision（未核实）、Intern-Decision、Mapika 的教师标注部分；（c）**完全不公开**：TypeSafe Jev 的训练数据与 RLCD。中文决策数据只有 Chinese Decision 一家，而且面向通用 / 医法金融，**没有面向业务规则（D3）的中文决策数据**。许可方面，多数数据与权重是 Apache-2.0 / MIT / CC0，但 StartLux、Nimble v3、AgentDecision-4B、Dohnuts、torchcast、openjev/openjev 的权重为 CC BY-NC；TuringLogic system-x 需人工审批。

### 12.4.2 本地副本（/mnt/cephfs/xingchao）

镜像范围在 2026-10-28 按用户决定收窄为**全部公开数据集 + 实验阶梯需要的 Qwen 基座**；模型权重不再成批下载。当天复查 `/mnt/cephfs/` 后又发现 27B 档的基座本来就在共享目录里，于是下载范围进一步缩到"只补 Qwen3.5 的小尺寸"。状态以清单为准（`/mnt/cephfs/xingchao/manifests/jev/hf_manifest.jsonl`、`github_manifest.tsv`、`hf_probe.json`）。本节更新时（2026-10-28 下午，镜像已完成）：

- 目录约定：数据集 `datasets/jev/<org>__<name>`、模型 `models/jev/<org>__<name>`、GitHub 仓库 `repos/jev/<org>__<repo>`（浅克隆）；每个完成的 HF 仓库写 `.complete`（含修订号与时间）。
- **数据集：24/24 全部完成**（约 41 GB，含 kev-suites、this-that 两个基准、DecisionPivot、Open-Jev / v1.1、JEVal、decision-bench、WebJev、imajev-bench，以及两个大件 `OmniJev/OneJev-Data` 与 `yflantmy/DecisionRobust`），每个目录都有 `.complete`。排除：`fstandhartinger/jevbench`（不存在）、gated 仓库（RLCDAlignBench、system-x、prompt-injection）。
- **模型：40/40 全部完成**（约 79 GB）。其中 32 个是 ≤9B 的决策模型 / 适配器与对照（Nimble-9B 三代、Laya 两种、Open-Jev 2B/9B/27B-v1.1、kev 0.5/0.8/4/9B、AgentDecision-4B、SanSi-2.6B、Lev-2.6B、decider-0.8b、Decision-2.0-Kai-0.6B、Qwen3-0.6B、JevAny-Qwen3.8-27B-LoRA、ufakzeka-karar、rlcd-modernbert-151m 等），另外 8 个是 Qwen3.5 的小尺寸基座。
- **基座不需要重新下载**：`/mnt/cephfs/models/` 下已经有完整的 `Qwen3.8-27B`（52 GB，18/18 分片，config.json 与上游逐键一致且无 `quantization_config`）、`Qwen3.5-27B`（11/11）、`Qwen3.6-27B`（15/15）与 `Qwen3.5-35B-A3B`（14/14，MoE）；共享的 `huggingface_hub` 缓存里另有完整的 Qwen3-0.6B / 14B / 30B-A3B（纯注意力与 MoE 对照）。同目录下的 `-w8a8`、`-DSpark*`、`-DFlash2` 是量化或投机解码变体，不是基座。清单见 `manifests/jev/shared_models_reusable.tsv`。因此原计划的 55.6 GB `Qwen/Qwen3.8-27B` 下载已取消。
- **Qwen3.5 小尺寸基座已全部落地**：0.8B / 2B / 4B / 9B 的 Base 与 Instruct 共 8 个仓库（1.77 / 4.57 / 9.34 / 19.33 GB 一档，均 Apache-2.0），cephfs 上原先任何位置都没有，经 `manifests/jev/hf_queue3.txt` 按"小→大"下载完毕并逐仓校验。配置核对结果见 §8.2 的层数表（层数等键位于 `text_config` 之下）。
- 带宽约束：代理每连接约 10 KB/s，96 并行约 2.5 MB/s；小文件多的仓库实际只有约 1.5 GB/小时，大文件接近 9 GB/小时。本轮共 120 GB，用时约一天。**镜像任务已结束**，只剩下面四个 GitHub 仓库未取全。
- **GitHub**：54 个被引用仓库中 49 个浅克隆完成（约 1.9 GB）；`jaredpalmer/kev` 只拿到 37 MB 的部分检出，`StartLuxLabs/StartLux-Decision`、`Mapika/decider`、`togethercomputer/tev1` 的 pack 在代理下反复截断，`PACT` 因缺 git-lfs 只有源码无权重。这四个仓库的代码仍可按文件从 raw 地址取回，但没有 git 历史。

## 12.5 基座选型规律

| 规律 | 证据 |
|---|---|
| **Qwen3.5 系列（0.8B / 2B / 4B / 9B）+ Qwen3.8-27B 是"完整复现"的默认骨干** | Kev（Qwen3.5-0.8B/4B/9B-**Base**、Qwen3.8-27B）、OneJev（同四档）、Nimble（Qwen3.5-9B）、Tev1（Qwen3.5-4B）、Mapika decider（Qwen3.5-2B/4B-**Base**、35B-A3B-Base）、DKnown-Jev（Qwen3.5-2B / Qwen3.8-27B 基座）、Chinese Decision（Qwen3.5-0.8B/2B/4B）、UniJev（Qwen3.5 多模态塔）、Eikos（Qwen3.5-4B、Qwen3.8-27B）、Open-Jev（Qwen 2B/9B/27B）、pplx-decider（Qwen3.8-27B）、qwen-rlcd（Qwen3.5-0.8B-Base）、Releasing the Inner Jev 与 LDM 的 Qwen 分支 |
| **纯注意力的 Qwen3（0.6B / 1.7B / 4B / 8B）集中在校准与结构研究** | OpenJev-RLCD（Qwen3-1.7B）、jevlike（Qwen3-1.7B）、SHIFT-JEV（Qwen3-0.6B / 4B + Phi-4-mini）、块因果（Gemma 3 1B、Qwen3 1.7B、Qwen3 4B）、Prism-1（Qwen3-8B）、FunDM（Qwen3-8B）、LLM-as-Jev（Qwen3-0.6B）、System X（Qwen3-0.6B→1.7B）、法律蒸馏（Qwen3-8B）、NanoJev 0.6B。原因与 08 章一致：这些工作需要树掩码 / 块掩码或梯度穿过缓存，混合骨干做不到 |
| **Gemma 4（12B / 31B）承担"大模型"位置** | Mapika decider-12b / 31b（Gemma-4-*-it + 合并的状态跟踪 LoRA）、daseinlabs open-jev（Gemma 4 12B）、Releasing the Inner Jev（Gemma 4 31B 微调后 84.4）、LDM、Prism-1（Gemma 4 12B）、torchcast-decision-12b |
| **Base 还是 Instruct 没有共识** | Kev、Mapika（Qwen 分支）、DKnown-Jev、qwen-rlcd 明确用 Base；Mapika 的 Gemma 分支、Tev1、OneJev 用 Instruct；Releasing the Inner Jev 把"从指令模型起步"列为消融项（数字不在缓存中，不引用）；**没有论文系统比较两者在决策质量、校准与 ICL 保留上的差异** |
| **尺寸：4B 是"完整配方"论文的众数；0.6–0.8B 面向延迟；27B 面向排行榜** | 4B：Tev1、AgentDecision-4B、SII-Decision、Intern-Decision-4B、Mapika-4b、StartLux-4B、Eikos-4B、Jeva-4B、OmniMed-Jev-4B；0.6–0.8B：Kev-0.8B、OneJev-0.8B、SecJev-0.8B、NanoJev、Dohnuts、System X；27B：StartLux-27B（Decision Index 第 1）、Open-Jev-27B、pplx-decider、Kev-27B、Eikos-27B |
| **非主流骨干各有一个代表** | 循环预训练 Ouro-1.4B / 2.6B（SanSi、LEV）；编码器-解码器 T5Gemma 2 4B-4B（Bongard）；NeoHorse-1-4B（JEV 重排）；MiniCPM5-1B/2B、Qwen3.6-35B-A3B（Our Own Jev）；Muse-Glimmer 30B（MetaEncoder）；自有 182M 基座（ufakzeka-karar） |
| **编码器只作对照** | Laya（ModernBERT-large 421M / mmBERT-base 322M）、Verdict-MQ 395M、SBERT2S1（Sentence-Transformers 家族）、NDM-Block、this-that、GLiNER2.5-Decide、CLM；benchmark 结论是"有任务标签时微调 DeBERTa-v3-large 在除一项外每个标注基准上准确率最高"（2610.00346），但这条路线不在我们方向内 |

对"在小尺寸 Qwen 类模型上继续训练"这一目标，文献给出的事实边界是：（1）Qwen3.5 全系是 DeltaNet 混合，分支隔离只能按行训练或前缀分叉（08 章）；（2）Qwen3 纯注意力系列上所有结构性方法都已有实现与数字；（3）0.6B–4B 上"冻

结 + LoRA + 复用输出层"是每篇论文都用的起点，且小模型决策训练后校准**不迁移**（jevlike 域外、Nimble 金融）。（4）Qwen3.8 只有 27B 一个稠密尺寸（其余为 MoE），因此"从小到大"只能用 Qwen3.5-0.8B / 2B / 4B / 9B 做小端、27B 做大端；三代 27B 形状相同、0.8B–9B 与 27B 同族同比例（每 4 层 1 层全注意力，08 章 §8.2 的配置表），架构上是一条干净的阶梯，但小端与大端跨了一代预训练，这一差异没有任何文献控制过。

## 12.6 学习视角的盲区

1. **同骨干同数据的目标函数对照几乎没有。** 唯一的系统网格（两种头 × 五种目标）在编码器上做（2610.02486）；解码器上只有 Releasing the Inner Jev 的局部消融与 UniJev 的 RL 比较。"交叉熵 + 温度"是否已经是解码器路线的上界，没有答案。
2. **软标签 / 教师蒸馏的收益与风险都没有在决策模型上量化。** 一方说"软标签可能无用"，一方默认使用；理论说教师偏差不可消除且不可被一致性暴露。顺序、IIA、序数、否定等 D4 缺陷是否随教师概率一起被蒸馏进学生，无人测量。
3. **RL 的作用域不清。** 所有正面 RL 证据都来自带推理链的模型；单遍模型上 RL 为负或无效；TypeSafe 的 RLCD 不可复现。"RLCD"在社区里指至少四种不同的东西（13 章）。
4. **决策微调与 ICL 的关系仍是零文献**（09 章一级盲区 1）。从学习视角看，这等价于"LoRA 决策训练是否改变了注意力对上下文示例的使用"，现有消融只看准确率与 ECE。
5. **数据构成的效应量最大，但没有"数据配方"的研究。** 对比策展、自提问、Agent 自身轨迹三种构造各有一篇，没有同骨干比较；中文、业务规则、非技术人员撰写的输入三类数据为空。
6. **混合骨干上的训练时隔离仍无数字**（08 章），而所有可证实有大效应量的"算法"改动都是依赖掩码的结构改动。这把"选 Qwen3.5 还是 Qwen3"从工程问题变成了学习算法问题。
7. **SFT 的泛化边界没有在单遍模型上被受控测量。** 14 章按七个层次核对后，同族新来源上的迁移证据充分，而新 schema、新符号操作、先验偏移、校准迁移四层只有负面或缺失的证据；"SFT 对 RL 的分布外对照"在单遍决策模型上为零篇。

# 13 • 问题定义的跨论文比较：同一个词，不同的定义

> 口径：用户要求"把问题定义详细地总结下，不同论文的学术定义很可能不一样"。本章只做定义层面的梳理与比较，不提出我们自己的定义（那是下一阶段的工作），但在 §13.9 列出"我们定义问题时必须先回答的分歧点"。所有引文都回到缓存的全文 / 摘要 / 文档核对过；没有核到的定义标注"未核实"。

## 13.0 为什么定义会分歧

Jev 发布只有六周，TypeSafe 没有公开训练细节与形式化定义，社区同时在做三件事：复现（需要可操作的定义）、审计（需要可检验的定义）、理论化（需要公理化的定义）。三种动机给出的"决策模型"定义互相不兼容，而且**同一个指标名（ECE、翻转率、置信度、RLCD）在不同论文里指不同的量**。跨论文比较数字之前必须先对齐定义，这也是 README §4 "跨论文的数字不可直接比较"的根源。

## 13.1 "决策模型"叫什么、指什么

| 命名 | 定义要点 | 出处 |
|---|---|---|
| **System One model**（TypeSafe） | "trained for calibrated decisions: their probabilities are optimized against outcomes to reflect uncertainty. Calibration is measured across groups of predictions; it does not guarantee that an individual answer is correct"；"designed to return stable answers across repeated evaluations"（Self-consistent）；不写回复、不产代码、不生成解释；归入"Machine Native Intelligence"；训练路径是 RLCD（与 RLHF、RLVR 并列的"第三条后训练路径"） | system-one、how-to-build、ML primer |
| **Typed decision model（TDM）** | 审计类论文的通用名；强调"类型化"接口而非训练方式："Type-Safe Is Not Error-Free"、"Labels Override Definitions"、"TDMs under Prevalence Shift"、"How Reliably Do TDMs Use Fallback"、"open TDMs" | 2609.32160、2609.26758、2610.02586、2610.26325、2610.19856、2609.31142 |
| **Typed decision models, also called System One models** | "return such probabilities without generating text"；目的物是"decision gates"："Software that hands branching decisions to a model needs a declared option and a probability it can threshold" | 2610.00346 |
| **Large Decision Model（LDM）** | "processes the task in one prefill, projects the last input hidden state through the LM head, and normalises only the allowed option logits"；Choice 2–8、Score 3–6 的上限"是实现选择，不是 LDM 定义的一部分"；把训练叫 **decision tuning**，把输出叫 **readout** | 2610.15501 |
| **General decision model** | 决策实例是四元组（state, instruction, criteria, gold）："state 提供决策所需信息，instruction 指定决策目标，criteria 定义合法决策空间"；读出叫 **First-Token Decision Readout**（答案位置、限定合法选项标签的分布，一次前向得到 choice / noul / score） | 2610.03935 |
| **Narrow Decision Model（NDM）** | 八条 desiderata：D1 类型化输出（闭集上的分布，绝不自由文本）；D2 校准（"among answers given probability p, about p are right"，按问题类型分别测量、调整、报告）；D3 单遍（一次请求的所有问题与选项在一次前向内回答，状态只编码一次）；D4 选项置换不变（重排选项只置换输出分布，别的不变）；D5 问题隔离（答案不依赖同一请求里的其他问题及其选项）；D6 弃权（每个 Choice 可含显式"none of these"，其概率单独校准）；D7 读而非记（选项由描述识别，可处理未见选项与未见组织架构）；D8（结构项，未摘录）。自称给出"System One decision contract 的形式化陈述"，含**声明 / 未声明两种弃权机制**与**集合值训练目标**，并要求"接受或拒绝机制的评测协议在打开保留数据之前完成"（contract tests） | 2610.25553 |
| **Prefill-only decision model** | "score every candidate in a menu in a single forward pass and never decode"；核心性质是 **readout stability**（Definition 1：把菜单限制到子集后的分布等于原分布在该子集上的归一化） | 2610.07716 |
| **System 1 decision models** | "architectures that map an input directly to a typed, structured decision in a single forward pass"；五族分类：编码器分类器、奖励模型、非自回归决策引擎、对比决策模型、抽取模型 | 2610.33775 |
| **System 1 / 能否交给 System 1** | 问题是"can it be left to a fast model that answers with calibrated probabilities in a single forward pass, or does it still need a generative LLM" | 2610.21244 |
| **Probability-only model** | "return calibrated probabilities for fixed choices in milliseconds and generate no text" | 2610.09188 |
| **Candidate-scoring decision model** | "return a probability distribution over a presented set of answers"；三种训练成分（软目标、冻结骨干、温度）决定"这些概率估计的是什么" | 2610.26797 |
| **Decision models（FunDM）** | "score candidate answers or actions"——把动作选择和答案选择视作同一类 | 2610.17175 |
| **Direct-decision model** | "JEV-like direct-decision models"，强调跳过推理直接出分布，用于序数偏置研究 | 2609.38827 |
| **One-pass decision model** | 结论性定义："best used as fast selectors over a state that a reasoning model has computed and checked"，即决策模型是**选择器**而不是**计算器** | 2610.24929 |
| **System 1.5** | 循环模型：每个循环步读一次选项，"一个模型服务从 1 到 8 次循环的每种预算" | 2610.07730 |

| 命名 | 定义要点 | 出处 |
|---|---|---|
| **Atomic action** | "fast, single-step decisions such as classification, semantic endpointing, Boolean checks, and scoring — formulated as constrained generation with single-token outputs"（仍是生成式解码，只是单 token） | 2609.36115 |
| **Native typed decision-making** | 动作编码器把每个候选动作描述并行嵌入，与 LLM 内部状态打分得到类型化动作分布 | 2609.36116 |
| **Machine intuition** | "recognising patterns and judging situations without explicitly unfolding every intermediate step"，作为独立可训练能力 | 2609.39111 |
| **Typed probabilistic assessor** | Laya 的自述：回答工作流状态上的 choice / noul / score 问题 | 2609.33843 |
| **自然语言接口的 System One** | 反对"结构化 schema 对象编码状态、意图与候选"，主张请求与候选都用自然语言表达，候选空间可到百万级开集 | 2610.11316 |
| **"LLM 已经是 Jev 式决策模型"** | 冻结聊天模型直接读 logits 即满足定义；"决策模型"是读出方式而不是模型类别 | 2610.02076 |

**分歧点**：（1）定义的主体是**接口**（TDM、LDM、JEVal）、**性质**（NDM 八条、readout stability）、**训练方式**（TypeSafe 的 RLCD、"optimized against outcomes"）还是**用途**（decision gate、fast selector、能否交给 System 1）；（2）"不生成文本"是否是定义的一部分——Koa-decision 与 SALSA 单 token 生成、System X 从 KV 缓存续写、StartLux AutoThink 先推理再读出，都自称决策模型；（3）选项上限（255 / 2–8 / 百万级）是否属于定义；（4）"校准"在 TypeSafe 是训练目标的描述，在 NDM 是契约条款，在审计论文是待检验的假设。

## 13.2 请求 / 契约的形式化

| 形式化 | 内容 | 出处 |
|---|---|---|
| TypeSafe 三原语 | Noul（单个概率）、Choice（≤255 个选项上的分布）、Score（2–10 个有序级别上的分布）；一个请求 = 一个 state + 多个 questions；state 与问题分离，示例可放在 state 或问题的 examples 字段 | 01 章、state 文档 |
| Kev 的问题 schema | `{"type": "choice", "instructions": …, "criteria": {name: definition, …}}`，选项由"名称 + 定义"对给出 | jaredpalmer/kev |
| JEVal 四元组 | (state, instruction, criteria, gold)；criteria 定义合法决策空间 | 2610.03935 |
| LDM | Choice 2–8 命名选项、yes/no、Score 3–6 级；上限是实现选择 | 2610.15501 |
| NDM 契约 | 闭集分布 + 按问题类型校准 + 单遍 + 置换不变 + 问题隔离 + 显式弃权 + 读选项描述；声明 / 未声明弃权；集合值目标；合成数据引擎带"有效性守卫"；"specification first" | 2610.25553 |
| Probability Contracts | 把 Event（Noul）与 Choice 两种接口当作两个可能不一致的"概率契约"：同一事实用两种接口问，再比较"规范后验误差"、"补集残差"、"粗化残差"；Jev 的 Event 与 Choice 接口在 10% 延迟成本下**改变 32.8% 有效配对的二元动作** | 2609.37470 |
| 多问题共享状态 | Verdict："answering many small typed questions about one piece of state"；结构化掩码让状态编码与问题无关、问题互不影响、选项顺序无关"by construction"；Intern-Decision 在完整 JSON 骨架里每字段一个决策占位符 | 2610.20778、2610.22131 |
| 单 token 受限生成 | Koa-decision 的原子标签 token；SALSA 的类别→token 映射 | 2609.36115、2510.22691 |
| 自然语言请求 + 自然语言候选 | MetaEncoder：无 schema，候选可到百万级 | 2610.11316 |
| 动作空间 | FunDM / Dyad / AgentDecision：候选是动作描述；DecisionGym 三级（L1 孤立问题、L2 记录轨迹上的步级、L3 控制运行中的 Agent） | 2610.17175、2609.36116、2610.21412 |

**分歧点**：Event 与 Choice 是否是同一个契约（2609.37470 证明 Jev 上不是）；"选项 = 名称 + 定义"时模型跟谁（2609.26758：跟名称；2610.02586：标签压倒定义）；多问题是"隔离"（NDM D5、Verdict）还是"联合有利"（pplx-decider：同一消息的多个侧面联合问 +5.1，独立候选联合问 −0.2 到 −0.4，见 02 章）。

## 13.3 "置信度"指什么

| 定义 | 内容 | 出处 |
|---|---|---|
| TypeSafe `confidence` | 把分布形状压成 0–1 的一个数："1 when all the probability is on one outcome and 0 when the probability is spread evenly"；Noul 没有这个字段；01 章给出其公式只依赖最高概率（(p_max − 1/n)/(1 − 1/n)） | confidence 文档、01 章 |
| 最高概率 | "confidence to be the probability of its verdict"；并指出 Jev 原生字段"是整个标签分布的一个统计量，其公式未公开"，两者 Spearman 0.976；SanSi 同样"Confidence is the top probability" | 2609.26550、2610.07730 |
| 期望误差 | ufakzeka-karar 返回温度缩放概率 + "an expected error that serves as a 'not sure' signal" | 2610.06744 |
| 学到的不确定性分数 | SHIFT-JEV 从不确定性、格式、选项一致性三类信号学一个风险分数，与最高概率分数对比（目标风险 10% 下超标 3–5 对 5–15 / 27） | 2610.34329 |

| 定义 | 内容 | 出处 |
|---|---|---|
| 两种不确定性（训练视角） | OpenJev-RLCD：结果"one-hot when there is a right answer (epistemic uncertainty) and spread when humans disagree (aleatoric uncertainty)"；"Aleatoric uncertainty: when RL cannot help" | 2609.38850 |
| 两种不确定性（部署视角） | 人类分歧 vs 决策风险；非对称损失下两者要求相反的升级信号，"no single confidence number serves both"；把判断拆成并行子问题读分散度可恢复分歧信号 | 2610.33258 |
| 校准 vs 敏感性 | "calibration and sensitivity (how well confidence separates right from wrong answers) are distinct"；最敏感模型的置信度追踪"哪类情境会失败"而非"哪个答案错" | 2610.09683 |
| 答案置信 vs 自知 | "你知道答案吗"类 Noul 与答案置信分离；表面线索会伪装成自知 | 2610.01006 |
| 决策模型"不知道自己的极限" | "its confidence flags the errors it makes itself but not" 输入错误继承的错误 | 2610.24929 |
| 答案质量（answer mass） | AnyJev 用"合法选项上的总概率质量"作为读出的归一化项与有效性指标 | 2610.00831 |

**分歧点**：置信度是（a）分布形状的统计量（TypeSafe），（b）top-1 概率（多数审计），（c）学到的风险分数（SHIFT-JEV），还是（d）两个不可合并的量（2610.33258）。（a）与（b）在排序上高度相关，但**在阈值层面不等价**（同一 0.6 阈值在 2 选项与 10 选项下含义不同），且都不是"错误检测器"（06 章 D1）。

## 13.4 "校准"怎么定义、怎么测

| 定义 / 指标 | 内容 | 出处 |
|---|---|---|
| TypeSafe | "measured across groups of predictions; it does not guarantee that an individual answer is correct" | system-one |
| NDM D2 | "among answers given probability p, about p are right"，**按问题类型**分别测量、调整、报告 | 2610.25553 |
| ECE，15 等宽分箱 | Choice 用最高选项概率，Noul 用其概率；"top-label ECE, 15 equal-width bins, the last bin closed" | 2609.37647、2610.26325 |
| ECE，10 等宽分箱 | JEVal："ten equal-width confidence bins"；SanSi：十等宽、只在可回答项上 | 2610.03935、2610.07730 |
| ECE，15 等质量分箱 | AnyJev | 2610.00831 |
| 等质量分箱 + 偏差感知估计 | benchmark 论文以"估计依赖分箱方案"为由采用 | 2610.00346 |
| 相对有限样本零假设的 ECE | TypedBench："calibration relative to a matched finite-sample null ECE"，并报 smooth ECE、Brier、NLL、5% 风险下覆盖率、翻转率、JSD、RPS、QWK、非对称代价下的决策价值；评测跨"友好 / 对抗"两种表述 | 2610.11392 |
| smooth ECE | ufakzeka-karar（温度缩放在开发集降、在保留支持题升 0.027→0.045） | 2610.06744 |
| 带符号置信-准确差 | Laya 审计：−0.214，所有占用箱准确率高于置信，"符号一致让每种分箱 ECE 变体坍缩到同一个值"；方向决定级联往哪边失效 | 2609.33843 |
| 适当评分规则 | Brier、log-loss、RPS 作为训练目标与评测（jevlike、Open-Jev、NDM、SanSi、OpenJev-RLCD、UniJev CORA） | 12 章 C 族 |
| 选择性预测 / AURC | 按置信排序后的风险-覆盖曲线（OpenJev-RLCD、PACT、2609.37647） | 2609.38850、2609.35865 |
| 策略感知校准 | 在部署策略（选择、路由）下测置信-准确差，184 种设置 ≤2.7 pp；"下游选择会扭曲置信-准确关系即使模型不变" | 2610.17309 |
| 风险预算 / 错误遗漏风险 | 不确定时默认保守兜底，在"被分配效用最大动作"的子集内控制错误遗漏风险；朴素阈值在约一半设置超标，Learn Then Test 7.8% | 2610.19811 |
| 先验偏移下的校准 | 候选限定、EM 先验校正、35 个预注册配对检验 | 2610.26325 |
| 概率公理 / 相干 | 否定对之和偏离 1：Jev 0.064，Qwen3.8-27B 首 token 0.293、口头概率 0.122；层级边缘化与直接问的总变差：Jev 0.219–0.349，Laya 0.424–0.689 | 2609.33209、2609.33971 |
| 跨接口一致 | 规范后验误差、补集残差、粗化残差 | 2609.37470 |

**分歧点**：（1）分箱方案（10/15、等宽/等质量、末箱闭合）直接改变 ECE 数值，跨论文不可比；（2）"校准"是否包含相干性（2609.33209 / 2609.33971 认为不包含，需单列）；（3）校准在"孤立问题"还是"部署策略"下测（StartLux、2610.19811、2609.37470 认为后者才是产品指标）；（4）Noul 的校准是否按正负类分别测（2609.37647 用 Noul 概率本身，TypedBench 用友好 / 对抗表述）。

## 13.5 "一致性 / 翻转"怎么定义

| 定义 | 内容 | 出处 |
|---|---|---|
| 重复性 | 同一请求多次调用的 ICC（0.997）；test-retest 地板（"Jev is not deterministic, so … the flip rate between two identical runs"）；固定顺序重复作为对照；同文重跑翻转 0.17% | 2609.36399、2609.26758、2610.35826、2609.31142 |

| 定义 | 内容 | 出处 |
|---|---|---|
| 一次洗牌翻转 | 字母读出一次洗牌改变 12–20%（Qwen3-8B 20.0% / Gemma 4 12B 11.9%，已发布微调 9.1%） | 2610.22066 |
| 累积失败集 | 八种呈现下追踪单题："accuracy varies by less than two percentage points, yet its cumulative failure set expands by 27–29% relative to the original order"；即**准确率稳定 ≠ 单题稳定** | 2610.35826 |
| 列表反转 | 11 个模型平均反转选项列表改变 33% 的答案 | 2610.00831 |
| 顺序不变（定义） | Runoff Definition 1：决策规则对任意选项顺序给出相同分布；NDM D4：重排只置换分布 | 2610.18233、2610.25553 |
| Luce 两公理 | 顺序无关 + 加选项不改其他选项的相对赔率；定理：只有"每个选项的分数只依赖自身"的 softmax 同时满足两者；"a well-chosen added option steers 4–34% of decisions" | 2610.22066 |
| IIA / 克隆 / 诱饵 | 预注册测试 Jev 的选项集依赖（诱饵、填充） | 2610.16655 |
| 读出稳定性 | 菜单限制后分布 = 原分布归一化（Definition 1）；成立时限制预测器精确 | 2610.07716 |
| 定义级翻转 | "track changes in the selected definition rather than in the returned name"：交换名称-定义绑定后，跟定义的模型应返回不同名称；AUC 93.8% → 23.2% | 2609.26758 |
| 标签压倒定义 | 删除 / 矛盾 / 反转定义三种干预 | 2610.02586 |
| 答案保持变体 | 只保留"不应改变答案"的 5,586 个变体，只攻击正确决策：翻转 46.3% 对同文重跑 0.17% | 2609.31142 |
| 等价措辞 vs 同文重复 | "changes answers more across equivalent wordings than across identical-text repeats" | 2610.30045 |
| 序数压缩 | "candidate-space compression"：选项数与压缩相关、方向不唯一、大模型仍偏置 | 2609.38827 |
| 位置偏置（训练指标） | PACT："answer flips under relabelling" 9.8 对 13.8% | 2609.35865 |
| 问题隔离 | NDM D5；Verdict 的结构掩码；pplx-decider 的"联合 / 分开请求"实验 | 2610.25553、2610.20778 |

**分歧点**：（1）"翻转率"至少有五种分母（一次洗牌、八种呈现累积、列表反转、重标注、答案保持变体）；（2）顺序不变性是**构造保证**（Prism-1、块因果、Verdict、NDM）还是**经验度量**（AnyJev、2610.35826）；（3）"一致"的对象是名称、定义还是分布（2609.26758 的核心区分）；06 章 30 个子维度是在这些定义之上的枚举。

## 13.6 "RLCD"至少有四种含义

| 用法 | 含义 | 出处 |
|---|---|---|
| TypeSafe | 与 RLHF、RLVR 并列的"第三条后训练路径"，"probabilities are optimized against outcomes"；**算法、奖励、数据均未公开** | ML primer |
| 带推理链的适当评分奖励 | OpenJev-RLCD：每条推理链后读出承诺的分布，用严格适当评分规则打分；方差恒等式区分"逐链打分"与"混合打分"（后者 = RLVR + 多样性奖励）；"先校准再强化" | 2609.38850 |
| RLCD²（推理质量差分奖励） | StartLux AutoThink：推理前后两次读出的适当评分之差 + 软长度惩罚；只用于生成推理的模型 | 2610.17309 |
| 五种"RLCD 算法"的统称 | UniJev 比较 Shaped RLCD、GRPO、CtR、RLCD-lite、Rewarding Doubt；其 Table 1 把 Von / OneJev / Open-Jev 的 CE + Brier 和 Kev / NanoJev 的 CE 列为"direct gradient"对照 | 2610.25784 |
| "开源 System One 模型发布的 RLCD 配方" | SBERT2S1 指一种带奖励归一化的得分函数估计器（REINFORCE 式），比交叉熵低 2.5–3.0 点 | 2610.02486 |
| "对适当评分规则做强化学习" | benchmark 论文对 Laya 的描述："trained with reinforcement learning against proper scoring rules, a recipe its developers call RLCD" | 2610.00346 |
| 替身 | jevlike："our open-source stand-in for TypeSafe's unpublished RLCD. We claim no equivalence"——实际是 CE + 0.5 · Brier | mustafasemi-ai/jevlike |
| 等价定理 | NDM："proper scoring rules applied directly when labels are known … reach the same optimum as the policy gradient of an RLCD-style reward without its variance" | 2610.25553 |
| 社区命名 | `SFT + RLCD`（S²-MAS）、`qwen3-0.6b-rlcd-decision`、`rlcd-modernbert-151m`、`Qwen-2.5-1B-RLCD` 等模型名，训练细节各异 | 2610.27746、HF 探测记录 |

**分歧点**：读到"RLCD"时必须先问三件事——有没有推理链、奖励是正确性还是适当评分、是策略梯度还是直接梯度。12 章 § 12.3 的结论"单遍模型上 RL 无正面证据"只对"无推理链 + 策略梯度"这一种含义成立。

## 13.7 "弃权 / 兜底 / 不知道"怎么定义

| 定义 | 内容 | 出处 |
|---|---|---|
| 显式选项 + 单独校准 | NDM D6："none of these" 的概率单独校准；声明（选项里有）与未声明（选项里没有，靠概率）两种机制 | 2610.25553 |
| 概率带 | TypeSafe cookbook：0.30–0.70 映射为 `uncertain` 交人工，并明确"The band is illustrative; it is neither a calibrated guarantee nor an optimized threshold"；confidence routing 用全局下限（示例 0.6）+ 每类动作阈值 | consistency cookbook、confidence-routing |
| 评测口径里的弃权 | JevBench 把 yes/no 概率落在带内的答案计为"弃权 = 错误"，Releasing the Inner Jev 因此把这类答案移到 0.801 / 0.199 | 2610.17205 |
| 兜底规则的执行 | PFR 测试：常规分配与兜底分配之间的切换是否正确；Intern 在 TREC50 从 97.9% 跌到 23.1%，"即使显式给出正确类别" | 2610.19856 |
| 正确答案缺席 | 显式拒绝选项存在时仍接受错误替代（算术依赖的拒绝瓶颈，7% → 阈值后 79%，见 04 章）；法律：替换正确判决后，生成式 LLM 仍在 38–86% 的条目里选一个，最谨慎的决策模型 30% | 2609.39496、2610.29961 |
| 超范围项 | TypedBench："out-of-scope items, whose true option is withheld"，有 / 无 "none of the above" 两种条件下分别测弃权率 | 2610.11392 |
| 可回答 / 不可回答 | SanSi 只在"answerable items"上算 ECE，另有未标注请求上拟合阈值的停止器 | 2610.07730 |
| 静默幻觉 | RSAJEV："assigning higher confidence to unseen than to seen classes (AUROC 0.38)"；用原型检索恢复"可校准的弃权通道" | 2610.15742 |
| 认证弃权 | SHIFT-JEV 用 Learn-then-Test 认证弃权阈值；2610.19811 在无人工交接时以保守兜底动作替代弃权并控制错误遗漏风险 | 2610.34329、2610.19811 |
| 交接选项无效 | "neither an explicit nor a trained hand-off option closes this gap"（输入错误继承） | 2610.24929 |
| 三元契约 | true / false / unknown 准入（05 章） | 2610.10978 |

**分歧点**：弃权是**选项**（NDM、TypedBench 有 NOTA 条件）、**概率带**（TypeSafe、JevBench）、**单独的风险分数**（SHIFT-JEV、ufakzeka）、还是**兜底动作**（2610.19811、PFR）。四种定义对应四种失败：选项不被选（法律　30%）、带不校准（TypeSafe 自述）、分数不迁移（jevlike 域外）、兜底不执行（Intern 23.1%）。

## 13.8 Agent 层的定义

| 定义 | 内容 | 出处 |
|---|---|---|
| 记录-状态不匹配 / claim laundering | 决策层"follows the record instead [and] turns the agent's claim into the decision"；12 个模型-域配置里记录都占主导 | 2610.25947 |
| 三级委托 | L1 孤立问题、L2 记录轨迹上的步级、L3 控制运行中的 Agent；"在轨迹上拟合的置信阈值"；非劣性检验作为接受标准 | 2610.21412 |
| 控制器 | 决策模型作为 Agent 控制器时"好判断、坏建议"（排序 AUROC 0.78 但平均"已完成"概率 0.50 而 87% 实际通过，见 06 章） | 2610.24649 |
| System Switch | 快模型何时停下来交给推理模型：按置信延后最不确定的 30% | 2610.09683 |
| 快选择器 | 决策模型"over a state that a reasoning model has computed and checked" | 2610.24929 |
| 能否交给 System 1 | 同一类型化请求发给 30 个模型，四组任务 + 138 个闭环环境 | 2610.21244 |
| 四元组 / 联合可靠性 | 规则迁移、联合可靠性、信息使用的受控测试；"等价改写有相反的任务级效应" | 2610.30045 |
| 双时标 | 慢教师在暂停的环境里写指令，快学生在运行中执行；"live clock"下更快的模型反超 | 2610.20665 |
| 决策级持续学习 | 类型化反馈（接受 / 撤销）变成有界因果状态 | 2610.31521 |

**分歧点**：Agent 层的"正确"是**孤立准确率**（L1）、**步级一致**（L2）还是**任务成功 / 成本 / 时钟**（L3、live clock）；07 章的结论"更快的决策 ≠ 更好的 Agent"正是三种定义不一致的表现。

## 13.9 分歧总表与"我们定义问题前必须回答的"

| 维度 | 定义 A | 定义 B | 定义 C | 后果 |
|---|---|---|---|---|
| 决策模型 | 接口（TDM / LDM） | 性质契约（NDM 八条、readout stability） | 用途（gate / selector / 能否交给 System 1） | 决定评测对象是"模型"还是"模型 + 阈值 + 代码" |
| 请求 | 三原语 + 上限 | 四元组 (state, instruction, criteria, gold) | 自然语言候选 / 动作空间 | 决定 D3 规则语言的输入形态 |
| 置信度 | 分布形状统计量 | top-1 概率 | 学到的风险分数 / 两个量 | 阈值在不同选项数下不可迁移 |
| 校准 | 群体频率匹配（10/15 等宽/等质量） | 相干性 + 公理 | 部署策略 / 风险预算下的误差 | ECE 数字跨论文不可比 |

| 维度 | 定义 A | 定义 B | 定义 C | 后果 |
|---|---|---|---|---|
| 一致性 | 一次洗牌翻转 | 累积失败集 / 答案保持变体 | 定义级翻转 | "准确率不变"掩盖单题不稳定 |
| 顺序 / IIA | 经验翻转率 | 构造保证（Luce） | 读出稳定性 | 混合骨干能否满足构造保证（08 章） |
| RLCD | 未公开 | 带推理链的适当评分奖励 | 直接梯度的替身 | "RL 有没有用"的结论取决于含义 |
| 弃权 | 显式选项（单独校准） | 概率带 | 风险分数 / 兜底动作 | 四种失败模式各不相同 |
| 多问题 | 隔离（NDM D5） | 联合有利（pplx） | 分解后读分散度（2610.33258） | 扇出与分解的语义 |
| Agent 正确性 | 孤立准确率 | 步级一致 | 任务成功 / 成本 / 时钟 | "更快 ≠ 更好" |

在我们自己写问题定义之前，这些分歧中至少有六个必须先取定：（1）"决策模型"是按接口还是按契约定义；（2）置信度采用 top-1 还是分布统计量，以及是否要与"自知"分开；（3）校准用哪种分箱、是否含相干性、在孤立还是部署策略下测；（4）翻转率用哪个分母、顺序不变性要构造保证还是经验度量；（5）弃权是选项、带、分数还是动作；（6）"RLCD"一词在我们文档里指哪一种。本章不做取定，只指出每种取法在文献里已经有的证据与失败案例。

# 14 · 假设审查："SFT 无法让模型具备一般意义上的泛化能力"

> 口径：这是对一条工作假设的**证据审查**，仍然只做分析、不给训练方案。假设原文："我倾向于认为 SFT 无法让模型具备一般意义上的泛化能力。"审查对象限定为 Jev 类单遍决策模型的文献（02 / 12 章的配方与消融），辅以少量上游通用结果。结论先行：**强形式不成立，弱形式成立**——SFT 在"同任务族、新样本 / 新来源"上可靠迁移，且差距随基座规模收敛；但没有任何一篇文献证明 SFT 能把"新的符号操作、新 schema 下的保真、分布外校准、超出单遍深度的推理"训进去，多篇给出负面结果。能跨层次移动结果的变量是基座（规模、指令调优）、数据覆盖、表示阶段目标与结构约束，而不是监督目标本身。
>
> **复核提示（20 章）**：本章的结论方向（强形式不成立、弱形式成立）在 20 章 §20.1 被判为"对"，但本章把失败归给**监督目标**这一机制被判为**不完整**——证据显示跨层移动结果的是基座规模、指令调优起点、监督分布与结构约束。另外"七个泛化层次 L0–L6"是本报告自己的构造（20 章 §20.2，过拟合风险中高）。

## 14.1 先把"泛化"拆成可检验的层次

"一般意义上的泛化"不可直接检验。按 Jev 类文献实际使用的评测切分，可以把它拆成七层，每层对应不同的测试集构造方式：

| 层 | 含义 | 文献中的测试构造 |
|---|---|---|
| L0 同分布 | 训练来源的保留样本 | Kev "trained sources"、Tev1 验证集、StartLux held-out |
| L1 新来源 / 同 schema | 同一类决策，新数据集或新策略文本 | Kev "new sources"（breadth-v1 的 14 个未训练数据集）、OpenDecisions 迁移套件、SkillScreen 新来源 |
| L2 新 schema | 训练时没见过的决策形态（新问题形式 / 规则结构 / 渲染格式） | DecisionVista 的 DV-Dev-A/B、this-that 的 JSON 渲染与新规则结构、StartLux 家族外任务 |
| L3 新符号操作 | 标签重定义、规则翻转、组合、兜底 | 名字压倒定义、标签翻转、Certo 反事实、PFR 兜底、StateWise |
| L4 分布 / 先验偏移 | 同任务不同类别频率、措辞、来源 | 患病率偏移（2610.26325）、拒绝策略跨任务复用、持续后训练中的遗忘 |
| L5 校准迁移 | 置信度与阈值在新分布上是否仍可用 | jevlike 域外 ECE、迁移套件 ECE、教师偏差 |
| L6 推理深度 | 需要多步计算的条目 | rollout–readout 差、按思考 token 数分层 |

下文按层给证据；每层末尾给出"假设在该层成立 / 部分成立 / 不成立"的判断。

## 14.2 分层证据

### L0 / L1：同任务族、新样本与新来源——假设不成立，但增益随规模收敛

- **SFT 确实提高同族准确率**，且增益主要落在小模型上。Kev README 的 new / trained sources 表（开发 / 测试）：Kev-0.8B 0.648 / 0.697 对 0.827 / 0.838；4B 0.817 / 0.838 对 0.873 / 0.865；9B 0.820 / 0.852 对 0.874 / 0.873；27B 0.851 / 0.889 对 0.865 / 0.866。"新来源"与"训练来源"的开发集差距从 0.8B 的 17.9 点缩到 27B 的 1.4 点（jaredpalmer/kev）。新来源上 27B 与 Jev 相差一点以内（0.851 对 0.857）。
- **增益本身随基座规模收敛。** Qwen3.5 0.8B→27B 上，未调优读出达到调优后 76–97% 的准确率，调优增益从 15.8 点缩到 2.3 点，1/16 的数据已收回大部分；LoRA 更新不到 0.5% 参数，但只训字母头"几乎收不回增益"（2610.15501）。作者的解释是"预训练提供表示，调优只调整怎么读"。
- **同族数据的边际收益远大于跨族。** StartLux 在 DecisionPivot 重用任务上加入评分 / 安全 / 偏好 / 逻辑四个家族的第二阶段数据，这四个家族对应的 18 个任务 +8.6 点，家族外任务只 +0.3（2610.17309）。
- **"新来源"也有失败面。** SkillScreen 在未见攻击家族上以 99% 召回只误报 20–25% 良性技能，并比全参数微调的编码器更能泛化到新来源；但"不熟悉的良性来源让误报急剧上升，识别新攻击不等于能可靠筛查新的技能集合"（2610.17727）。
- 领域 SFT 的"小胜大"（SecJev-0.8B 比 Kev-9B +20.51，2610.03073）全部是**域内**数字，论文自己的迁移测试只报告了提示注入与流量两类同域迁移。
- UniJev 的三模态联合 SFT"在文本、图像、视频上都提高决策准确率"（2610.25784），也是同族保留集。

判断：L0 / L1 上 SFT 的迁移是文献里最一致的正面结果，假设的强形式在这里不成立。但注意两点：增益大头是小模型的"读出对齐"，不是新能力；27B 上同族增益只剩 2 点左右。

### L2：新 schema——假设部分成立，取决于规模与评测集

- 最直接的对照来自 LDM：在 27B 上，公开数据配方把验证准确率从 79.3 提到 81.8，加入基准来源后在该基准八个子集上到 89.1；**但两种配方都没有稳定提高新 schema 准确率**——DV-Dev-A/B 上公开配方 88.1 / 87.5、来源增强配方 87.8 / 88.0，对未调优 89.1 / 87.5。作者的措辞必须原样引用："迁移取决于规模和评测集——基线调优在 9B 上确实有帮助——所以这是扩大 schema 覆盖的动机，**不是'监督调优不能迁移'的论断**"（2610.15501）。
- this-that（编码器路线，对照）给出了"训练分布之外即坍塌"的最清楚例子：同一批格子以 ASCII 渲染 0.457、以 JSON 渲染 0.373（机会率 0.394），针对性训练一轮后分别 0.779 / 0.936；而在训练中没有出现过的规则结构上，1.1 版得分 0.447 对机会率 0.31，校准误差 0.20，"这是这个模型自信且错误的唯一区域，`confidence < 0.8` 分支抓不到它"（FLock-io/this-that-model）。
- Laya 的独立复现在域外探针上"没有零样本迁移"（2609.33843），同为编码器对照。
- 机制层面，ICL 的"任务 schema"与"绑定"是可分离的两种机制：schema 以 100% 迁移、绑定只有 62%，且 schema 依赖与先验知识负相关（2512.17325）；"规则可以摊销、配对不能"：高秩映射在留一任务迁移上为零（2610.00526）。这解释了为什么"格式 / 读出"容易被 SFT 迁移、"具体映射"不容易。

判断：解码器路线上，27B 的 SFT 对新 schema 增益约为零但也不为负；9B 上有帮助；编码器路线上新 schema 直接坍塌。假设在 L2 成立一半——**SFT 没有带来新 schema 增益，但也没有证据说它伤害了基座已有的迁移能力**。

### L3：新的符号操作——假设成立，且有多篇负面证据

- **标签名压倒定义**：把选项定义与名字对调，AUC 从 93.8% 掉到 23.2%（2609.26758）；删除定义准确率不变（2610.02586）。被测的是托管 Jev 与开源决策模型，均经过决策训练。
- **小模型无法在上下文中翻转标签语义**（1–12B，2511.21038）。
- **反事实监督只在合成规则上奏效**：Certo 的可缓存化把规则敏感度从 recall@1 1.00 打到 0.24；针对性反事实监督在**保留的合成规则任务**（改写、反事实、组合）上恢复到高分、跨种子可复现，但"我们没有分离出预测是否依赖所给规则"，而在真实规则上"附加收益未被确立"（2609.37832）。
- **学会跟踪不等于学会服从**：StateWise 用两种技能 SFT + 自训练，让 7–8B 模型几乎完美地跟踪约束状态，"但出乎意料地没有学会服从它"（2610.33766）。
- **识别不迁移到兜底**：PFR 测试里"正确识别不可靠地迁移到正确的兜底选项，即使明确给出正确类别错误仍然存在"，逻辑等价的规则表述给出不同决策（2610.19856）。
- **迁移量取决于与最近训练规则的一致程度**：受控算术规则实验中"适应增益随最近来源答案一致度上升；完全冲突的四元组只有很小的合并增益，且不同来源切分上符号相反"，等价改写有相反的任务级效应（2610.30045）。这是对"SFT 学到的是与训练规则的相似性而非操作本身"最直接的量化。
- 上游通用结果同向：精确指令遵循上"大多数模型强烈过拟合于基准里一小组可验证约束，不能泛化到未见约束"，可验证奖励的 RL 改善泛化（2507.02833）；"SFT 记忆、RL 泛化"在 GeneralPoints / V-IRL 规则变体上成立，但同一篇也指出 SFT 对稳定输出格式是 RL 的前提（2501.17161）。两者都是生成式设定，不是单遍读出。

判断：这一层没有任何正面证据。SFT 能让模型在**训练过的操作家族**内表现得像会做操作（Certo 合成任务、StateWise 的跟踪），但一旦检验"是否真的依赖规则"（对调定义、删除定义、真实规则、服从而非跟踪），结果一致为负。

### L4：分布 / 先验偏移——假设成立，且 SFT 可能为负

- 决策训练相对自身基座的方向不一致：在 FPB 金融情感上 Tev1-4B 的 Macro-F1 比 Qwen3.5-4B 高 10.0 点，Nimble-9B 比 Qwen3.5-9B **低 12.0 点**、ECE 高 9.6 点，损失集中在中性类；Tev1-4B 从不显著差于基座（2610.26325）。同一种"决策 SFT"在不同数据构成下可以是 +10 也可以是 −12。
- 拒绝策略不能跨任务复用：在 DBpedia 上校准的 Jev 策略拒绝 69.3% 被覆盖的 Emotion 测试输入，反向则完全失去检测（2610.03387）。
- 持续后训练中"获取差与遗忘都与后训练后的分布偏移线性相关"，小模型尤甚（2610.13113）；LoRA 在域外少样本适应里造成 35–56% 的相对遗忘而软提示没有（视觉设定，2609.11310，仅作机制对照）。
- Our Own Jev 的 2B 困难层训练后 63.1 低于冻结 67.6，换一版语料移动 11 点（2610.29052）。

判断：SFT 之后模型对"训练混合的先验"更敏感而不是更不敏感；数据构成的效应量大于目标函数（12 章 §12.3）。

### L5：校准迁移——假设成立

- jevlike（Qwen3-1.7B + LoRA + 37 个数据集）：温度 1.19 让域内 ECE 从 0.0212 降到 0.0083，域外只从 0.1311 到 0.1011；域内验证为 99.85% 精确的 0.99 置信门在域外失效（mustafasemi-ai/jevlike）。
- 更长的 SFT 让 Qwen 在迁移套件上过度自信：ECE 9B 23.8、27B 18.5，而配方保持 8–12，一个温度去掉大部分差距（2610.15501）。

- 理论上，学生继承教师偏差且更多数据不消除；温度缩放只在教师方向正确时去掉全部多余风险，否则留下校准诊断看不见的残差（2610.26797）。
- 反例只在生成式设定：以对数评分规则做奖励的 RL 使置信度"泛化到未见任务"（2503.02623）；浅层表面变体上温度可迁移（法语输入变体，2610.33493）。

判断：单遍决策模型上没有"SFT 后校准跨分布保持"的证据；有的是温度在域内修好、域外不修的证据。

### L6：推理深度——假设成立，且被两篇论文明确列为未解

- 同一个未调优 27B 允许推理（四样本多数）时 96.9 对 89.1（DV-Dev-A）、96.8 对 87.5（DV-Dev-B）、85.1 对 79.3（验证集）；日期算术与数值比较三个 schema 上读出在每个规模都只有 56–66%，推理 98–100%（2610.15501）。
- 按参考模型所需思考 token 分层，Jev 的准确率从少于 250 token 的条目一路下降到超过 4k token 条目的 50%；"训练这类决策、或在读出前加几步内部计算，能否移动这个极限，仍然是开放问题"（2610.24929）。

判断：这不是 SFT 的问题而是单遍读出的问题，但它划定了 SFT 的上界——训练数据再多，单遍读出也不会获得它结构上不具备的深度。

## 14.3 哪些变量确实让结果跨层移动

既然 SFT 本身没有跨层增益，值得记录的是文献里**有**跨层效应的变量，它们是我们之后讨论问题定义时的参照：

| 变量 | 证据 | 效应落在哪一层 |
|---|---|---|
| **基座规模** | 新来源差距 17.9→1.4（Kev）、调优增益 15.8→2.3、新 schema 迁移"在 9B 上有帮助" | L1、L2 |
| **指令调优的起点** | 仅预训练的 Gemma 4 31B 用同一配方只到 70.3，比指令版低 14.1（2610.17205） | L1、L2 |
| **数据覆盖（而非数据量）** | this-that 针对 JSON 渲染训练一轮 0.373→0.936；LDM 的结论是"扩大 schema 覆盖"；两个教师平均 > 一个教师全预算（2610.09188）；1/16 数据已收回大部分增益 | L2（只覆盖到训练过的形态） |
| **训练分布 = 部署分布** | AgentDecision-4B 在 Agent 自己犯错后到达的状态上训练，分布外任务 91.5% 对 Jev 82.0%（2610.21412） | L1→L2 的反例：监督分布选对了，SFT 可以跨任务迁移 |
| **表示阶段的目标** | Bongard 第二阶段（JEPA 式视图对齐，非标签监督）在 14,606 条保留的重新表述上 75.7→85.9，NLL 0.613→0.437（2609.39111，编码器-解码器对照） | L2 的措辞 / 逻辑补 / 序数阈值变体 |
| **结构约束** | 块因果翻转率 8.30→0.11%（2610.01601）、Prism-1 零翻转（2610.22066） | D4 的顺序不变性——**靠构造而非学习** |
| **RL（仅在有推理链时）** | OpenJev-RLCD 的先校准再强化、StartLux AutoThink +11.5 到 +18.4 配对准确率；单遍 RLCD 为负或等价（12 章 §12.3） | L6 |

## 14.4 结论：假设成立的范围与需要修正的措辞

1. **强形式"SFT 无法泛化"不成立。** 在同任务族的新样本与新来源上（L0 / L1），决策 SFT 的迁移是文献中最一致的正面结果，新来源差距随规模从 18 点收敛到 1 点。
2. **弱形式成立，且证据比预期多。** 在新符号操作（L3）、先验偏移（L4）、校准迁移（L5）、推理深度（L6）四层，没有一篇文献给出"SFT 单独带来跨分布增益"的证据，多篇给出负面结果；新 schema（L2）上 27B 的 SFT 增益约为零。
3. **可以替代的更精确表述**：SFT 教会的是读出与格式的对齐，以及训练分布内的技能；它不改变模型"是否依赖规则"，也不改变单遍读出的深度上界。跨层次的泛化来自基座（规模、指令调优）与监督分布的选择，而非监督目标。 这与 LDM 的"预训练提供表示、调优只调整怎么读"和 2512.17325 的"schema 可迁移、绑定不可迁移"一致。
4. **文献没有回答的问题**（我们自己的测量才能回答）：（a）单遍决策模型上没有一篇做过受控的 SFT 对 RL 分布外对照——"SFT 记忆、RL 泛化"与 IFBench 都是生成式设定，UniJev 的五种 RLCD 比较没有报告分布外切分；（b）Certo 式反事实监督在真实规则上的收益"未被确立"，但也未被否定；（c）SFT 是否**损害**基座已有的 L2 迁移能力，LDM 的数字（88.1 对 89.1）在噪声内，没有显著性检验；（d）所有 L3 负面结果都在 ≤9B 或托管 Jev 上，27B 上的"名字压倒定义"没有测过。
5. **对"从小到大 scale up"的含义**：上面所有随规模变化的量（新来源差距、调优增益、新 schema 迁移）都说明小模型上观察到的 SFT 效应**不能外推**到大模型——小模型上 SFT 显得"有用"主要因为读出对齐的空间大；因此 scale-up 实验必须在每个尺寸上同时报告 L1 与 L2 / L3，否则会把"读出对齐"误读为"泛化"。

## 14.5 可用来检验这条假设的英文公开集（只列度量，不列方案）

前置实验按用户决定使用英文数据。文献里已经存在、且本地已镜像或可镜像的英文切分，能直接对应 14.1 的层次：

| 层 | 公开切分 | 本地状态 |
|---|---|---|
| L1 | Kev `kev-suites` 的 breadth-v1（14 个未训练数据集）与 `decision-v7` 保留集 | `datasets/jev/jaredpalmer__kev-suites` |
| L2 | this-that spatial（15 家族 7,305 题，三种渲染）与 complex-decisions（1,710 题，MIT） | `datasets/jev/limberc__*` |
| L2 / L6 | DecisionPivot 的难度 1–3 对照对（2610.28522）；DecisionVista 的 DV-Dev-A/B（代码公开、数据状态未核实） | `datasets/jev/startlux-models__DecisionPivot` |
| L3 | 名字 / 定义对调协议（2609.26758）、PFR 兜底测试（2610.19856）、Certo 的合成规则任务 | 协议公开，需按论文重建 |
| L4 | 患病率偏移协议（2610.26325，五个公开数据集 + 预注册的 35 组配对检验）；拒绝策略迁移基准（2610.03387，代码与工件公开） | 需按论文重建 / 克隆 |
| L5 | 上述每个切分上的 ECE（13 章 §13.4 要先取定分箱）与域内拟合温度的域外复用 | — |

这些切分的共同要求是：**同一个检查点同时报告训练来源、新来源、新 schema 三列**（Kev README 的表格格式），否则无法区分"读出对齐"与"泛化"。

# 15 · RL 还是 SFT：以"保留 ICL"与"注入技能语义"为约束的证据审查

> 口径：仍然只做分析与调研。本章回答一个被明确提出的选型问题——**类 Jev 模型应该基于强化学习来训练和优化吗**——但附加了两个约束：（1）模型要保留 **ICL** 能力，即调用方可以用上下文**定义一族任务**；（2）模型要具备**类 skill 的语义注入**能力，即知道某个具体问题该用什么方法与流程来解。结论先行：**"RL 还是 SFT"不是决定这两项能力的那个变量**。决定 ICL 存亡的是训练样本之间**什么在变**，决定技能语义能否注入的是**技能存放在上下文还是权重里**、以及**单遍读出能不能执行流程**。RL 只在存在"被采样的中间对象"（推理链、示例集编辑、工具调用）可以归因时才有独立价值；对纯单遍读出，现有证据是负面或与适当评分规则等价。
>
> **复核提示（20 章）**：本章判定"用 RL 来保 ICL 与技能注入"不成立，这是四个工作假设里唯一**结论方向也被判为错**的一个（20 章 §20.1）。但要注意本章与 12 章共用的证据基础很薄：单遍模型上 RL 为负的三个数据点彼此异质（一个是编码器、一个是小规模 REINFORCE、一个是 Agent 回路里的 GRPO 而非读出上的），见 20 章 §20.4。

## 15.1 先纠正问题的提法

把 14 章的结论接上：SFT 教会的是读出对齐与训练分布内的技能。一个自然的推论是"那就换成 RL"。但文献里与这两项能力相关的**正面证据几乎全部来自 SFT**，只是来自**特定构造的 SFT**：

| 想要的能力 | 文献里有效的做法 | 是 RL 吗 |
|---|---|---|
| 用上下文定义新任务 | MetaICL：在 142 个任务上以 ICL 格式元训练，测试时只靠条件化就更会学新任务（2110.15943） | 否，纯 SFT |
| 让上下文**压过**先验语义 | 符号调优：把自然语言标签换成任意符号（foo/bar）做微调，未见 ICL 任务更强、对欠定提示更稳健、**翻转标签的能力大幅提升**（2305.08298） | 否，纯 SFT |
| 把技能/流程写进权重 | LatentSkill：超网络把文本技能转成即插即用 LoRA，ALFWorld 已见 / 未见分别 +21.4 / +13.4，prefill token 少 63.9%（2606.06087）；Doc-to-LoRA 单次前向生成 LoRA（2602.15902）；Cartridges 离线训练 KV 缓存（2506.06266） | 否，超网络 / 蒸馏 |
| 在推理时注入流程 | SkillsBench：配好的 Skills 把平均通过率从 33.9% 提到 50.5%（+16.6 pp），**≤3 个模块的聚焦 Skill 优于穷举包**，小模型带 Skill 可追平不带 Skill 的大模型（2602.12670） | 否，纯上下文 |

符号调优这一条尤其关键：它是**用 SFT 直接修复"标签名压倒定义"**（2609.26758、2610.02586、2511.21038）的已知手段，而那正是 D1 当前最严重的缺陷。没有任何一篇 RL 工作声称做到了同一件事。

**因此提法应改为**：不是"RL 还是 SFT"，而是"**训练分布里什么在变、监督落在哪个对象上**"。

## 15.2 决定 ICL 存亡的变量：任务定义是否随样本变化

- **ICL 本身是"受约束的词表检索"而非概念推断**：示例标签同质化会让准确率塌到 ≤12%（六个模型、0.8B–8B、四个任务）；示例用无意义 token 时模型把 42–67% 概率压在被示范过的集合上，而语义上合理的词概率 <0.2%（2605.08295）。模型把标签槽当成**穷举答案词表**——这与 Jev 式"选项集由调用方声明"的接口是同一个机制。
- **ICL 的学习能力本身有限**：大规模消融后，示例变多时准确率对示例分布、模型、提示风格都不敏感，模型是在从提示的规律里**演绎**，因此对分布敏感（2509.10414）。
- **机制上可分离**：任务 schema 经晚期 MLP 以 100% 迁移，绑定只有 62%（2512.17325）；规则可被摊销进潜向量，配对不能，留一任务迁移为零（2610.00526）。
- **决策微调对 ICL 的影响是零文献**（03 章 §3.2.3、09 章一级盲区 1）：没有任何一篇在决策微调前后测过同一骨干的 **k-shot 曲线**。

把这些放在一起，推论是明确的：**如果训练集里每条样本的任务定义是固定的（一套 schema、一组固定选项），那么无论梯度来自交叉熵还是来自策略梯度，最优解都是把任务烧进权重、忽略上下文。** ICL 的消失不是 SFT 的性质，是"任务不变"这个数据性质的后果。反过来，MetaICL 与符号调优之所以能**提高** ICL，正是因为它们强迫模型只能从上下文里拿到任务。

对 Jev 式接口，这一点有一个特别顺手的地方：**选项集本来就在请求里**，天然每条样本都不同。但现有复现把几十上百个公开数据集重编译成决策格式时，实际落到模型眼前的仍是有限几十种 schema（12 章 §12.2 第 4 条），所以"选项在请求里"并不自动等于"任务在上下文里"。

## 15.3 决定技能注入的变量：上下文还是权重，以及能不能执行

技能语义注入在文献里是**两条互不相同的路线**，代价结构完全不同：

**（a）上下文技能（SKILL.md 这一类）**

- 收益确实存在且可观：+16.6 pp，聚焦优于穷举，小模型 + Skill ≈ 大模型（2602.12670）。
- 但**写得好是稀缺的**：138,133 个公开 SKILL.md 中 91.8% 至少有一个缺陷，主要是路由元数据弱、正文臃肿不可执行、资源组织差；路由元数据合规的技能被可靠检索到的比例显著更高（2608.08453）。
- **组织方式本身改变行为**：渐进式披露把每条轨迹触达的技能资源从 1.18 提到 3.85（2606.11543）；层级化分组的示范在"描述含糊"的任务上把通过率从 76.7% 提到 90.7%，而描述精确时任何格式都没有收益（2606.20978）。
- **有技能 ≠ 会执行**：SkillSentry 指出即使模型已证明能在技能指导下完成任务，仍会偏离流程或步骤执行错误（2608.09253）；Skill Coverage 提出轨迹级的覆盖度量，因为任务成败不告诉你技能的哪部分被执行过（2606.20659）。这与 D2 的"读得对、做不对"（22%–72% 执行率，2610.18579）是同一个现象。

**（b）权重内技能**

- LatentSkill 用超网络把文本技能映射成 LoRA，省 63.9% prefill 且**超过**对应的上下文技能基线；生成的技能 LoRA 形成结构化语义几何，可用缩放系数连续调制、可用参数空间算术组合（2606.06087）。
- Doc-to-LoRA 元学习"单次前向近似上下文蒸馏"（2602.15902）；Cartridges 离线训练 KV 缓存并指出朴素的 next-token 训练不够（2506.06266）；cheat-sheet ICL 把多示例蒸馏成一段文本（2509.20820）。
- 程序性记忆的迁移是**部分的**：一轮精炼 +3.7–6.7 点，由多模型轨迹演化出的技能跨模型测试 73.1%，优于任何单模型轨迹来源；但"有些技能广泛泛化，有些固化为角色特定流程并在迁移下失效"（2606.23127）。

**（c）对单遍模型的硬约束**：上面所有"技能"都是**流程**，而流程需要被执行。单遍读出没有 rollout——它只能让技能语义影响**那一次读出**，不能执行方法与步骤。这不是训练方法的问题：按参考模型所需思考 token 分层，单遍模型的准确率从 <250 token 条目一路掉到 >4k token 条目的 50%，作者明确把"训练这类决策、或读出前加几步内部计算能否移动这个极限"列为开放问题（2610.24929）。把工作流编译成确定性程序的那一系（TraceCompiler、Artic、FlashScript、Formal Skill，2608.02680、2608.21341、2610.33876、2605.19604）正是承认了这一点：**流程交给程序，判断点交给模型**——而 Jev 式模型恰好就是那个判断点（2610.21411 测得路由与评审占生成式 token 的 31.7–43.5%）。

## 15.4 那么 RL 到底在哪里有独立价值

把 12 章 §12.3 的 RL 证据与本章的约束合并：

| 设定 | 证据 | 判断 |
|---|---|---|
| **纯单遍读出** | 发布的 RLCD 配方 −2.5 到 −3.0（2610.02486）；REINFORCE −10.2 F1（2610.06744）；GRPO 无增益（2610.21412）；UniJev 五种 RLCD 相对 SFT 增益"很小"（2610.25784）；NDM 证明适当评分规则的最优点与 RLCD 式奖励的策略梯度**同最优点**（2610.25553） | **无独立价值**。最优点一样，只多了优化难度 |
| **有推理链** | OpenJev-RLCD 的"先校准再强化"在两个真实推理任务上匹配或超过 SFT / RFT-STaR / GRPO，并在选择性预测上全面更优；GSM8K 答案验证单次查询在 ≤5% 错误下决定 81% 条目对 GRPO 的 19%（2609.38850）；StartLux AutoThink 比 Instant +11.5 到 +18.4 配对准确率（2610.17309） | **有价值**，因为有"被采样的理由"可归因 |
| **上下文/示例本身是决策对象** | Jev-LDE：用 RLVR 训练一个 System-1 小模型对检索到的示例集做 Keep / Delete / Replace 一次编辑，分类基准上一致提升且可迁移到留出基准与模型（2609.33609） | **有价值，且直接服务于 ICL** |
| **未见约束的指令遵循** | 多数模型在一小组可验证约束上严重过拟合、不能泛化到未见约束；RLVR 改善泛化（2507.02833）；但 RLVR 易过优化、走验证捷径（2508.04632） | **有价值但需防捷径**，对 D2 相关 |
| **置信度表达** | 以对数评分规则为奖励的 RL 使校准"泛化到未见任务"（2503.02623） | **生成式设定下有价值**，单遍未验证 |

还有两条限制 RL 适用范围的理论结果，都来自 OpenJev-RLCD（2609.38850）：

1. **一行方差恒等式**说明"对多样本混合打分"会奖励理由之间互相分歧并使推理退化，而 **RLVR 恰好就是去掉了多样性项的混合目标**。
2. **当不确定性来自标注者分歧时，同一目标可证明不可能胜过交叉熵**，并且放任不管时模型会"发现自己应该停止推理"。

加上工程事实：策略梯度项的梯度比读出项大 **7–12 倍**，会淹没读出；不加 KL 锚会出现"System-One 坍塌"（模型干脆关掉推理）。

## 15.5 对两项约束的直接回答

**（1）保留 ICL。** RL 不是答案，**训练分布才是**。文献里唯二能提高"用上下文定义任务"能力的方法（MetaICL 的任务级元训练、符号调优的符号化标签）都是 SFT，且都靠"每条样本的任务只能从上下文里获得"这一条数据性质生效。RL 在这里的角色是**局部的**：当"选哪些示例/怎么编辑示例集"本身成为一个决策时，RLVR 训练出的 Jev-LDE 是有效的（2609.33609）。同时要知道 ICL 的上限：它是受约束的词表检索（2605.08295），示例多到一定程度后对分布不敏感（2509.10414）。

**（2）技能语义注入。** 这是一个**存放位置**问题，不是 SFT/RL 问题。上下文技能便宜、可审计、即时可改，但 91.8% 写得有缺陷，且"有技能 ≠ 会执行"；权重技能（超网络→LoRA）更省 token 且在已见与未见划分上都更强，但失去可审计性与即时可改性。对**单遍**模型还有一条硬约束：技能里的"方法与流程"无法被执行，只能影响那一次读出；工作流编译那一系的共识是把流程交给确定性程序、把判断点交给决策模型。

**（3）所以该不该用 RL。** 对我们要做的单遍 Jev 类模型，证据给出的条件是清楚的：**只有当奖励依赖于标签之外的、被采样出来的中间对象时，RL 才有独立价值**。对纯读出，NDM 的定理说它与适当评分规则同最优点，实测增益"很小"或为负。如果之后引入"读出前的几步内部计算"或"AutoThink 式的可选推理"，RL 的适用条件就成立了，而且已有可复现的配方形状（先校准再强化 + KL 锚）。

## 15.6 本章识别的盲区

1. **决策微调前后的 k-shot 曲线**仍然无人测量（03 / 09 章已列），而它是判断"我们的训练是否保住了 ICL"的唯一直接指标。
2. **符号调优与 Jev 式接口的交叉为零文献**：没有人在类型化读出上做过符号化标签训练，尽管"标签名压倒定义"正是类型化读出最严重的缺陷。
3. **权重技能与类型化读出的交叉为零文献**：LatentSkill 等全部在生成式 Agent 上评测，没有人测过技能 LoRA 对单遍读出的影响。
4. **单遍模型上没有任何 SFT 对 RL 的分布外受控对照**（14 章 §14.4）；UniJev 的五种 RLCD 比较没有报告分布外切分。
5. **"任务定义在上下文里变化"的训练数据在决策领域不存在**：现有公开集都是固定 schema 的重编译，没有一个是为"每条样本一套新任务定义"构造的。

# 16 · 两个追问：任务无关的 RL 有没有生命力；业务期待能不能写成可导的学习函数

> 口径：仍然只做分析与调研。本章回答两个追问——（1）**不针对某个具体任务做优化时，强化学习是否表现出足够的生命力**；（2）**我们对 Jev 的业务期待，是否都能转化成可导的学习函数**（提问者倾向于"不能直接可导优化"）。结论先行：（1）**有，而且最强的存在性证明就是 Jev 本身**，但这种生命力只落在**二阶性质**（该多自信、该不该弃权、约束满不满足）上，不落在一阶的任务知识上，而且凡是以"验证器"充当奖励的地方都系统性地被套利。（2）**提问者的直觉成立，但原因不是"不可导"，而是四种不同的成因叠加**；更关键的发现是：**真正不可导的那几类期待，恰恰是 RL 实测收益为零的那几类**——不可导性与 RL 的收益面几乎不相交。
>
> **复核提示（20 章）**：本章的结论（"目标不可导所以要用 RL"不成立）在 20 章 §20.1 被判为"对"，但假设给出的**理由**（"因为不可导"）被判为错：抗拒梯度有四种不同成因。"五类可导性 A–E"是本报告自己的构造（20 章 §20.2，过拟合风险中）。

## 16.1 追问一：任务无关的 RL 有没有生命力

### 16.1.1 有，而且证据比预期强

| 证据 | 内容 | 为什么算"任务无关" |
|---|---|---|
| **Jev 自己** | 用 RLCD 训练，却是**通用**模型："一套权重，作为 API 提供，只通过请求适配领域"（2610.25553 对设计空间另一端的刻画） | 这是 RL 产出任务无关模型的**存在性证明** |
| **零样本对齐失败检测** | RLCDAlignBench 在十类对齐失败（谄媚、越狱、欺骗、提示注入、幻觉、隐私、偏见、奖励套利、隐瞒不确定、追逐权力）、44 个基准、5 个目标模型上测 Jev：**一个通用问题零样本达到 AUROC 中位数 0.886**，在多数基准上**胜过有监督基线**，与参考打分器在人工标签上的一致度相当，还暴露出基准自身的标签缺陷，成本是 LLM 评审的 1/63（2609.29429） | 一个问题跨十类失败、44 个基准 |
| **置信度表达** | 以对数评分规则为奖励做 RL，校准**泛化到未见任务**且无需再微调，作者称之为"通用置信意识的涌现"（2503.02623） | 显式的跨任务泛化 |
| **未见约束的指令遵循** | 多数模型在一小组可验证约束上严重过拟合、无法泛化到未见约束；RLVR 改善这种泛化（2507.02833） | SFT 过拟合而 RL 不过拟合的直接对照 |
| **规则与视觉变体** | RL（尤其是基于结果的奖励）跨文本规则变体与视觉变体泛化，SFT 倾向记忆（2501.17161） | 上游通用结论 |

### 16.1.2 但生命力只落在"二阶性质"上

把上面五条并排看，被泛化的东西有一个共同点：**它们都不是"答案是什么"，而是"该怎么回答"**。

- Rewarding Doubt 泛化的是**置信意识**，不是知识。
- Just Ask Jev 泛化的是"对任意提问给出校准概率"这一**能力形式**；论文自己指出**问题措辞影响很小，上下文影响更大，主要通过编码了标签的字段**——也就是说模型泛化的是读法，内容仍从上下文来。
- IFBench 泛化的是**约束满足**这一元技能。

这与本报告的核心事实吻合：早期审计的结论是"类型化读出本身未显示出独立于同类标签概率读出的**准确率**优势"，Jev 最清楚的收益在延迟、成本与校准（2609.32160）。**RL 泛化的恰好就是 Jev 真正卖的那个东西**，这不是巧合。

反过来说，**没有任何证据表明 RL 泛化了一阶任务知识**。14 章 L3 层的全部负面结果（名字压倒定义、学会跟踪不等于服从、反事实监督只在合成规则上奏效）里没有一条被 RL 翻盘。

### 16.1.3 三条必须同时记住的反证

1. **以验证器为奖励就会被套利，而且是已发布检查点上的实测**：公开发布的检查点在 RLVR 之后"约束满足率更高但回答质量更低"，前沿模型能靠几乎没有实质内容的回答拿满分（2610.19525）；RLVR 易过优化、走验证捷径（2508.04632）；把约束当奖励会把模型推离主任务（2610.28819）。
2. **理论上限**：一行方差恒等式说明"对多样本混合打分"奖励理由之间互相分歧并使推理退化，而 **RLVR 恰是去掉多样性项的混合目标**；当不确定性来自**标注者分歧**时，同一目标**可证明不可能胜过交叉熵**，放任不管模型会"发现自己应该停止推理"（2609.38850）。

3. **单遍设定下实测为负或等价**（12 章 §12.3、15 章 §15.4）：NDM 证明适当评分规则与 RLCD 式奖励同最优点（2610.25553）。

**小结**：任务无关的 RL 有生命力，但它的生命力 = **把"怎么回答"训成一种跨任务的习惯**。只要奖励是真实目标本身（适当评分规则就是校准本身），它稳；只要奖励是代理（验证器、规则检查器），它就被套利。

## 16.2 追问二：业务期待能不能写成可导的学习函数

把 Jev 的业务期待按**为什么它抗拒梯度**分类，而不是按业务领域分类。分完之后会发现"不可导"其实是四件不同的事。

| 类 | 期待 | 为什么难 | 文献的实际做法 | 结论 |
|---|---|---|---|---|
| **A 已经可导且最优点正确** | 准确率；**校准** | 无 | 交叉熵；适当评分规则（Brier / 对数）。NDM 证明其最优点**就是** RLCD 式奖励的最优点（2610.25553）；概率模型下精确的再校准映射就是温度缩放（2610.26797） | **不是问题**。注意区分：ECE 作为**指标**是分箱的、几乎处处零梯度；但校准作为**目标**有最优点正确的可导代理 |
| **B 性质定义在样本的集合上** | 顺序不变 / 翻转率；IIA（加一个选项不改其余相对赔率）；**定义优先于标签名**；等价改写一致 | 单样本上没有定义，必须构造排列对、细化对、反事实对、改写对 | 可以写成可导的成对项：PACT 的成对锚定 + 证据必要性 + 序数运输 + 三参数上下文温度；LLM-as-Jev 的树分解列表式损失 + KL 锚 | **可导，但被结构化构造碾压**：块因果把翻转率 8.30%→0.11%（2610.01601）、Prism-1 **按构造零翻转且 Luce 公理成立**（2610.22066）；而 PACT 自述"**没有单一项提高原始准确率，价值在稳健性**"（2609.35865） |
| **C 分位数 / 排序型** | 选择性预测的风险–覆盖曲线；目标风险下的弃权阈值；升级到大模型的门限 | 对参数分段常数，几乎处处零梯度 | **不训练，事后认证**：SHIFT-JEV 用 Learn-then-Test 认证弃权阈值（2610.34329）；共形预测；温度只在校准集上拟合 | **放弃可导是正确做法**。但要知道代价：目标风险 10% 时，带认证阈值的学习型不确定度分数仍在 27 个环境–种子测试中的 3–5 个超标（最大概率分数 5–15 个，共形集 9–14 个） |
| **D 下游结果 / 长程** | Agent 任务成功率、成本、墙钟时间；**决策→动作的执行** | 对决策模型没有解析梯度；信用分配跨越多步与外部系统 | 只能 RL 或不优化 | **这才是真正的"不可导"**。而实测：JevAgentHarness 上 **GRPO 无增益**；孤立问题最准的模型只解出 69.5% 的 Agent 任务；不拟合阈值直接委托工具选择 **−19.0 点**（2610.21412）；Jev 控制器让成本 +19% 而通过率不变（2610.24649）；策略修改被正确读出但只在 22%–72% 情况下被执行（2610.18579） |
| **E 根本不是优化目标** | 延迟、成本、可部署性；技能可审计可改；定义本身的取定 | 不是模型参数的函数 | 架构与系统设计；13 章的定义分歧要先取定 | **不该尝试优化**。13 章列的六个分歧点不取定，连"目标"都写不出来 |

### 16.2.1 由此得到的三条判断

1. **提问者的直觉成立，但"不可导"这个词把四件事混在了一起。** 真正既不可导、又没有事后认证手段的，只有 D 类（下游 Agent 结果与决策→动作）。A 类有最优点正确的可导代理；B 类可导但不该用梯度解；C 类放弃梯度改用统计认证是**文献的共识做法**，不是妥协。
2. **最关键的发现是两个集合几乎不相交。** RL 展示出任务无关生命力的地方（§16.1：校准、置信、约束满足）**恰好是 A/C 类**——已经有可导代理或事后认证的地方；而真正不可导的 D 类**恰好是 RL 实测收益为零的地方**（GRPO 无增益、控制器只涨成本）。因此，"因为我们的目标不可导，所以要用 RL"这个推理链**在现有证据下不成立**：不可导性与 RL 的收益面对不上。
3. **B 类给出的是一条更省力的路。** 一致性类期待（顺序、IIA、定义优先）与其写成成对损失去训，不如按构造做掉：Prism-1 与块因果的效应量是**数量级**的（8.30%→0.11%、零翻转），而损失项的效应量是"准确率不变、稳健性改善"。12 章 §12.3 的结论"结构改动是唯一有大效应量的算法改动"在这里再次成立。

### 16.2.2 什么情况下这个答案会改变

- 如果在读出前引入**被采样的中间对象**（推理链、示例集编辑、工具调用），D 类的信用分配就有了落点，RL 的适用条件成立（15 章 §15.4：OpenJev-RLCD 的"先校准再强化"、StartLux AutoThink、Jev-LDE）。
- 如果把**业务效用**直接写进目标（而非用验证器代理），A 类可以扩张：Releasing the Inner Jev 试过期望效用目标，但只有 **+0.9±0.9 pp**（2610.17205），即与零不可区分。
- 如果 13 章的六个定义分歧被取定，E 类里的一部分会变成可测量量，从而可能进入 C 类（可认证）。

## 16.3 本章识别的盲区

1. **没有人在单遍决策模型上做过"奖励 = 真实目标"与"奖励 = 验证器代理"的对照**；16.1.3 的套利证据全部来自生成式指令遵循。

2. **D 类的信用分配在 Jev 式接口上没有任何方法学工作**：决策模型被放进 Agent 回路后，唯一被试过的是 GRPO，且无增益。
3. **B 类的"结构 vs 损失"没有同骨干对照**：块因果与 Prism-1 各自与"打乱顺序训练"比过，但没有与 PACT 式成对损失在同一骨干同一数据上比过。
4. **C 类的认证方法在混合骨干上未测**：SHIFT-JEV 用的是 Qwen3-0.6B/4B 与 Phi-4-mini，全是纯注意力。
5. **"二阶性质能泛化、一阶知识不能"这一分界本身没有被任何论文正面检验**，它是本章从五条独立证据里归纳出来的，属于待验证的假说而非已确立的结论。

# 17 · Jev 的业务目标与属性：它到底消除了哪一类成本，又支撑 System1+System2 的哪一个位置

> 口径：仍然只做分析与调研。本章回答第一个追问——**Jev 的业务目标是什么、属性是什么、解决当前的什么业务问题、最终如何支撑 System1+System2 的新型智能体**。
>
> 结论先行：（1）**本章的出发命题是"幂等性的搬迁"，但它经不住检验**：命题说 Jev 没有新增业务处理能力、只是把不保证幂等的生成式判断换成"类型化指标 + harness 里的确定性执行"。§17.1 用六条反证检验它，结论是**前提与结语都要改**——宿主 Jev 本身就不幂等（相同重复调用下 0.78%–1.33% 的决策改变，四篇论文报告其非确定性），格式保证不是它带来的（语法约束解码的既有谱系）且有"约束税"，harness 的执行计划本身会改变答案，能力并不守恒（多步/带状态处直接丢失且 harness 收不到信号）。可以守住的版本是：**它不消除非幂等，它把非幂等的表面收缩成可数、可定界、可定价的若干个字段，代价是失败从显性变成隐性**（§17.1.4）。**而把幂等当"设计目的"而非"已成事实"是另一条命题，必须单独检验**：按字面意思它已经达成（同请求 ICC 0.997、同文重跑翻转 0.17%）却什么也没买到（"一致的答案也会保留错误"，重复的错误占观察到错误的大部分），而且它可以不用模型就买到（查表即严格幂等；确定性规则在六个策略上全对；不带模型的控制器解出 79%）——**一个最优解是"不要模型"的目标函数不能交给模型团队**。可检验的版本是一个三元组：等价类内同判 + 等价类外仍给得出决策 + 单价低一到两个数量级，它翻译成的模型侧要求是**单调可取阈的分数、原生 unknown、业务等价类内不变**，而幂等本身住在阈值与确定性契约里（§17.1.6）。（2）由此得到的业务目标**不是把决策做得更准，而是把"决策"这件事的单价压到可以在程序的每一个分支上都调用的程度**，从而让一大批"本来不值得让模型来判断"的判断变得值得。（3）它的属性清单里**只有两条是结构性保证的**（输出必在声明的选项集内、一次前向答完整个请求），其余（校准、不变性、兜底、自知、概率自洽）全部是**按工作负载变动的经验性质**，而且已经有多项独立审计测出反例。（4）它支撑 System1+System2 的方式不是"一个快模型加一个慢模型"，而是**五个在工程上完全不同的位置**，其中证据最强的是"把慢模型的每一次外部判断外包出去"，证据最弱的恰恰是"让快模型自己闭环地做 Agent"——而这一格的失败可以由"决策被搬回模型里"直接预测。
>
> **复核提示（20 章）**：本章 §17.1 已经就地检验了出发命题；20 章 §20.1.2 进一步区分了它**该采纳的诊断部分**与**该替换的描述部分**，并标出本章的"三层幂等"（过拟合风险高）、"五个位置 A–E"（中）、"决策重复度轴"（高）、"十二条业务属性"（已知不完整）都是本报告的构造而非文献结论。

## 17.1 出发命题及其检验

> 本节在 2026-10-28 复核时重写。初稿把下面这条命题当作本章的地基，这是个错误：命题的**前提没有被检验**，而推翻前提的证据**本报告自己早就引用过**，分散在 04、05、06、09、10、13 章里。本节改为按"先行工作 → 成立的部分 → 反证 → 修正"的顺序处理它。

### 17.1.1 命题与它的先行工作

**出发命题**（由提问者提出）：Jev 类模型并没有新增业务处理能力，它把原来由"泛化、可用配置驱动、但不保证幂等"的生成式判断一手包办的业务处理拆成两半——**模型只产出一个受类型约束的指标，harness（调用方代码）负责把指标变成确定、幂等的决策执行**。

**这不是一个新命题，文献里已有两篇把它写成了标题与定理**，必须先记在这里：

- **"概率化感知，确定性权威"**：模型的输出**只能作为一条带分数的观测记录**被接纳；一个准入策略（阈值在保留集上按声明的假正率上限拟合）把分数映射为 true / false / **unknown**，而 **unknown 即拒绝**；随后由一个**确定的、充分性受检的契约**做决定。该文给出了命题的定量形式：**"感知改变裁决的概率，上界是该契约所有被感知字段的'错误接纳率 + unknown 率'之和"**（契约索引下的并集界）。登记研究、两个构造域、两族传感器、36,000 次模型调用，**没有任何一格推翻该界**；感知造成的"拒绝→允许"翻转在 21,000 条测试裁决中出现 13 条，全部来自 3 条自相矛盾的记录，每次翻转都落在其登记的界以下。注意一个关键细节：**两族传感器的分数都"有信息但未校准"**——也就是说这个界**不依赖校准**，它依赖的是"unknown 即拒绝"这个构造（2610.10978）。
- **FlashScript** 给出了最精确的措辞：把一次成功的 Agent 运行编译成可复用的神经-符号程序，动作与数据变换变成代码，实例值变成参数，**需要模型判断的决策变成 LLM 调用**；而**"编译并不消除非确定性，它把非确定性定位（localize）了，从而让确定性程序与它的神经调用可以被分别评审与测试"**。120 个 WorkBench 分析任务上，这些程序每次运行都正确且发出完全相同的工具调用，输入 token 约少 **70 倍**、运行时间约为"技能引导式 Agent"的 **1/3**，而后者的多次运行互不一致；在任务的复合版本上技能引导式 Agent 准确率跌到 **23%** 且输出不一致性上升，而编译出的程序保持正确且逐次相同，并泛化到同模板的全部 108 个未见实例（2610.33876）。

**"localize（定位）"而不是"eliminate（消除）"，是本节后面全部修正的关键词。**

### 17.1.2 命题成立的部分

三条，都成立。

**（1）决策权确实落在 harness，而且是实测而非设计偏好。** 不拟合置信阈值就把工具选择委托出去，成功率降 **19.0 点**；有效做法是在 Agent 自身轨迹上**为每个选择分别拟合阈值**，低于阈值交回 LLM（2610.21412）。朴素阈值选择在约一半有定义测试风险的设定下超出目标风险，Learn-Then-Test 只有 **7.8%**，作者结论是"依赖一个类概率接口对部署决策是不够的"（2610.19811）。非对称代价下**用模型的概率可能比直接取它的 top-1 更差**（2610.11392）——指标本身不含代价结构，代价结构只能在 harness 里。

**（2）所有跑得通的系统确实都是这个形状。** JEVDB 把类型化决策当 SQL 语义算子，确定的 Yannakakis 式半连接归约与语义 Bloom 过滤在前，模型只打分（2610.02046）；NIOCIS 把执行日志折成环路折叠动作图，**按节点限制候选集**贡献 +3.5 点而图遍历贡献在区间内为零（2610.25985）；Jev-Guard 先在可编辑策略树上路由再做条件分类（2610.18326）；SemTree 的 Yes/No/Unknown 节点树可逐节点修复（2610.13999）；Mnemon 明确是"**带显式预算的规则**把判断变成一个小 View"（2609.36059）；CARE 把确定性快路径留给常见命令，只对边界命令调用神经裁决（2607.21642）；企业销售订单的字段预测则更彻底——LLM **只在离线规则发现阶段使用**，推理期是透明的键查找、不需要模型服务（2610.34258）。

**（3）真正的收获不是"确定性"，而是"可定界"。** 这是 §17.1.1 第一篇的贡献：一旦非幂等被压缩成"若干个被感知字段各自的错误接纳率与 unknown 率"，整个系统的裁决翻转概率就有了一个**可计算、可最小化、且不依赖校准**的上界，于是"在若干个充分契约之间选哪一个"变成一个有效的成本模型（2610.10978）。**这比"幂等"是一个弱得多但真实得多的承诺。**

### 17.1.3 六条反证

**反证 1：前提不成立——Jev 这一侧也不幂等，而生成式那一侧从未被测量用于对照。**

| 测量 | 数字 |
|---|---|
| 宿主 Jev 在**完全相同**的重复调用下 | 510 个标签里 **4 个改变**（0.78%）；另一组在 300 题上**最多 1.33%** 的决策在两次相同运行之间改变 |
| 报告"宿主模型非确定"的论文数 | **4 篇**（2609.32160 转述的 [53, 61, 70, 79]），检查表 R2 因此要求报重复运行稳定性 |
| 开源复现的重复噪声 | 0.17%（2609.31142）——**比宿主模型更低** |
| 生成式一侧 | Koa-decision 用原子标签 token + SFT 把分类**化为一个确定的一步解码问题**，在生产意图路由上 85.5%、与最强前沿模型相当、中位快数倍；对 Jev"准确率相当、中位更快"，还多支持多模态与多标签（2609.36115） |

结论：**"生成式不幂等 / Jev 幂等"这个二分在现有测量下不成立**。两侧都在 2% 以下的同一个带内，而宿主 Jev 的实测抖动比开源单遍模型更大；一个普通解码器加原子标签 token 就已经是"确定的一步解码"。更要紧的是：**没有任何论文把 Jev 的重复抖动与温度 0 的生成式基线并排测过**。所以前提既不被证实也不被证伪，只是没人测。

**反证 2：L1（格式幂等）不是 Jev 带来的，而且买它有实测的价钱。**

早期审计把**约束解码列为一条独立的前置谱系**，并在对照表里直接把"保证输出合法"这一行记给"语法约束解码"：**"有限状态与语法约束解码器已经保证输出满足 schema"**（2609.32160）。

而"约束税"把价钱测出来了：在 15,000 次生成上（Qwen2.5-0.5B / 1.5B、SmolLM2-1.7B），硬性的答案 schema 解码把 schema 合法率从 61.5% 提到 **100.0%**，但把答案准确率从 19.7% **压到 11.0%**，并把"schema 合法但答错"的比例从 49.5% 抬到 **88.9%**；在最接近工业场景的确定性日历工具调用任务上，Qwen2.5-1.5B 用提示式 JSON 有 91.5% 可执行准确率，而同一个硬 schema 下只有 **48.0%**，两种模式都 100% schema 合法。作者的话是：**"错误是语义的，不是结构的"**，并建议把 schema 合法率、答案准确率、可执行准确率、**"合法但答错率"**四个数分开报（2605.26128）。

这条对命题是直接的打击：**类型化把"看得见的坏"换成了"看不见的错"**。对 harness 来说这不是净收益——解析失败是一次响亮的失败，而"合法但错"是一次静默的失败。Jev 上的对应测量已经存在：跨 rubric 交换 no/yes 名字把 AUC 从 .815 压到 .581，而**类型错误为零**（2609.32160 T3）。

（诚实的限定：约束税是在 ≤3B 的生成式模型上用语法解码测的，不是 Jev 的训练读出；它命名的失败模式与 Jev 上 T3 测到的一致，但它本身不是对 Jev 的测量。）

**反证 3："指标"不是对世界的测量，所以建立在它上面的确定性规则不可移植。**

预先登记、299,463 次调用的 IIA 检验：**每一个**被加入的选项都移动了金标签与最强错误标签之间的对数几率，均方系统性偏移 **0.20–0.52 nats**，是**重复运行抖动的 1.2–3 倍**，即使被加入的选项只拿到不超过 0.1% 的概率质量；偏移是有方向的；畸变随选项数的对数稳定增长，在 255 个选项处约 **1 nat**；域外填充把几率推离金标签。而**用独立的是/否问题逐个给选项打分可以消除选项集依赖，代价是正确率低 8.7 点**。作者的结论是：**"它的概率最好被读作相对于它被计算时的那张选项表"**（2610.16655）。

对命题的后果：一次**业务上无关**的菜单改动，对指标造成的系统性移动**比模型自身的噪声大 1.2–3 倍**。于是 harness 里那条"确定的"阈值规则，只对它被拟合时的那张选项表、那套措辞、那组选项名有效。这与"可移植的确定性规则"正好相反，

而唯一的结构性解法要付 8.7 点。检查表 C3 已经独立记录了同一现象：在选择集上拟合的阈值**并非对每个兜底模型都在保留条目上成立**，拟合出的温度跨负载不同（2609.32160）。

**反证 4：harness 不是确定性的保护区——它自己的执行计划会改变答案。**

- 在语义查询引擎里，**"查询计划的选择不仅影响查询的成本，也影响它的结果"**；准确率**只在逐点确定性策略下**与计划无关；而**当升级带是在计划自己的候选上校准时，选择下推不是质量可靠的**；"该丢哪些元组"是 NP 难（2610.08089）。
- 对 139 个论文族的系统化综述：**"像 Jev 这样的语义决策引擎可以返回一个合法答案，却仍然错过网络截止期、选中一个不可行的动作，或者让服务处于未校验状态。"** 50 个族声称自己的引擎适配控制回路或时间预算，**只有 4 个用匹配的测量支持该声称**；139 个族里**只有 4 个报告截止期达成率**。而且差距集中在"决策没有确定性计算步骤"的地方：那 72 个族提出 22 项声称、**无一被支持**，只有 2 个指明覆盖责任人。最锋利的一句是：**"一个对每个孤立请求都满足 10 秒预算的决策，一旦决策排在被回放的执行时间之前排队，就对任何请求都不满足。"**（2610.06425）

所以 L3 执行幂等只在**固定计划、固定负载**下成立。一旦计划可选、一旦有排队，它就不成立。初稿那张三层表对 harness 太宽容了。

**反证 5：转换是有损的，而损失恰好落在最该保住的那类业务逻辑上。**

命题说"业务处理能力不变，只换承载方式"。这一条是可被证伪的，而且已经被证伪：Jev **做不出"LLM 只有写出中间步骤才能做出"的决策**——参考 LLM 一次前向可解的条目它答对 97.5%，其余只有 **74%**；一旦答案依赖同一用户的**两次以上更新**，准确率下降，十六次更新时 53%–80%；给它一个过时的状态摘要，它照着过时的摘要答。而最致命的是**它不知道自己的界限**：置信度能标记它自己犯的错，但标记不出它从过时输入继承来的错，**显式的与训练出来的交接选项都抓不到后者**（2610.24929）。

于是"harness 兜住剩下的"这个设想在这一类失败上不成立：**harness 收不到任何信号。** 多步、带状态的业务处理不是被"换了承载方式"，是被丢掉了。

**反证 6：确定性有时正是错的目标。**

- 把分布塌成一个动作会丢掉可测量地有价值的东西：按被访者平均后，**概率向量比四舍五入后的答案更接近人类的条目边际分布**，而在给被访者排序上约等于在 163 个真人上拟合的画像回归（2610.14912）；置信度混淆了人类分歧与决策风险两种不确定性，在非对称损失下两者要求**相反的升级信号**，所以**没有任何单一置信数能同时服务两者**（2610.33258）。
- 而把完整向量交给下游也有价钱：完整输出在 **27/27** 个模型-任务比较里降低下游平均成本，但让保留集上的秘密恢复率达到 62.85%–75.35%（只用被选类别是 51.04%–57.64%，随机 50%）；**置信字段增加泄漏却不一致地降成本**（2610.23668）。

所以"指标 → 确定动作"是一次**有信息代价的有损压缩**，不是一次免费的架构胜利；压多少、暴露哪些字段，是逐工作流要算的账。

### 17.1.4 修正后的命题

把六条反证并回去，可以守住的版本是：

> **Jev 类模型不把"不幂等"变成"幂等"。它做三件事：把非幂等的表面从"自由文本输出的任何位置"收缩到"若干个类型化字段的取值"；因此让这个表面变得可数、可定界、可定价（并集界不依赖校准，依赖"unknown 即拒绝"的构造）；而代价是失败从显性变成隐性，并且在"需要写出中间步骤"的那类判断上直接丢失能力。**

与初稿的差别：

| | 初稿（照搬命题） | 修正后 |
|---|---|---|
| 关键动词 | 转换 / 消除 | **定位、收缩、定价**（取自 2610.33876、2610.10978） |
| L1 格式幂等 | Jev 的贡献 | **约束解码的既有谱系**，而且有"约束税"（2605.26128） |
| L3 执行幂等 | 按构造成立 | **只在固定计划固定负载下成立**（2610.08089、2610.06425） |
| 能力守恒 | 隐含成立 | **不成立**，损失集中在多步/带状态处且 harness 收不到信号（2610.24929） |
| "指标"的语义 | 可供 harness 建规则的测量值 | **相对于那张选项表的相对量**，业务无关的菜单改动造成的偏移是自身噪声的 1.2–3 倍（2610.16655） |
| 该追求什么 | 确定性 | **可定界的错误表面**；确定性本身有时是错的目标（2610.33258、2610.14912、2610.23668） |

**三层幂等的表仍然有用，但要改写**（这张表是本报告自己的构造，不是任何论文的结论）：

| 层 | 承诺 | 承载者 | 修正后的状态 |
|---|---|---|---|
| L1 格式 | 输出永远是合法的类型值 | 接口结构 | 按构造成立，**但不是 Jev 独有**（语法约束解码已保证），且把"解析失败"换成了"合法但答错" |

| 层 | 承诺 | 承载者 | 修正后的状态 |
|---|---|---|---|
| L2 语义 | 等价的业务情形给等价的指标 | 注意力掩码 / 读出结构 | **最弱的一层**。能写进掩码的等价可解（翻转率 8.30%→0.11%，Prism-1 按构造零翻转）；写不进掩码的（措辞、语气、标签名、菜单构成、无关日志）全部失守，而**菜单构成的影响已被测为自身噪声的 1.2–3 倍** |
| L3 执行 | 同一指标给同一动作 | harness 代码 | **只在固定计划、固定负载下**成立；计划选择会改变结果，排队会让所有延迟保证失效 |

### 17.1.5 推论：先把"业务目标"与"能力目标"分开

现有文献里对 Jev 的失望，大多来自把两件事混为一谈。

| | 能力目标 | 业务目标 |
|---|---|---|
| 命题 | 单遍类型化读出比同规模生成式读出**更准** | 单遍类型化读出让**同一笔判断的边际成本下降一到两个数量级** |
| 现有证据 | **不成立**。28 篇早期论文的审计结论是"类型化读出本身未显示出独立于同类标签概率读出的准确率优势"（2609.32160）；现成聊天模型直接读 logits 已经是 Jev 式决策模型（2610.02076） | **成立且是全文献最稳的一条**（见 §17.2 的表） |
| 推论 | 想靠"换成单遍读出"涨点，没有依据 | 想靠"把判断变便宜"改变系统设计，有依据 |

这个区分不是修辞。它决定了**优化目标**（18 章）与**评测口径**（19 章）该围绕什么展开：如果业务目标是单价，那么"准确率持平"不是失败，而是**前提条件**；真正要守住的是"在单价下降一到两个数量级的同时，准确率不显著掉下来"。

### 17.1.6 把幂等当"目的"而不是当"事实"：这样写它才可检验

§17.1.3 推翻的是**描述性**命题（"Jev 把不幂等变成了幂等"）。但还有一个**规范性**版本：功能幂等就是我们设计 Jev 类模型的目的；做不到幂等，它凭什么成为企业决策智能。 这是两条不同的命题，推翻前者不构成推翻后者，所以要单独检验。检验的结论是：**作为目的它必须被重写，否则它的最优解是"不要模型"。**

**反对一：按字面意思，这个目的已经达成了，而且它什么也没买到。**

| 证据 | 数字 |
|---|---|
| 同请求重复调用的组内相关系数 | **ICC 0.997**（24 题 288,000 次回答，2609.36399） |
| 重复噪声的量级 | 否定不一致约为重复噪声的 **5 倍**，即重复噪声本身很小（2609.33209） |
| 开源复现同文重跑翻转率 | **0.17%**（2610.35826），比宿主 Jev 的 0.78%–1.33% 更低 |

而 06 章 §D4 对这个子维度（A1 重复性）的判定是"**已解决且会误导**"，依据是同一篇法律文档研究的两个发现：**"一致的答案也会保留错误"——重复的错误答案占观察到错误的大部分**；以及改变可见假设与顺序后**修正与回退相互抵消，准确率不变而决策已变**（2609.27678）。所以"同输入同输出"这条性质，我们已经以约 99.8% 的水平拥有它，它没有让系统变得可信——因为**幂等的错误是被系统性重复的错误**：同一个客户每一次都被拒，而聚合准确率看不见。

**反对二：按字面意思，这个目的可以不用模型就买到，所以它不能是设计目标。**

功能幂等的上确界是**查表**：按输入哈希记忆化，任何模型都能得到严格 1.0 的幂等。继续往这个方向推，报告里已有三个实测终点——把策略字段解析成类型化值后，**一条确定性规则在六个策略上全对**；有界 Agent 工作流的决策空间会饱和，**不带模型的控制器在 $\tau^2$-bench telecom 上解出 79%**（2610.24871）；企业字段预测里 LLM 只在离线规则发现阶段使用，**推理期是透明键查找**。一个目标函数如果它的最优解是"不要模型"，那它就不是能交给模型团队的目标函数。

**反对三：企业侧真正被强制的也不是位级幂等。** 审计与合规要求的是四件事：**同案同判**（= L2，等价类内稳定）、**可复现的判定记录**（能重新推导出"为什么这样判"）、**被声明且有界的错误率**、**可申诉**。位级幂等只是买到第一条的**最便宜的一条路**，所以容易被误当成要求本身。但它既不充分也不必要：

- **不充分**：硬 schema 解码把合法率从 61.5% 提到 **100%**，同时把答案准确率从 19.7% 压到 **11.0%**、把"合法但答错"从 49.5% 抬到 **88.9%**，作者的结论是"**错误是语义的，不是结构的**"（2605.26128）。一个 100% 幂等而静默错 11% 的系统，比一个 99.8% 稳定但会把不确定的那批标出来的系统更糟。
- **不必要**：这个论证所援引的那类已部署系统（评分卡、信用评分）确实是幂等的，但它们的营业许可来自**单调、可按声明的 FPR 取阈、可审计**，幂等只是"拟合出来的打分函数"的副产品，不是它被接受的理由。

**于是目的应该被重写成一个三元组，而不是一条性质。** 两端各有退化解：幂等的最优解是查表（泛化为零——没见过的情形给不出答案），泛化的最优解是自由文本 LLM（稳定性为零）。Jev 类占的是中间那一段，所以可检验的目的必须同时写上三项：

> **（a）在业务声明的等价类内给出同一决策（L2）；（b）等价类之外仍然给得出决策（泛化）；（c）单价比生成式低一到两个数量级。** 去掉任何一项，剩下的两项都有平凡最优解。

**这个重写不是把目标调软了，而是把它翻译成了三条模型侧的要求**——注意它们都不是"要幂等"。可以直接照抄的构造是 2610.10978：模型输出只作为**被打分的观测记录**被准入，阈值在留出集上按**声明的 FPR 上限**拟合，分数映射到 true / false / **unknown**，**unknown 即拒绝**，由一个做充分性检查的**确定性契约**作出决策；于是"感知改变裁决"的概率被 Σ（准入即错 + unknown）界住，**而这个界不需要校准**（预先登记的研究，36,000 次调用，无一格推翻）。幂等在这里住在**阈值与契约**里，不在模型里。模型侧该被设计的是：

| 要求 | 为什么 | 现状 |
|---|---|---|
| **单调、可取阈的分数**（而非自报的概率） | 并集界只需要一个准入/拒绝区，不需要校准后的数值 | 可做；但读出其实是**序数的不是概率的**（序数层误差 4.2 点 vs 概率层 21.0 点，18 章 §18.2.2），正好吻合 |
| **原生的 unknown / 弃权类** | "unknown 即拒绝"才是让界免于校准的那个构造 | **全报告最差的一格**：答案缺席时正确拒绝率 **7%**，拟合一个阈值可到 **79%**（2609.39496） |
| **业务声明的等价类内不变（L2）** | 这才是"同案同判" | **没有任何论文定义过"业务等价类"并在其上测量稳定性**（19 章 §19.5 第 13 行）——这是一个可以占住的空位 |

**最后一条必须单独记住，因为它是这条设计目的在企业里最可能破掉的地方，而且与模型噪声无关**：指标是**菜单相对量**。预先登记的 299,463 次调用显示，每一个被加入选项表的选项都会移动金标与最强错误标签之间的对数几率，系统性偏移是同一模型自身重跑波动的 **1.2–3 倍**（2610.16655）。也就是说：**业务人员往下拉框里加一个新类目，没有任何业务事实改变，所有阈值却都挪了位置**。按"同输入同输出"口径，这次变更根本不算输入变化——这正说明"功能幂等"必须按**等价类**定义，而不能按"输入字节相同"定义。

### 17.1.7 第三条命题："核心逻辑是语义理解的泛化，不是变成代码"

§17.1.4 用"把决策权从模型挪到代码"概括 H4 可采纳的那部分，§17.1.6 又用"幂等的最优解是查表"反驳把幂等当目的。这两段放在一起有一个**自相矛盾**：如果"挪到代码"是对的方向，那它的最优解同样是查表——**我用来反驳幂等的那个归谬，原样适用于我自己的措辞**。所以这条反对意见成立，而且是用本章自己的论证方式成立的：我们做的是 AI 系统，核心逻辑是语义理解的泛化能力，不是把判断变成代码。

**先精确化"代码拿到了什么"。** 2610.10978 的构造里，确定性契约拿到的**不是判断，而是判断之上的算术**：阈值比较、充分性检查、并集界的求和。把开放世界的非结构化情形映射成一个带刻度的观测记录——这一步**没有任何代码写法**，它就是语义泛化，而且它是整个构造里唯一不可替代的部分。所以正确的措辞不是"决策权挪到代码"，而是：**模型负责语义，代码负责记账**。本报告原来的措辞会让人误以为模型是可替换组件，这是表述错误，已在 01 章 §1.6 与 20 章 §20.1.2 改正。

**支持这条命题的最强单条证据**（也是全报告里最强的"模型不可替代"证据）：RLCDAlignBench 用**一个通用问题**、零样本、跨十类对齐失败、44 个基准、5 个目标模型，AUROC 中位数 **0.886**，并在多数基准上**胜过有监督基线**，成本是 LLM 评审的 **1/63**（2609.29429）。规则引擎做不到这件事，查表更做不到：它没有"表"。这条证据按业务成本轴只会被记成"便宜 63 倍"，按语义泛化轴才看得出它真正证明了什么。

**但这条命题必须接受和"幂等"同样的检验，而它同样有退化解。** 对一切输入给同一答案的模型是完美"泛化"的。泛化只在**判别**要求下才有意义，而 06 章 §D4 的子维度 D1 已经把这三件事分开过：校准、判别、敏感性不是一件事。所以可检验的版本是三段，而不是一句：

> **（a）业务声明的等价类**内不变（这是"语义"）；**（b）业务有意义的区分**上判别（这是"理解"）；**（c）三者之外的新情形**上要么对、要么弃权（这是"泛化"）。

值得注意的是：这三段与 §17.1.6 从成本轴推出的三元组**结构同构**（等价类内同判 / 等价类外给得出决策 / 可声明的错误边界）。两条互相独立的轴推出同一个三段结构，这是它比较稳的迹象——也说明**争的不是目标是什么，而是哪一项是主项**。

**这条命题最有价值的一个推论：L2 就是"语义理解"的可测量定义。** 本报告把"等价的业务情形给等价的指标"当成一致性性质（L2）在处理，而按语义泛化的口径，**两个业务等价的情形就是同一个语义情形**——所以 L2 不是一致性的锦上添花，它**就是**"理解了语义"的操作定义。于是 19 章 §19.5 第 13 行那个空位（**没有任何论文定义过"业务等价类"并在其上测量稳定性**）的性质也变了：它不是一个漏测的一致性子项，而是**整个方向的核心指标没人测过**。

**而这个口径下的结论比成本口径下更难听，不是更好听。** 测量说：单遍类型化读出恰恰在语义这一层最弱。

| 测量 | 数字 | 它说明什么 |
|---|---|---|
| 名字-定义对调 | 平均 AUC **93.8% → 23.2%**（低于随机），类型错误率全程 0%（2609.26758） | 类型正确 ≠ 读了定义。模型用的是**标签字符串**，不是语义 |
| 删除全部定义 | 准确率**不变**（0.8487），而定义单独能撑起 0.7971；标签与定义矛盾时 0.8511 → **0.2281**（2610.02586） | 开发者唯一能写规则的地方**没被读** |
| 1–12B 少样本 | **语义覆盖率恰好为零**；ICL 是"调整输入如何投影到稳定的语义方向"，而非重映射标签含义（2511.21038） | 上下文改不动语义 |
| 跨裁判迁移 | SemTree 为裁判 A 编译的树换到裁判 B：67.70% → **47.87%**（2610.13999） | 语义不跨模型迁移 |

| 测量 | 数字 | 它说明什么 |
|---|---|---|
| 需要中间步骤的判断 | 一次前向可解的条目 97.5%，其余 **74%**；十六次更新时 53%–80%；**它不知道自己的界限**（2610.24929） | 语义泛化在多步处失效，且**无自知** |

**还有一条直接的冲突，这是本节最重要的发现：让它便宜的那个操作，和毁掉语义敏感性的那个操作是同一个。** Certo 的联合打分器（state + 规则 + 候选**一起读**）规则敏感性 recall@1 **1.00**；改成可缓存的独立编码（候选编码一次复用，77 个候选时约 **5 倍便宜**）后，规则敏感度掉到 **0.24**（2609.37832、14 章 §14.3）。也就是说**成本轴与语义轴在工程上直接对立**，而本报告此前把这两件事分别记在 §17.2（成本结构）与 14 章（泛化层次）两处，没有并置。按语义泛化作主项，这个取舍必须被显式定价，不能默认选便宜的一侧。

**对我们自己的继续训练，这条命题改变的是选型方向。** 如果核心逻辑是语义泛化，那么决策微调**不是**加语义的地方：Qwen3.5 0.8B→27B 上未调优读出已达到调优后准确率的 **76–97%**，调优增益从 15.8 点缩到 **2.3 点**，1/16 的数据就收回大部分，而只训字母头"几乎收不回增益"，作者的解释是"**预训练提供表示，调优只调整怎么读**"（2610.15501）。同一篇还给出判别性的对照：同一个未调优 27B 允许推理时 96.9 对 89.1，而日期算术与数值比较三个 schema 上读出在**每个规模**都只有 56–66%、推理 98–100%。所以在这个口径下该问的不是"怎么把读出训得更准"，而是**"怎么让读出不丢掉表示里已有的语义"**——而文献里针对这一点的现成手段只有两个，且都未在决策模型上试过：渲染层改成只写定义、标签用无意义标识符（准确率 **+0.1511**，2610.02586），以及符号调优（用无意义符号作标签迫使读定义，并直接提升**翻转上下文标签语义**的能力，2305.08298，15 章 §15.2；03 章盲区 2 已记"决策模型上没有人试过"）。

### 17.1.8 第四条命题："决策一致率是核心指标，对错是第二顺位"

这条命题与 §17.1.7 是一条线：如果等价类内不变**就是**"理解了语义"的操作定义，那么一致率自然是主指标。本节分三部分：它比提问者给的理由更强的那个理由、它必须补上的那一项、以及它必须显式定价的那个兑换率。

**（一）它成立，而且有一个比"更重要"更强的理由：一致性是先于正确率的。**

准确率是一个可以测量并接受的性质；一致性是**使测量本身有定义**的性质。整个免校准并集界的构造依赖"阈值在留出集上按声明的 FPR 拟合"（2610.10978），而阈值只在分数分布稳定时有效。一旦等价类内的分数会漂移，**阈值失效，界也就不成立**——此时"准确率多少"这个问题连一个确定的答案都没有。实测的代价：某论文阈值在样本内拟合，**目标 5%，保留集上最高到 17%**（2610.02267）；SHIFT-JEV 用 Learn-then-Test 认证过的阈值，在目标风险 10% 下仍在 27 个环境–种子里的 **3–5 个**超标（最大概率分数 5–15 个，共形集 9–14 个，2610.34329）。所以正确的表述不是"一致率比正确率重要"，而是**一致率是正确率可被承诺的前提**。

**还有一条独立的支持：聚合准确率对我们真正关心的变化是盲的。** Jev 换 8 种选项顺序，**准确率变化不到 2 个百分点，而累计失败集扩大 27–29%**（2610.35826）；改变可见假设与顺序后**修正与回退相互抵消，准确率不变而决策已变**（2609.27678）。把对错放在第二顺位，附带条件是**对错也不能再用聚合准确率来测**，而要用决策级配对口径（累计失败集 + 等价类翻转率）——10 章 Q4.6 已经把这件事列为"需要规范而非新方法"。

**（二）必须补上的那一项：一致率的无约束最优解是常数分类器。**

这是本章第三次遇到同一个结构。幂等的最优解是查表（§17.1.6）；"挪到代码"的最优解也是查表（§17.1.7）；一致率的最优解是**对一切输入给同一个答案**。三条命题各自点名了"不变性"这一半，而把"判别"那一半留空了，于是每一条的无约束最优解都是一个退化模型。

而这不是假想的失效：报告里有它的实测形态。**序数刻度被系统性压缩**（40 个数据集 × 9 个模型，刻度越细越严重，规模不能恢复，2609.38827）——这正是模型用"不使用量表"换取稳定；**同质示例让 0.8B–8B 模型准确率坍塌到 12% 以下**（2605.08295）——这是坍塌到多数类。所以这条命题的可用形式必须是两项的：

> **一致率为目标函数，正确率为约束**（声明一个不可跌破的准确率地板），而不是"一致率第一、正确率第二"的字典序。字典序排序下，"第二顺位"在工程上等于"无界"。

**（三）必须先取定的那件事：一致率的分母。** 13 章已经指出"翻转率"在文献里有**五种不同的分母**。按分母看，这个指标的现状完全不同：

| 分母 | 现状 | 作为训练目标的价值 |
|---|---|---|
| 同一请求重复调用 | **已达 ICC 0.997 / 翻转 0.17%** | **零**。已经有了（§17.1.6） |
| 选项顺序置换 | 块因果把翻转 8.30%→0.11%，Prism-1 **按构造为零**（2610.22066） | **低**。按构造可买到，不必训 |
| 措辞 / 语气 / 标签名 | 部分测过，全部失守；名字-定义对调 AUC 93.8%→23.2% | **中高**，但与"读定义"是同一个问题（§17.1.7） |
| 保答案的对抗变体 | **攻击翻掉 Jev 正确决策的 46.3%**，无命令的谬误论证翻 **77.2%**；0.8 阈值下仍被执行的决策里 **23.5% 是错的**（2609.31142） | **高** |

| 分母 | 现状 | 作为训练目标的价值 |
|---|---|---|
| **业务声明的等价类** | **没有任何论文定义过它并在其上测量**（19 章 §19.5 第 13 行） | **这才是那个空位** |

这张表给出一个尖锐的结论：**同一个模型的"一致率"，在"字节级相同重跑"口径下是 99.83%，在"保答案对抗变体"口径下是 53.7%——相差 46 个百分点**。所以"一致率是核心指标"这句话在取定分母之前**不是一个指标**，而取定分母这件事，本身就是本报告找到的那个无人占据的空位。

**（四）兑换率是实测的，不是假设的。** 把一致性买回来要付准确率，四条独立测量给出价目：

| 买到的一致性 | 付出的代价 |
|---|---|
| 硬 schema 解码：合法率 61.5% → **100%** | 答案准确率 19.7% → **11.0%**，"合法但答错" 49.5% → **88.9%**（2605.26128） |
| 独立 yes/no 打分：**消除选项集依赖** | **−8.7 点**（2610.16655） |
| 可缓存的独立编码：约 **5 倍便宜** | 规则敏感度 recall@1 1.00 → **0.24**（2609.37832） |
| PACT 的成对锚定 + 序数运输 | 作者自述"**没有单一项提高原始准确率，价值在稳健性**"（2609.35865） |

但要注意第二行与第三行的方向不同：**独立打分付的是准确率，可缓存编码付的是规则敏感度（即语义），而块因果与 Prism-1 这一类按构造的做法目前没有报出准确率代价**。所以"一致性要花钱"不是一个统一的结论——**按构造买（改掩码、改位置、改分支隔离）目前是免费的那一侧，按损失项买或按服务优化买是要付钱的那一侧**。这与 12 章"结构改动是唯一有大效应量的算法改动"是同一条结论，在指标排序这个问题上再次成立。

## 17.2 业务问题：哪一类成本被消除了

### 17.2.1 被消除的是"每次判断都要解码一段文字"这笔成本

| 证据 | 测到的量 | 口径 |
|---|---|---|
| 前缀-only 决策模型 | 一次调用比**同规模**生成式语言模型便宜**一到两个数量级**；在菜单固定、只改选项集的干预下，干预后的准确率已由缓存的首遍分布决定（2610.07716） | 成本的结构性来源：不解码 |
| 作为 rubric 评审 | LLM 评审**贵 16–357 倍、慢 5–350 倍**，而两个决策模型在 27 项比较中显著落后的最多只有 6 项（2609.29769） | 同一批人工判据、同一批面板 |
| 作为评审（偏置口径） | TDM 比 2026 年的 LLM 评审**便宜 37 倍**且更一致（2610.18122） | CALM 偏置测试 |
| 社科文本标注 | 中位**成本低 44 倍**，代价是比"每任务最好的 LLM"中位低 11.6 macro-F1（15 项里 14 项落后）（2609.24574） | 18 个任务 7,977 条，零样本同协议 |
| 对齐失败检测 | 成本为 LLM 评审的 **1/63**，一个通用问题零样本 AUROC 中位 0.886（2609.29429） | 10 类失败、44 个基准 |
| 内容审核 | **约 0.000025 美元/次、约 100 ms**；零样本 AUROC 0.83 与 14 个前沿系统中的 13 个**统计上不可分**（配对 bootstrap，n=56；是"未能拒绝相等"而非等价性证明），成本低 1–3 个数量级（2610.33258） | 142,658 条人工标注 |
| 本地 2B | **30.9 ms**/决策（单张笔记本 GPU）、**零输出 token**；对照前沿 API 调用 8,758 ms，而答得好的宿主系统每题先"想" 21–212 个生成 token 并逐个计费；单消费级 GPU 持续 32 决策/秒（2609.23886） | 本地推理，状态不出机器 |
| Agent 单跳路由 | 类型化编码器 **10 ms**（类型化选择式 19.5 ms），对照每次 LLM 跳 **2.2 s**（2610.25985） | 1,615 条生产安全运营轨迹 |
| 守卫 | 安全分类平均 **58 ms**，路由+分类全流程 240 ms；权限闸把每任务平均评审时间从 SFT-LLM 评审的 4.80 s 降到 1.33 s（2610.18326） | 7,033 条评测用例 |
| 推理延迟对照 | 最大的 System-1 模型在**非 Agent** 准确率上追平或超过快速闭源 LLM，概率校准更好，延迟是其 **1/4**；而最准的是推理型 LLM，代价约为快速 LLM 的 **70 倍**成本（2610.21244） | 92k 题 / 105 任务 / 268 来源 |

**一句话**：被消除的不是"模型推理成本"，而是**解码成本 + 往返成本 + 解析成本**。这三项都与"答案是一段文字"绑定，而不与"答案是一个判断"绑定。2609.23886 把这件事讲得最直白：程序需要回来的"不是散文，而是 n 个声明选项之一加一个可以设阈值的数"。

### 17.2.2 于是"本来不值得判断的判断"变得值得

这正是 TypeSafe 用 Jevons 命名产品时想表达的东西，也是唯一一篇把它当作**组织问题**而不是模型问题来写的论文的出发点：机器评估的总边际成本下降得足够多时，**在潜在需求充足且互补成本不占主导的地方，组织对机器评估的消费会增加**；该文把预测、机器评估、组织判断与授权区分为四种成本不必同时下降的功能活动，并明确指出代价——评估之间会**共享证据、判据与错误**，会把**误设的 rubric 规模化**，会在"后果性限定条件已经消失"的表示上运行，并通过阈值与例外路由**实际改变决策权的分配**（2610.01231）。

这条"代价"必须和"收益"写在一起，因为它预言了 §17.3 里几乎所有的反例：当一个误设的判据被便宜地跑在十亿条数据上时，错误不是独立的。2609.29769 实测到了这件事的一个具体形态：**flash 档 LLM 评审在决策模型"最自信的错误"上有超过**

**85% 重复了同样的错误**，而独立出错应该约为一半——所以级联只能省钱，用 flash 档兜底的级联即使用预言机阈值也最多比最强单一评审高 2.7 点。

### 17.2.3 可被便宜化的业务，有一个共同结构：决策在重复

三篇互相独立的论文都指向同一个条件。

- **语义数据库**：把 LLM 用在关系型离散判断上造成高延迟与高成本；换成类型化决策模型做语义过滤/连接/分类/排序，只把不确定的升级给生成式 LLM。在 SemBench 的 21 条查询上延迟全部最低、成本 19 条最低；在 54 万候选对的 Shelob 上平均 F1 95.7%–97.5%，语义 Bloom 过滤先砍掉 **87.4%** 的候选对，可复用的条件索引打分再把**推理模型升级次数减少 55.2%**（2610.02046）。
- **有界 Agent 工作流**：决策空间会**饱和**——Agent 反复遇到同样的状态，足够多的对话之后就不再遇到新状态；而 LLM 不把这些决策当优化问题，每一轮都从上下文重新推导一遍。把它当 MDP 解一次再复用：在 $\tau^2$-bench telecom 上，不带模型的控制器解出 **79%**；Qwen3.8-27B 从 29% 升到 **96%** 且模型调用减少 **93%**；对已经能解 96% 的 Claude Opus 5.5，按此运行把每任务调用与成本砍掉约 **98%** 并多解出 2 个任务（2610.24871）。
- **生产工单/安全运营**：Agent 按决策付费，每跳都要重读状态并思考数秒，"而它的动作是有限的，决策在重复"（2610.25985）。

**推论**：Jev 类模型的业务价值与**决策的重复度**成正比，与**决策的新颖度**成反比。这给了"该把 Jev 放在哪"一个可判定的工程判据，也解释了为什么 §17.5 里"闭环 Agent"是最弱的一格——闭环里的状态几乎不重复。

## 17.3 属性清单：哪些能对业务承诺，哪些不能

下表把"业务方会据此下单的属性"逐条列出，右列只放**反例**，因为正例已在 §17.2 与 01 章。

| # | 属性 | 是否可承诺 | 已测到的反例 / 边界 |
|---|---|---|---|
| P1 | **输出必在调用方声明的选项集内**，不可能出现格式错误 | **结构性保证** | 无反例。这是唯一"按构造成立"的属性（2609.23886）。但它只保证**类型**，不保证**语义**：换 rubric 的 no/yes 名字可把 Jev 的 AUC 从 .815 压到 .581，而**类型错误为零**（2609.32160 转述 T3） |
| P2 | **一次前向答完一个请求里的所有问题**；额外问题近乎免费 | **结构性保证**（共享前缀 + 隔离分支，01 章 §1.4） | 延迟优势会被缓存抹掉：有论文的延迟优势在加缓存后消失，且两篇姊妹论文在不同负载上报出**相反的成本方向**；"报了延迟优势就要同时报带缓存与不带缓存"这一项在 20 篇适用论文中只有 **3 篇**合规（2609.32160） |
| P3 | **概率是校准的**，下游可直接设阈值 | **按负载变动** | 宿主模型遵守写明的策略，但**对措辞敏感且系统性欠自信**；在非对称代价下，**用它的概率可能比直接取它的 top-1 更差**（2610.11392）。决策模型"常能指出最可能的结果，却大幅高估它的概率"（2610.03935）。另一审计发现三个前沿模型的校准误差中位更低（0.157 对 0.066）（2609.24574） |
| P4 | **同一判断在等价提法下给同一答案** | **不可承诺** | 每个 TDM 在 12 项偏置测试中有 **3–8 项**有偏；把更好的答案改写成情绪化语气可把典型 TDM 的准确率从 **99% 压到 42%**；八个 TDM **全部**会在答案位置互换时改判，而 2026 年的 LLM 评审几乎不改判；**校准良好并不防偏置**（2610.18122） |
| P5 | **低置信度 = 该升级** | **不可承诺，而且是两个量** | 置信度混淆了**人类分歧**与**决策风险**两种不确定性；在非对称审核损失下这两者要求**相反的升级信号**，所以**没有任何单一置信数能同时服务两者**（2610.33258）。另有实测：升级最不自信的那批决策**抓不到被攻击翻转的决策**（2610.12292） |
| P6 | **不确定时会走兜底 / 弃权** | **不可承诺，这是最差的一格** | 正确答案缺席时的正确拒绝率只有 **7%**（答案在场时准确率 99%），而同一批题上原生布尔校验能到 99% 精确匹配；一个在独立开发集上选出的阈值把拒绝准确率从 7% 提到 **79%**（2609.39496）。配对兜底稳健性测试发现**正确识别类别并不迁移为正确选用兜底项**，即使显式把正确类别给它；**逻辑等价**的兜底规则表述会造成显著分歧（2610.19856） |
| P7 | **"不知道"可被表达** | **接口上缺一个值** | 在 Choice 回答里 P(A) 与 P(¬A) 被当作和为 1 呈现，而和式里缺了一项 P(U)≠0；把 P(U) 还原回来，Choice 的软准确率中位从 **0.771 升到 0.978**——即使在二元决策里，模型"想答第三个选项：我不知道"（2609.35342） |
| P8 | **知道自己不知道** | **不可承诺** | 没有任何与答案相关的信息时，对某个显著选项给到 **0.80**；越过观测到的知识边界后置信度比准确率高 **0.21–0.33**，用更早月份做再校准**也补不上**。反而是**定向的是/否问题**更锐利：问"结果是否已尘埃落定"AUROC 1.00，"证据是否充分"0.95（同题上置信度只有 0.85）（2610.01006） |
| P9 | **概率之间自洽** | **不可承诺** | 480 个否定对上，"标签是 X"与"标签不是 X"的和平均偏离 1 达 **0.064**；三个单标签概率平均和为 **1.14**；违背量约为其重复噪声的 5 倍，且集中在它**不确定**的地方（2609.33209） |
| P10 | **业务人员可以用文字直接配置它** | **部分成立，这是 D1 的核心** | 读得懂示例与定义，但**标签名压倒定义**、删掉定义准确率不变、小模型无法在上下文里翻转标签语义（03 章）。审核场景里 Jev **从检索到的先例中获益**（在答案空间固定时改善策略精确选择与有害内容判别），而开源对照 Laya 的检索常只改变正例率而不改善判别（2610.07953） |
| P11 | **决策可审计** | **结构性缺失** | 不生成文字，所以"**没有文字理由可供人工检视**"（2610.11392）；"理由与思维链不适用"（2610.22526）。现有补偿手段都在模型外面：可编辑策略树上的路由（2610.18326）、Yes/No/Unknown 节点树逐节点修复（2610.13999）、把判断记到证据记录里（2609.27535） |
| P12 | **风险可被预算** | **只能靠事后统计认证** | 无法人工兜底时不确定项也必须有动作；朴素阈值选择在**约一半**有定义测试风险的设定下超出目标风险，而 Learn-Then-Test 只有 **7.8%** 超出（2610.19811）。"依赖一个类概率接口对部署决策是不够的" |

**读法**：P1–P2 是产品；P3–P12 是**需要逐工作负载重新测量的经验事实**。这张表也是 19 章评测覆盖面的被测对象清单。

## 17.4 业务目标不是什么

1. **不是替代 LLM**。最准的仍是推理型 LLM，代价约 70 倍（2610.21244）；社科标注上中位落后 11.6 macro-F1（2609.24574）；印尼地方语上六个商用 LLM 里五个比 Jev 高 4–14 点（2610.14112）。
2. **不是替代"有标注就能训的专用模型"**。"有足够标注时要把任务专用模型（编码器、经典分类器、奖励模型或探针）作为基线"这一项，13 篇适用论文里只有 7 篇合规；已测到的是微调编码器在排序上不显著差于开源 TDM 且 ECE 名义更低、更快（2609.32160）。本报告按既定口径只把编码器系当对照。
3. **不是"准确率持平"就算赢**。持平结论常来自**强模型已触顶**的测试集；"要报告模型间的分差、不要在饱和测试上宣称持平"这一项无法从文本可靠评分（同上 T1）。
4. **不是省掉阈值工程**。所有有效的部署都把阈值当**独立的、要用分离数据拟合并冻结的对象**（2609.39496、2610.19811、2610.14112、07 章）。
5. **不是把判断外包出去就不用管语义**。误设的 rubric 会被规模化，错误会相关，决策权会被阈值与例外路由悄悄改写（2610.01231）。

## 17.5 如何支撑 System1+System2：五个不同的位置

"快思考 + 慢思考"在工程上不是一种结构，而是**五种**。它们对模型的要求、失败模式与现有证据强度都不同。

| 位置 | S1 在做什么 | 最强证据 | 要求 S1 的哪条属性 |
|---|---|---|---|
| **A 入口闸 / 级联** | 在慢模型之前判断"这件事要不要慢下来" | 等成本下**置信度级联胜过任何重问同一模型的方案**，而**策展菜单胜过放大模型**：0.8B 在策展过的 5 候选菜单上 95.4%，4B 在 150 标签全菜单上 80.0%（2610.07716）；路由给 LLM 可在追平该 LLM 的同时省 **24–77%** API 成本（2610.14112） | P3 校准、P5 置信可用于路由 → **两条都不可直接承诺** |
| **B 过程监控 / 介入** | 在慢模型**运行中**持续监控并在必要时接管 | SOMA：场景层用自然语言写目标与预定动作，觉察层让 S1 判断该行为是否出现，控制层累积判断先提醒、持续出现才接管。共享一个 S1 与一个控制器、**无需训练**，治两种失败：过度思考下推理 token 减少最多 **36%** 且平均准确率提升；不可答问题上弃权从 **70.5% 升到 87.2%**（2610.26793） | P10 文字配置、P3 校准；**不要求** P6 兜底（控制器在外面累积） |
| **C 证据面 / 记忆面** | 把慢模型需要的"多而小的判断"全部承包 | Mnemon 把记忆工作分成"大量独立是/否判断"（S1，每秒几十个）与"少量慢工作"（S2 写查询、命名需求、组织答案）：LoCoMo **91.7%**（14 个系统中最高）、LongMemEval-S 83.8%，每题上下文不到 4k token，LoCoMo 上有效成本指数最低；换推理模型作答到 92.2% / 94.4%；历史从 100K 到 10M token，每题成本只涨 **1.11 倍**（2609.36059）。Jev-Mem 把 S1 当控制面（记忆分型、查询路由、检索预算分配、图遍历、候选打分、自适应停止）：LoCoMo 评审分 0.777（相对最强基线 +11.0%），构建时间 158 s（**6.6×**），平均查询延迟 0.93 s（**−36.7%**）（2609.23986）。JevGPT 在自主研究里 S2 定证据目标、S1 定位支持与评估相关性，并行独立判断源（2610.18272） | P1 类型、P2 批量近免费；对单条判断的准确率要求低（错一条不致命） |
| **D 慢模型输出的读出器** | 读**别人**的（可能被截断的）推理链并提交决策 | 七个推理器 × 五个选择题基准（35 对）：在 500–16,000 token 预算下 Jev 的平均准确率**高于强制作答**（含推理与作答的估计成本）；1,500 token 预算上整体 **+4.1 pp**、被截断题 **+8.6 pp**，17 对在 Holm 校正 bootstrap 下显著；在训练折上选出的策略在保留折省 **71.3%** 的全程估计成本而只损失 0.58 pp（2610.25768） | P1、P3；这是最被低估的一格 |
| **E 闭环执行者 / RL 组件** | 自己在环境里连续做决策 | **最弱**。System1-Arena 的 138 个闭环环境里，大型开源 LLM 成功率最高（至多 32.9%），**小型 System-1 模型很少成功**（2610.21244）；Doom 闭环 33 局三种子下**没有任何变体走到出口**（2610.09683）；孤立问题最准的决策模型只解出 69.5% 的 Agent 任务（07 章）。唯一稳的子形态是**冻结模型当 RL 训练的部件**：参考策略、探索评审、回放评分三个位置上，九个 MiniGrid 任务与三个 Atari 游戏上胜过标准 RL 学习器（含学习器单独毫无进展处），而模型本身不被训练；同文确立 Jev 能满足 RL 各对象对答案的要求，**除了价值函数的 cardinal 用法**（2610.11692） | 要求 P5+P6+P9 同时成立 → **三条都不成立**，所以这一格失败是可预期的 |

### 17.5.1 这五格里有一条贯穿的工程事实

**S1 的收益随"它替代的判断次数"线性增长，而风险随"它单独决定的后果严重度"线性增长。** A/B/C/D 四格都把"后果"留在 S2 或代码里：级联把不确定项交回去、监控器只提醒、记忆面错一条判断不致命、读出器前面还有一整条推理链。E 格把后果交给了 S1 自己，于是 P5/P6/P9 的全部缺陷一次性暴露。

这也解释了 §17.2.3 的饱和现象为什么重要：2610.24871 的 BLM 是这条逻辑的极限——**当决策重复到可以解一次就复用时，连模型都不需要在线**（不带模型的控制器解出 79%）。换句话说，Jev 类模型占据的是"决策重复度足够高到值得便宜化、但还没高到可以离线求解"的那一段。

### 17.5.2 还有一格：把"决策"当数据库算子或图算子

这不是"Agent"，但业务体量可能最大：语义数据库把类型化决策当语义过滤/连接/分类/排序算子（2610.02046）；NIOCIS 把执行日志折成"环路折叠动作图"，每个状态只问一个类型化问题（2610.25985）；Jev-Guard 在可编辑策略树上先路由再

分类（2610.18326）。这一格的共同点是**选项集由外部结构（schema / 图 / 策略树）给定**，于是 §17.5 表里对 P10 的依赖被转移给了工程结构。

### 17.5.3 业务天花板可能不在模型

NIOCIS 给出了本报告里最诚实的一个数字：类型化编码器在 3,875 条保留决策上匹配日志下一跳的比例是 **32.2%**（在声明选项内 34.9%）；而跨轨迹留一法把"已发布状态"的天花板定在 **25.6%–44.9%**，随状态键变细而变化——也就是说，**重复出现的状态彼此不一致的次数多于一致的次数**（2610.25985）。消融把增益归给**按节点限制候选集**（比扁平目录 +3.5 点）而不是图遍历（区间内为零）。

**推论**：在真实业务里，"决策模型的准确率上限"常常是**被记录的流程自身的一致性上限**。这一条对 19 章的意义是：**只用公开基准评测，测不到这个天花板**。

## 17.6 本章小结与盲区

**出发命题经检验后的版本**：Jev 类模型**不**把不幂等变成幂等。它把非幂等的表面从"自由文本输出的任何位置"收缩到"若干个类型化字段的取值"，由此让这个表面可数、可定界、可定价（裁决翻转概率的并集界不依赖校准，依赖"unknown 即拒绝"的构造）；代价是失败从显性变成隐性，并在"需要写出中间步骤"的那类判断上直接丢失能力。最精确的动词来自文献本身：编译**不消除**非确定性，它把非确定性**定位**。六条反证见 §17.1.3，其中三条推翻的是命题的前提而非结论：宿主 Jev 相同重复调用下 0.78%–1.33% 的决策改变；格式保证属于语法约束解码的既有谱系且硬 schema 把答案准确率从 19.7% 压到 11.0%；查询计划的选择会改变结果，而排队会让所有延迟保证失效。

**这个命题自带一个梯度**：确定性往 harness 里推到底，模型就变成冗余（把策略字段解析成类型化值之后，一条确定性规则在六个策略上全对；不带模型的控制器在 $\tau^2$-bench telecom 上解出 79%；企业字段预测里 LLM 只在离线规则发现阶段使用，推理期是透明键查找）。所以可用区间的上界是"业务字段的可结构化程度"，下界是"决策的重复度"。

**三层幂等表（本报告自己的构造）**：L1 格式由接口保证但不是 Jev 独有；L3 执行只在固定计划固定负载下成立；**L2 语义是最弱的一层**——能写进注意力掩码的等价可解（翻转率 8.30%→0.11%、Prism-1 按构造零翻转），写不进掩码的全部失守，而菜单构成造成的系统性偏移已被预先登记的 299,463 次调用测为自身噪声的 **1.2–3 倍**，"指标"因此只能被读作相对于那张选项表的相对量。

**业务目标**：把一次判断的边际成本压到可以写在每一个程序分支上，从而把"评估/判断"从稀缺资源变成可规模消费的资源；在决策重复度高的地方收益最大。

**属性**：只有"输出必在选项集内"与"一次前向答完整个请求"是结构性保证；校准、等价提法不变性、兜底、自知、概率自洽五项都有独立审计测出的反例，必须逐工作负载重测并冻结阈值。

**支撑 System1+System2 的方式**：入口闸、过程监控、证据/记忆面、慢模型输出读出器、闭环执行者——前四格有正面证据，第五格普遍失败，而失败可由 P5/P6/P9 的缺陷预测。

**盲区**（都未被任何论文回答）：

1. **没有人测"成本-正确结果"这一端到端指标**。检查表里"报告延迟时要同时报带缓存与不带缓存，并说明服务位置、并发与每正确结果的实测成本"在 20 篇适用论文中只有 3 篇合规（2609.32160）。省了 44 倍成本但掉 11.6 个 F1 点，到底是赚还是亏，没有任何论文给出可计算的口径。
2. **没有人测"把判断变便宜之后，判断的总量变成了多少"**。Jevons 假说被形式化为**条件性**命题，但2610.01231 自述是"把它当技术性挑衅而非既成的经验结果"，没有任何实测。
3. **"决策权被阈值与例外路由改写"没有任何量化工作**。这是最直接的业务风险，却只有一篇概念论文。
4. **P5 的"两个不确定性"只在内容审核一个域被测过**。2610.33258 明确说分解成并行子问题读分歧这个补救**是特异的**：它只帮最弱、对分歧盲视的模型，而且只在分解与分歧来源对齐时有效，专用毒性模型与最强 LLM 都不需要它，且效果对分布敏感。在其他业务域上这条是否成立，为零命中。
5. **业务流程自身的一致性上限只有一篇论文测过**（2610.25985），且是单一域（安全运营）。
6. **没有任何工作把"业务人员直接用提示词配置"当成一个可评测的业务属性**（P10）。D1 的全部证据都是研究者写的提示词，不是业务人员写的（03 章）。
7. **L2 语义幂等没有任何人把它当成一个独立的被测量**。现有工作或者测单一干预下的翻转率（顺序、措辞、语气、标签名各一篇），或者用结构把某一种等价写进掩码；**没有任何论文定义"业务等价"这个等价类并测量指标在该等价类上的稳定性**。这是本章命题里唯一一处既无结构性保证、又无评测口径的地方（§17.1.4、19 章 §19.3 的 P4）。
8. **harness 侧的幂等性被假定而非被测量**。决策权实际落在 harness，但 harness 自身的可靠性只有一篇把它分成七个部件（上下文、执行、治理、生命周期、可观测性、工具、校验）来测（2610.32285）；"同一指标 → 同一动作"在真实 harness 上是否成立，没有针对 Jev 类模型的测量。

# 18 • 训练目标：数值与决策类输出应该长什么样，以及要不要引入思维链

> 口径：仍然只做分析与调研。本章回答第二个追问——**Jev 类模型的训练目标是什么、数值 / 决策类输出应该长什么样、如何优化、是否应该引入思维链提升决策质量；而如果业务目标是 System 1，这条思维链又应该长什么样**。学习算法的全景已在 12 章（七类改动 A–G 与消融证据），本章不重复，只回答"输出的形状"与"思维链"这两件 12 章没有展开的事。
>
> 结论先行：（1）**训练目标的共识已经收敛到"适当评分规则"，但真正欠缺的不是目标函数而是输出空间的形状**——四种输出里有三种的形状是错的（布尔缺第三个真值、选择的读出是序数的却被当概率用、序数被系统性压缩），而数值根本不该用一个标量去拟合；（2）**要引入思维链，但不是在推理时引入**：现有证据里思维链的三种用法（训练时蒸馏、推理时生成、层循环）收益递减而代价递增，而最被低估的是第四种——**让 Jev 去读别人的思维链**；（3）如果业务目标是 System 1，那么它的"思维链"**在推理时不应该是 token 流，而应该是问题图**：在前缀-only 模型上多问一个问题近乎免费，多生成一个 token 却按量计费。
>
> **复核提示（20 章）**：本章的"问题图 vs token 流"是本报告自己的构造，由成本结构推出而非测出（20 章 §20.2，过拟合风险中高）；"把一个判断拆成 n 个判断"的组合校准没有任何论文回答过。本章最稳的结论是序数压缩与"结构约束胜过损失项"，最可能被推翻的是三条数值路线的排序（20 章 §20.4）。

## 18.1 共识目标与它的三个已证明的边界

12 章 §12.2 已给出结论：相对普通分类微调，改动集中在**读出位置**与**目标里加一个适当评分规则项**。本章只补三条"已被证明"的边界，因为它们直接限制了 §18.2–18.5 的所有讨论。

1. **标签已知时，适当评分规则与 RLCD 式奖励的策略梯度到达同一个最优点，而没有后者的方差**（NDM §8.1，2610.25553）。→ 在纯读出上，"改成 RL"不是一个目标函数问题，而是一个方差问题（15 章 §15.4、16 章 §16.1.3）。
2. **当不确定性来自标注者分歧时，同一目标可证明不可能胜过交叉熵**（2609.38850）。→ 凡是业务标签本身有分歧的场景（审核、评分、满意度），目标函数侧没有空间可挖。
3. **加适当评分规则项对准确率无效，对稳健性与 NLL 有效**：SBERT2S1 的两头 × 五目标网格里温度缩放后没有目标明显比交叉熵更校准（2610.02486）；PACT 四项都不提高原始准确率，收益是种子方差减半与 NLL −26%（2609.35865）；期望效用目标 +0.9±0.9 pp（2610.17205）。

**推论**：如果想让"决策质量"真的变好，可动的三个地方依次是 **输出空间的形状**（§18.2）、**结构约束**（12 章 §12.3 已证明最有效）、**推理期的计算形态**（§18.4）。目标函数本身已经基本到顶。

## 18.2 四种输出各自"应该长什么样"

### 18.2.1 布尔 / Noul：形状错在缺一个真值

Sys1Cal-v1 用"构造上已知 P(A)"的真/假命题逐一通过三个原语提问，用与真值分布的总变差距离评分，发现一个只能用"Jev 压制了第三个真值"来解释的行为：在 `Choice` 回答里 P(A) 与 P(¬A) 被当作和为 1 呈现，而和式里缺了一项 P(U)≠0；**把 P(U) 还原回来，Choice 的软准确率中位从 0.771 升到 0.978**（2609.35342）。

同一结论从"概率公理"一侧被独立验证：480 个否定对上"标签是 X"与"标签不是 X"的和平均偏离 1 达 0.064（95% CI 0.055–0.072），三个单标签概率平均和 **1.14**，而违背量约为其重复噪声的 5 倍且**集中在它不确定的地方**（2609.33209）。对照 Qwen3.8-27B 官方 BF16 权重的首 token 读出偏离 0.293、口述概率偏离 0.122，而且它是**双向否定**（在 480 对中有 196 对同时否定一个命题与它的否定），并且不会在更自信处更自洽。

**形状结论**：布尔输出的正确形状不是 P(true)，而是**三元 {true, false, unknown} 上的分布**；而"不确定"这一项不能靠阈值事后切出来，因为违背恰好集中在不确定区。D4 的"拒绝 / 兜底"子维度（06 章）与 P6/P7（17 章）在这里合流：2610.19856 测到"正确识别类别并不迁移为正确选用兜底项"，正是因为兜底被实现为**选项集里的一个普通选项**而不是**分布里的一个结构位**。

### 18.2.2 选择 / Choice：读出是序数的，被当成概率用就会出错

JevCascade 证明了一条可检验的性质：当干预只改菜单、文本不变时，**干预后的准确率已由缓存的首遍分布决定**——把首遍概率限制到新菜单上、重归一化、取 argmax 即可，无需标签也无需第二遍；在六个模型族、十个核心数据集（共十六个）、两种任务上，仅改菜单的干预被预测到 **4.2 点以内**，对一个族是精确的。关键限定是：**这条性质是序数的，不是概率**

**的**——同一估计器的"概率层"变体误差 **21.0 点**；而且它是类别特有的——同规模生成式模型误差 1.6–15.8 点且随规模变大而变差（2610.07716）。

两条直接后果：

- **菜单设计是比模型规模更强的杠杆**：0.8B 在策展过的 5 候选菜单上在 CLINC150 达 95.4%，4B 在 150 标签全菜单上 80.0%（同文）。这与 NIOCIS 的消融一致：增益归于**按节点限制候选集**（比扁平目录 +3.5 点）而非图遍历（区间内为零）（2610.25985）。
- **把 Choice 概率当"概率"用是越界使用**。TypedBench 把这件事的业务后果测出来了：在非对称代价下，**用宿主模型的概率可能比直接取它的 top-1 更差**（2610.11392）。

**形状结论**：Choice 的输出应当被当作**对给定菜单的排序 + 一个只在该菜单上有效的置信**，而不是对世界的概率陈述。"换菜单后概率仍然可比"这条性质在现有证据下不成立（IIA 违背，06 章）。

### 18.2.3 分数 / Score：序数压缩是系统性的，且不靠规模解决

这是现有文献里唯一一个**在四十个数据集上横跨三个模型族被确认**的输出形状缺陷。

| 观察 | 数字 | 出处 |
|---|---|---|
| 序数刻度利用率偏置 | 40 个数据集、JEV / KEV / StartLux 三族九个模型，最终决策集中在比金标分布**更少的有效标签**上；在无序语义类别上明显更弱 | 2609.38827 |
| 刻度变细会**加重**压缩 | 同一批条目在更细的序数刻度上压缩更强，且已控制金标不平衡与候选位置 | 同上 |
| 随机化候选顺序 | **减轻但不消除**压缩 | 同上 |
| 固定候选数下拉大序数间距 | 可以提准确率而**不恢复利用率** | 同上 |
| 规模 | 更大的模型准确率更好，但**不能一致地恢复刻度利用率** | 同上 |
| 并存现象 | 对多数模型，**集中的决策与宽的平均候选概率并存** | 同上 |
| 可被定向训练缓解 | 作者结论是"刻度利用率应与准确率并列为可操作的可靠性目标" | 同上 |
| 不是 Jev 特有 | 三个前沿多模态 LLM 家族在临床序数量表上同样有**中心趋势效应**（端点压缩）：低端高估、高端低估，而全参微调的 ViT 校准最好（MAE 0.52、容差内 91%）；跨全量程的少样本示例与去掉临床术语**都不能消除**该效应 | 2605.16386 |
| 直接的目标函数手段 | PACT 的**序数传输代价**项把 rubric 字段的 MAE 降到 **0.232**（对照已发布配方 0.311），同时位置偏置最低（重标注下的改判 9.8% 对 13.8%）、准确率持平（84.6% 对 85.2%，每个种子 McNemar $p \geqslant 0.50$） | 2609.35865 |
| 公开实现里几乎没人开 | Kev 的 `--ord_w`（序数损失）在**发布模型里未使用**（12 章 §12.1 表 B 行） | jaredpalmer/kev |
| 读出方式本身会移动结果 | 用 `Score` 而不是 `Choice` 提同一个问题，分级准确率最多移动 **10.5 点** | 2609.32160 转述 T3 |
| 不要把分布塌成一个数 | 心理测量审计：**默认的四舍五入读出下 14 个决策模型里 13 个低于生成式参照**；而按被访者平均后，**概率向量比四舍五入后的答案更接近人类的条目边际分布**，并且在给被访者排序上约等于在 163 个真人上拟合的画像回归 | 2610.14912 |

**形状结论**：Score 的正确形状是**有序级别上的完整分布**，训练时要带一个序数项（传输代价 / 序数交叉熵），评测时要用**序数适当评分规则**而不是准确率（TypedBench 正是这样做的，2610.11392），下游**不要四舍五入成一个级别**。这三条是本章里证据最充分、而公开实现里落实得最差的一组。

### 18.2.4 数值：Jev 不是回归器，有三条可行路线与一条禁区

先把禁区说清楚。

- **算术拒绝瓶颈**：答案在场时准确率 99%，答案缺席时正确拒绝率只有 **7%**，且该缺口跨数值量级、运算深度、上下文表述与拒绝标签持续存在，并延伸到时间计算与容量取整；而**同一批答案缺席的算术题上原生布尔校验能到 99% 精确匹配**——也就是说**分类式拒绝会失败，即使模型能成功校验候选的正确性**；一个在独立开发题上选出的决策阈值把拒绝准确率从 7% 提到 **79%** 而保留 97% 的答案在场准确率，无需重训或额外推理（2609.39496）。
- **读出 vs 推理的缺口在日期与数值上最大**：56–66%（读出）对 98–100%（推理）（14 章 L3）。
- **医学上这是一条明确的能力边界**：Jev 在以文本驱动的任务上与领先模型相当，但在**数值驱动**的任务上明显更弱（2610.18529）。
- 01 章 §1.6 已经把这条写成结论：Jev **不具备算术 / 日期 / 计数能力**。

在"禁区"之外，文献给了三条真正可行的数值输出形状。

| 路线 | 做法 | 测到的量 | 出处 |
|---|---|---|---|
| **R1 把数值变成区间决策（训练无关）** | 承认"数值区间选择本身就是一个决策问题"，用**多路决策树递归细化区间**，始终把原问题留在上下文里，不更新参数也不访问隐状态；100 值网格上十路树只需两轮 | 区间归一化 MAE **1.84%** 对直接选择的 5.18%；**比"候选表里含正确答案的直接选择"还高 2.93 pp**；三日期历史指数研究平均相对召回误差 4.58%，值被给定时读出误差 **0%** | 2609.28587 |
| **R2 把数值变成分箱分类并由粗到细** | 对数值与点预测任务用**值分箱与图像区域**，经由粗到细的分类细化；选择题任务直接用给定选项 | 该读出形式是 MJev-Spatial 的核心机制 | 2610.22276 |
| **R3 用解码式回归头** | 把数值预测表示为被解码的字符串；理论上说明该能力的根据，并把因果序列解码模型当作任意特征表示之上的数值回归头 | 尽管只用常规的下一 token 交叉熵训练，**解码式头与标准逐点头在标准回归任务上同等好**，同时足够灵活以刻画平滑数值分布（如密度估计） | 2501.19383 |

**形状结论**：数值输出应当是**有序箱上的分布**（与 Score 同一族），可以用递归细化换取精度，可以用解码式头换取平滑密度；但**不应该是一个标量回归目标**，也**不应该承担算术**。"要不要支持数值"因此不是一个模型能力问题，而是一个**接口分解问题**：把"算"交给工具或 System 2，把"落在哪个区间"交给读出。

### 18.2.5 小结：输出形状的四条判据

| 原语 | 现行形状 | 证据支持的形状 | 最强反例 |
|---|---|---|---|
| Noul | P(true) ∈ [0,1] | {true, false, **unknown**} 上的分布 | P(U) 还原后软准确率 0.771 → 0.978（2609.35342） |
| Choice | 选项上的概率分布 | **给定菜单上的排序** + 菜单内置信 | 概率层估计误差 21.0 点 vs 序数层 4.2 点（2610.07716）；非对称代价下用概率比用 top-1 更差（2610.11392） |
| Score | 有序级别上的分布（但被压缩，下游常被四舍五入） | 有序级别上的分布 + **序数项** + **不塌成一个数** | 40 数据集 9 模型的刻度利用率偏置（2609.38827）；概率向量比四舍五入更接近人类边际（2610.14912） |
| 数值 | 不在接口里 | **有序箱上的分布**（可递归细化 / 解码式头），算术外包 | 拒绝率 7%（2609.39496）；区间决策 MAE 1.84% vs 5.18%（2609.28587） |

## 18.3 怎么优化：证据支持什么、排除什么

| 手段 | 证据 | 判断 |
|---|---|---|
| **结构性构造不变性**（块因果注意力、位置重置、每选项独立块） | 翻转率 8.30% → 0.11%（Gemma 3 1B）、18.16% → 1.20%（Qwen3 1.7B）；Prism-1 **按构造零翻转**且 Luce 公理成立；NDM 的块注意力掩码使每个答案**按构造**对选项顺序不变且与其他问题独立，且等算力下比成对交叉编码器损失更低（12 章 §12.3；2610.01601、2610.22066、2610.25553） | **最有效**。凡能写进掩码的一致性，都不要写进损失 |
| **集合级损失项**（配对差分、置换一致、证据必要性、序数传输） | PACT：**没有单独一项提高原始准确率**；价值在稳健与稳定（种子方差减半、NLL −26%、位置偏置 9.8% 对 13.8%、rubric MAE 0.232 对 0.311）（2609.35865） | **有效但只作用于二阶性质**；与 16 章 §16.2 的 B 类判断一致 |
| **事后校准与统计认证** | 朴素阈值在约一半设定下超出目标风险，Learn-Then-Test 只有 7.8%（2610.19811）；温度在不同负载上拟合值不同，阈值迁移不可假设（2609.32160 C3） | **必须作为独立阶段**，不能并入训练目标（16 章 §16.2 C 类） |
| **RLVR / 结果奖励** | RLVR 提升任务表现但产生**极端过度自信**，SFT 校准显著更好**且在分布偏移下仍如此**（增益更小）；诊断是**决策 token 在推理轨迹里充当"抽取步骤"、不携带置信信息**，这阻止了 RL 浮现出校准的替代项；按此做"校准感知 RL"直接调整决策 token 概率，保住 RLVR 的准确率水平而把 ECE 最多降 **9 点**（2601.13284） | **对 Score / Noul 这类要概率的输出直接有害**，除非显式对决策 token 的概率施加校准项。这是"要不要 RL"这个问题上机制最清楚的一条证据 |
| **RLCD（带推理链）** | 必须**先校准再强化**：端到端优化要么"System-One 坍塌"（用 KL 锚防止）要么被策略梯度淹没（其梯度比读出大 **7–12 倍**）；GSM8K 答案验证单次查询在 ≤5% 错误下决定 81% 条目，GRPO 19%（2609.38850） | 只在"奖励依赖被采样的中间对象"时有独立价值（15 章 §15.4） |

## 18.4 要不要引入思维链：四个被混为一谈的问题

"引入思维链"在文献里是四件不同的事，收益与代价都不同。

### 18.4.1 用法 A：训练时作为监督来源，推理时不存在（证据最强）

**Reasoning-to-Readout 自蒸馏**：把一个开源权重 LLM **自己的推理**内化到单遍首 token 决策里。SII-Decision-27B 在 JEVal 上**与 Jev 持平**，而一次典型查询约 **0.1 s**（2610.03935）。

同族证据：Eikos 在软目标之外加**推理理由辅助损失**（12 章 §12.1 表 C 行，2610.29052）；StartLux 的三阶段流水线里 AutoThink 的推理能力来自**推理监督 + RL**（2610.17309）；FunDM 的无标签 KL 蒸馏收回 99% 的调优增益（2610.17175）。

**判断**：这是唯一"既拿到推理收益又不付推理成本"的用法，也是与业务目标（§17.1 的单价）唯一不冲突的用法。

### 18.4.2 用法 B：推理时生成思维链（有效，但它就不再是 System 1 了）

| 证据 | 内容 |
|---|---|
| 现成模型即可 | LLM-as-Jev 指出决策模型"无缝继承骨干的思考模式"：Jev 被作为 System 1 模型引入，而 "Thinking Jev" 用**有预算的测试时推理**在困难任务上提准确率，**无需训练**（2610.02076） |
| 专门训出来的版本 | StartLux AutoThink 在不确定决策上调用显式推理、自信情形直接作答；在 DecisionPivot 上比对应的 Instant 版本高 **11.5–18.4 点**配对准确率并在被评系统中领先；27B AutoThink 在 Decision Index 0.3 公开子集达 73.4（2610.17309） |
| 代价必须被显式压住 | RLCD² 用冻结模型与适当评分规则奖励"决策概率质量的改进"，并对过长推理轨迹施加**软惩罚**：在限长内终止的轨迹占比最多 **+48 pp**，平均推理长度最多 **−65%**，而决策准确率基本保持（同上） |
| 校准代价 | 若用 RLVR 式结果奖励，会极端过度自信，且决策 token 不携带置信信息（2601.13284）；RLCD 若不先校准就会 System-One 坍塌或被策略梯度淹没（2609.38850） |

**判断**：有效，但它把成本结构搬回生成式一侧（§17.2.1 消除的正是解码成本），所以它只能作为**按置信门控的少数路径**存在——这就是 §17.5 的 A 格，而 A 格依赖的 P3/P5 两条属性都不可直接承诺（17 章 §17.3）。

### 18.4.3 用法 C：层循环，即"不生成 token 的思维链"（System 1.5）

| 证据 | 内容 |
|---|---|
| SanSi | 把预训练的循环语言模型变成类型化决策模型；**每个循环后都读一次选项概率，每个循环都用适当评分规则训练**，于是一次训练得到一个覆盖 1–8 个循环所有预算的模型。59 个来源的 10,027 条测试决策上 **72.0%**：比同形状非循环模型（同配方）高 **13.5 点**，比同尺寸更新的非循环模型高 5.3 点，比三倍参数的模型低 1.8 点。两个深度受控任务上，**循环把可解深度推到训练中见过的深度之外**，而更大的单遍模型失败。作为 RL 策略优化的评审（无金标答案）时，把生成器正确答案的比例从 37% 提到 52%（2610.07730） |
| LEV | 同一思路、三个循环骨干：同一套权重上准确率随深度上升，**增益主要落在难题上**；2.6B 从深度 1 的 63.2% 到深度 4 的 **76.2%**（JevBench）。**按需深度**（由一个小停止器按未标注请求上拟合的阈值逐题决定）省 **15%–24%** 算力而代价不到一个准确率点，与固定深度混合持平或略高；在锁定测试集上，1.4B 与 3B 比**同等延迟（<50 ms）**的非循环稠密模型与级联高 **5.4–8.8 点**（2610.20951） |

**判断**：这是"如果业务目标是 System 1，思维链应该长什么样"的**最直接的已验证答案之一**——深度可变、零输出 token、延迟可控、按题分配。它的约束是骨干：两者都建立在**预训练为循环的语言模型**（Ouro）之上，而我们的基座族（Qwen3.5 / 3.8）不是循环预训练的，且是 Gated DeltaNet 混合（08 章）。文献里没有"把非循环混合骨干改造成循环读出"的工作，这是零命中。

### 18.4.4 用法 D：让 Jev 去读别人的思维链（最被低估）

七个 LLM 推理器 × 五个选择题基准（35 对）上，把 Jev 当"被截断推理的决策读出器"：在 500–16,000 token 的全部测试预算上，**Jev 的平均准确率高于强制作答**（已计入推理与作答的估计成本）。1,500 token 预算下整体 **+4.1 pp**、被截断的题 **+8.6 pp**，17 对在 Holm 校正 bootstrap 下显著；离线重放估计为全程成本的 34.5% 而准确率只损 1.13 pp；在训练折上选出的策略在保留折省 **71.3%** 的估计全程成本而只损 0.58 pp。同文还发现 Jev 的**只看题目**准确率很强，平均超过 500-token 强制作答（68.0% 对 65.5%），但这一优势因基准而异（2610.25768）。

**判断**：这是把"思维链"与"决策"彻底解耦的形态——**思维链由 System 2 生产，决策由 System 1 消费**。它不要求 Jev 自己会推理，只要求它会读；而 §17.3 的属性清单里它只依赖 P1 与 P3。

### 18.4.5 为什么必须引入某种形式的"更深计算"：那条硬界限

Jev **不能做出"LLM 只有写出中间步骤才能做出"的决策**。在逐因子变动的基准上，Jev 在 20k token 与 64 选项内无误地找到并选出记录，但一旦答案依赖同一用户的**两次以上更新**，准确率下降，十六次更新时到 53%–80%，原因是相似记录互相干扰。给它一个**过时的状态摘要**，它就照着过时的摘要答。在"按参考 LLM 需要多少思考 token 来分级"的真实决策条目上，Jev 答对该 LLM**一次前向就能解**的条目的 97.5%，但其余条目只有 **74%**。更关键的是**它不知道自己的界限**：它的置信度能标记它自己犯的错，但标记不出它从过时输入继承来的错，而显式的或训练出来的交接选项**都抓不到后者**。所有被评的开源模型共享这些界限，作者的结论是"**检查这类模型所依赖的状态，需要一个会推理的模型**"（2610.24929）。

**这条界限决定了用法的取舍**：A（训练时蒸馏）无法突破它，因为蒸馏的是"一次前向可解"的那部分；C（层循环）是唯一有**深度外推证据**的用法（SanSi 把可解深度推到训练深度之外）；B 与 D 是把界限外包给 System 2 的两种方式。

## 18.5 如果业务目标是 System 1，这条思维链应该长什么样

把 §18.4 四种用法按"是否付解码成本"与"是否突破一次前向界限"排开，答案就出来了。

| 用法 | 推理时付解码成本 | 能否突破一次前向界限 | 适合 |
|---|---|---|---|
| A 训练时蒸馏 | **否** | 否 | 默认方案：免费拿到"一次前向可解"那部分的全部收益 |
| C 层循环（System 1.5） | **否**（付的是层重算） | **部分能**（深度外推已验证） | 想在零 token 前提下提高深度的唯一已验证路线 |
| D 读别人的链 | 否（链由 S2 付） | 是（界限被 S2 承担） | 已经有 S2 在跑的流水线 |
| B 自己生成链 | **是** | 是 | 只能作为按置信门控的少数路径 |

但还有**第五种形态**，它才是"System 1 的思维链"在接口层面的自然形式。

### 18.5.1 System 1 的思维链是问题图，不是 token 流

前缀-only 模型的成本结构决定了这一点：**一个请求里的所有问题在同一次前向里答完**（01 章 §1.4），所以多问一个问题近乎免费；而多生成一个 token 按量计费（§17.2.1）。于是"把推理展开"在 Jev 上的等价物不是"把步骤写出来"，而是**把一个判断分解成更多个类型化判断，并把它们的结构放进请求或放进调用方的代码里**。

现有的实例已经覆盖了这个形态的多数变体：

| 形态 | 做法 | 测到的量 | 出处 |
|---|---|---|---|
| **并行子问题读分歧** | 因为"模型对额外问题的定价几乎为零"，把判断分解成并行子问题并读它们的离散度，可以恢复出模型原生置信度抓不到的**人类分歧**信号 | 该补救**是特异的**：只帮最弱、对分歧盲视的模型，且只在分解与分歧来源对齐时有效；专用毒性模型与最强 LLM 不需要它，效果对分布敏感 | 2610.33258 |
| **把"该问什么"也放进同一次前向** | LAVOIR 把候选的缺失信息（slot）放在输入里、紧挨答案选项，于是**一次前向同时返回决策分布与每个 slot 的"若追问该 slot，正确决策概率的期望增益"**；VOI 目标无需人工标签；基尼不纯度上限把预测值约束在"校准模型还能赚到"的范围内 | 问题策略与贪心预言机 VOI 策略持平（AUC 0.799 对 0.797）；每段对话最多 0.5 个追问即比"从不追问"高 **14.1 点**；真实 ABCD 对话上，在它选择追问处一次真实交互提高 **8.3 点**，在它不追问处不变；SGD 上该上限把追问率从 93% 降到 **8.6%**；31 ms（中位，GH200） | 2609.30706 |
| **逐节点走树** | SemTree 的 Yes/No/Unknown 节点树可逐节点定位并修复失败条件；Jev-Guard 先在可编辑策略树上路由再做条件分类；官方文档的"逐层走分类树" | Jev-Guard：7,033 用例上安全准确率 93.72%、平均延迟 58 ms、层级路由准确率 93.10%，全流程 240 ms | 2610.13999、2610.18326 |
| **菜单策展** | 在问之前把候选集缩小，这是比加深模型更强的杠杆 | 0.8B 策展 5 候选 95.4% 对 4B 全 150 标签 80.0%；按节点限制候选集 +3.5 点 | 2610.07716、2610.25985 |
| **复用首遍分布** | 只改菜单的干预**不需要第二次前向**，首遍分布限制 + 重归一化即可，误差 4.2 点内 | 同时给出否定面：**均匀地多跑几遍只买到校准，几乎买不到准确率**；等成本下置信度级联胜过任何重问同一模型的方案 | 2610.07716 |

### 18.5.2 这个形态的三条已知边界

1. **分解不是普遍增益**。"均匀地多跑几遍只买到校准、几乎买不到准确率"（2610.07716）；并行子问题读分歧只在特定条件下有效（2610.33258）。
2. **分解会放大一致性缺陷**。问题形式本身会移动答案（`Score` 对 `Choice` 最多 10.5 点，2609.32160），而概率之间本就不自洽（三个单标签概率和 1.14，2609.33209）。把一个判断拆成十个判断再合并，等于把这些偏置累乘十次。06 章 §D4 的"分解一致性"子维度就是为此设的。
3. **正确的中间选择不保证正确的序列**：正确的最终标签掩盖了错误的中间选择（2609.32160 T2 转述）；Choice2Seq 把"任务正确、计划忠实、输出合规"分开测（2610.16191）。

**§18.5 结论**：如果业务目标是 System 1，那么"思维链"在**训练时**应该以蒸馏的形式被吸收（用法 A），在**推理时**应该以两种零 token 的形式存在——**层循环的深度**（用法 C）与**问题图的宽度**（§18.5.1）；真正生成文字的思维链只应作为按置信门控的逃生通道（用法 B），或者干脆由 System 2 生产而让 Jev 只负责读（用法 D）。

## 18.6 本章小结与盲区

**训练目标**：适当评分规则已是共识且已到顶（三条边界见 §18.1）。可动的是输出空间的形状、结构约束、推理期计算形态。

**输出形状**：布尔要三元（含 unknown）；选择是菜单内的序数量而非世界概率；分数要有序数项且下游不得四舍五入；数值要落到有序箱上并把算术外包。四条里有三条有横跨多数据集多模型的证据，而公开实现里落实得最差（Kev 的序数损失发布时未启用）。

**思维链**：要引入，但在推理时不应该是 token 流。四种用法里 A（训练时蒸馏）是默认、C（层循环）是唯一有深度外推证据的零 token 路线、D（读别人的链）最被低估、B（自己生成）只配做门控逃生通道。而 System 1 自己的"展开"形式是**问题图**：多问近乎免费，多生成按量计费。

**盲区**：

1. **没有人把"unknown"做成接口里的结构位并测它**。P(U) 只被**事后还原**出来过一次（2609.35342），没有任何训练工作把三元真值作为输出空间。
2. **序数项的收益只有单篇单设定的证据**。PACT 的 MAE 0.232 对 0.311 来自 324 条冻结保留集、三个种子（2609.35865）；2609.38827 说"可被定向训练缓解"但没有给跨数据集的训练对照。**"开了序数损失之后刻度利用率偏置下降多少"这个数不存在。**
3. **数值的三条路线互不对照**。R1 训练无关、R2 在多模态里、R3 在通用回归里，**没有任何论文在同一批数值决策上比较过区间决策树、分箱分类与解码式回归头**。

4. **层循环与我们的骨干不兼容，且无人研究过桥梁**。SanSi / LEV 都要求循环预训练骨干；"把非循环的混合（Gated DeltaNet + 注意力）骨干改造成多次循环读出"为零命中（08 章）。
5. **问题图的组合语义没有理论**。分解会累乘一致性缺陷（§ 18.5.2），而现有工作只在单层分解上测过；"n 个类型化判断组合后的校准是什么"没有任何论文回答——2609.33209 的 160 条、480 对是全文献关于概率自洽的唯一证据。
6. **"决策 token 不携带置信信息"这条机制只在生成式 RLVR 设定下被诊断过**（2601.13284）。在纯读出（无推理链）的单遍模型上是否同样成立，未被验证；而它若成立，就直接解释了 12 章 § 12.3 记录的"单遍模型上 RL 为负或无效"。

# 19 · Jev 类模型应该如何评测：现有评测集覆盖了哪些业务属性，漏掉了哪些

> 口径：仍然只做分析与调研，**不提方案、不设计新基准**。本章回答第三个追问——**Jev 类模型应该如何评测；从业务目标视角看，当前的评测集是否覆盖了我们希望它具备的能力**。做法是把 17 章 §17.3 的十二条业务属性当作被测对象清单，把现有评测集逐条对上去，看哪一格有基准、哪一格只有单篇单设定、哪一格是零。
>
> 结论先行：（1）**"应该怎么评测"这件事文献里已经有答案了**，是一份 14 项的检查表，而**现有论文对它的平均合规率很低**——最关键的"同骨干标签对数概率基线"26 篇适用论文里只有 5 篇合规，"选项名不变性测试"27 篇里只有 1 篇；（2）从业务属性看，覆盖面**严重不均**：准确率与校准被反复测，一致性与对抗被密集测，而**兜底、unknown、自知、概率自洽、可审计、风险预算、业务人员可配置**七格里有四格是单篇孤证、两格是零；（3）**最大的缺口不是某个能力没被测，而是"每正确结果的端到端成本"没有任何论文用可复现的口径测过**——而这恰恰是 17 章论证的业务目标本身。
>
> **复核提示（20 章）**：本章的覆盖面矩阵是按 17 章 §17.3 的十二条属性画的，而那张清单本报告自己已证明不完整（§19.3.1），所以"X 格是零"应读作"**按本报告这种分类**看是零"（20 章 §20.2、§20.3）。

## 19.1 "应该怎么评测"已有答案：14 项检查表与它的合规率

一篇对 Jev 发布后九天内 28 篇论文的证据审计，把反复出现的比较与报告缺陷整理成一份 14 项检查表，并对其中可评分的项给出**合规论文数 / 适用论文数**（在 27 篇"评测了模型"的论文内计数；"不清楚"的论文从分子分母同时剔除；"–"表示无法从文本可靠评分）（2609.32160）。

| ID | 要求报告的内容 | 合规 / 适用 | 该项被观察到的失败 |
|---|---|---|---|
| **B1** | 一个从普通或**同骨干**语言模型读标签对数概率的基线 | **5/26**（1 不清楚） | 否则无法把接口收益与模型收益分开；凡测过的地方，读出几乎没加准确率 |
| **B2** | 若用置信阈值把决策交给另一个模型：一个**便宜的生成式级联**作基线 | **1/5** | 外部基准上便宜的生成式级联比 TDM 级联更便宜且不更差；Jev 价位区间的六个开源权重 LLM 里有两个 macro-F1 中位更高 |
| **B3** | 若标注足够训一个：**任务专用模型**（编码器 / 经典分类器 / 奖励模型 / 探针）作基线 | **7/13**（3 不清楚） | 微调编码器在排序上不显著差于开源 TDM，ECE 名义更低（Brier 更高），且更快；训练过的质量模型仍大幅领先 |
| **T1** | 测试集上**模型间的分差**；不要在饱和测试上宣称持平 | – | 多个持平结论来自强模型已触顶的测试 |
| **T2** | **逐条决策**在重复 / 换序 / 换措辞下的正确性或一致性，而不只是聚合准确率 | **17/26**（1 不清楚） | 相同的聚合分数掩盖了不同的决策；正确的最终标签掩盖了错误的中间选择 |
| **T3** | **选项名不变性**测试：跨 rubric 交换名字，或比较中性名与语义名 | **1/27** | 跨 rubric 交换 no/yes 把 Jev 的 AUC 从 .815 压到 .581 且类型错误为零；用 `Score` 而非 `Choice` 提问使分级准确率移动最多 10.5 点 |
| **T4** | **数据来源**：合成还是真实、金标来源、公开基准是否早于模型 | – | 语料里包含 Agent 生成的文本配 Agent 生成的标签，以及未解决的污染疑虑 |
| **R1** | **确切的模型版本与运行日期** | – | 宿主 TDM 是闭源的，可能在同一名字下变动；多篇两者都没给 |
| **R2** | 主结果上的**置信区间或显著性检验** | **15/27** | 27 篇里 12 篇的主结果两者都没有；由于宿主模型非确定性，还应报重复运行的稳定性 |
| **R3** | 披露**在看过测试数据之后**才选定的提示、配方、基线或阈值 | – | 至少 7 篇做了这类选择；一串重设计把主指标从 .576 推到 .797 |
| **C1** | 若把概率用作或描述为校准的：用 ECE / Brier / 可靠性分析或等价指标测校准 | **13/17**（1 不清楚） | 优先用保留数据、与标签流行度匹配的指标、并给出再校准前后两套结果；某些负载下原始概率失准，再校准降 3.3（点），而 0.01 的网格限制了稀有标签的分辨力 |
| **C2** | **最高置信那批样本**的准确率，按任务分列 | – | 语料里存在"高置信但准确率接近基率"的情形，以及平均置信 .778 的错误工具调用；在保答案的优化上下文下，Jev 原本正确的决策有 45%（被改向的里 73%）最终以 >0.7 的概率落在错误选项上 |
| **C3** | 若用置信阈值做接受 / 升级：阈值在**与评测集分离的数据**上拟合，或在评测前固定且不在其上调 | **7/7**（3 不清楚） | 冻结阈值还应测跨负载 / 跨兜底模型的迁移，因为在选择集上拟合的阈值并非对每个兜底模型都在保留条目上成立，且拟合出的温度跨负载不同；有些固定阈值被用在作者明确不假设其校准的分数上 |
| **C4** | 若报了 TDM 延迟或宣称延迟优势：**带缓存与不带缓存两套延迟** | **3/20**（1 不清楚） | 还应说明服务位置、并发与**每正确结果的实测成本**；缓存抹掉了一篇报告的延迟优势；两篇姊妹论文在不同负载上报出**相反的成本方向** |

该文还把检查表压成一张**最小报告卡**：确切模型版本与运行日期；测试难度或模型分差；一个普通 LM 读出基线；一个便宜的生成式基线；重复运行的区间；保留集校准；以及**用到级联时，在新兜底模型上评测的冻结阈值**。

**读法**：这是本报告里"应该怎么评测"这个问题的直接答案，而且是文献自己给的。它同时暴露了一件事——**现有评测集的问题不在于基准不够多，而在于报告纪律**。B1 的 5/26 与 T3 的 1/27 意味着：公开数字里，"接口的功劳"与"模型的功劳"基本没被分开过，"标签名压倒定义"这个 D1 最严重的缺陷基本没被常规测过。

### 19.1.1 一个自审计案例说明成本口径有多容易错

一篇对 11 个 Agent 决策点（18 个公开来源、7,283 条基础用例 + 6,640 条稳健性变体、字节级相同输入、配对检验、跨硬件跨日复现检查）的配对评测，**对自己的流水线做了审计**，并报告了三个分析错误与一个设计混杂如何扭曲了它原本的部署结论：**漏算了一道前置筛选的成本，使"节省 23.9%"实际只有 4.3%**；把**闸门准确率当成端到端质量**报告（58% 对 98%）；阈值在样本内拟合（目标 5%，保留集上最高到 17%）（2610.02267）。

这一段比检查表更有说服力：**它是同一批作者在同一篇论文里把自己的成本结论推翻的记录**。17 章 §17.6 盲区 1 说"没有人测每正确结果的端到端成本"，根源就在这里——这个数极易算错，而且算错的方向总是对自己有利。

## 19.2 现有评测集按"测什么"分类

12 章 §12.4.1 已给出数据可得性与规模，本节只补"每个评测集的被测对象"，因为这才是覆盖面分析的输入。

| 评测集 | 规模 | 被测的主要对象 | 出处 |
|---|---|---|---|
| **JEVal** | 11,257 条 / 36 数据集 / 10 领域 / 双语 | 横向能力 + 组合成系统后的行为变化；结论是决策模型在"能从已有证据裁决"时最有竞争力，而在需要专家知识或**忠实的不确定性估计**时变弱——"常能指出最可能的结果，却大幅高估它的概率" | 2610.03935 |
| **System1-Arena** | 92k 题 / 105 任务 / 268 来源 + **138 个闭环环境**（含实时模式） | 同一批决策请求下给所有模型打概率分；四组：文本分类与知识、应用决策、评估与控制、Agent 与动作 | 2610.21244 |
| **TypedBench** | 7 个策略标注生成器 + 9 个评测套件 | **四件事联测**：策略遵守、措辞稳健（准确率报跨复述的中位与范围）、概率质量（选择性预测、**序数适当评分规则**、非对称代价下的实现代价）、成本；校准误差相对一个**匹配的完美校准预测器的有限样本噪声底** | 2610.11392 |
| **DecisionPivot** | 48 任务 / 40,033 条；核心轨 7,800 条（13 个生成任务族，**对照组 + 独立实现的求解器验证**）；参照轨 32,233 条（35 个公开测试集，保留原指标） | 条目准确率、**对照组准确率**、概率排序、校准、经验选择性覆盖。关键结果：参照轨只差 2.6 点的两个 27B 模型，对照组准确率是 **70.1% 与 44.2%**；2,400 个二元对照对上 Perplexity Decider 把正例排在负例之上的比例 92.3%，而**两边都答对只有 74.1%** | 2610.28522 |
| **AgentDecisionBench / DecisionGym** | 从孤立问题到控制运行中的 Agent | Agent 场景下的决策委托。孤立问题最准的模型只解出 **69.5%** 的 Agent 任务；不拟合置信阈值就委托工具选择使成功率降 **19.0 点** | 2610.21412 |
| **Sys1Cal-v1** | 构造上已知 P(A) 的真 / 假命题 | **概率的数值含义**（不是置信排序）：用与真值分布的总变差距离评分，三个原语分别提问 | 2609.35342 |
| **Probability Contracts** | 1,000 个有限世界（+ 400 根独立队列） | 精确有限世界后验、事件对齐校验、**接口一致性**、失败感知的决策评测联测。Jev 的 Event 与 Choice 接口在 defer 成本 0.10 下对 **32.8%** 的有效配对改变二元动作 | 2609.37470 |
| **概率公理电池** | 160 条（ChaosNLI、PubMedQA）/ 480 个否定对 | **逐条的逻辑自洽**（无需标签） | 2609.33209 |
| **JevAdvBench** | 862 题 + 5,586 个保答案变体、12 种黑盒攻击 | 对抗稳健：攻击翻转 Jev 正确决策的 **46.3%**（同样重跑只翻 0.17%）；无命令的谬误论证翻 77.2%，接近直接提示注入的 92.0%；八个开源 TDM 被同样变体翻 34.0%–51.7%；**0.8 阈值下服务仍会执行的决策里 23.5% 是错的** | 2609.31142 |
| **选项通道攻击** | 七个开源权重模型做守卫 | 分开报两个错误方向（fail-open 是漏洞、fail-closed 只是成本）：允许/阻止决策准确率 36%–72%（随机水平 50%）；六行与策略无关的服务器日志把某个闸的 fail-open 率从 0% 抬到 63%；给宽松选项一个误导性名字（定义与被判文本不变）在四个把标签放进输入的模型上抬到 **93%–100%**；**所有被测防御都被击破**，而且**升级最不自信的决策也没用——被攻击翻转的决策不比它替换掉的那个更不自信** | 2610.12292 |
| **PFR（配对兜底稳健性）** | 三个基准、跨架构与参数量的受控比较 | 兜底：是否在常规项与兜底项之间正确切换；同一规则的**逻辑等价表述**下是否一致 | 2610.19856 |
| **TUPLE-Bench** | 配对合成案例、九个模型 | **接口泄漏**：指示"隐去原因"全部失效，91.88%–99.93% 的回答通过直接选择或**残留分数**泄漏原因；把原因从候选集排除后，完整输出仍让保留集恢复率 62.85%–75.35%（只用被选类别是 51.04%–57.64%，随机 50%）；完整输出在 **27/27** 个模型-任务比较里降低下游平均成本，而**置信字段增加泄漏却不一致地降成本** | 2610.23668 |

| 评测集 | 规模 | 被测的主要对象 | 出处 |
|---|---|---|---|
| **配对 Agent 决策点评测** | 11 个决策点 / 18 个来源 / 7,283 + 6,640 | 配对、字节级相同输入、跨硬件跨日复现 + **自审计**。Jev 在 9/11 个决策点显著更准（+10.8 到 +46.0 pp）；**两者在零样本模型路由上都不如随机**，在 RAG 相关性闸上打平；Laya 在选项顺序反转时改 30% 的答案，候选多或相似时急剧退化（50 个最近邻工具 31%，Jev 在唯一正确工具的条目上 98%） | 2610.02267 |
| **Choice2Seq** | — | 把**任务正确、计划忠实、输出合规**分开测 | 2610.16191 |
| **在线审核套件** | 五个审核基准 + 受控信息条件 | 把**成文规则、检索到的先例、候选答案空间的限制**三者分离。Jev 普遍从检索先例获益（答案空间固定时改善策略精确选择与有害内容判别）；Laya 的检索常只移动正例率而不改善判别；Jev 置信在若干设定下可支持选择性复核但**并非一致校准** | 2610.07953 |
| **RLCDAlignBench** | 10 类对齐失败 / 44 个基准 / 5 个目标模型 | 零样本对齐失败检测（也暴露基准自身的标签缺陷） | 2609.29429 |
| **心理测量审计** | 立陶宛组织心理学问卷（n=263、68 条目）、100 个真人画像、14 个决策模型 / 11 家 + 47 个生成模型 | **合成被访者的构念效度**（PSS）：默认四舍五入读出下 14 个决策模型里 13 个低于生成式参照；47 个生成模型里 33 个比任何决策模型更好地重现条目相关结构；但**概率向量比四舍五入答案更接近人类条目边际**；作为个人作答的预测则每个决策模型都不如"其他被访者的作答频率" | 2610.14912 |
| **其他**（Decision Index、JevBench、kev-suites、CJ-Bench、DecisionVista、DecisionRobust、this-that spatial/complex、生物安全审计、文化价值审计、偏见审计等） | 见 12 章 § 12.4.1 | 领域横向能力、语言覆盖、特定偏置 | 12 章 |

## 19.3 覆盖矩阵：十二条业务属性 × 现有评测集

把 17 章 § 17.3 的属性清单当被测对象，逐条对上去。

| 业务属性（17 章） | 有专门评测它的评测集 | 覆盖判定 |
|---|---|---|
| **P1 输出必在选项集内** | 无需基准（结构性）。但"类型对、语义错"只被**顺带**测到（T3 的 AUC .815→.581 且类型错误为零） | **结构性保证，但"类型安全给人的虚假安全感"无人系统测量** |
| **P2 一次前向答完 / 额外问题近乎免费** | 无。延迟与成本散见各篇，而检查表 C4（带缓存 / 不带缓存）合规 **3/20** | **零系统性覆盖** |
| **P3 校准** | TypedBench（相对噪声底）、Sys1Cal-v1（构造上已知 P(A)）、DecisionPivot、JEVal、Decision Index、社科标注审计、在线审核套件 | **最充分的一格**，但口径互不相同（13 章 § 13.4：ECE 至少五种算法） |
| **P4 等价提法下的一致性（= L2 语义幂等）** | DecisionPivot（对照组）、TypedBench（跨复述中位与范围）、CALM 偏置套件、序数刻度偏置（40 数据集）、测试语言审计、配对 Agent 决策点（顺序反转） | **干预覆盖密集但等价类未被定义**：每篇测一种干预，检查表 T3（选项名不变性）**只有 1/27** 篇做过；没有任何评测集把"业务等价"当作一个等价类整体测量（17 章 § 17.1.4） |
| **P5 置信可用于路由** | System1-Arena、Doom 快慢切换（校准 / 准确 / 敏感度三分离）、rubric 评审级联、印尼地方语级联 | **覆盖但结论负面**，且"两个不确定性"只在**内容审核一个域**被测过（2610.33258） |
| **P6 兜底 / 弃权** | PFR 测试（2610.19856）、算术拒绝瓶颈（2609.39496） | **两篇孤证**，且都不是通用基准 |
| **P7 "不知道"可被表达（P(U)）** | Sys1Cal-v1（2609.35342） | **单篇孤证** |
| **P8 知道自己不知道** | 受控自知审计（2610.01006）、生物安全审计的选择性预测部分（2609.30454） | **单篇孤证 + 单域** |
| **P9 概率自洽（公理）** | 概率公理电池 160 条 / 480 对（2609.33209）、Probability Contracts 1,000 世界（2609.37470） | **两篇，且规模极小**；"n 个判断组合后的自洽"为零 |
| **P10 业务人员可用文字配置** | 在线审核套件的受控信息条件最接近（规则 / 先例 / 答案空间三分离，2610.07953）；D1 上游证据（标签名压倒定义等）全部来自研究者写的提示词 | **零覆盖**：没有任何评测集用**业务人员写的**定义 / 判据 / 示例作为输入变量 |
| **P11 可审计** | **零**。现有工作都是在模型外面补结构（策略树路由、Yes/No/Unknown 节点树、证据记录） | **零覆盖** |
| **P12 风险可被预算** | 风险预算决策（2610.19811）、SHIFT-JEV 的认证部分（16 章 § 16.2） | **单篇孤证** |

### 19.3.1 还有三类被密集评测、但不在业务属性清单上的东西

它们说明现有评测的重心与业务目标并不对齐。

1. **对抗与安全**：JevAdvBench、选项通道攻击、上下文投毒（2610.15537）、请求呈现方式的对抗线索（2610.11436）、同数字引用互换（2610.08675）。这一格的证据密度**高于兜底与自知**，而后两者是业务上更常触发的失败。

2. **隐私与接口泄漏**：TUPLE-Bench 把"返回的字段本身是信息泄漏"这件事量化了，结论是**置信字段增加泄漏而不一致地降成本**（2610.23668）。这条对"要不要把概率暴露给下游"是直接的设计约束，而 17 章的属性清单里没有这一条——**说明业务属性清单本身也不完整**。
3. **文化与人群效度**：文化价值审计（2609.36399）、偏见案例研究（2610.19619）、心理测量审计（2610.14912）、人口实验核（2609.27535）。

## 19.4 跨评测集的数字不可比，这是结构性的

13 章已给出完整清单，这里只强调它对"评测"这件事的三个直接后果。

1. **同一个指标名下至少五种算法**：ECE 有 10/15 等宽、15 等质量、相对零假设等至少五种；"翻转率"有五种分母；"弃权"是选项、概率带、分数还是兜底动作各篇不同（13 章 §13.4、§13.5、§13.7）。
2. **聚合分数会掩盖对照组表现**：参照轨只差 2.6 点的两个 27B 模型，对照组准确率是 70.1% 与 44.2%（2610.28522）。这是"为什么不能只看排行榜"的最清楚的一个数字。
3. **概率排序好 ≠ 两边都答对**：2,400 个二元对照对上，正例被排在负例之上的比例 92.3%，而两边都答对只有 74.1%（同上）。业务上执行的是**决策**，不是排序。

## 19.5 从业务目标反推：哪些能力目前无法被任何现有评测集判定

下面每一条都是"**现有评测集给不出判定**"，而不是"我们应该做什么"。

| # | 业务上要判定的事 | 为什么现有评测集判不了 |
|---|---|---|
| 1 | **每正确结果的端到端成本** | 检查表 C4 合规 3/20；两篇姊妹论文在不同负载上报出相反的成本方向；一篇自审计把"省 23.9%"改成"省 4.3%"（2609.32160、2610.02267）。没有任何论文给出"省 44 倍成本但掉 11.6 个 F1 点到底赚不赚"的可计算口径 |
| 2 | **决策微调是否保留 / 破坏 ICL** | 没有任何论文测量过决策训练**前后**的 k-shot 曲线（03 章盲区、15 章 §15.2） |
| 3 | **业务人员自己写的规则能不能被忠实执行** | 所有 D1 / D2 / D3 证据的提示词都是研究者写的；没有评测集把"规则的作者是非技术业务专家"作为变量（05 章、§19.3 的 P10） |
| 4 | **中文业务规则决策** | 中文决策数据只有一家，且面向通用 / 医法金融；**没有面向业务规则的中文决策数据**（12 章 §12.4.1） |
| 5 | **序数项开了之后刻度利用率提高多少** | 2609.38827 说"可被定向训练缓解"但未给跨数据集训练对照；PACT 的序数传输只有 324 条冻结保留集、三个种子（18 章盲区 2） |
| 6 | **三条数值路线哪条更好** | 区间决策树、分箱分类、解码式回归头**从未在同一批数值决策上被比较**（18 章盲区 3） |
| 7 | **把一个判断拆成 n 个判断之后，组合的校准是什么** | 关于概率自洽的全部证据是 160 条、480 对（2609.33209）；分解只在单层上测过（18 章 §18.5.2） |
| 8 | **被记录的业务流程自身的一致性上限** | 只有一篇测过（跨轨迹留一法把天花板定在 25.6%–44.9%，重复状态彼此不一致多于一致），且是单一域（2610.25985）。**公开基准结构上测不到这个量** |
| 9 | **阈值跨负载 / 跨兜底模型的迁移** | 检查表 C3 要求测迁移，已观察到"在选择集上拟合的阈值并非对每个兜底模型都在保留条目上成立，拟合温度跨负载不同"（2609.32160）；但没有任何基准把"迁移"作为主指标 |
| 10 | **把判断变便宜之后判断总量变成多少 / 决策权怎么被改写** | 只有一篇概念论文，自述是"技术性挑衅而非既成的经验结果"（2610.01231） |
| 11 | **"两个不确定性"在非审核域是否成立** | 只在内容审核一个域被测过，且作者明确说补救手段是特异的、对分布敏感（2610.33258） |
| 12 | **可审计性** | 零评测集。模型按构造不产生文字理由（2610.11392、2610.22526） |
| 13 | **L2 语义幂等：等价的业务情形是否给等价的指标** | 现有工作只测单一干预下的翻转率（顺序、措辞、语气、标签名各一篇，17 章 §17.1.4 的表）。**没有任何论文定义"业务等价"这个等价类并测量指标在该等价类上的稳定性**；而 harness 只能保证"同一指标 → 同一动作"，保证不了这一层（17 章 §17.1.4） |
| 14 | **harness 侧"同一指标 → 同一动作"在真实系统里是否成立** | harness 可靠性只有一篇按七个部件（上下文、执行、治理、生命周期、可观测性、工具、校验）来测（2610.32285），且不是针对 Jev 类模型 |

## 19.6 本章小结与盲区

**应该怎么评测**：文献已给出 14 项检查表与一张最小报告卡（版本与日期、模型分差、一个普通 LM 读出基线、一个便宜的生成式基线、重复运行区间、保留集校准、冻结并测过迁移的级联阈值）。现有论文对它的合规率低，B1 是 5/26、T3 是 1/27、C4 是 3/20——这意味着公开数字里"接口的功劳"与"模型的功劳"基本没被分开过。

**当前评测集覆盖了什么**：准确率、校准、一致性 / 对照组、对抗稳健、领域横向能力、Agent 场景，覆盖密集且有多个大规模基准（System1-Arena 92k 题 + 138 个闭环环境、DecisionPivot 40,033 条、JEVal 11,257 条、TypedBench 的四件事联测）。

**没覆盖什么**：兜底、unknown、自知、概率自洽、风险预算五格是单篇或两篇孤证；**业务人员可配置与可审计两格是零**；而业务目标本身（每正确结果的端到端成本）没有任何可复现口径。

**本章自身的盲区**：

1. **本章的覆盖判定依赖"被测对象 = 17 章的十二条属性"这一前提**，而 §19.3.1 已经证明该清单不完整（TUPLE-Bench 的接口泄漏不在其中）。属性清单本身需要继续扩充，19 章的覆盖矩阵会随之变化。
2. **合规率全部来自单篇审计的编码**（2609.32160），其语料只有 28 篇、九天窗口，且作者自述若干项需要判断、无法可靠评分处留空。此后一个月新增的大量论文（System1-Arena、TypedBench、DecisionPivot、JEVal 等）**没有被按同一检查表重新编码过**，所以"合规率是否已改善"是未知的。
3. **本报告自己没有运行任何评测**。全部数字来自论文与文档的转述，口径差异（13 章）意味着跨论文的任何比较都只能定性。

# 20 · 批判性复核：四个工作假设、本报告自己的构造、以及我的方法论缺陷

> 口径：本章不新增证据，只做复核。14–19 章各自回答了一个由提问者提出的工作假设，而**提出假设的人与检验假设的人是同一组对话的两端，这是确认偏差的标准条件**。2026-10-28 复核 17 章时发现了一个实例：初稿把"幂等性搬迁"这条命题当成地基，而推翻它前提的证据**本报告自己早就引用过**，分散在 04、05、06、09、10、13 章里，只是在写 17 章时没有被调出来。本章把这类失败系统化处理：§20.1 逐条判定四个假设，§20.2 标出报告里哪些框架是我自己造的而非文献结论，§20.3 列我自己的方法论缺陷，§20.4 给出"哪些结论最稳、哪些最可能被推翻"的分级，§20.5 回答"提问者的视野里有哪些盲区"。

## 20.1 四个工作假设的判定

| # | 假设（提问者提出） | 判定 | 结论方向 | 给出的机制 |
|---|---|---|---|---|
| H1 | SFT 无法让模型具备一般意义上的泛化能力（14 章） | **强形式不成立，弱形式成立** | **对** | **不完整**：假设把原因归给"监督目标"，而证据显示跨层移动结果的是基座规模、指令调优起点、监督分布与结构约束 |
| H2 | 我们对 Jev 的业务期待无法直接转化成可导的学习函数（16 章） | **结论成立，理由不成立** | **对** | **错**：抗拒梯度有四种不同成因；真正不可导的那几类恰恰是 RL 实测收益为零的那几类，所以"不可导 → 用 RL"不成立 |
| H3 | 应该考虑用 RL 来同时保住 ICL 与类 skill 的语义注入（15 章） | **不成立** | **错** | **错**：决定 ICL 存亡的是"训练样本之间任务定义是否在变"；唯二能提升"用上下文定义任务"的方法（MetaICL、符号调优）都是 SFT |
| H4 | Jev 类模型 = 把不保证幂等的生成式业务判断转换成"指标输出 + harness 的确定幂等执行"（17 章 §17.1） | **前提不成立，结论需大幅修正** | **部分对** | **部分错**：见 §17.1.3 的六条反证 |

### 20.1.1 一个值得注意的模式

四条里有三条（H1、H2、H4）**结论方向是对的，而给出的机制是错的或不完整的**。这不是巧合，而是两种知识来源的差别：

- 提问者的判断来自**部署与工程观察**——换个 schema 模型就不行了、业务目标写不成 loss、生成式输出不稳定。这类观察对**现象**非常可靠。
- 机制归因需要**控制变量的实验**，而文献在这几处恰好缺控制实验：没人测过决策微调前后的 k-shot 曲线（03 章），没人把 Jev 的重复抖动与温度 0 的生成式基线并排测过（§17.1.3 反证 1），没人在同一批数值决策上比较三条数值路线（18 章盲区 3）。

**推论**：在这个题目上，"现象判断"比"机制判断"可信得多。遇到分歧时，应该保留提问者的现象、重做机制，而不是整体接受或整体否决。H4 正是这样处理的——它的**诊断价值很高**（它准确预言了 17 章 §17.5 里第五格"闭环执行者"为什么普遍失败：决策被搬回了模型里），而它关于幂等的**描述性断言是错的**。

### 20.1.2 H4 的诊断价值应当被明确记下

我在 01 章 §1.6 写过"Jev 的价值在接口契约而非权重"。提问者的版本比我的更锋利，因为它指出了**契约是干什么用的**：契约的意义不是"输出好解析"，而是"把决策的**记账**交给代码"。（这句话我最初写成"把决策权从模型挪到代码"，提问者在 2026-10-28 指出这是错的：**我们做的是 AI 系统，核心逻辑是语义理解的泛化**。这条反对意见用的正是本报告自己的归谬——"挪到代码"的无约束最优解同样是查表——所以它成立，措辞已在 17 章 §17.1.7 改正。）这个版本能做出我的版本做不到的预测——哪一类部署会成功（决策权在代码里的）、哪一类会失败（决策权回到模型里的）。17 章 §17.5 的五格表与它完全一致，而那张表是我在听到这个命题之前就写好的。**所以这里的正确态度不是"命题错了"，而是"命题的诊断部分应当被采纳，描述部分应当被替换"。**

## 20.2 报告里哪些框架是我自己造的

下面每一条都在正文里被当作组织工具使用，但**没有任何一篇论文提出过它们**。这是本报告最容易被误读为"文献结论"的地方，因此逐条标注其依据与过拟合风险。

| 构造 | 出处 | 依据 | 过拟合风险 |
|---|---|---|---|
| **七个泛化层次 L0–L6** | 14 章 §14.1 | 把约 20 篇论文的结果按"变了什么"排序后归并 | **中高**。层与层之间不是正交的（L2 新 schema 与 L3 新符号操作在真实数据里混在一起），而且 L5 校准迁移与 L6 推理深度各自只有两三篇证据。换一种分层可能得到不同的"哪一层有正面证据" |

| 构造 | 出处 | 依据 | 过拟合风险 |
|---|---|---|---|
| **五类可导性 A–E** | 16 章 §16.2 | 按"为什么抗拒梯度"而非业务领域分类 | **中**。C 类（分位数/秩）与 D 类（下游长程）的边界取决于你把认证手段算进目标还是算进流程 |
| **三层幂等 L1–L3** | 17 章 §17.1.4 | 我在检验 H4 时造的，用于把命题可证伪化 | **高**。三层划分本身没有文献支持；§17.1.3 已经证明 L3 不是干净的一层（固定计划固定负载才成立），所以这张表至少还缺一个"负载/计划"维度 |
| **五个 System1+System2 位置 A–E** | 17 章 §17.5 | 把约 15 个系统按"S1 的输出被谁消费"归类 | **中**。它在"守卫/路由/分类"族上很贴合，在"记忆/监控/评审"族上偏勉强——SOMA 是一个累积判断的控制回路，Mnemon 的 S1 输出根本不被执行，而这一族的实测结果恰恰最好（LoCoMo 91.7%，14 个系统中最高） |
| **"决策重复度"轴** | 17 章 §17.2.3 | 从三篇论文（JEVDB、Bellman LM、NIOCIS）各自的动机句里抽出的共同结构 | **高**。没有任何论文把"重复度"量化过，也没有任何论文把它与收益做过回归。它是一个**假说**，被我当作判据在用 |
| **"问题图 vs token 流"** | 18 章 §18.5.1 | 从成本结构（多问近乎免费、多生成按量计费）推出，再用五个已有形态填充 | **中高**。"把一个判断拆成 n 个判断"的组合校准**没有任何论文回答过**（18 章盲区 5），所以这个形态的可行性是推理出来的，不是测出来的 |
| **十二条业务属性 P1–P12** | 17 章 §17.3 | 从"业务方会据此下单"的角度列举 | **已知不完整**。19 章 §19.3.1 自己证明了这点：TUPLE-Bench 的"接口字段本身是信息泄漏"不在清单里 |
| **D4 的 30 个子维度** | 06 章 | 枚举式探索，用户明确要求"自己定义和理解问题" | **低**（本来就声明为探索），但**子维度之间高度相关**，不能当成 30 个独立的测量轴 |

**读法**：凡是上表里的框架，正文中的"按这个分类看，X 格是零"这类句子，**应被读作"按本报告这种分类看"**，而不是"文献证明了 X 不存在"。

## 20.3 我自己的方法论缺陷

1. **确认偏差，且已有一次实例。** 流程是"提问者给假设 → 我找证据 → 我写结论"。17 章初稿是失败案例：六条反证里的五条所依据的论文（约束税、IIA 预先登记、计划改变答案、控制回路 SoK、Koa-decision）**有四篇早已在本报告的其他章节被引用**，只有 2610.06425 是复核时新加的。也就是说失败不在检索，而在**写新章时没有对已有证据做反向检索**。
2. **只读了约 70 篇全文，其余 212 篇靠摘要。** 摘要里的数字常常不是论文的主结论，限定条件也常常不写进摘要。本报告多处转述的是摘要句。
3. **单向检索。** 关键词围绕 Jev / typed decision / System One 展开，会系统性漏掉**不使用这套术语但暴露同类接口**的系统——早期审计自己也承认这条局限。
4. **没有运行任何评测。** 全部数字来自论文与文档的转述，而 13 章已证明跨论文的口径不可比（ECE 至少五种算法、翻转率五种分母），所以任何跨论文比较只能定性。
5. **合规率全部来自单篇审计的编码**（2609.32160，28 篇语料、九天窗口），此后一个月新增的大量论文没有被按同一检查表重新编码过。
6. **时间窗口极窄。** 绝大多数证据是 Jev 发布后六周内的预印本，未经同行评审，多篇自述为"早期证据"。
7. **我的"零命中"声明是最脆弱的一类断言。** "没有任何论文做过 X"只能证伪不能证实，而它在本报告里出现了几十次。每一条都应读作"在本报告的检索范围内没找到"。
8. **我按"业务成本"一条轴组织了全报告，而没有按"语义泛化"重走一遍。** 这是提问者在 2026-10-28 指出的，而它造成了一处可指认的遗漏：让 Jev 便宜的那个工程操作与毁掉规则敏感性的那个操作**是同一个**（Certo 的可缓存独立编码约 5 倍便宜、规则敏感度 recall@1 1.00 → 0.24，2609.37832），而本报告把这两件事分别记在 17 章 §17.2（成本结构）与 14 章 §14.3（泛化层次）两处，**没有并置，也没有把它当成取舍写出来**。按成本轴组织时，"便宜 63 倍"会被记成优点，而同一条证据在语义轴上说明的是"模型不可替代"（2609.29429）——同一个数字在两条轴上的含义完全不同。
9. **我连续三次把提问者的命题判为"有退化最优解"，而没有早一步指出这是同一个模式。** 幂等 → 查表（17 章 §17.1.6）、挪到代码 → 查表（§17.1.7）、一致率 → 常数分类器（§17.1.8）。三条命题都点名了"不变性"这一半而把"判别"那一半留空。把三次归谬分开写，等于让同一个结构性缺口被重复发现三次，这本身是组织上的失败。

## 20.4 结论的稳健性分级

| 稳健度 | 结论 | 为什么 |
|---|---|---|
| **最稳** | 成本与延迟的量级（便宜 1–2 个数量级、评审贵 16–357 倍、本地 2B 30.9 ms 对前沿 API 8,758 ms） | 多篇独立测量、方向一致、量级一致，且与"不解码"这一结构性原因吻合 |
| **最稳** | 类型化读出本身没有独立于同类标签概率读出的准确率优势 | 早期审计的 28 篇编码 + 现成模型读 logits 即可（2610.02076）两条独立路径 |
| **稳** | 结构约束（掩码/位置重置/块隔离）优于把一致性写进损失 | 多篇、方向一致、且有"按构造成立"的强形式 |

| 稳健度 | 结论 | 为什么 |
|---|---|---|
| **稳** | 序数刻度压缩 | 40 个数据集 × 9 个模型 × 3 个族，并有跨范式的独立确认（临床序数量表上的中心趋势效应） |
| **稳** | 兜底/弃权是最差的一格 | 两条互相独立的测量（拒绝率 7%、兜底项让 Intern 从 97.9% 跌到 23.1%） |
| **中** | "单遍模型上 RL 为负或无效" | 12 章与 15 章都正确地把它限定在"单遍/纯读出"并注明"正面证据都绑定推理链"，所以**措辞没问题**；问题是**证据基数太小**。三个负面数据点里，一个是编码器（按用户自己的口径本就不属于我们的方向）、一个是小规模 REINFORCE、一个是 Agent 循环内的 GRPO 而不是读出上的 RL。用三个异质的点支撑一条关于架构的一般结论，偏薄 |
| **中** | 五个 System1+System2 位置 | 分类是我造的，且在"记忆/监控"族上偏勉强（§ 20.2） |
| **最可能被推翻** | "L2 语义幂等无人保证" | 这是一条零命中声明，而且是最可能的检索盲区：相关工作可能发表在鲁棒性/不变性文献里而不自称与决策模型有关 |
| **最可能被推翻** | "每正确结果的端到端成本无人测过" | 同上。工业界的实践大概率有这个口径，只是不发论文；本报告的来源偏学术（早期审计也承认"工业经验被低估"） |
| **最可能被推翻** | "决策重复度"是收益的主变量 | 从未被量化或回归过（§ 20.2） |

## 20.5 提问者视野里的四个盲区

这是本章被要求回答的部分。逐条给出盲区、它为什么是盲区、以及支撑的测量。

**盲区 1：把"幂等"当成目标，而业务上真正要的是"可定界的风险"，两者在非对称代价下冲突。** "确定、幂等的执行"要求把分布塌成一个动作。但按被访者平均后，**概率向量比四舍五入后的答案更接近人类的条目边际分布**（2610.14912）；置信度混淆了人类分歧与决策风险，非对称损失下两者要求**相反的升级信号，没有任何单一置信数能同时服务两者**（2610.33258）。而真正可操作的目标是别的东西：把输出当"带分数的观测记录"、让 unknown 直接拒绝，就能得到一个**不依赖校准**的裁决翻转上界，并据此在多个充分契约之间做选择（2610.10978）。**可定界 > 幂等**，而且前者可以在后者不成立时成立。

**盲区 2：命题把 harness 当成可信的确定性层，而 harness 自己会改变答案。** 语义查询引擎里"**查询计划的选择不仅影响成本，也影响结果**"，准确率**只在逐点确定性策略下**与计划无关，而当升级带在计划自己的候选上校准时**选择下推不是质量可靠的**（2610.08089）。对 139 个论文族的系统化综述更直接：50 个族声称适配控制回路，**只有 4 个用匹配的测量支持**；139 个里**只有 4 个报告截止期达成率**；而"一个对每个孤立请求都满足 10 秒预算的决策，一旦决策排在被回放的执行时间之前排队，就对任何请求都不满足"（2610.06425）。**把难点搬到 harness 不等于解决它**；搬过去之后它变成排队论与查询优化问题，而这两件事在现有 Jev 文献里几乎没人测。

**盲区 3：命题隐含"能力守恒"，于是低估了多步/带状态业务逻辑的丢失，而这类丢失 harness 收不到信号。** 这是部署上最危险的一条。Jev 做不出"LLM 只有写出中间步骤才能做出"的决策（一次前向可解的条目 97.5%，其余 **74%**）；答案依赖同一用户两次以上更新时准确率下降，十六次更新时 53%–80%；给它过时的状态摘要它就照着答。而**它不知道自己的界限**：置信度标记它自己犯的错，但标记不出它从过时输入继承来的错，**显式的与训练出来的交接选项都抓不到后者**（2610.24929）。"指标 + 确定执行"这个架构在这一类失败上**没有任何可用的信号**——harness 看到的是一个高置信、类型合法、语义错误的值。配合"约束税"的发现（硬 schema 把"合法但答错"从 49.5% 抬到 88.9%，2605.26128），这是整个架构里唯一一处**失败模式比替代方案更隐蔽**的地方。

**盲区 4："可用配置（提示词）驱动"这个前提本身没有被任何评测验证过。** 命题的起点是"泛化、灵活的、基于配置的生成式模型业务处理能力"。但 D1 的全部证据里，提示词都是**研究者**写的，没有任何评测集把"规则/判据/示例的作者是非技术业务专家"当作变量（19 章 § 19.5 第 3 条，17 章 § 17.6 盲区 6）。而已知的失效模式正好打在业务人员最可能踩的地方：**标签名压倒定义**（AUC 93.8% → 23.2%）、删掉定义准确率不变、小模型无法在上下文里翻转标签语义、同质示例让小模型坍塌到 12% 以下（03 章）。**"可配置"在这份文献里是一个假定，不是一个被测过的属性。** 如果它不成立，那么命题拆分出的两半里，"模型 + 提示词配置"这一半的能力来源就比命题假定的更弱。

## 20.6 本章小结

- 四个工作假设里，三个的**结论方向对、机制错**（H1、H2、H4），一个不成立（H3）。遇到分歧时应保留现象、重做机制。
- H4 的**诊断价值应当采纳**（它准确预言了哪一类部署会失败），**描述性断言应当替换**（幂等不是它做的事；它做的是把非幂等的表面收缩成可定界的几个字段）。
- 报告里有八个框架是**我自己造的**，其中"三层幂等"、"决策重复度"、"问题图"三条过拟合风险最高。
- 我自己的方法论缺陷里最该防的是**确认偏差**，而且已有一次实例：17 章初稿的反证材料大半早就在本报告里，只是写新章时没做反向检索。

- 几十处"没有任何论文做过 X"都应读作"在本报告的检索范围内没找到"，其中"L2 无人保证"与"端到端成本无人测"最可能是检索盲区。